

Material Auxiliar: Métodos Bayesianos

Inferência Estatística - Prof. Abraão D. C. Nascimento

Preparação para Prova

19 de novembro de 2025

Sumário

1	Introdução aos Métodos Bayesianos	2
1.1	Comparação: Inferência Clássica vs. Inferência Bayesiana	2
1.2	O Paradigma Bayesiano	2
1.3	Teorema de Bayes	3
2	Distribuições a Priori e a Posteriori	3
2.1	Elementos da Inferência Bayesiana	3
2.1.1	Elemento 1: Distribuição a Priori	4
2.1.2	Elemento 2: Amostra Aleatória	4
2.1.3	Elemento 3: Estatística Suficiente	4
2.1.4	Elemento 4: Distribuição Conjunta	4
2.1.5	Elemento 5: Distribuição Marginal	4
2.1.6	Elemento 6: Distribuição a Posteriori	5
2.2	Exercícios Resolvidos	5
3	Priori Conjugada	9
3.1	Motivação	9
3.2	Definição de Priori Conjugada	9
3.3	Exercícios Resolvidos	9
3.4	Tabela de Prioris Conjugadas Comuns	13
4	Estimadores Bayesianos	13
4.1	Motivação à Estimação Bayesiana	13
4.2	Contexto e Notação	13
4.3	Função de Perda e Risco	13
4.4	Risco Bayesiano	14
4.5	Teoremas Fundamentais	14
4.6	Definição Geral de Estimador Bayesiano	15
4.7	Exercícios Resolvidos	15
5	Resumo de Fórmulas Importantes	19
5.1	Fórmulas Fundamentais	19
5.2	Propriedades da Função Gama e Beta	19
6	Observações Finais	19

1 Introdução aos Métodos Bayesianos

1.1 Comparação: Inferência Clássica vs. Inferência Bayesiana

Na **Inferência Clássica** (ou Frequentista), o paradigma tradicional segue o seguinte padrão:

- Os métodos de estimação pontual, intervalar e teste de hipóteses dependem fundamentalmente da **função de verossimilhança**:

$$L(\theta; \mathbf{x}) = \prod_{i=1}^n f(x_i; \theta)$$

- O parâmetro $\theta \in \Theta \subset \mathbb{R}$ é tratado como um valor **desconhecido, mas fixo**
- $\mathbf{x} = (x_1, \dots, x_n)^\top$ é uma realização de uma amostra aleatória n -dimensional de X
- A função $f(x; \theta)$ representa a função densidade de probabilidade (fdp) ou função de massa de probabilidade (fmp) de X

Na **Inferência Bayesiana**, ocorre uma mudança fundamental de paradigma:

- O parâmetro desconhecido θ é tratado como uma **variável aleatória** V
- V possui uma distribuição de probabilidade sobre o suporte Θ , chamada de **distribuição a priori** com fdp (ou fmp) $h(v)$
- A notação $f(x; \theta)$ agora representa a fdp (ou fmp) de $\{X|V = \theta\}$, ou seja, a distribuição condicional de X dado que $V = \theta$
- A distribuição a priori $h(v)$ frequentemente reflete a **crença subjetiva** do experimentador sobre quais valores de V são mais ou menos prováveis

Diferença Fundamental

A principal diferença conceitual é que na abordagem clássica, θ é um valor fixo desconhecido, enquanto na abordagem bayesiana, θ é uma variável aleatória com distribuição de probabilidade.

1.2 O Paradigma Bayesiano

O paradigma dos Métodos Bayesianos pode ser resumido como:

Combinar a evidência sobre V da distribuição a priori com a função de verossimilhança por meio do Teorema de Bayes, resultando na distribuição a posteriori.

Simbolicamente, o processo pode ser representado como:

$$[V = \theta], \quad [X|V = \theta], \quad [T(X)|V = \theta] \quad \Rightarrow \quad [V = \theta|T(X) = t]$$

onde:

- $[V = \theta]$: distribuição a priori de V
- $[X|V = \theta]$: distribuição condicional dos dados dado o parâmetro
- $[T(X)|V = \theta]$: distribuição da estatística suficiente dado o parâmetro
- $[V = \theta|T(X) = t]$: distribuição a posteriori de V dado os dados observados

1.3 Teorema de Bayes

O Teorema de Bayes é a ferramenta fundamental que permite combinar informação a priori com os dados observados.

Teorema 1.1 (Teorema de Bayes - Caso Discreto). Assuma que os eventos A_1, A_2, \dots, A_k formam uma partição do espaço amostral Ω e B é um outro evento tal que $\Pr(B) > 0$. Então

$$\Pr(A_j|B) = \frac{\Pr(A_j) \Pr(B|A_j)}{\sum_{i=1}^k \Pr(A_i) \Pr(B|A_i)},$$

para $j = 1, 2, \dots, k$ fixado.

Para o caso contínuo (que é o foco deste curso), temos:

Teorema 1.2 (Teorema de Bayes - Caso Contínuo). Se V é uma variável aleatória contínua com fdp a priori $h(\theta)$ e T é uma estatística com fdp condicional $g(t|\theta) = f_{T|V=\theta}(t|\theta)$, então a fdp a posteriori de V dado $T = t$ é:

$$k(\theta; t) = f_{V|T=t}(\theta|t) = \frac{g(t; \theta)h(\theta)}{m(t)},$$

onde $m(t) = \int_{\Theta} g(t; \theta)h(\theta)d\theta$ é a fdp marginal de T .

Exemplo 1.1 (Interpretação Intuitiva). Imagine que você quer estimar a probabilidade de chuva amanhã (θ). Você tem:

- **Priori:** Sua crença inicial baseada em experiência (ex: 30% de chance)
- **Dados:** Informação meteorológica observada hoje
- **Posteriori:** Sua crença atualizada combinando sua crença inicial com os dados observados

O Teorema de Bayes combina essas duas fontes de informação de forma matematicamente rigorosa.

2 Distribuições a Priori e a Posteriori

2.1 Elementos da Inferência Bayesiana

Na abordagem Bayesiana, adotamos que V (ao invés de v) assume um modelo contínuo de valor real com fdp $h(v)$, em que $v \in \Theta \subset \mathbb{R}$.

Os seis elementos fundamentais da Inferência Bayesiana são:

2.1.1 Elemento 1: Distribuição a Priori

A **distribuição a priori** $h(\theta)$ para $\theta \in \Theta$ representa nosso conhecimento ou crença sobre o parâmetro antes de observar os dados.

Observação 2.1. A escolha da priori é crucial e pode ser:

- **Informativa:** Baseada em conhecimento prévio ou estudos anteriores
- **Não-informativa:** Representa ignorância ou neutralidade (ex: uniforme)
- **Conjugada:** Escolhida por conveniência matemática (ver Seção 3)

2.1.2 Elemento 2: Amostra Aleatória

$\mathbf{x} = (X_1, \dots, X_n)^\top$ é uma amostra aleatória de $[X|V = \theta]$, ou seja, cada X_i tem distribuição condicional $f(x_i|\theta)$ dado que $V = \theta$.

2.1.3 Elemento 3: Estatística Suficiente

$T \triangleq T(\mathbf{x})$ é uma estatística suficiente (mínima) que assume frequentemente valor real. A fdp ou fmp de $[T|V = \theta]$ será denotada por:

$$g(t; \theta) \triangleq f_{T|V=\theta}(t|\theta),$$

para $t \in \mathcal{T} \subset \mathbb{R}$ e θ fixado.

Por que usar Estatística Suficiente?

O uso de estatística suficiente reduz a dimensão dos dados sem perder informação sobre θ , simplificando os cálculos bayesianos.

2.1.4 Elemento 4: Distribuição Conjunta

A fdp (ou fmp) do par aleatório (T, V) é dada por:

$$f_{T,V}(t, \theta) = f_{T|V=\theta}(t|\theta)h(\theta) = g(t; \theta)h(\theta),$$

para $t \in \mathcal{T}$ e $\theta \in \Theta$.

Esta é a distribuição conjunta que combina a informação dos dados (através de T) com a informação a priori (através de $h(\theta)$).

2.1.5 Elemento 5: Distribuição Marginal

A fdp (ou fmp) marginal de T é obtida integrando $f_{T,V}(t, \theta)$ em termos de θ :

$$m(t) \triangleq f_T(t) = \int_{\theta \in \Theta} f_{T,V}(t, \theta) d\theta = \int_{\theta \in \Theta} g(t; \theta) h(\theta) d\theta,$$

para todo $t \in \mathcal{T}$.

Observação 2.2. A distribuição marginal $m(t)$ é frequentemente chamada de **distribuição preditiva** ou **verossimilhança marginal**. Ela representa a probabilidade de observar $T = t$ considerando todas as possíveis valores de θ ponderados pela priori.

2.1.6 Elemento 6: Distribuição a Posteriori

Finalmente, a fdp (ou fmp) de $[V|T = t]$ é dada por:

$$k(\theta; t) \triangleq f_{V|T=t}(\theta|t) = \frac{g(t; \theta)h(\theta)}{m(t)},$$

para todo $t \in \mathcal{T}$ fixado e $\theta \in \Theta$ tal que $m(t) > 0$.

Esta fdp (ou fmp) é chamada de **distribuição a posteriori** e representa nossa crença atualizada sobre θ após observar os dados.

Interpretação da Posteriori

A distribuição a posteriori combina:

- **Numerador:** $g(t; \theta)h(\theta)$ - informação dos dados vezes informação a priori
- **Denominador:** $m(t)$ - constante de normalização que garante que a posteriori seja uma distribuição válida

Observação 2.3. A tratabilidade analítica de $k(\theta; t)$ depende da obtenção de $m(t)$. Em alguns casos, as distribuições marginal e a posteriori podem ser obtidas numericamente através de métodos computacionais como MCMC (Markov Chain Monte Carlo).

2.2 Exercícios Resolvidos

Exercício 2.1 (Exercício 1.a). Sejam X_1, \dots, X_n uma amostra aleatória de $[X|V = \theta] \sim \text{Bernoulli}(\theta)$ tal que $\theta \in (0, 1)$, em que V é uma probabilidade de sucesso tal que $0 < V < 1$. Assumindo a distribuição a priori como $V \sim U(0, 1)$, encontre:

- (a) A densidade marginal da estatística suficiente para θ (diga-se $T \triangleq T(\mathbf{x})$), em que $\mathbf{x} = (X_1, \dots, X_n)^\top$;
- (b) A densidade da distribuição a posteriori de $[V|T = t]$.

Solução do Exercício 1.a

Passo 1: Identificar a estatística suficiente

Para uma amostra de n observações de uma distribuição Bernoulli(θ), a estatística suficiente mínima é:

$$T = \sum_{i=1}^n X_i$$

que representa o número total de sucessos na amostra.

Passo 2: Determinar a distribuição de T dado θ

Como $X_i \sim \text{Bernoulli}(\theta)$ e são independentes, temos:

$$T|V = \theta \sim \text{Binomial}(n, \theta)$$

Portanto, a fmp de T dado θ é:

$$g(t; \theta) = \binom{n}{t} \theta^t (1 - \theta)^{n-t}, \quad t = 0, 1, \dots, n$$

Passo 3: Especificar a distribuição a priori

A priori uniforme em $(0, 1)$ tem fdp:

$$h(\theta) = \begin{cases} 1 & \text{se } 0 < \theta < 1 \\ 0 & \text{caso contrário} \end{cases}$$

Passo 4: Calcular a densidade marginal $m(t)$

A densidade marginal é:

$$m(t) = \int_0^1 g(t; \theta) h(\theta) d\theta = \int_0^1 \binom{n}{t} \theta^t (1 - \theta)^{n-t} \cdot 1 d\theta$$

Fatorando a constante:

$$m(t) = \binom{n}{t} \int_0^1 \theta^t (1 - \theta)^{n-t} d\theta$$

A integral $\int_0^1 \theta^t (1 - \theta)^{n-t} d\theta$ é uma função Beta. Lembrando que:

$$B(a, b) = \int_0^1 u^{a-1} (1 - u)^{b-1} du = \frac{\Gamma(a)\Gamma(b)}{\Gamma(a+b)}$$

Temos:

$$\int_0^1 \theta^t (1 - \theta)^{n-t} d\theta = B(t+1, n-t+1) = \frac{\Gamma(t+1)\Gamma(n-t+1)}{\Gamma(n+2)}$$

Como $\Gamma(k+1) = k!$ para k inteiro não-negativo:

$$\int_0^1 \theta^t (1 - \theta)^{n-t} d\theta = \frac{t!(n-t)!}{(n+1)!}$$

Portanto:

$$m(t) = \binom{n}{t} \frac{t!(n-t)!}{(n+1)!} = \frac{n!}{t!(n-t)!} \cdot \frac{t!(n-t)!}{(n+1)!} = \frac{1}{n+1}$$

Resultado (a): A densidade marginal de T é:

$$m(t) = \frac{1}{n+1}, \quad t = 0, 1, \dots, n$$

Ou seja, T tem distribuição uniforme discreta sobre $\{0, 1, \dots, n\}$.

Passo 5: Calcular a distribuição a posteriori

A distribuição a posteriori é:

$$k(\theta; t) = \frac{g(t; \theta)h(\theta)}{m(t)} = \frac{\binom{n}{t}\theta^t(1-\theta)^{n-t} \cdot 1}{\frac{1}{n+1}}$$

Simplificando:

$$k(\theta; t) = (n+1) \binom{n}{t} \theta^t (1-\theta)^{n-t}$$

Reescrevendo:

$$k(\theta; t) = \frac{\Gamma(n+2)}{\Gamma(t+1)\Gamma(n-t+1)} \theta^t (1-\theta)^{n-t}$$

Resultado (b): A densidade a posteriori de V dado $T = t$ é:

$$k(\theta; t) = \frac{\Gamma(n+2)}{\Gamma(t+1)\Gamma(n-t+1)} \theta^t (1-\theta)^{n-t}, \quad 0 < \theta < 1$$

Ou seja, $V|T = t \sim \text{Beta}(t+1, n-t+1)$.

Observação Importante

Note que começamos com uma priori uniforme (que é um caso especial de $\text{Beta}(1,1)$) e obtivemos uma posteriori Beta. Isso ilustra o conceito de priori conjugada que será estudado na próxima seção!

Exercício 2.2 (Exercício 1.b). Sejam X_1, \dots, X_n uma amostra aleatória de $[X|V = \theta] \sim \text{Poisson}(\theta)$ tal que $\theta > 0$, em que V é o número esperado de ocorrências em um dado intervalo de tempo. Assumindo a distribuição a priori como $V \sim \Gamma(\alpha, \beta)$, encontre:

- (a) A densidade marginal da estatística suficiente para θ (diga-se $T \triangleq T(\mathbf{x})$), em que $\mathbf{x} = (X_1, \dots, X_n)^\top$;
- (b) A densidade da distribuição a posteriori de $[V|T = t]$.

Solução do Exercício 1.b

Passo 1: Identificar a estatística suficiente

Para uma amostra de n observações de uma distribuição Poisson(θ), a estatística suficiente mínima é:

$$T = \sum_{i=1}^n X_i$$

que representa o número total de ocorrências na amostra.

Passo 2: Determinar a distribuição de T dado θ

Como $X_i \sim \text{Poisson}(\theta)$ e são independentes, temos:

$$T|V = \theta \sim \text{Poisson}(n\theta)$$

Portanto, a fmp de T dado θ é:

$$g(t; \theta) = \frac{(n\theta)^t e^{-n\theta}}{t!}, \quad t = 0, 1, 2, \dots$$

Passo 3: Especificar a distribuição a priori

A priori Gama(α, β) tem fdp:

$$h(\theta) = \frac{\beta^\alpha}{\Gamma(\alpha)} \theta^{\alpha-1} e^{-\beta\theta}, \quad \theta > 0$$

onde $\alpha > 0$ e $\beta > 0$ são os parâmetros da distribuição Gama.

Passo 4: Calcular a densidade marginal $m(t)$

A densidade marginal é:

$$\begin{aligned} m(t) &= \int_0^\infty g(t; \theta) h(\theta) d\theta \\ &= \int_0^\infty \frac{(n\theta)^t e^{-n\theta}}{t!} \cdot \frac{\beta^\alpha}{\Gamma(\alpha)} \theta^{\alpha-1} e^{-\beta\theta} d\theta \end{aligned} \quad (1)$$

Reorganizando os termos:

$$m(t) = \frac{n^t \beta^\alpha}{t! \Gamma(\alpha)} \int_0^\infty \theta^t \theta^{\alpha-1} e^{-n\theta} e^{-\beta\theta} d\theta$$

Simplificando:

$$m(t) = \frac{n^t \beta^\alpha}{t! \Gamma(\alpha)} \int_0^\infty \theta^{t+\alpha-1} e^{-(n+\beta)\theta} d\theta$$

A integral $\int_0^\infty \theta^{t+\alpha-1} e^{-(n+\beta)\theta} d\theta$ pode ser resolvida usando a função Gama. Fazendo a substituição $u = (n + \beta)\theta$, temos $du = (n + \beta)d\theta$, então:

$$\begin{aligned} \int_0^\infty \theta^{t+\alpha-1} e^{-(n+\beta)\theta} d\theta &= \int_0^\infty \left(\frac{u}{n+\beta} \right)^{t+\alpha-1} e^{-u} \frac{du}{n+\beta} \\ &= \frac{1}{(n+\beta)^{t+\alpha}} \int_0^\infty u^{t+\alpha-1} e^{-u} du \end{aligned}$$

$$= \frac{\Gamma(t + \alpha)}{(n + \beta)^{t+\alpha}} \quad (2)$$

Portanto:

$$m(t) = \frac{n^t \beta^\alpha}{t! \Gamma(\alpha)} \cdot \frac{\Gamma(t + \alpha)}{(n + \beta)^{t+\alpha}}$$

Simplificando:

$$m(t) = \frac{\Gamma(t + \alpha)}{t! \Gamma(\alpha)} \cdot \frac{n^t \beta^\alpha}{(n + \beta)^{t+\alpha}}$$

$$m(t) = \binom{t + \alpha - 1}{t} \left(\frac{\beta}{n + \beta} \right)^\alpha \left(\frac{n}{n + \beta} \right)^t$$

Resultado (a): A densidade marginal de T é:

$$m(t) = \frac{\Gamma(t + \alpha)}{t! \Gamma(\alpha)} \cdot \frac{n^t \beta^\alpha}{(n + \beta)^{t+\alpha}}, \quad t = 0, 1, 2, \dots$$

Ou seja, T tem distribuição Binomial Negativa com parâmetros α e $\frac{\beta}{n+\beta}$.

Passo 5: Calcular a distribuição a posteriori

A distribuição a posteriori é:

$$k(\theta; t) = \frac{g(t; \theta) h(\theta)}{m(t)}$$

Substituindo as expressões:

$$k(\theta; t) = \frac{\frac{(n\theta)^t e^{-n\theta}}{t!} \cdot \frac{\beta^\alpha}{\Gamma(\alpha)} \theta^{\alpha-1} e^{-\beta\theta}}{\frac{\Gamma(t+\alpha)}{t! \Gamma(\alpha)} \cdot \frac{n^t \beta^\alpha}{(n+\beta)^{t+\alpha}}}$$

Simplificando:

$$\begin{aligned} k(\theta; t) &= \frac{n^t \theta^t e^{-n\theta} \beta^\alpha \theta^{\alpha-1} e^{-\beta\theta} \Gamma(\alpha) (n + \beta)^{t+\alpha}}{\Gamma(\alpha) \Gamma(t + \alpha) n^t \beta^\alpha} \\ &= \frac{\theta^{t+\alpha-1} e^{-(n+\beta)\theta} (n + \beta)^{t+\alpha}}{\Gamma(t + \alpha)} \\ &= \frac{(n + \beta)^{t+\alpha}}{\Gamma(t + \alpha)} \theta^{t+\alpha-1} e^{-(n+\beta)\theta} \end{aligned} \quad (3)$$

Resultado (b): A densidade a posteriori de V dado $T = t$ é:

$$k(\theta; t) = \frac{(n + \beta)^{t+\alpha}}{\Gamma(t + \alpha)} \theta^{t+\alpha-1} e^{-(n+\beta)\theta}, \quad \theta > 0$$

Ou seja, $V|T = t \sim \Gamma(t + \alpha, n + \beta)$.

Observação Importante

Note que começamos com uma priori $\text{Gama}(\alpha, \beta)$ e obtivemos uma posteriori $\text{Gama}(t + \alpha, n + \beta)$. Isso confirma que a distribuição Gama é conjugada para a distribuição Poisson!

3 Priori Conjugada

3.1 Motivação

Como visto na seção anterior, a obtenção da distribuição a posteriori requer o cálculo da distribuição marginal $m(t)$:

$$m(t) = \int_{\Theta} g(t; \theta) h(\theta) d\theta$$

Se a priori $h_V(\theta) \triangleq h(\theta)$ de V é tal que a marginal $m(t) = f_T(t)$ de T no par aleatório (T, V) (em que T é a estatística suficiente minimal para θ) é analiticamente intratável, então não será possível derivar a posteriori $k(\theta; t) = f_{V|T=t}(\theta|t)$ de forma fechada.

Para muitas verossimilhanças, podemos formular um tipo especial de priori $h(\theta)$ tal que se tenha simplicidade analítica, chamada **priori conjugada**.

3.2 Definição de Priori Conjugada

Definição 3.1 (Priori Conjugada). Suponha que a fdp à priori de V dada por $h(\theta)$ pertence a uma família de fdp's \mathcal{P} . Então $h(\theta)$ é chamada de **priori conjugada** para V se e somente se a posteriori $k(\theta; t)$ também pertence à família \mathcal{P} .

Vantagens das Prioris Conjugadas

- **Tratabilidade analítica:** Permitem obter a posteriori em forma fechada
- **Interpretação intuitiva:** Os parâmetros da posteriori são atualizações simples dos parâmetros da priori
- **Eficiência computacional:** Evitam a necessidade de métodos numéricos complexos

3.3 Exercícios Resolvidos

Exercício 3.1 (Exercício 2.a). Sejam X_1, X_2, \dots, X_n uma amostra aleatória de $[X|V = \theta] \sim \text{Bernoulli}(\theta)$ tal que $\theta \in (0, 1)$. Encontre a distribuição a priori conjugada.

Solução do Exercício 2.a

Passo 1: Identificar a verossimilhança

Para uma amostra de n observações de uma distribuição Bernoulli(θ), a estatística suficiente é $T = \sum_{i=1}^n X_i$ e sua distribuição é:

$$T|V = \theta \sim \text{Binomial}(n, \theta)$$

A fmp é:

$$g(t; \theta) = \binom{n}{t} \theta^t (1 - \theta)^{n-t}$$

Passo 2: Procurar uma família de distribuições conjugada

Queremos encontrar uma família de distribuições \mathcal{P} tal que:

- A priori $h(\theta) \in \mathcal{P}$
- A posteriori $k(\theta; t) \in \mathcal{P}$

A posteriori é proporcional a:

$$k(\theta; t) \propto g(t; \theta)h(\theta) = \binom{n}{t} \theta^t (1 - \theta)^{n-t} h(\theta)$$

$$\propto \theta^t (1 - \theta)^{n-t} h(\theta)$$

Para que a posteriori tenha a mesma forma funcional da priori, precisamos que $h(\theta)$ seja proporcional a $\theta^a (1 - \theta)^b$ para alguns $a, b > -1$.

Passo 3: Identificar a família Beta

A distribuição Beta tem fdp:

$$h(\theta) = \frac{\Gamma(\alpha + \beta)}{\Gamma(\alpha)\Gamma(\beta)} \theta^{\alpha-1} (1 - \theta)^{\beta-1}, \quad 0 < \theta < 1$$

onde $\alpha > 0$ e $\beta > 0$ são os parâmetros.

Passo 4: Verificar que Beta é conjugada

Se $h(\theta) \sim \text{Beta}(\alpha, \beta)$, então:

$$k(\theta; t) \propto \theta^t (1 - \theta)^{n-t} \cdot \theta^{\alpha-1} (1 - \theta)^{\beta-1}$$

$$\propto \theta^{t+\alpha-1} (1 - \theta)^{n-t+\beta-1}$$

Esta é exatamente a forma de uma distribuição Beta com parâmetros $(t + \alpha, n - t + \beta)$.

Portanto:

$$V|T = t \sim \text{Beta}(t + \alpha, n - t + \beta)$$

Resultado: A distribuição a priori conjugada para Bernoulli(θ) é a **distribuição Beta**(α, β).

Interpretação dos Parâmetros

Os parâmetros da priori Beta podem ser interpretados como:

- α : "número de sucessos anteriores" (pseudo-observações)
- β : "número de fracassos anteriores" (pseudo-observações)
- $\alpha + \beta$: "tamanho da amostra anterior"

A posteriori atualiza esses valores somando os sucessos e fracassos observados.

Exercício 3.2 (Exercício 2.b). Sejam X_1, X_2, \dots, X_n uma amostra aleatória de $[X|V = \theta] \sim \text{Poisson}(\theta)$ tal que $\theta > 0$, em que a variável V descreve a média populacional. Encontre a distribuição a priori conjugada.

Solução do Exercício 2.b

Passo 1: Identificar a verossimilhança

Para uma amostra de n observações de uma distribuição $\text{Poisson}(\theta)$, a estatística suficiente é $T = \sum_{i=1}^n X_i$ e sua distribuição é:

$$T|V = \theta \sim \text{Poisson}(n\theta)$$

A fmp é:

$$g(t; \theta) = \frac{(n\theta)^t e^{-n\theta}}{t!}$$

Passo 2: Procurar uma família de distribuições conjugada

A posteriori é proporcional a:

$$k(\theta; t) \propto g(t; \theta)h(\theta) = \frac{(n\theta)^t e^{-n\theta}}{t!} h(\theta)$$

$$\propto \theta^t e^{-n\theta} h(\theta)$$

Para que a posteriori tenha a mesma forma funcional da priori, precisamos que $h(\theta)$ seja proporcional a $\theta^a e^{-b\theta}$ para alguns $a > -1$ e $b > 0$.

Passo 3: Identificar a família Gama

A distribuição Gama tem fdp:

$$h(\theta) = \frac{\beta^\alpha}{\Gamma(\alpha)} \theta^{\alpha-1} e^{-\beta\theta}, \quad \theta > 0$$

onde $\alpha > 0$ e $\beta > 0$ são os parâmetros.

Passo 4: Verificar que Gama é conjugada

Se $h(\theta) \sim \Gamma(\alpha, \beta)$, então:

$$k(\theta; t) \propto \theta^t e^{-n\theta} \cdot \theta^{\alpha-1} e^{-\beta\theta}$$

$$\propto \theta^{t+\alpha-1} e^{-(n+\beta)\theta}$$

Esta é exatamente a forma de uma distribuição Gama com parâmetros $(t + \alpha, n + \beta)$.

Portanto:

$$V|T = t \sim \Gamma(t + \alpha, n + \beta)$$

Resultado: A distribuição a priori conjugada para $\text{Poisson}(\theta)$ é a **distribuição Gama** (α, β) .

Interpretação dos Parâmetros

Os parâmetros da priori Gama podem ser interpretados como:

- α : "número de ocorrências anteriores" (pseudo-observações)
- β : "escala do intervalo de tempo anterior"
- A média da priori é α/β

A posteriori atualiza esses valores somando as ocorrências observadas e o tamanho da amostra.

3.4 Tabela de Prioris Conjugadas Comuns

Tabela 1: Prioris Conjugadas para Distribuições Comuns

Distribuição dos Dados	Priori Conjugada	Posteriori
Bernoulli(θ)	Beta(α, β)	Beta($t + \alpha, n - t + \beta$)
Binomial(n, θ)	Beta(α, β)	Beta($t + \alpha, n^2 - t + \beta$)
Poisson(θ)	Gama(α, β)	Gama($t + \alpha, n + \beta$)
Normal(μ, σ^2) conhecido σ^2	Normal(μ_0, τ_0^2)	Normal(μ_n, τ_n^2)
Normal(μ, σ^2) conhecido μ	Gama Inversa(α, β)	Gama Inversa($\alpha + n/2, \beta + S/2$)
Exponencial(θ)	Gama(α, β)	Gama($\alpha + n, \beta + t$)

Observação 3.1. Na tabela acima, t representa a estatística suficiente e n o tamanho da amostra. Os parâmetros da posteriori são atualizações dos parâmetros da priori com base nos dados observados.

4 Estimadores Bayesianos

4.1 Motivação à Estimação Bayesiana

Até agora, exploramos como obter a distribuição a posteriori de V dado os dados observados. Neste ponto, exploramos como **estimar θ sob uma função de perda particular**.

4.2 Contexto e Notação

Relembrando o contexto:

- X_1, \dots, X_n é uma amostra aleatória de $[X|V = \theta]$
- T é uma estatística suficiente (minimal) para θ
- \mathcal{T} é o domínio de t
- $g(t; \theta)$ é a fdp (ou fmp) de $[T|V = \theta]$
- $h(\theta)$ é a fdp (fmp) a priori de V para $\theta \in \Theta$
- $k(\theta; t)$ é a fdp (fmp) a posteriori de $[V|T = t]$

4.3 Função de Perda e Risco

Seja $\delta \equiv \delta(T)$ um estimador arbitrário para $V = \theta$, que assume valor $\delta(t)$ quando se observa $T = t$, $t \in \mathcal{T}$.

Assumamos que a **perda** em se estimar $V = \theta$ por $\delta(T)$ é dada por:

$$L^*(\theta, \delta) \equiv [\delta(T) - \theta]^2,$$

que se chama de **perda erro quadrado**.

Com base nesta medida é possível definir o **erro quadrático médio** que corresponde à média ponderada com respeito à fdp (ou fmp) de $[T|V = \theta]$, $g(t; \theta)$. A função **risco** é dada por:

$$R^*(\theta, \delta) \equiv E_{[T|V=\theta]}[L^*(\theta, \delta)] = \int_{\mathcal{T}} L^*(\theta, \delta(t))g(t; \theta)dt.$$

Esta medida é chamada de **risco frequentista**.

Na prática, dados dois estimadores $\delta_1 \equiv \delta_1(T)$ e $\delta_2 \equiv \delta_2(T)$, se $R^*(\theta, \delta_1) < R^*(\theta, \delta_2)$ para $\theta \in \Theta^* \subset \Theta$ então δ_1 é melhor do que δ_2 neste subespaço paramétrico.

4.4 Risco Bayesiano

Como alternativa ao risco frequentista, tem-se o **risco bayesiano**:

$$r^*(\theta, \delta) \equiv E_V[R^*(V, \delta)] = \int_{\Theta} R^*(\theta, \delta)h(\theta)d\theta.$$

O risco bayesiano integra o risco frequentista sobre toda a distribuição a priori, fornecendo uma medida única de desempenho do estimador.

Suponha que \mathcal{D} seja uma classe de todos os estimadores de θ cujos riscos bayesianos são finitos. Assim o melhor estimador sob o paradigma Bayesiano será δ^* em \mathcal{D} tal que:

$$r^*(\theta, \delta^*) = \inf_{\delta \in \mathcal{D}} r^*(\theta, \delta).$$

Este estimador é chamado de **estimador Bayesiano**.

4.5 Teoremas Fundamentais

Teorema 4.1. O estimador de Bayes $\delta^* \equiv \delta^*(T)$ é determinado tal que o risco a posteriori de $\delta^*(T)$ é o menor possível:

$$\int_{\Theta} L^*(\theta, \delta^*(t))k(\theta; t)d\theta = \inf_{\delta \in \mathcal{D}} \int_{\Theta} L^*(\theta, \delta(t))k(\theta; t)d\theta,$$

para todo $t \in \mathcal{T}$.

Teorema 4.2 (Estimador Bayesiano sob Perda Quadrática). No caso da função de perda erro quadrado, a estimativa de Bayes $\delta^* \equiv \delta^*(t)$ é a média da distribuição a posteriori com fdp (ou fmp) $k(\theta; t)$; isto é,

$$\delta^*(t) = \int_{\Theta} \theta k(\theta; t)d\theta \equiv E_{V|T=t}[V],$$

para todo $t \in \mathcal{T}$.

Interpretação

Sob perda quadrática, o estimador Bayesiano é simplesmente a **média da distribuição a posteriori**. Isso faz sentido intuitivamente: a média minimiza o erro quadrático médio.

4.6 Definição Geral de Estimador Bayesiano

Definição 4.1 (Estimador Bayesiano). Sejam X_1, X_2, \dots, X_n uma amostra aleatória de $[X|V = \theta]$ tendo fdp (ou fmp) $f_{X|V=\theta}$. Seja ainda V uma variável aleatória representando a distribuição a priori com fdp (ou fmp) $h(\theta)$. O estimador bayesiano para $\tau(\theta)$ é definido por:

$$\begin{aligned} \hat{\tau}_{\text{Bayes}}(\theta) &= E_{V|T=t}[\tau(V)|T(\mathbf{x}) = t] = \int_{\Theta} \tau(\theta)k(\theta|t)d\theta \\ &= \frac{\int_{\Theta} \tau(\theta)g(t|\theta)h(\theta)d\theta}{\int_{\Theta} g(t|\theta)h(\theta)d\theta}, \end{aligned}$$

em que $T(\mathbf{x}) \equiv T(X_1, \dots, X_n)$ é uma estatística suficiente (minimal) para θ .

Observação 4.1. Note que o estimador Bayesiano para uma função $\tau(\theta)$ é simplesmente a esperança de $\tau(V)$ com respeito à distribuição a posteriori. Isso generaliza o resultado do teorema anterior.

4.7 Exercícios Resolvidos

Exercício 4.1 (Exercício 3). Sejam X_1, X_2, \dots, X_n uma amostra aleatória de $[X|V = \theta] \sim \text{Bernoulli}(\theta)$ tal que $\theta \in (0, 1)$ e $V \sim U(0, 1)$. Encontre o estimador Bayesiano para θ e para $\theta(1 - \theta)$.

Solução do Exercício 3

Parte 1: Estimador Bayesiano para θ

Do Exercício 1.a, sabemos que:

$$V|T = t \sim \text{Beta}(t + 1, n - t + 1)$$

A fdp a posteriori é:

$$k(\theta; t) = \frac{\Gamma(n + 2)}{\Gamma(t + 1)\Gamma(n - t + 1)} \theta^t (1 - \theta)^{n-t}, \quad 0 < \theta < 1$$

O estimador Bayesiano para θ sob perda quadrática é a média da distribuição a posteriori:

$$\begin{aligned} \hat{\theta}_{\text{Bayes}} &= E_{V|T=t}[V] = \int_0^1 \theta k(\theta; t) d\theta \\ &= \int_0^1 \theta \cdot \frac{\Gamma(n + 2)}{\Gamma(t + 1)\Gamma(n - t + 1)} \theta^t (1 - \theta)^{n-t} d\theta \\ &= \frac{\Gamma(n + 2)}{\Gamma(t + 1)\Gamma(n - t + 1)} \int_0^1 \theta^{t+1} (1 - \theta)^{n-t} d\theta \end{aligned}$$

A integral é uma função Beta:

$$\int_0^1 \theta^{t+1} (1 - \theta)^{n-t} d\theta = B(t + 2, n - t + 1) = \frac{\Gamma(t + 2)\Gamma(n - t + 1)}{\Gamma(n + 3)}$$

Portanto:

$$\begin{aligned} \hat{\theta}_{\text{Bayes}} &= \frac{\Gamma(n + 2)}{\Gamma(t + 1)\Gamma(n - t + 1)} \cdot \frac{\Gamma(t + 2)\Gamma(n - t + 1)}{\Gamma(n + 3)} \\ &= \frac{\Gamma(n + 2)\Gamma(t + 2)}{\Gamma(t + 1)\Gamma(n + 3)} \end{aligned}$$

Usando $\Gamma(k + 1) = k\Gamma(k)$:

$$\Gamma(t + 2) = (t + 1)\Gamma(t + 1)$$

$$\Gamma(n + 3) = (n + 2)\Gamma(n + 2)$$

Portanto:

$$\hat{\theta}_{\text{Bayes}} = \frac{\Gamma(n + 2)(t + 1)\Gamma(t + 1)}{\Gamma(t + 1)(n + 2)\Gamma(n + 2)} = \frac{t + 1}{n + 2}$$

Resultado para θ :

$$\hat{\theta}_{\text{Bayes}} = \frac{t + 1}{n + 2} = \frac{T + 1}{n + 2}$$

onde $T = \sum_{i=1}^n X_i$ é o número de sucessos.

Parte 2: Estimador Bayesiano para $\theta(1 - \theta)$

O estimador Bayesiano para $\tau(\theta) = \theta(1 - \theta)$ é:

$$\begin{aligned}\widehat{\theta(1 - \theta)}_{\text{Bayes}} &= E_{V|T=t}[\theta(1 - \theta)] = \int_0^1 \theta(1 - \theta)k(\theta; t)d\theta \\ &= \int_0^1 \theta(1 - \theta) \cdot \frac{\Gamma(n+2)}{\Gamma(t+1)\Gamma(n-t+1)} \theta^t(1 - \theta)^{n-t} d\theta \\ &= \frac{\Gamma(n+2)}{\Gamma(t+1)\Gamma(n-t+1)} \int_0^1 \theta^{t+1}(1 - \theta)^{n-t+1} d\theta\end{aligned}$$

A integral é:

$$\int_0^1 \theta^{t+1}(1 - \theta)^{n-t+1} d\theta = B(t+2, n-t+2) = \frac{\Gamma(t+2)\Gamma(n-t+2)}{\Gamma(n+4)}$$

Portanto:

$$\widehat{\theta(1 - \theta)}_{\text{Bayes}} = \frac{\Gamma(n+2)}{\Gamma(t+1)\Gamma(n-t+1)} \cdot \frac{\Gamma(t+2)\Gamma(n-t+2)}{\Gamma(n+4)}$$

Usando propriedades da função Gama:

$$\Gamma(t+2) = (t+1)\Gamma(t+1)$$

$$\Gamma(n-t+2) = (n-t+1)\Gamma(n-t+1)$$

$$\Gamma(n+4) = (n+3)(n+2)\Gamma(n+2)$$

Portanto:

$$\begin{aligned}\widehat{\theta(1 - \theta)}_{\text{Bayes}} &= \frac{\Gamma(n+2)(t+1)\Gamma(t+1)(n-t+1)\Gamma(n-t+1)}{\Gamma(t+1)\Gamma(n-t+1)(n+3)(n+2)\Gamma(n+2)} \\ &= \frac{(t+1)(n-t+1)}{(n+2)(n+3)}\end{aligned}$$

Resultado para $\theta(1 - \theta)$:

$$\widehat{\theta(1 - \theta)}_{\text{Bayes}} = \frac{(T+1)(n-T+1)}{(n+2)(n+3)}$$

Observação

Note que $\theta(1 - \theta)$ é a variância de uma variável Bernoulli(θ). O estimador Bayesiano leva em conta tanto a informação dos dados quanto a informação a priori.

Exercício 4.2 (Exercício 4). Sejam X_1, X_2, \dots, X_n uma amostra aleatória de $[X|V = \theta] \sim \text{Bernoulli}(\theta)$ tal que $\theta \in (0, 1)$ e $V \sim \text{Beta}(\alpha, \beta)$. Encontre o estimador Bayesiano para θ .

Solução do Exercício 4

Passo 1: Determinar a distribuição a posteriori

Como visto no Exercício 2.a, se $V \sim \text{Beta}(\alpha, \beta)$ e $T|V = \theta \sim \text{Binomial}(n, \theta)$, então:

$$V|T = t \sim \text{Beta}(t + \alpha, n - t + \beta)$$

A fdp a posteriori é:

$$k(\theta; t) = \frac{\Gamma(n + \alpha + \beta)}{\Gamma(t + \alpha)\Gamma(n - t + \beta)} \theta^{t+\alpha-1} (1 - \theta)^{n-t+\beta-1}, \quad 0 < \theta < 1$$

Passo 2: Calcular o estimador Bayesiano

O estimador Bayesiano para θ sob perda quadrática é a média da distribuição a posteriori. Para uma distribuição $\text{Beta}(a, b)$, a média é:

$$E[\text{Beta}(a, b)] = \frac{a}{a + b}$$

Portanto:

$$\hat{\theta}_{\text{Bayes}} = E_{V|T=t}[V] = \frac{t + \alpha}{t + \alpha + n - t + \beta} = \frac{t + \alpha}{n + \alpha + \beta}$$

Resultado:

$$\hat{\theta}_{\text{Bayes}} = \frac{T + \alpha}{n + \alpha + \beta}$$

onde $T = \sum_{i=1}^n X_i$ é o número de sucessos.

Interpretação

O estimador pode ser reescrito como:

$$\hat{\theta}_{\text{Bayes}} = \frac{\alpha}{\alpha + \beta} \cdot \frac{\alpha + \beta}{n + \alpha + \beta} + \frac{T}{n} \cdot \frac{n}{n + \alpha + \beta}$$

Isso mostra que o estimador é uma média ponderada entre:

- A média da priori: $\frac{\alpha}{\alpha + \beta}$
- A média amostral: $\frac{T}{n}$

Os pesos dependem do "tamanho efetivo" da priori ($\alpha + \beta$) e do tamanho da amostra (n).

Verificação alternativa usando a definição:

$$\begin{aligned} \hat{\theta}_{\text{Bayes}} &= \int_0^1 \theta k(\theta; t) d\theta \\ &= \int_0^1 \theta \cdot \frac{\Gamma(n + \alpha + \beta)}{\Gamma(t + \alpha)\Gamma(n - t + \beta)} \theta^{t+\alpha-1} (1 - \theta)^{n-t+\beta-1} d\theta \end{aligned}$$

$$\begin{aligned}
&= \frac{\Gamma(n + \alpha + \beta)}{\Gamma(t + \alpha)\Gamma(n - t + \beta)} \int_0^1 \theta^{t+\alpha} (1 - \theta)^{n-t+\beta-1} d\theta \\
&= \frac{\Gamma(n + \alpha + \beta)}{\Gamma(t + \alpha)\Gamma(n - t + \beta)} \cdot \frac{\Gamma(t + \alpha + 1)\Gamma(n - t + \beta)}{\Gamma(n + \alpha + \beta + 1)} \\
&= \frac{\Gamma(n + \alpha + \beta)(t + \alpha)\Gamma(t + \alpha)}{\Gamma(t + \alpha)(n + \alpha + \beta)\Gamma(n + \alpha + \beta)} \\
&= \frac{t + \alpha}{n + \alpha + \beta}
\end{aligned}$$

Confirmando o resultado anterior.

5 Resumo de Fórmulas Importantes

5.1 Fórmulas Fundamentais

Tabela 2: Resumo de Fórmulas Bayesianas

Conceito	Fórmula
Distribuição Conjunta	$f_{T,V}(t, \theta) = g(t; \theta)h(\theta)$
Distribuição Marginal	$m(t) = \int_{\Theta} g(t; \theta)h(\theta)d\theta$
Distribuição a Posteriori	$k(\theta; t) = \frac{g(t; \theta)h(\theta)}{m(t)}$
Estimador Bayesiano (perda quadrática)	$\hat{\theta}_{\text{Bayes}} = E_{V T=t}[V]$
Estimador Bayesiano (geral)	$\hat{\tau}_{\text{Bayes}} = E_{V T=t}[\tau(V)]$
Risco Frequentista	$R^*(\theta, \delta) = E_{[T V=\theta]}[L^*(\theta, \delta)]$
Risco Bayesiano	$r^*(\theta, \delta) = E_V[R^*(V, \delta)]$

5.2 Propriedades da Função Gama e Beta

- $\Gamma(k + 1) = k\Gamma(k)$ para $k > 0$
- $\Gamma(n + 1) = n!$ para n inteiro não-negativo
- $B(a, b) = \int_0^1 u^{a-1}(1 - u)^{b-1} du = \frac{\Gamma(a)\Gamma(b)}{\Gamma(a+b)}$
- Se $X \sim \text{Beta}(a, b)$, então $E[X] = \frac{a}{a+b}$
- Se $X \sim \Gamma(\alpha, \beta)$, então $E[X] = \frac{\alpha}{\beta}$

6 Observações Finais

Pontos-Chave para a Prova

1. Entenda a diferença fundamental entre Inferência Clássica e Bayesiana
2. Domine os 6 elementos da Inferência Bayesiana e como eles se relacionam
3. Saiba identificar e usar prioris conjugadas
4. Lembre-se: sob perda quadrática, o estimador Bayesiano é a média da posteriori
5. Pratique o cálculo de integrais envolvendo funções Beta e Gama
6. Entenda a interpretação dos parâmetros das prioris conjugadas

Observação 6.1. Este material foi desenvolvido como auxílio para estudo. Recomenda-se também revisar as notas de aula originais e resolver exercícios adicionais para consolidar o aprendizado.