

# Estatística Aplicada

## Regressão linear múltipla

**Francisco Cribari-Neto**

Departamento de Estatística, Universidade Federal de Pernambuco

2025

# O modelo de regressão múltipla

MOTIVAÇÃO: Mensurar o impacto sobre a média de  $y$  de mais de uma covariável.

O **modelo linear de regressão múltipla** é dado por

$$y_t = \beta_1 + \beta_2 x_{t2} + \cdots + \beta_K x_{tK} + e_t, \quad t = 1, \dots, T$$

Note que o modelo de regressão simples é obtido como um caso particular quando tomamos  $K = 2$ .

$\beta_1$ : média de  $y_t$  quando  $x_{t2} = \cdots = x_{tK} = 0$ .

Para  $j = 2, \dots, K$ ,  $\partial \mu_t / \partial x_{tj} = \beta_j$ . Ou seja,  $\beta_j$  mede o impacto sobre a média da resposta quando o  $j$ -ésimo regressor aumenta em uma unidade e todos os demais regressores permanecem inalterados.

# Exemplo motivador 1

Sejam:


- ▶  $y_t$ : Nota em um exame, cuja escala varia entre 0 e 100;
- ▶  $x_{t2}$ : Número médio de horas de estudo semanal (aulas + estudos individuais) nos 12 meses anteriores ao exame;
- ▶  $x_{t3}$ : Renda familiar;
- ▶  $x_{t4}$ : Idade;
- ▶  $x_{t5}$ : Sexo (masculino / feminino).

Nosso modelo:

$$y_t = \beta_1 + \beta_2 x_{t2} + \beta_3 x_{t3} + \beta_4 x_{t4} + \beta_5 x_{t5} + e_t.$$

Aqui,  $\beta_2$  é a pontuação adicional esperada decorrente de um aumento de uma hora semanal de estudo com os demais regressores mantidos constantes.

## Exemplo motivador 2: Queda no PIB (%) na primeira metade de 2020 vs mortes cumulativas por Covid-19



## Exemplo motivador 2: Queda no PIB (%) na primeira metade de 2020 vs mortes cumulativas por Covid-19

Regressores adicionais:

- ▶ Montante relativo e extensão de auxílios individuais;
- ▶ Peso relativo do setor de serviços na economia;
- ▶ Grau de abertura da economia para o comércio internacional.

## O modelo de regressão múltipla (cont.)

Podemos escrever o modelo, em forma matricial, como

$$y = X\beta + e$$

Aqui,  $y = (y_1, \dots, y_T)'$  é um vetor  $T \times 1$  de respostas,  $\beta = (\beta_1, \dots, \beta_K)'$  é o vetor de parâmetros (de dimensão  $K \times 1$ ),  $e = (e_1, \dots, e_T)'$  é um vetor  $T \times 1$  contendo os erros e  $X$  é uma matriz  $T \times K$  ( $K < T$ ) com observações sobre os regressores.

Quando o modelo contém um intercepto, a primeira coluna de  $X$  é um vetor de uns.

## O modelo de regressão múltipla (cont.)

Ou seja,

$$X = \begin{bmatrix} 1 & x_{12} & x_{13} & \dots & x_{1K} \\ 1 & x_{22} & x_{23} & \dots & x_{2K} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & x_{T2} & x_{T3} & \dots & x_{TK} \end{bmatrix}.$$

Podemos também escrever o modelo como

$$y_t = x_t' \beta + e_t, \quad t = 1, \dots, T$$

em que  $x_t$  é a  $t$ -ésima linha de  $X$  (como vetor coluna).

# Suposições

Para o processo inferencial seja viabilizado, precisamos fazer algumas suposições.

## SUPOSIÇÕES

**[S0]** O modelo em uso está correto, ou seja, ele fornece uma boa representação para a população / fenômeno de interesse.

**[S1]** O erro possui média zero, ou seja,  $\mathbb{E}(e_t) = 0 \ \forall t$ .

**[S2]** A variância do erro é constante, i.e.,

$$\text{var}(e_t) = \sigma^2 \ \forall t$$

$(0 < \sigma^2 < \infty)$ .

**[S3]** Os erros são não correlacionados, i.e.,

$$\text{cov}(e_t, e_s) = 0 \ \forall t \neq s.$$



## Suposições (cont.)

**[S4]** As colunas de  $X$  são linearmente independentes.

Em outras palavras,  $\text{posto}(X) = K$ .

Lembre que o **posto** de uma matriz é a dimensão da maior submatriz quadrada com determinante diferente de zero.

Em outras palavras,  $\nexists c = (c_1, \dots, c_K)' \neq 0$  tal que

$$c_1 + c_2 x_{t2} + \dots + c_K x_{tK} = 0 \quad \forall t.$$

Para estimação intervalar e testes de hipóteses, adicionamos a seguinte suposição (que não é necessária para estimação pontual):

**[S5]** Os erros são normalmente distribuídos.

DEF. Uma **forma quadrática** é uma função escalar definida como

$$Q(z) = z'Az,$$

em que  $z$  é um vetor de dimensão  $K \times 1$  e  $A$  é uma matriz de dimensão  $K \times K$ .

Note que  $Q(z)$  é um escalar.

A seguir, abordaremos a **derivada de uma função escalar em relação a um vetor**. Esse conceito representa um vetor de derivadas parciais, onde cada elemento corresponde à derivada da função em relação a uma das variáveis do vetor.

# Revisão

Seja  $A$  uma matriz simétrica de dimensão  $K \times K$  e sejam  $z$  e  $w$  vetores  $K \times 1$ . Então,

$$\frac{\partial z'w}{\partial z} = \frac{\partial(z_1 \times w_1 + \cdots + z_K \times w_K)}{\partial z} = w.$$

(Ou seja, derivamos o escalar  $z'w$  em relação a cada elemento de  $z$ .)

Adicionalmente,

$$\frac{\partial z'Az}{\partial z} = 2Az.$$

Se  $A$  não for simétrica, então  $\partial z'Az / \partial z = (A + A')z$ .

# Estimação pontual

OBJETIVO: Estimar  $\beta$ , o vetor de parâmetros do modelo  $y = X\beta + e$ .

MÉTODO DE ESTIMAÇÃO: Mínimos quadrados ordinários, ou seja, minimizaremos  $S \equiv S(\beta) = \sum_{t=1}^T e_t^2 = e'e$ .

Note que

$$\begin{aligned} S &= e'e = (y - X\beta)'(y - X\beta) \\ &= y'y - \beta'X'y - y'X\beta + \beta'X'X\beta \\ &= y'y - 2\beta'X'y + \beta'X'X\beta. \end{aligned}$$

FATO:  $X'X$  é simétrica.

FATO: Sob [S4],  $X'X$  é não singular.

## Pausa para revisão

**RESULTADO 1** Seja  $A$  uma matriz simétrica de ordem  $T \times T$  e seja  $B$  uma matriz  $T \times K$ . Então,  $B'AB$  é simétrica. Tomando  $A = I_T$ , temos que  $B'B$  é simétrica.

**RESULTADO 2** Seja  $B$  uma matriz de dimensão  $T \times K$  com posto  $K$ . Então,  $B'B$  é não singular.

## Pausa para revisão (cont.)

Seja  $A$  uma matriz simétrica de dimensão  $K \times K$  e seja  $z$  um vetor  $K \times 1$ .

- ▶  $A$  é **positiva definida** se  $z'Az > 0 \forall z \neq 0$ .
- ▶  $A$  é **positiva semi-definida** se  $z'Az \geq 0 \forall z$ .
- ▶  $A$  é **negativa definida** se  $z'Az < 0 \forall z \neq 0$ .
- ▶  $A$  é **negativa semi-definida** se  $z'Az \leq 0 \forall z$ .

Se  $A$  é positiva-definida (p.d.), então  $|A| > 0$ .

Se  $A$  é p.d., então  $A^{-1}$  é p.d.

Se  $A$  é p.d. e  $c$  é um escalar positivo, então  $cA$  é p.d.

Se  $A$  e  $B$  são p.d. (e de mesma dimensão), então  $A + B$  é p.d.

Se  $A$  é p.d., então  $a_{ii} > 0$  para  $i = 1, \dots, K$ .

## Estimação pontual (cont.)

A condição de primeira ordem é

$$\frac{\partial S}{\partial \beta} = -2X'y + 2(X'X)\beta = 0.$$

Segue que

$$X'X b = X'y,$$

em que  $b = (b_1, \dots, b_K)'$  é o **estimador de mínimos quadrados ordinários** de  $\beta$ .

Assim,

$$b = (X'X)^{-1}X'y$$

Mas e a condição de segunda ordem? Note que  $\partial^2 S / \partial \beta \partial \beta' = 2X'X$ , que é positiva definida. Ou seja, trata-se de ponto de mínimo.

## Pausa para revisão

RESULTADO Seja  $B$  uma matriz de dimensão  $T \times K$  com posto  $K$ . Então,  $\text{posto}(B'B) = K$  e  $B'B$  é positiva definida. Adicionalmente,  $c B'B$  é positiva definida  $\forall c > 0$ .

CONSEQUÊNCIA  $2 X'X$  é positiva definida. Assim, a condição de segunda ordem é satisfeita.

RESULTADO ADICIONAL 1 Seja  $C$  uma matriz de dimensão  $K \times T$ . Então,  $CC'$  é positiva semi-definida. Se  $\text{posto}(C) = K$ , então  $CC'$  é positiva definida.

RESULTADO ADICIONAL 2 (Decomposição de Choleski) Seja  $A$  uma matriz positiva definida de dimensão  $K \times K$ . Então,  $A = LL'$ , em que  $L$  é uma matriz triangular inferior de ordem  $K \times K$  com elementos diagonais positivos.

OBS.: Alguns autores escrevem  $A = L'L$ . Nesse caso,  $L$  é triangular superior.



## Pausa para revisão (cont.)

EXEMPLO SIMPLES DE DECOMPOSIÇÃO DE CHOLESKI Considere a matriz

$$A = \begin{bmatrix} 1 & 2 \\ 2 & 13 \end{bmatrix}.$$

Temos que  $A = LL'$ , em que

$$L = \begin{bmatrix} 1 & 0 \\ 2 & 3 \end{bmatrix}.$$

Note que

$$LL' = \begin{bmatrix} 1 & 0 \\ 2 & 3 \end{bmatrix} \begin{bmatrix} 1 & 2 \\ 0 & 3 \end{bmatrix} = \begin{bmatrix} 1 & 2 \\ 2 & 13 \end{bmatrix} = A.$$

OBS.: Se a decomposição for definida como  $L'L$ , então  $L$  é triangular superior, ou seja,

$$L = \begin{bmatrix} 1 & 2 \\ 0 & 3 \end{bmatrix}.$$

## Pausa para revisão (cont.)

O R utiliza a segunda notação, ou seja,  $L'L$ .

```
> A = matrix(c(1, 2, 2, 13), nrow = 2, ncol = 2)
> A
      [,1] [,2]
[1,]    1    2
[2,]    2   13
> A.chol = chol(A)
> A.chol
      [,1] [,2]
[1,]    1    2
[2,]    0    3
```

# Estimação pontual no R

Para estimar regressões lineares usando o software R, use a função `lm` ('linear model'). Por exemplo,

```
> ajuste = lm(y ~ x2 + x3 + x4)
> summary(ajuste)
```

Para remover o intercepto do modelo, adicione `-1`:  
`lm(y ~ -1 + x2 + x3 + x4)`.

Para mais detalhes,

```
> help(lm)
```

# Estimação pontual no R I

Façamos um exemplo.

```
> # Carregar o conjunto de dados
> data(mtcars)
> # Detalhes sobre os dados
> help(mtcars)
> # Ver as primeiras linhas
> head(mtcars)
```

	mpg	cyl	disp	hp	drat	wt	qsec	vs	am	gear	carb
Mazda RX4	21.0	6	160	110	3.90	2.620	16.46	0	1	4	4
Mazda RX4 Wag	21.0	6	160	110	3.90	2.875	17.02	0	1	4	4
Datsun 710	22.8	4	108	93	3.85	2.320	18.61	1	1	4	1
Hornet 4 Drive	21.4	6	258	110	3.08	3.215	19.44	1	0	3	1
Hornet Sportabout	18.7	8	360	175	3.15	3.440	17.02	0	0	3	2
Valiant	18.1	6	225	105	2.76	3.460	20.22	1	0	3	1

```
> # sumário dos dados
```

```
> with(mtcars, summary(mpg)) |> round(2)
```

Min.	1st Qu.	Median	Mean	3rd Qu.	Max.
10.40	15.43	19.20	20.09	22.80	33.90

```
> with(mtcars, summary(wt)) |> round(2)
```

Min.	1st Qu.	Median	Mean	3rd Qu.	Max.
------	---------	--------	------	---------	------

## Estimação pontual no R II

```
1.51    2.58    3.33    3.22    3.61    5.42
> with(mtcars, summary(hp)) |> round(2)
  Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
 52.00  96.50 123.00 146.69 180.00 335.00
> # correlações
> with(mtcars, cor(mpg, wt)) |> round(2)
[1] -0.87
> with(mtcars, cor(mpg, hp)) |> round(2)
[1] -0.78
> with(mtcars, cor(wt, hp)) |> round(2)
[1] 0.66
> # Ajustar o modelo de regressão linear
> modelo = lm(mpg ~ wt + hp, data = mtcars)
> summary(modelo)
```

Call:

```
lm(formula = mpg ~ wt + hp, data = mtcars)
```

Residuals:

Min	1Q	Median	3Q	Max
-3.940979469	-1.600221937	-0.182013641	1.049855518	5.853790850

## Estimação pontual no R III

Coefficients:

	Estimate	Std. Error	t value	Pr(> t )
(Intercept)	37.22727011645	1.59878753800	23.28469	< 2.22e-16
wt	-3.87783074240	0.63273349438	-6.12870	0.0000011196
hp	-0.03177294698	0.00902970968	-3.51871	0.0014512

Residual standard error: 2.59341178 on 29 degrees of freedom

Multiple R-squared: 0.826785452, Adjusted R-squared:  
0.814839621

F-statistic: 69.2112134 on 2 and 29 DF, p-value: 9.10905439e-12

## Estimação pontual no R

A estimativa de  $\beta_2$  obtida usando o modelo de regressão simples foi  $-5.344$ . Aqui, ela passa a ser  $-3.8778$ . Concluimos que para cada aumento de 1000 libras no peso do carro a eficiência (medida em MPG) diminui em 3.8778 quando a potência do motor é mantida constante.

A estimativa de  $\beta_3$  é  $-0.0318$ . Assim, um aumento de uma hp (“horsepower”) de potência do motor conduz a uma redução de eficiência de 0.0318 (medida em MPG) quando o peso do carro é mantido constante. Ou seja, para um dado peso do carro, um aumento de 10 hp na potência conduz a uma redução de eficiência de aproximadamente 0.3 MPG.

# Resíduos

Os erros representam discrepâncias entre as respostas  $(y_1, \dots, y_T)$  e a reta de regressão populacional  $(x'_t\beta)$ :

$$e_t = y_t - x'_t\beta = \beta_1 - \beta_2x_{t2} - \dots - \beta_Kx_{tK}.$$

Podemos 'estimar' tais erros tomando as discrepâncias entre as respostas  $(y_1, \dots, y_T)$  e a reta de regressão amostral  $(x'_tb)$ . Essas medidas são chamadas de **resíduos**:

$$\hat{e}_t = y_t - x'_tb = y_t - b_1 - b_2x_{t2} - \dots - b_Kx_{tK}.$$

Denotaremos por  $\hat{e}$  o vetor de resíduos de mínimos quadrados ordinários, ou seja,  $\hat{e} = (\hat{e}_1, \dots, \hat{e}_T)'$ .



## Estimação de $\sigma^2$

OBJETIVO: Obter um estimador para  $\sigma^2$ .

Lembre que  $\sigma^2 = \text{var}(e_t) = \mathbb{E}(e_t^2)$  (dado que  $e_t$  possui media zero).

IDEIA: Podemos usar a variância amostral dos resíduos como um estimador para a variância populacional dos erros.

MELHORAMENTO: Ao fazer isso, incorporaremos uma 'correção de graus de liberdade'.

Temos, assim, o seguinte estimador da variância dos erros:

$$\hat{\sigma}^2 = \frac{1}{T - K} \sum_{t=1}^T \hat{e}_t^2$$

Ou seja,  $\hat{\sigma}^2 = \hat{e}'\hat{e}/(T - K)$ .

## Pausa para revisão

Seja  $Z = (Z_1, \dots, Z_m)'$  um **vetor aleatório** de dimensão  $m \times 1$  com média  $\xi = (\xi_1, \dots, \xi_m)'$ .

A **matrix de covariância** de  $Z$  é

$$\text{cov}(Z) = \mathbb{E} [(Z - \xi)(Z - \xi)'] .$$

Os elementos diagonais são as variâncias:  $\text{var}(Z_1), \dots, \text{var}(Z_m)$ .

Os demais elementos são covariâncias:  $\text{cov}(Z_1, Z_2), \text{cov}(Z_1, Z_3), \dots$

Uma vez que  $\text{cov}(Z_i, Z_j) = \text{cov}(Z_j, Z_i)$  para todo  $i \neq j$ ,  $\text{cov}(Z)$  é **simétrica**.

ALHOS E BUGALHOS: Nas derivações a seguir, não confundir  $\text{cov}(b)$  com  $\text{cov}(e)$ . Note também que as dimensões são distintas:  $K \times K$  e  $T \times T$  (respec.).

OBS.: Dado que  $\mathbb{E}(e) = 0$  (por [S1]), segue que  $\text{cov}(e) = \mathbb{E}(ee')$ .

## Propriedades de $b$

OBJETIVO: Estudar as propriedades de  $b$ , o EMQO de  $\beta$ . Assumiremos que [S4] vale. Note que [S0] garante que  $X\beta + e$  fornece uma boa representação para  $y$ .

**PROPRIEDADE 1** Sob [S0] e [S1],  $b$  é não viesado.

Note que

$$\begin{aligned} b &= (X'X)^{-1}X'y \stackrel{[S0]}{=} (X'X)^{-1}X'(X\beta + e) \\ &= \beta + (X'X)^{-1}X'e. \end{aligned}$$

Segue que

$$\begin{aligned} \mathbb{E}(b) &= \mathbb{E}(\beta) + \mathbb{E}[(X'X)^{-1}X'e] \\ &= \beta + (X'X)^{-1}X'\mathbb{E}(e) \\ &\stackrel{[S1]}{=} \beta + 0 \\ &= \beta. \end{aligned}$$

Ou seja,  $\mathbb{E}(b) = \beta \forall \beta \in \mathbb{R}^K$ . Note que só precisamos de [S0] e [S1].

## Propriedades de $b$ (cont.)

**PROPRIEDADE 2** Sob  $[S0]$ ,  $[S1]$ ,  $[S2]$  e  $[S3]$ ,  $\text{cov}(b) = \sigma^2(X'X)^{-1}$ .

Note que

$$\text{cov}(b) = \mathbb{E}\{[b - \mathbb{E}(b)][b - \mathbb{E}(b)]'\} \stackrel{[S0] \text{ e } [S1]}{=} \mathbb{E}[(b - \beta)(b - \beta)'].$$

Mas  $b - \beta = (X'X)^{-1}X'e$ . Segue que

$$\begin{aligned}\text{cov}(b) &= \mathbb{E}[(X'X)^{-1}X'ee'X(X'X)^{-1}] \\ &= (X'X)^{-1}X'\mathbb{E}(ee')X(X'X)^{-1} \\ &\stackrel{[S1] \text{ a } [S3]}{=} (X'X)^{-1}X'\sigma^2I_TX(X'X)^{-1} \\ &= \sigma^2(X'X)^{-1}X'X(X'X)^{-1} \\ &= \sigma^2(X'X)^{-1},\end{aligned}$$

em que  $I_T$  é a matriz identidade de ordem  $T$ .

Note que  $\text{cov}(e) = \sigma^2I_T$ .

## Propriedades de $b$ (cont.)

Como notamos,

$$\text{cov}(e) = \mathbb{E}(ee') = \begin{bmatrix} \mathbb{E}(e_1^2) & \mathbb{E}(e_1 e_2) & \cdots & \mathbb{E}(e_1 e_T) \\ \mathbb{E}(e_2 e_1) & \mathbb{E}(e_2^2) & \cdots & \mathbb{E}(e_2 e_T) \\ \vdots & \vdots & \ddots & \vdots \\ \mathbb{E}(e_T e_1) & \mathbb{E}(e_T e_2) & \cdots & \mathbb{E}(e_T^2) \end{bmatrix}.$$

Segue que

$$\text{cov}(e) = \begin{bmatrix} \sigma^2 & 0 & \cdots & 0 \\ 0 & \sigma^2 & \cdots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \cdots & \sigma^2 \end{bmatrix} = \sigma^2 I_T.$$

Para esse resultado, usamos [S1], [S2] e [S3].

## Propriedades de $b$ (cont.)

Note que podemos facilmente estimar essa matriz de variâncias e covariâncias:

$$\widehat{\text{cov}}(b) = \hat{\sigma}^2 (X'X)^{-1}.$$

Os **erros-padrão** de  $b_1, \dots, b_K$  são obtidos tomando as raízes quadradas dos elementos diagonais de  $\widehat{\text{cov}}(b)$ .

**PROPRIEDADE 3** O estimador de máxima verossimilhança de  $\beta$  obtido sob a suposição de normalidade coincide com  $b$ .

A função de verossimilhança construída assumindo que  $y_1, \dots, y_T$  são variáveis aleatórias independentes tais que  $y_t \sim \mathcal{N}(x_t'\beta, \sigma^2)$ ,  $t = 1, \dots, T$ , é dada por

$$L \equiv L(\beta, \sigma^2 | y, X) = (2\pi\sigma^2)^{-T/2} \exp \left( -\frac{1}{2\sigma^2} (y - X\beta)'(y - X\beta) \right).$$

A função de log-verossimilhança é

$$\ell \equiv \ell(\beta, \sigma^2 | y, X) = -\frac{T}{2} \log(2\pi) - \frac{T}{2} \log(\sigma^2) - \frac{1}{2\sigma^2} (y - X\beta)'(y - X\beta).$$

## Propriedades de $b$ (cont.)

As condições de primeira ordem são

$$\begin{aligned}\frac{\partial \ell}{\partial \beta} &= -\frac{1}{2\sigma^2}(-2X'y + 2X'X\beta) = 0, \\ \frac{\partial \ell}{\partial \sigma^2} &= -\frac{T}{2} \times \frac{1}{\sigma^2} + \frac{1}{2\sigma^4}e'e = 0.\end{aligned}$$

Da primeira equação, obtemos

$$\hat{\beta}_{MV} = (X'X)^{-1}X'y$$

que é igual a  $b$ .

Da segunda equação, obtemos  $\hat{e}'\hat{e}/\hat{\sigma}^4 = T/\hat{\sigma}^2$ . Ou seja,

$$\hat{\sigma}_{MV}^2 = \frac{\hat{e}'\hat{e}}{T}$$

que é diferente de  $\hat{\sigma}^2$ .

## Propriedades de $b$ (cont.)

**PROPRIEDADE 4**  $b$  é um **estimador linear**, pois pode ser escrito como um múltiplo de  $y$ :  $b = Ay$ , em que  $A = (X'X)^{-1}X'$ .

**PROPRIEDADE 5** Se  $y \sim \mathcal{N}$ , então  $b \sim \mathcal{N}$ .

**PROPRIEDADE 6** (Teorema de Gauss-Markov) Sob [S0], [S1], [S2] e [S3],  $b$  é o melhor estimador linear não viesado de  $\beta$ .

Ou seja,  $\forall a \in \mathbb{R}^K$  e para qualquer estimador  $b^*$  de  $\beta$  que seja linear e não viesado, segue que

$$\text{var}(a'b^*) \geq \text{var}(a'b) \Rightarrow \text{var}(a'b^*) - \text{var}(a'b) \geq 0.$$

Ou seja,

$$a'[\text{cov}(b^*)]a - a'[\text{cov}(b)]a \geq 0 \Rightarrow a'[\text{cov}(b^*) - \text{cov}(b)]a \geq 0.$$

Ou seja, a diferença entre  $\text{cov}(b^*)$  e  $\text{cov}(b)$  deve ser positiva semi-definida.



## Propriedades de $b$ (cont.)

PROVA. Defina a classe de estimadores lineares de  $\beta$  como

$$b^* = [(X'X)^{-1}X' + C]y,$$

em que  $C$  é uma matriz (não-aleatória) de dimensão  $K \times T$ .

Note que o estimador de MQO  $b$  é um membro desta classe quando  $C$  é uma matriz de zeros.

Note ainda que

$$\begin{aligned} b^* &= [(X'X)^{-1}X' + C]y \\ &\stackrel{[S0]}{=} [(X'X)^{-1}X' + C](X\beta + e) \\ &= \beta + Ce + CX\beta + (X'X)^{-1}X'e. \end{aligned}$$

Dado que  $\mathbb{E}(e) = 0$  (por [S1]), então  $\mathbb{E}(b^*) = \beta + CX\beta$ .

Assim, para que  $b^*$  seja não viesado, requeremos  $CX = 0$ .

## Propriedades de $b$ (cont.)

Temos então

$$b^* - \beta = Ce + (X'X)^{-1}X'e = [C + (X'X)^{-1}X']e.$$

Portanto,

$$(b^* - \beta)(b^* - \beta)' = [C + (X'X)^{-1}X']ee'[C' + X(X'X)^{-1}].$$

A matriz de covariância de  $b^*$  é

$$\begin{aligned}\text{cov}(b^*) &= \mathbb{E}[(b^* - \beta)(b^* - \beta)'] \\ &= [C + (X'X)^{-1}X']\mathbb{E}(ee')[C' + X(X'X)^{-1}] \\ &\stackrel{[S1]}{=} \stackrel{[S3]}{=} [C + (X'X)^{-1}X']\sigma^2 I_T [C' + X(X'X)^{-1}] \\ &= \sigma^2 [CC' + (X'X)^{-1}X'C' + CX(X'X)^{-1} + (X'X)^{-1}X'X(X'X)^{-1}] \\ &= \sigma^2 [CC' + (X'X)^{-1}].\end{aligned}$$

(Note que usamos acima a propriedade de não viés, i.e.,  $CX = 0$  e  $X'C' = 0$ , e também [S0], [S1], [S2] e [S3].)

## Propriedades de $b$ (cont.)

Assim,

$$\text{cov}(b^*) = \sigma^2(X'X)^{-1} + \sigma^2CC' = \text{cov}(b) + \sigma^2CC'.$$

Ou seja,

$$\text{cov}(b^*) - \text{cov}(b) = \sigma^2CC',$$

uma matriz positiva semi-definida.



OBS. Se  $C = 0$ , então  $b^* = b$  e, claro,  $\text{cov}(b^*) - \text{cov}(b) = 0$ .

OBS. Se  $\text{posto}(C) = K$  (que implica  $b^* \neq b$ ), então  $\sigma^2CC'$  é positiva definida.

OBS. Lembre desse resultado que revisamos: *Seja  $C$  uma matriz de dimensão  $K \times T$ . Então,  $CC'$  é positiva semi-definida. Se  $\text{posto}(C) = K$ , então  $CC'$  é positiva definida.*

## Duas propriedades de uma matriz importante

Considere a seguinte matriz (de ordem  $T \times T$ ):

$$M = I_T - X(X'X)^{-1}X'.$$

[PROP. 1] A matriz  $M$  é **simétrica**:

$$M' = (I_T - X(X'X)^{-1}X')' = I_T - X(X'X)^{-1}X' = M.$$

[PROP. 2] A matriz  $M$  é **idempotente**:

$$\begin{aligned} MM &= (I_T - X(X'X)^{-1}X')(I_T - X(X'X)^{-1}X') \\ &= I_T - X(X'X)^{-1}X' - X(X'X)^{-1}X' + X(X'X)^{-1}X'X(X'X)^{-1}X' \\ &= I_T - X(X'X)^{-1}X' - X(X'X)^{-1}X' + X(X'X)^{-1}X' \\ &= I_T - X(X'X)^{-1}X' = M. \end{aligned}$$

Mais adiante, denotaremos a matriz  $X(X'X)^{-1}X'$  por  $H$  e a chamaremos de **matriz chapéu**.

Vimos que se  $Z_1, Z_2, \dots, Z_k \stackrel{\text{indep}}{\sim} \mathcal{N}(0, 1)$ , então  $\sum_{i=1}^k Z_i^2 \sim \chi_k^2$ .

Agora, sejam  $Z_1, Z_2, \dots, Z_k$  variáveis aleatórias independentes tal que  $Z_i \sim \mathcal{N}(\mu_i, 1)$ , para  $i = 1, \dots, k$ . Então  $\sum_{i=1}^k Z_i^2 \sim \chi_k^2, \lambda$ , em que  $\lambda = \sum_{i=1}^k \mu_i^2$ . Essa é a **distribuição qui-quadrado não central**.

## Dois resultados importantes

LEMA 1. Seja  $s \sim \mathcal{N}(\psi, I_T)$  e seja  $A$  uma matriz não estocástica de dimensão  $T \times T$  simétrica e idempotente. Então,

$$s'As \sim \chi_{a,\lambda}^2,$$

em que  $a = \text{posto}(A)$  e  $\lambda = \psi' A \psi / 2$ .

LEMA 2. Seja  $s \sim \mathcal{N}(\psi, I_T)$ , seja  $A$  uma matriz não estocástica simétrica de dimensão  $T \times T$  e seja  $B$  uma matriz não estocástica de dimensão  $K \times T$ . Se

$$BA = 0,$$

então

$$s'As \quad \text{e} \quad Bs$$

são independentes.

## Propriedades de $b$ (cont.)

**PROPRIEDADE 7** Sob normalidade (e [S0] a [S3]),  $b$  e  $\hat{\sigma}^2$  são independentes.

PROVA. Dado que  $e \sim \mathcal{N}(0, \sigma^2 I_T)$ , segue que  $y \sim \mathcal{N}(\mu, \sigma^2 I_T)$  e

$$b = (X'X)^{-1}X'y \sim \mathcal{N}(\beta, \sigma^2(X'X)^{-1}).$$

Seja  $z = y/\sigma$ . Segue que

$$z \sim \mathcal{N}(\sigma^{-1}X\beta, I_T).$$

Seja  $M = I_T - X(X'X)^{-1}X'$ . Temos que

$$\frac{T-K}{\sigma^2} \hat{\sigma}^2 = z'Mz.$$

Mostremos que isso é verdade.

## Propriedades de $b$ (cont.)

Temos

$$\begin{aligned}\frac{T-K}{\sigma^2} \hat{\sigma}^2 &= \frac{T-K}{\sigma^2} \times \overbrace{\hat{e}'\hat{e}}^{\hat{\sigma}^2} = \frac{1}{\sigma^2} (y - Xb)'(y - Xb) \\ &= \frac{1}{\sigma^2} [y - X(X'X)^{-1}X'y]'[y - X(X'X)^{-1}X'y] \\ &= \frac{1}{\sigma^2} y'[I_T - X(X'X)^{-1}X']'[I_T - X(X'X)^{-1}X']y \\ &= \frac{1}{\sigma^2} y'M'My.\end{aligned}$$

Lembre que  $M$  é simétrica (i.e.,  $M = M'$ ) e idempotente (i.e.,  $MM = M$ ). Isso implica que  $M'M = M$  e, assim,

$$\frac{T-K}{\sigma^2} \hat{\sigma}^2 = \frac{1}{\sigma^2} y'MMy = \left(\frac{y}{\sigma}\right)' M \left(\frac{y}{\sigma}\right) = z'Mz.$$

Sigamos em frente...



## Propriedades de $b$ (cont.)

Pelo Lema 1,

$$\mathbf{z}'M\mathbf{z} \sim \chi_{a,\lambda}^2.$$

Aqui,  $a = \text{posto}(M)$ . Note que, dado que  $M$  é idempotente, segue que  $\text{posto}(M) = \text{tr}(M)$  e

$$\begin{aligned}\text{tr}(M) &= \text{tr}(I_T - X(X'X)^{-1}X') \\ &= \text{tr}(I_T) - \text{tr}(X(X'X)^{-1}X') \\ &= T - \text{tr}(X'X(X'X)^{-1}) \\ &= T - \text{tr}(I_K) \\ &= T - K.\end{aligned}$$

Ou seja,  $a = T - K$ . Agora precisamos determinar o valor de  $\lambda$ .

## Propriedades de $b$ (cont.)

Dado que  $z \sim \mathcal{N}(\sigma^{-1}X\beta, I_T)$ , segue que

$$\lambda = \frac{\beta'X'MX\beta}{2\sigma^2}.$$

Note que

$$\begin{aligned}X'MX &= X'[I_T - X(X'X)^{-1}X']X \\&= X'X - X'X(X'X)^{-1}X'X \\&= X'X - X'X \\&= 0.\end{aligned}$$

Assim,  $\lambda = 0$ .

Temos, assim, que  $z'Mz \sim \chi^2_{T-K}$ . Ou seja,  $(T-K)/\sigma^2 \times \hat{\sigma}^2 \sim \chi^2_{T-K}$ .

## Propriedades de $b$ (cont.)

O passo final de nossa prova será aplicar o Lema 2 com  $A = M$  e  $B = (X'X)^{-1}X'$ . Note que

$$\begin{aligned}BA &= (X'X)^{-1}X'[I_T - X(X'X)^{-1}X'] \\&= (X'X)^{-1}X' - (X'X)^{-1}X'X(X'X)^{-1}X' \\&= (X'X)^{-1}X' - (X'X)^{-1}X' \\&= 0.\end{aligned}$$

Portanto,  $z'Mz$  e  $(X'X)^{-1}X'z$  são independentes. Temos, assim, que

$$\hat{\sigma}^2 \text{ e } b$$

são independentes.



**PROPRIEDADE 8**  $b$  e  $\hat{\sigma}^2$  são consistentes. (Provaremos mais adiante.)

## Propriedades de $\hat{\sigma}^2$

**PROPRIEDADE 1** Sob normalidade (e [S0] a [S3]),

$$\frac{T-K}{\sigma^2} \hat{\sigma}^2 \sim \chi_{T-K}^2$$

Note que esse resultado foi provado ao longo da prova de que  $\hat{\sigma}^2$  e  $b$  são independentes. Ele segue do nosso Lema 1.

**PROPRIEDADE 2** Sob normalidade (e [S0] a [S3]),  $\hat{\sigma}^2$  é não viesado.

Note que

$$\mathbb{E} \left( \frac{T-K}{\sigma^2} \hat{\sigma}^2 \right) = T-K \quad (\text{média da dist. } \chi_{T-K}^2)$$

Assim,

$$\mathbb{E}(\hat{\sigma}^2) = \sigma^2.$$



## Propriedades de $\hat{\sigma}^2$ (cont.)

Note ainda que

$$\text{var} \left( \frac{T-K}{\sigma^2} \hat{\sigma}^2 \right) = 2(T-K) \text{ (variância da dist. } \chi_{T-K}^2 \text{)}$$

Ou seja,

$$\frac{(T-K)^2}{\sigma^4} \text{var}(\hat{\sigma}^2) = 2(T-K).$$

Ou seja,

$$\text{var}(\hat{\sigma}^2) = \frac{2\sigma^4}{T-K} \rightarrow 0$$

quando  $T \rightarrow \infty$ .

## Propriedades de $\hat{\sigma}^2$ (cont.)

**PROPRIEDADE 3** Mesmo sem normalidade (mas sob [S0] a [S3]),  $\hat{\sigma}^2$  é não viesado.

PROVA. Note, de início, que

$$\begin{aligned}\hat{e} &= y - Xb \\ &= y - X(X'X)^{-1}X'y \\ &= [I_T - X(X'X)^{-1}X']y \\ &= My.\end{aligned}$$

Sob [S0],

$$\begin{aligned}\hat{e} &= [I_T - X(X'X)^{-1}X'](X\beta + e) \\ &= X\beta - X(X'X)^{-1}X'X\beta + Me \\ &= Me.\end{aligned}$$

Precisamos obter  $\mathbb{E}(\hat{\sigma}^2) = \mathbb{E}[\hat{e}'\hat{e}/(T - K)]$ .

## Propriedades de $\hat{\sigma}^2$ (cont.)

Note que

$$\begin{aligned}\mathbb{E}(\hat{\sigma}^2) &= \mathbb{E}\left(\frac{\hat{e}'\hat{e}}{T-K}\right) = \frac{1}{T-K} \mathbb{E}[e' \overbrace{M'M}^M e] \\&= \frac{1}{T-K} \mathbb{E}[\text{tr}(e'Me)] \\&= \frac{1}{T-K} \mathbb{E}[\text{tr}(Mee')] \\&= \frac{1}{T-K} \text{tr}(M \overbrace{\mathbb{E}(ee')}^{\sigma^2 I_T}) \\&= \frac{\sigma^2}{T-K} \text{tr}(I_T - X(X'X)^{-1}X') \\&= \frac{\sigma^2}{T-K} \times (T-K) \\&= \sigma^2.\end{aligned}$$

O **quantil**  $p \in (0, 1)$  da variável aleatória  $W$  é

$$w_p = \inf \{w \in \mathbb{R} \mid \Pr(W \leq w) \geq p\}.$$

O quantil 0.5 é a mediana e os quantis 0.25 e 0.75 são conhecidos como primeiro e terceiro quartis, respectivamente.

Por exemplo, os quantis de nível 0.90, 0.95, 0.975, 0.99, 0.995 da distribuição normal padrão são

```
> qnorm(c(0.90, 0.95, 0.975, 0.99, 0.995)) |> round(4)
[1] 1.2816 1.6449 1.9600 2.3263 2.5758
```

Para a distribuição  $t_5$ , obtemos

```
> qt(c(0.90, 0.95, 0.975, 0.99, 0.995), df = 5) |> round(4)
[1] 1.4759 2.0150 2.5706 3.3649 4.0321
```



## Estimação intervalar

OBJETO DE DESEJO: Realizar inferência intervalar sobre os parâmetros do modelo de regressão linear.

Em particular, para um  $\alpha \in (0, 1)$  selecionado, desejamos encontrar um intervalo aleatório cujos limites sejam estatísticas e cuja probabilidade de conter o valor verdadeiro do parâmetro seja  $1 - \alpha$ . No que segue, para  $\delta \in (0, 1)$ ,  $z_\delta$  denota o quantil  $\delta$  da distribuição normal padrão.

SUPOSIÇÃO IMPORTANTE: Assumiremos **normalidade**, i.e., nossa suposição [S5].

**CASO IRREALISTA** Suponha que  $\sigma^2$  é conhecido. Para  $j = 1, \dots, K$ ,

$$b_j \sim \mathcal{N}(\beta_j, \text{var}(b_j)),$$

em que  $\text{var}(b_j)$  é o elemento  $(j, j)$  da matriz  $\sigma^2(X'X)^{-1}$ .

Note que

$$\frac{b_j - \beta_j}{\sqrt{\text{var}(b_j)}} \sim \mathcal{N}(0, 1).$$

## Estimação intervalar (cont.)

Assim,

$$\Pr \left( z_{\alpha/2} \leq \frac{b_j - \beta_j}{\sqrt{\text{var}(b_j)}} \leq z_{1-\alpha/2} \right) = 1 - \alpha.$$

Dada a simetria da distribuição normal,  $z_{\alpha/2} = -z_{1-\alpha/2}$ . Segue que

$$\Pr \left( b_j - z_{1-\alpha/2} \sqrt{\text{var}(b_j)} \leq \beta_j \leq b_j + z_{1-\alpha/2} \sqrt{\text{var}(b_j)} \right) = 1 - \alpha.$$

Chegamos ao seguinte intervalo de confiança de nível  $(1 - \alpha) \times 100\%$  para  $\beta_j$ :

$$\left[ b_j - z_{1-\alpha/2} \sqrt{\text{var}(b_j)}, b_j + z_{1-\alpha/2} \sqrt{\text{var}(b_j)} \right]$$

## Estimação intervalar (cont.)

**CASO REALISTA** Suponha que  $\sigma^2$  é desconhecido.

Seja  $c_{jj}$  o  $j$ -ésimo elemento diagonal de  $(X'X)^{-1}$ ,  $j = 1, \dots, K$ .  
Trabalharemos com os seguintes resultados:

RESULTADO 1:  $(b_j - \beta_j) / \sqrt{\sigma^2 c_{jj}} \sim \mathcal{N}(0, 1)$ .

RESULTADO 2:  $(T - K)\hat{\sigma}^2 / \sigma^2 \sim \chi_{T-K}^2$ .

RESULTADO 3:  $b_j$  e  $\hat{\sigma}^2$  são independentes.

Segue desses três resultados combinados que

$$\frac{b_j - \beta_j}{\sqrt{\widehat{\text{var}}(b_j)}} = \frac{b_j - \beta_j}{\sqrt{\hat{\sigma}^2 c_{jj}}} \sim t_{T-K}.$$

## Estimação intervalar (cont.)

EXPLICAÇÃO: Temos

$$\frac{\frac{b_j - \beta_j}{\sqrt{\sigma^2 c_{jj}}}}{\sqrt{\frac{(T-K)\hat{\sigma}^2/\sigma^2}{T-K}}} = \frac{b_j - \beta_j}{\sqrt{\hat{\sigma}^2 c_{jj}}}.$$

Note que: (i) O numerador (lado esquerdo da igualdade) possui distribuição  $\mathcal{N}(0, 1)$ , (ii) O denominador (lado esquerdo da igualdade) é a raiz quadrada de uma variável aleatória  $\chi^2_{T-K}$  dividida por  $T - K$  (número de graus de liberdade), (iii) O numerador e o denominador são independentes.

OBS. A independência entre o numerador e o denominador segue da independência entre  $b$  e  $\hat{\sigma}^2$ .

## Estimação intervalar (cont.)

Fazendo desenvolvimento análogo ao anterior, chegamos ao seguinte intervalo de confiança de nível  $(1 - \alpha) \times 100\%$  para  $\beta_j$ :

$$\left[ b_j - t_{T-K;1-\alpha/2} \sqrt{\widehat{\text{var}}(b_j)}, b_j + t_{T-K;1-\alpha/2} \sqrt{\widehat{\text{var}}(b_j)} \right]$$

em que  $t_{m;\delta}$  denota o quantil  $\delta$  da distribuição  $t_m$ .

Ou seja,

$$\left[ b_j - t_{T-K;1-\alpha/2} \sqrt{\hat{\sigma}^2 c_{jj}}, b_j + t_{T-K;1-\alpha/2} \sqrt{\hat{\sigma}^2 c_{jj}} \right]$$

PERGUNTA PARA REFLEXÃO: Qual dos dois intervalos (caso irrealista e caso realista) tende a ser mais amplo e por quê?

## Estimação intervalar (cont.)

EXERCÍCIO: Seguindo os desenvolvimentos anteriores, mas fazendo as devidas modificações, construa um intervalo de confiança de nível  $(1 - \alpha) \times 100\%$  para  $\sigma^2$ .

## Estimação intervalar (cont.)

No R, use a função `confint`. Por exemplo,

```
> data(cars)
> help(cars)
> ajuste = lm(dist ~ speed, data = cars)
> intervalos de confiança de 95%
> confint(ajuste)
                2.5 %          97.5 %
(Intercept) -31.16784960239 -3.99034017863
speed        3.09696432814  4.76785319011
> # intervalos de confiança de 90%
> confint(ajuste, level = 0.90)
                5 %          95 %
(Intercept) -28.91451427065 -6.24367551037
speed        3.23550067632  4.62931684193
> # estimativas pontuais (b_1 e b_2)
> coef(ajuste)
      (Intercept)          speed
-17.57909489051    3.93240875912
```

## Testes de hipóteses

OBJETO DE DESEJO: Realizar inferência por testes de hipóteses sobre os parâmetros do modelo de regressão linear.

SUPOSIÇÃO IMPORTANTE: Assumiremos normalidade, i.e., nossa suposição [S5].

**TESTE 1** Suponha que desejamos testar  $\mathcal{H}_0 : \beta_j = \beta_j^{(0)}$  vs.

$\mathcal{H}_1 : \beta_j \neq \beta_j^{(0)}$ , para algum  $j \in \{1, \dots, K\}$ .

Seja  $\text{ep}(b_j)$  o erro-padrão de  $b_j$ , i.e.,  $\text{ep}(b_j) = \sqrt{\widehat{\text{var}}(b_j)}$ .

Lembre que  $(b_j - \beta_j) / \text{ep}(b_j) \sim t_{T-K}$ . Note que

$$t = \frac{b_j - \beta_j^{(0)}}{\text{ep}(b_j)}$$

é uma estatística de teste que podemos usar. Ela mede a evidência amostral contra  $\mathcal{H}_0$ .

Note que, sob  $\mathcal{H}_0$ ,  $\beta_j = \beta_j^{(0)}$  e, assim, sob a hipótese nula

$$t \sim t_{T-K}.$$



## Testes de hipóteses (cont.)

Desta forma, rejeitamos  $\mathcal{H}_0$  ao nível de significância  $\alpha \in (0, 1)$  se

$$|t| > t_{T-K; 1-\alpha/2}.$$

Esse teste é chamado de **teste t**.

O teste apresentado é um teste bilateral ou bicaudal. Podemos realizar testes unilaterais ou unicaudais.

CASO 1. Suponha que desejamos testar  $\mathcal{H}_0 : \beta_j = \beta_j^{(0)}$  vs.

$$\mathcal{H}_1 : \beta_j > \beta_j^{(0)}.$$

Rigorosamente, testamos  $\mathcal{H}_0 : \beta_j \leq \beta_j^{(0)}$  vs.  $\mathcal{H}_1 : \beta_j > \beta_j^{(0)}$ . Ao escrever  $\mathcal{H}_0 : \beta_j = \beta_j^{(0)}$ , desconsideramos a possibilidade que  $\beta_j$  seja menor que  $\beta_j^{(0)}$ .

Usamos a mesma estatística de teste e rejeitamos a hipótese nula se

$$t > t_{T-K; 1-\alpha}.$$

# Testes de hipóteses (cont.)

EXEMPLO:

$$\text{consumo}_t = \beta_1 + \beta_2 \text{renda}_t + \beta_3 \text{riqueza}_t + e_t,$$

$\mathcal{H}_0 : \beta_3 = 0$  vs  $\mathcal{H}_1 : \beta_3 > 0$  (i.e., riqueza não tem impacto ou tem impacto positivo).

CASO 2. Suponha que desejamos testar  $\mathcal{H}_0 : \beta_j = \beta_j^{(0)}$  vs.

$\mathcal{H}_1 : \beta_j < \beta_j^{(0)}$ .

Rigorosamente, testamos  $\mathcal{H}_0 : \beta_j \geq \beta_j^{(0)}$  vs.  $\mathcal{H}_1 : \beta_j < \beta_j^{(0)}$ . Ao escrever  $\mathcal{H}_0 : \beta_j = \beta_j^{(0)}$ , desconsideramos a possibilidade que  $\beta_j$  seja maior que  $\beta_j^{(0)}$ .

Usamos a mesma estatística de teste e rejeitamos a hipótese nula se

$$t < -t_{T-K; 1-\alpha}.$$

# Testes de hipóteses (cont.)

EXEMPLO:

$$\text{inflação}_t = \beta_1 + \beta_2 \text{ taxa de juros}_t + e_t,$$

$\mathcal{H}_0 : \beta_2 = 0$  vs  $\mathcal{H}_1 : \beta_2 < 0$  (i.e., taxa de juros não tem impacto ou tem impacto negativo).

TERMINOLOGIA. Quando  $\beta_j^{(0)} = 0$ , a estatística  $t$  é chamada de razão  $t$ .

Note que podemos lidar com casos mais complexos. Por exemplo, suponha que desejamos testar  $\mathcal{H}_0 : \beta_2 = \beta_3$  vs.  $\mathcal{H}_1 : \beta_2 \neq \beta_3$ . Equivalentemente,  $\mathcal{H}_0 : \beta_2 - \beta_3 = 0$  vs.  $\mathcal{H}_1 : \beta_2 - \beta_3 \neq 0$ .

EXEMPLO:

$$\text{consumo}_t = \beta_1 + \beta_2 \text{ renda do trabalho}_t + \beta_3 \text{ renda de outras fontes}_t + e_t.$$

## Testes hipóteses (cont.)

Nossa estatística de teste:

$$t = \frac{b_2 - b_3}{\sqrt{\widehat{\text{var}}(b_2 - b_3)}} = \frac{b_2 - b_3}{\sqrt{\widehat{\text{var}}(b_2) + \widehat{\text{var}}(b_3) - 2\widehat{\text{cov}}(b_2, b_3)}}.$$

Note que  $\widehat{\text{var}}(b_2)$ ,  $\widehat{\text{var}}(b_3)$  e  $\widehat{\text{cov}}(b_2, b_3)$  são os elementos (2, 2), (3, 3) e (2, 3) de  $\hat{\sigma}^2(X'X)^{-1}$ .

Rejeitamos  $\mathcal{H}_0$  ao nível de significância  $\alpha$  se

$$|t| > t_{T-K; 1-\alpha/2}.$$

## Testes de hipóteses (cont.)

PERGUNTA: Possuímos alguma informação, relevante ou não, sobre a distribuição (da estatística de teste) sob a hipótese alternativa?

Suponha que  $\mathcal{H}_0 : \beta_j = \beta_j^{(0)}$  é falsa. Seja  $\beta_j^{(1)}$  o valor verdadeiro do parâmetro.

Lembre que se  $Z_1 \sim \mathcal{N}(0, 1)$  e  $Z_2 \sim \chi_\nu^2$  são variáveis aleatórias independentes, então

$$\frac{Z_1}{\sqrt{Z_2/\nu}} \sim t_\nu.$$

FATO: Se  $Z_1 \sim \mathcal{N}(\varphi, 1)$ , então

$$\frac{Z_1}{\sqrt{Z_2/\nu}} \sim t_{\nu, \varphi}$$

( $t$  de Student não central, i.e.,  $t$  de Student com  $\nu$  graus de liberdade e parâmetro de não centralidade  $\varphi$ ; para detalhes, ver, e.g.,

[https://en.wikipedia.org/wiki/Noncentral\\_t-distribution](https://en.wikipedia.org/wiki/Noncentral_t-distribution)).

## Testes de hipóteses (cont.)

Se  $W \sim t_{\nu, \varphi}$ , então

$$\mathbb{E}(W) = \varphi \sqrt{\frac{\nu}{2}} \frac{\Gamma((\nu-1)/2)}{\Gamma(\nu/2)} \quad \text{para } \nu > 1.$$

Também,

$$\text{var}(W) = \frac{\nu(1+\varphi^2)}{\nu-2} - \varphi^2 \left( \sqrt{\frac{\nu}{2}} \frac{\Gamma((\nu-1)/2)}{\Gamma(\nu/2)} \right)^2 \quad \text{para } \nu > 2.$$

FATO: A seguinte aproximação é válida:

$$\sqrt{\frac{\nu}{2}} \frac{\Gamma((\nu-1)/2)}{\Gamma(\nu/2)} \approx \frac{1}{1 - \frac{3}{4\nu-1}}.$$

FATO: Se  $\varphi \neq 0$ , a distribuição é assimétrica. A assimetria da distribuição  $t_{\nu, \varphi}$  diminui à medida que  $\nu$  aumenta.

## Testes de hipóteses (cont.)

Temos que  $b_j \sim \mathcal{N}(\beta_j^{(1)}, \sigma^2 \mathbf{c}_{jj})$ . Assim,

$$b_j - \beta_j^{(0)} \sim \mathcal{N}(\beta_j^{(1)} - \beta_j^{(0)}, \sigma^2 \mathbf{c}_{jj}).$$

Ou seja,

$$\frac{b_j - \beta_j^{(0)}}{\sqrt{\sigma^2 \mathbf{c}_{jj}}} \sim \mathcal{N}\left(\frac{\beta_j^{(1)} - \beta_j^{(0)}}{\sqrt{\sigma^2 \mathbf{c}_{jj}}}, 1\right).$$

Segue que, sob  $\mathcal{H}_1$ ,

$$t \sim t_{T-K, \varphi},$$

em que

$$\varphi = \frac{\beta_j^{(1)} - \beta_j^{(0)}}{\sqrt{\sigma^2 \mathbf{c}_{jj}}}.$$

## Testes de hipóteses (cont.)

Ou seja, a estatística  $t$  pode ser expressa como

$$\frac{\mathcal{N}(\varphi, 1)}{\sqrt{\chi_{T-K}^2/(T-K)}},$$

as variáveis aleatórias no numerador e denominador sendo independentes.

Quando  $\mathcal{H}_0$  é verdadeira,  $\varphi = 0$  e  $t \sim t_{T-K}$  (central). Quando  $\mathcal{H}_0$  é falsa,  $\varphi \neq 0$  e  $t \sim t_{T-K;\varphi}$  (não central).

Note que quanto maior  $|\varphi|$ , mais distintas serão as distribuições nula e não nula de  $t$ .

Assim, quanto maior  $|\varphi|$ , maior deverá ser o poder do teste.

Note que  $|\varphi|$  aumenta quando: (i)  $|\beta_j^{(1)} - \beta_j^{(0)}|$  aumenta, ou (ii)  $T$  aumenta (o que causa redução no erro-padrão de  $b_j$ ).

OBS. A consistência do teste segue de (ii).



## Testes de hipóteses (cont.)

PRÓXIMO OBJETIVO: Testar várias restrições simultaneamente.

**TESTE 2** Suponha que desejamos testar a hipótese nula de que não há relação de regressão (linear) entre a resposta e os regressores. Ou seja, queremos testar  $\mathcal{H}_0 : \beta_2 = \beta_3 = \dots = \beta_K = 0$  vs.  $\mathcal{H}_1 : \text{não } \mathcal{H}_0$  (i.e., pelo menos uma das inclinações é diferente de zero).

Note que, sob a hipótese nula,  $y_t = \beta_1 + e_t$ .

Sejam  $\beta_s = (\beta_2, \dots, \beta_K)'$ ,  $b_s = (b_2, \dots, b_K)'$  e  $\widehat{\text{cov}}(b_s)$  a matriz de covariância estimada de  $b_s$ .

Note que queremos testar  $\mathcal{H}_0 : \beta_s = 0$  vs.  $\mathcal{H}_1 : \beta_s \neq 0$ .

Temos que

$$\frac{(b_s - \beta_s)' [\widehat{\text{cov}}(b_s)]^{-1} (b_s - \beta_s)}{K - 1} \sim F_{K-1, T-K}.$$

## Testes de hipóteses (cont.)

Note que, sob a hipótese nula,  $\beta_s = 0$ . Desta forma, podemos usar a seguinte estatística de teste:

$$F = \frac{b'_s [\widehat{\text{cov}}(b_s)]^{-1} b_s}{K - 1}$$

Sob  $\mathcal{H}_0$ ,  $F \sim F_{K-1, T-K}$ . Assim, rejeitamos  $\mathcal{H}_0$  ao nível de significância  $\alpha$  se

$$F > F_{K-1, T-K; 1-\alpha}.$$

Esse teste é conhecido como **teste F**.

# Estimação pontual no R I

Revisitemos uma regressão que já estimamos.

```
> # Carregar o conjunto de dados
> data(mtcars)
> # Detalhes sobre os dados
> help(mtcars)
> # Ajustar o modelo de regressão linear
> modelo = lm(mpg ~ wt + hp, data = mtcars)
> summary(modelo)
```

Call:

```
lm(formula = mpg ~ wt + hp, data = mtcars)
```

Residuals:

	Min	1Q	Median	3Q	Max
	-3.940979469	-1.600221937	-0.182013641	1.049855518	5.853790850

Coefficients:

	Estimate	Std. Error	t value	Pr(> t )
(Intercept)	37.22727011645	1.59878753800	23.28469	< 2.22e-16
wt	-3.87783074240	0.63273349438	-6.12870	0.0000011196

## Estimação pontual no R II

```
hp          -0.03177294698  0.00902970968 -3.51871    0.0014512
```

```
Residual standard error: 2.59341178 on 29 degrees of freedom
```

```
Multiple R-squared:  0.826785452,    Adjusted R-squared:  
0.814839621
```

```
F-statistic: 69.2112134 on 2 and 29 DF,  p-value: 9.10905439e-12
```

O valor da estatística  $F$  para o teste de  $\mathcal{H}_0 : \beta_2 = \beta_3 = 0$  é **69.2112** e o  $p$ -valor do teste é muito pequeno.

## Testes de hipóteses (cont.)

Há uma relação entre os testes  $F$  e  $t$  no modelo de regressão simples ( $K = 2$ ). Testamos aqui  $\mathcal{H}_0 : \beta_2 = 0$  vs.  $\mathcal{H}_1 : \beta_2 \neq 0$ .

Note que, nesse caso,

$$F = \frac{b_2^2}{\widehat{\text{var}}(b_2)} = t^2.$$

Lembre que se  $Z \sim t_{T-K}$ , então  $Z^2 \sim F_{1, T-K}$ .

Nesse caso, o teste  $t$  possui uma vantagem. PERGUNTA: Qual?

RESPOSTA: É possível fazer testes unilaterais com o teste  $t$ .

REFLEXÃO: Considere o modelo  $y_t = \beta_1 + \beta_2 x_{t2} + \beta_3 x_{t3} + e_t$ . Testar  $\mathcal{H}_0 : \beta_2 = 0$  e  $\mathcal{H}_0 : \beta_3 = 0$  usando dois testes  $t$  é equivalente a testar  $\mathcal{H}_0 : \beta_2 = \beta_3 = 0$  usando um teste  $F$ ? Por quê?

RESPOSTA: Não. Os testes  $t$  e  $F$  usam informações distintas. A estatística  $F$  inclui  $\widehat{\text{cov}}(b_2, b_3)$ .

## Pausa para revisão

Suponha que  $Z$  é um vetor aleatório de dimensão  $J \times 1$  e que

$$Z \sim \mathcal{N}(\mu, \Sigma),$$

em que  $\mu$  é um vetor de médias de dimensão  $J \times 1$  e  $\Sigma$  é uma matriz de covariância positiva definida de dimensão  $J \times J$ . Então,

$$(Z - \mu)' \Sigma^{-1} (Z - \mu)$$

tem distribuição  $\chi^2_J$ .

## Testes de hipóteses (cont.)

**TESTE 3** Ambicionamos generalidade e agora desejamos testar

$$\mathcal{H}_0 : R\beta = r \text{ vs. } \mathcal{H}_1 : R\beta \neq r$$

$R$ : matriz  $J \times K$  de posto  $J$  que impõe  $J$  restrições sobre  $\beta$

$r$ : vetor  $J \times 1$  dado

OBJETO DE DESEJO: Uma estatística de teste.

Começemos notando que

$$b \sim \mathcal{N}(\beta, \sigma^2(X'X)^{-1}) \Rightarrow Rb - r \sim \mathcal{N}(R\beta - r, R\sigma^2(X'X)^{-1}R').$$

Note que, sob a hipótese nula, a média da distribuição é zero ( $R\beta - r = 0$ ).

## Testes de hipóteses (cont.)

Sabemos que

$$\frac{T-K}{\sigma^2} \hat{\sigma}^2 \sim \chi_{T-K}^2.$$

Sabemos também que, sob  $\mathcal{H}_0$ ,

$$(Rb - r)' [\sigma^2 R(X'X)^{-1} R']^{-1} (Rb - r) \sim \chi_J^2.$$

Por fim, sabemos que  $b$  e  $\hat{\sigma}^2$  são independentes.

Dividindo a segunda variável aleatória  $\chi^2$  padronizada pela primeira variável aleatória  $\chi^2$  padronizada chegamos à estatística de teste

$$F = \frac{(Rb - r)' [R(X'X)^{-1} R']^{-1} (Rb - r)}{J \hat{\sigma}^2}$$

Sob  $\mathcal{H}_0$ ,  $F \sim F_{J, T-K}$ . Assim, rejeitamos  $\mathcal{H}_0$  ao nível de significância  $\alpha$  se

$$F > F_{J, T-K; 1-\alpha}.$$



# Testes de hipóteses (cont.)

EXEMPLO: Considere o seguinte modelo

$$y_t = \beta_1 + \beta_2 x_{t2} + \beta_3 x_{t3} + \beta_4 x_{t4} + e_t,$$

em que

- ▶  $y_t$ : gasto familiar com alimentação;
- ▶  $x_{t2}$ : renda familiar do trabalho;
- ▶  $x_{t3}$ : renda familiar de outras fontes;
- ▶  $x_{t4}$ : riqueza.

Suponha que desejamos testar  $\mathcal{H}_0 : \beta_2 = \beta_3$  e  $\beta_4 = 0$ . Ou seja,

$$\mathcal{H}_0 : \beta_2 - \beta_3 = 0 \text{ e } \beta_4 = 0$$

e  $J = 2$  (duas restrições).

## Testes de hipóteses (cont.)

Ou seja, desejamos testar a igualdade entre as duas propensões marginais a consumir e, simultaneamente, que a riqueza não impacta o gasto familiar com alimentação médio.

Aqui,

$$r = \begin{pmatrix} 0 \\ 0 \end{pmatrix}.$$

A matriz  $R$ , de dimensão  $2 \times 4$ , é

$$R = \begin{bmatrix} 0 & 1 & -1 & 0 \\ 0 & 0 & 0 & 1 \end{bmatrix}.$$

Podemos testar nossa hipótese nula usando o teste  $F$ .

## Estimação intervalar

Voltemos a estimação intervalar. Nosso interesse agora residirá na construção de **regiões de confiança** para dois ou mais coeficientes de regressão.

**CASO 1** Nosso interesse reside em construir uma **região de confiança** de nível  $(1 - \alpha) \times 100\%$  para  $\beta$ . Sob normalidade (suposição [S5]),

$$b \sim \mathcal{N}(\beta, \sigma^2(X'X)^{-1}).$$

Assim,

$$(b - \beta)' \sigma^{-2} (X'X) (b - \beta) \sim \chi_K^2.$$

Lembre que, sob [S5],  $[(T - K)/\sigma^2] \hat{\sigma}^2 \sim \chi_{T-K}^2$ . Assim,

$$\begin{aligned} F_\beta &= \frac{(b - \beta)' \sigma^{-2} (X'X) (b - \beta) / K}{[(T - K)/\sigma^2] \hat{\sigma}^2 / (T - K)} \\ &= \frac{(b - \beta)' (X'X) (b - \beta)}{\hat{\sigma}^2 K} \sim F_{K, T-K}. \end{aligned}$$

## Estimação intervalar (cont.)

A **região de confiança** de nível  $(1 - \alpha) \times 100\%$  para  $\beta$  é dada pelo conjunto de valores de  $\beta$  tais que

$$\Pr(F_\beta \leq F_{K, T-K; 1-\alpha}) = 1 - \alpha.$$

**CASO 2** Particionemos  $\beta$  como  $\beta = (\beta'_1, \beta'_2)'$ , em que  $\beta_1$  é um vetor  $q \times 1$  e  $\beta_2$  é um vetor  $(K - q) \times 1$ . Suponha que desejamos obter uma **região de confiança** de nível  $(1 - \alpha) \times 100\%$  para  $\beta_1$ . Nosso modelo é

$$y = X_1\beta_1 + X_2\beta_2 + e,$$

em que  $X = [X_1 \ X_2]$ ,  $X_1$  sendo de dimensão  $T \times q$  e  $X_2$  tendo dimensão  $T \times (K - q)$ .

## Estimação intervalar (cont.)

Sejam  $b = (b'_1, b'_2)'$  e

$$F_{\beta_1} = \frac{(b_1 - \beta_1)'(X'_1 X_1)(b_1 - \beta_1)}{\hat{\sigma}^2 q} \sim F_{q, T-K}.$$

A **região de confiança** de nível  $(1 - \alpha) \times 100\%$  para  $\beta_1$  é dada pelo conjunto de valores de  $\beta_1$  tais que

$$\Pr(F_{\beta_1} \leq F_{q, T-K; 1-\alpha}) = 1 - \alpha.$$

## Estimação intervalar (cont.) I

EXEMPLO: Considere a regressão  $y_t = \beta_1 + \beta_2 x_{t2} + \beta_3 x_{t3} + e_t$  e suponha que desejamos obter uma região de confiança de nível 95% para  $(\beta_2, \beta_3)$ . Usemos o conjunto de dados `mtcars`.

Nosso código:

```
# 1. Carregar o pacote car
library(car)

# 2. Carregar o conjunto de dados
data(mtcars)

# 3. Ajustar o modelo de regressão linear
modelo = lm(mpg ~ wt + hp, data = mtcars)


# 4. Gerar o gráfico da região de confiança de 95%
# Use confidenceEllipse() para coeficientes de regressão
confidenceEllipse(modelo, which.coef = c(2, 3), levels = 0.95,
  xlab = "Coeficiente de 'wt' (peso)",
```

## Estimação intervalar (cont.) II

```
ylab = "Coeficiente de 'hp' (potência)",  
main = "Região de confiança de 95% para os coeficientes  
dos regressores wt e hp")
```

```
# Adicionar ponto correspondente aos coeficientes estimados  
points(coef(modelo)[2], coef(modelo)[3], pch = 19,  
col = "red", cex = 1.5)
```

## Estimação intervalar (cont.)





# Uma pergunta relevante sobre testes de hipóteses

PERGUNTA: Como realizar estimação intervalar e testes de hipóteses sem assumir normalidade?

Note que sem normalidade as estatísticas  $t$  e  $F$  não possuem, sob a hipótese nula distribuições  $t$  de Student e  $F$  de Snedecor, respectivamente. De onde, então, obteríamos valores críticos para esses testes?

## Teste z

Suponha que desejamos testar  $\mathcal{H}_0 : \beta_j = \beta_j^{(0)}$  vs  $\mathcal{H}_1 : \beta_j \neq \beta_j^{(0)}$  sem assumir normalidade.

A estatística de teste é

$$t = \frac{b_j - \beta_j^{(0)}}{\text{ep}(b_j)}.$$

Sem normalidade, a distribuição nula de  $t$  não é  $t_{T-K}$ . Assim, não podemos usar valores críticos obtidos da distribuição  $t$  de Student.

RESULTADO: Sob  $\mathcal{H}_0$ ,  $t \xrightarrow{d} \mathcal{N}(0, 1)$ .

Assim, um teste (aproximado) é: Rejeite  $\mathcal{H}_0$  ao nível de significância  $\alpha$  se  $|t| > z_{1-\alpha/2}$ . Esse teste é conhecido como teste z.

Não temos mais  $\Pr(\text{rejeitar } \mathcal{H}_0 \mid \mathcal{H}_0 \text{ é verdadeira}) = \alpha$ . Sabemos apenas que  $\Pr(\text{rejeitar } \mathcal{H}_0 \mid \mathcal{H}_0 \text{ é verdadeira}) \rightarrow \alpha$  quando  $T \rightarrow \infty$ .

RESULTADO: Sejam  $\{Z_T; T \in \mathbb{N}\}$  e  $\{V_T; T \in \mathbb{N}\}$  sequências de variáveis aleatórias,  $Z$  variável aleatória e  $c \in \mathbb{R}$  (constante real). Se  $V_T \xrightarrow{p} c$  e  $Z_T \xrightarrow{d} Z$ , então  $V_T \times Z_T \xrightarrow{d} cZ$ .

CASO PARTICULAR ( $Z_T = Z \forall T$ ):  $V_T \times Z \xrightarrow{d} cZ$ .

CASO AINDA MAIS PARTICULAR ( $Z_T = Z \forall T$  e  $c = 1$ ):  $V_T \times Z \xrightarrow{d} Z$ .

EXEMPLO: Seja  $V_T = 1$  com probabilidade  $1 - 1/T$  e  $V_T = 0$  com probabilidade  $1/T$  e seja  $Z \sim \mathcal{N}(0, 1)$ . Dado que  $V_T \xrightarrow{p} 1$ , segue que  $V_T \times Z \xrightarrow{d} \mathcal{N}(0, 1)$ .

## Teste Wald

Suponha que desejamos testar  $\mathcal{H}_0 : R\beta = r$  vs  $\mathcal{H}_1 : R\beta \neq r$  (sem [S5]).

Sob  $\mathcal{H}_0$  e com normalidade,

$$(Rb - r)'[\sigma^2 R(X'X)^{-1}R']^{-1}(Rb - r) \sim \chi_J^2.$$

Sob  $\mathcal{H}_0$  e sem normalidade,

$$\frac{\sigma^2}{\hat{\sigma}^2} \times (Rb - r)'[\sigma^2 R(X'X)^{-1}R']^{-1}(Rb - r) \xrightarrow{d} \chi_J^2.$$

Dado que  $\hat{\sigma}^2$  é consistente para  $\sigma^2$ , temos que  $\sigma^2/\hat{\sigma}^2 \xrightarrow{p} 1$ . Segue que, sob  $\mathcal{H}_0$ ,

$$W = (Rb - r)'[\hat{\sigma}^2 R(X'X)^{-1}R']^{-1}(Rb - r) \xrightarrow{d} \chi_J^2.$$

## Teste Wald (cont.)

Use valores críticos da distribuição nula assintótica (aproximação).  
Rejeite  $\mathcal{H}_0$  se  $W > \chi^2_{J;1-\alpha}$ .

Não temos mais  $\Pr(\text{rejeitar } \mathcal{H}_0 \mid \mathcal{H}_0 \text{ é verdadeira}) = \alpha$ . Sabemos apenas que  $\Pr(\text{rejeitar } \mathcal{H}_0 \mid \mathcal{H}_0 \text{ é verdadeira}) \rightarrow \alpha$  quando  $T \rightarrow \infty$ .

# Estimação intervalar sem normalidade

Suponha que desejamos obter um intervalo de confiança de nível  $(1 - \alpha) \times 100\%$  para  $\beta_j, j = 1, \dots, K$ , para algum  $\alpha \in (0, 1)$ .

Com normalidade, nosso intervalo é

$$IC_{1-\alpha}(\beta_j) = b_j \pm t_{T-K; 1-\alpha/2} \text{ ep}(b_j)$$

e  $\Pr(IC_{1-\alpha}(\beta_j) \text{ contém } \beta_j) = 1 - \alpha$ .

Sem normalidade, nosso intervalo é

$$IC_{1-\alpha}(\beta_j) = b_j \pm z_{1-\alpha/2} \text{ ep}(b_j)$$

e  $\Pr(IC_{1-\alpha}(\beta_j) \text{ contém } \beta_j) \rightarrow 1 - \alpha$ .

## Consequências de especificação incorreta

Considere os seguintes modelos:

$$[M1] \quad y = X_1\beta_1 + X_2\beta_2 + e_1 = X\beta + e_1,$$

$$[M2] \quad y = X_1\beta_1 + e_2.$$

Ou seja, o modelo M1 usa os regressores utilizados em M2 e mais algum(ns) regressor(es) adicional(is). O modelo M2 pode ser obtido do modelo M1 impondo  $\beta_2 = 0$ .

**CASO 1** O modelo M1 é o correto, mas estimamos M2.

O efeito da(s) variável(is) omitida(s) é absorvido pelo erro, que deixa de ter média zero:

$$\begin{aligned} b_1 &= (X_1'X_1)^{-1}X_1'y \\ &= (X_1'X_1)^{-1}X_1'(X_1\beta_1 + X_2\beta_2 + e_1) \\ &= \beta_1 + (X_1'X_1)^{-1}X_1'X_2\beta_2 + (X_1'X_1)^{-1}X_1'e_1. \end{aligned}$$

Assim,

$$\mathbb{E}(b_1) = \beta_1 + (X_1'X_1)^{-1}X_1'X_2\beta_2 \neq \beta_1.$$

## Consequências de especificação incorreta (cont.)

Ou seja, o EMQO se torna **viesado**.

MENSAGEM: A omissão de regressores importantes resulta em estimadores viesados.

**CASO 2** O modelo M2 é o verdadeiro, mas estimamos M1.

Ou seja, incluímos na regressão variáveis explicativas que não são relevantes.

Aqui, não violamos a suposição de que os erros têm média zero ([S1]) e, assim, as consequências não são tão severas.

O EMQO  $b = (X'X)^{-1}X'y$  permanece não viesado:

$$\mathbb{E}(b) = \beta = \begin{bmatrix} \beta_1 \\ 0 \end{bmatrix}.$$

A consequência indesejável é que o EMQO se torna **ineficiente**.



# Exemplo empírico I

`cars`

`package:datasets`

R Documentation

Speed and Stopping Distances of Cars

Description:

The data give the speed of cars and the distances taken to stop.  
Note that the data were recorded in the 1920s.

Usage:

`cars`

Format:

A data frame with 50 observations on 2 variables.

[,1]	speed	numeric	Speed (mph)
[,2]	dist	numeric	Stopping distance (ft)

# Exemplo empírico I

```
> # dados
> data(cars); attach(cars)
> # informação sobre os dados
> help(cars)
> # número de observações
> nobs = length(dist)
> # sumário dos dados
> summary(cars)
      speed          dist
Min.   : 4.0   Min.   : 2.00
1st Qu.:12.0   1st Qu.: 26.00
Median :15.0   Median : 36.00
Mean   :15.4   Mean    : 42.98
3rd Qu.:19.0   3rd Qu.: 56.00
Max.   :25.0   Max.    :120.00
> # desvios-padrão
> round(sd(speed), 4); round(sd(dist), 4)
[1] 5.2876
[1] 25.7694
> # ajuste de regressão
> ajuste = lm(dist~speed)
> # sumário do ajuste
> summary(ajuste)
```

Call:

```
lm(formula = dist ~ speed)
```

Residuals:

Min	1Q	Median	3Q	Max
-29.06908029	-9.52532117	-2.27185401	9.21471533	43.20128467

Coefficients:

## Exemplo empírico II

	Estimate	Std. Error	t value	Pr(> t )
(Intercept)	-17.579094891	6.758440169	-2.60106	0.012319
speed	3.932408759	0.415512777	9.46399	1.4898e-12

Residual standard error: 15.3795867 on 48 degrees of freedom  
Multiple R-squared: 0.651079381, Adjusted R-squared: 0.643810201  
F-statistic: 89.5671065 on 1 and 48 DF, p-value: 1.4898365e-12

```
> # calculemos as principais quantidades do ajuste de regressão
> # usando as fórmulas apresentadas em aula
> # matriz X
> X = cbind(1, speed)
> # vetor b
> b = solve(t(X) %*% X) %*% t(X) %*% dist
> # resíduos
> echapeu = dist - X %*% b
> # estimativa de sigma^2
> sigma2chapeu = crossprod(echapeu)/(nobs-ncol(X))
> # desvio padrão
> sqrt(sigma2chapeu)
      [,1]
[1,] 15.3795867488
> sqrt(sigma2chapeu) |> as.double()
[1] 15.3795867488
> # erros-padrão de b_1 e b_2
> ep = sqrt(as.double(sigma2chapeu)*diag(solve(t(X) %*% X)))
> ep
      speed
6.758440169379 0.415512776657
> # estimativas de MQO
> b
      [,1]
```

## Exemplo empírico III

```
-17.57909489051
speed  3.93240875912
> # vejamos as estimativas obtidas via função lm
> coef(ajuste)
      (Intercept)          speed
-17.57909489051    3.93240875912
> # razões t
> t = b / ep
> t
      [,1]
-2.60105800302
speed  9.46398999030
> # p-valor do teste de H_0: \beta_1 = 0 vs H_1: \beta_1 \neq 0
> pv1 = 2*(1-pt(abs(t[1]), df=nobs-ncol(X)))
> pv1
[1] 0.0123188161538
> # p-valor do teste de H_0: \beta_2 = 0 vs H_1: \beta_2 \neq 0
> pv2 = 2*(1-pt(abs(t[2]), df=nobs-ncol(X)))
> pv2
[1] 1.48991929905e-12
```

# Nosso próximo tópico

Na saída do R do ajuste da nossa regressão, falta entendermos essas informações:

Multiple R-squared: 0.651079381, Adjusted R-squared: 0.643810201

Esse é nosso próximo tópico.