



# Teste de Hipótese em Regressão Normal Linear Múltipla

Caio César Barros de Araújo

Universidade Federal de Pernambuco

18 de novembro de 2025

# 1 Modelo e Fundamentos Teóricos

A regressão linear múltipla modela a relação entre uma variável resposta  $Y$  e múltiplas variáveis explicativas  $X_1, X_2, \dots, X_p$ . Os testes de hipótese permitem avaliar a significância estatística dos parâmetros e a relevância das variáveis explicativas. Este trabalho apresenta o teste de hipótese  $H_0 : \beta_1 = \mathbf{0}_p$  no modelo de regressão normal linear múltipla, analisando sua fundamentação teórica.

## 1.1 Especificação do Modelo

O modelo de regressão linear múltipla é especificado como:

$$\mathbf{y} = \mathbf{X}\beta + \varepsilon \quad (1)$$

onde  $\mu_i(\beta) = \mathbf{x}_i^T \beta = \beta_0 + \beta_1 x_{i1} + \dots + \beta_p x_{ip}$ ,  $\mathbf{y}^T = (y_1, \dots, y_n)$  é o vetor de variáveis resposta,  $\beta = (\beta_0, \beta_1, \dots, \beta_p)^T$  são parâmetros desconhecidos,  $\mathbf{X}$  é a matriz modelo  $n \times (p+1)$  de planejamento com primeira coluna de uns, e  $\varepsilon^T = (\varepsilon_1, \dots, \varepsilon_n)$  é o vetor de erros aleatórios.

## 1.2 Pressupostos Clássicos

**Definição 1.1** (Pressupostos do Modelo Normal Linear).

1. **Linearidade:**  $\mu_i(\beta) = \mathbf{x}_i^T \beta$ .
2. **Normalidade:**  $\varepsilon_i \sim N(0, \sigma^2)$ ,  $i = 1, \dots, n$ , independentes.
3. **Homocedasticidade:**  $\text{Var}(Y_i | \mathbf{x}_i) = \sigma^2$  constante.
4. **Independência:**  $\text{Cov}(\varepsilon_i, \varepsilon_j) = 0$ ,  $\forall i \neq j$ .
5. **Não-colinearidade:**  $\mathbf{X}^T \mathbf{X}$  é inversível.

Sob esses pressupostos,  $\mathbf{y} \sim N(\mathbf{X}\beta, \sigma^2 \mathbf{I}_n)$ . A violação da não-colinearidade (multicolinearidade), mesmo mantendo  $\mathbf{X}^T \mathbf{X}$  inversível, aumenta drasticamente a variância dos estimadores  $\hat{\beta}$ , alargando intervalos de confiança e reduzindo o poder dos testes  $t$  individuais [2, Seção 3.10].

## 1.3 Estimadores de Mínimos Quadrados

O estimador de mínimos quadrados (E.M.Q.) para  $\beta$  é definido como o minimizador da soma de quadrados dos resíduos:

$$\hat{\beta} = \arg \min_{\beta \in \mathbb{R}^{p+1}} S(\beta) \quad (2)$$

onde

$$S(\beta) = (\mathbf{y} - \mathbf{X}\beta)^T (\mathbf{y} - \mathbf{X}\beta) = \mathbf{y}^T \mathbf{y} - 2\beta^T \mathbf{X}^T \mathbf{y} + \beta^T \mathbf{X}^T \mathbf{X} \beta \quad (3)$$

Calculando a derivada de primeira ordem e igualando a zero, obtemos as **equações normais**:

$$\frac{\partial S(\beta)}{\partial \beta} = -2\mathbf{X}^T \mathbf{y} + 2\mathbf{X}^T \mathbf{X} \beta = \mathbf{0} \quad (4)$$

Assumindo que  $\mathbf{X}^T \mathbf{X}$  é inversível (condição de não-colinearidade), o estimador de mínimos quadrados é:

$$\hat{\beta} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y} \quad (5)$$

Como a segunda derivada  $\frac{\partial^2 S(\beta)}{\partial \beta^2} = 2\mathbf{X}^T \mathbf{X}$  é positiva definida,  $\hat{\beta}$  é o minimizador global de  $S(\beta)$ .

**Teorema 1.1** (Propriedades do Estimador). *Sob os pressupostos clássicos:*

- (i)  $E[\hat{\beta}] = \beta$  (não-viesado);
- (ii)  $\hat{\beta}$  é o melhor estimador linear não-viesado (Teorema de Gauss-Markov);
- (iii)  $\hat{\beta} \sim N(\beta, \sigma^2(\mathbf{X}^T \mathbf{X})^{-1})$ .

*Demonstração.* A propriedade (i) segue diretamente da linearidade da esperança. Para (ii), pelo Teorema de Gauss-Markov, qualquer estimador linear não-viesado  $\tilde{\beta}$  possui  $\text{Var}(\tilde{\beta}) = \text{Var}(\hat{\beta}) + \sigma^2 \mathbf{C}\mathbf{C}^T$ , onde  $\mathbf{C}\mathbf{C}^T$  é semidefinida positiva, garantindo  $\text{Var}(\tilde{\beta}) \geq \text{Var}(\hat{\beta})$  no sentido matricial [1, Teorema 11.2.1]. A propriedade (iii) segue da normalidade de  $\mathbf{y}$  e da linearidade de  $\hat{\beta}$ .  $\square$

O estimador não-viesado de  $\sigma^2$  é dado por:

$$\hat{\sigma}^2 = \frac{SSE}{n - p - 1}, \quad \text{onde} \quad SSE = (\mathbf{y} - \mathbf{X}\hat{\beta})^T (\mathbf{y} - \mathbf{X}\hat{\beta}) \quad (6)$$

**Proposição 1.1** (Distribuição de  $\hat{\sigma}^2$  e Independência). *Sob os pressupostos do modelo,  $\frac{(n-p-1)\hat{\sigma}^2}{\sigma^2} \sim \chi_{n-p-1}^2$  e é independente de  $\hat{\beta}$ .*

*Demonstração.* Seja  $\mathbf{P} = \mathbf{X}(\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T$  a matriz de projeção ortogonal no espaço coluna de  $\mathbf{X}$ . Note que  $\mathbf{P}$  é simétrica e idempotente, com  $\text{tr}(\mathbf{P}) = p + 1$ . Para aplicar o Teorema de Cochran, consideramos  $\mathbf{Q}_1 = \mathbf{P}$  e  $\mathbf{Q}_2 = \mathbf{I}_n - \mathbf{P}$ . Como  $\mathbf{P}$  é idempotente,  $\mathbf{I}_n - \mathbf{P}$  também é idempotente e  $\mathbf{P}(\mathbf{I}_n - \mathbf{P}) = \mathbf{0}$ , garantindo ortogonalidade. Além disso,  $\mathbf{Q}_1 + \mathbf{Q}_2 = \mathbf{I}_n$  e  $\text{tr}(\mathbf{Q}_1) + \text{tr}(\mathbf{Q}_2) = n$ .

Como  $SSE = \mathbf{y}^T (\mathbf{I}_n - \mathbf{P}) \mathbf{y}$  e  $\mathbf{I}_n - \mathbf{P}$  é uma matriz de projeção ortogonal com  $\text{tr}(\mathbf{I}_n - \mathbf{P}) = n - p - 1$ , segue do Teorema de Cochran que  $\frac{SSE}{\sigma^2} \sim \chi_{n-p-1}^2$ .

A independência entre  $\hat{\beta}$  e  $\hat{\sigma}^2$  decorre da ortogonalidade: como  $\hat{\beta}$  depende linearmente de  $\mathbf{P}\mathbf{y}$  e  $SSE$  depende de  $(\mathbf{I}_n - \mathbf{P})\mathbf{y}$ , e  $\mathbf{P}(\mathbf{I}_n - \mathbf{P}) = \mathbf{0}$  implica que  $\mathbf{P}\mathbf{y}$  e  $(\mathbf{I}_n - \mathbf{P})\mathbf{y}$  são vetores normais independentes, segue que  $\hat{\beta}$  e  $\hat{\sigma}^2$  são independentes [3, Teorema 3.5(iii)].  $\square$

## 1.4 Teorema de Cochran e Distribuições Qui-Quadrado

O resultado fundamental sobre distribuições qui-quadrado de formas quadráticas é dado pelo Teorema de Cochran, que fundamenta teoricamente a decomposição de somas de quadrados.

**Teorema 1.2** (Teorema de Cochran). *Seja  $\mathbf{y} \sim N(\boldsymbol{\mu}, \sigma^2 \mathbf{I}_n)$  e sejam  $\mathbf{Q}_1, \dots, \mathbf{Q}_k$  matrizes simétricas idempotentes tais que  $\sum_{i=1}^k \mathbf{Q}_i = \mathbf{I}_n$  e  $\sum_{i=1}^k \text{tr}(\mathbf{Q}_i) = n$ . Se  $\mathbf{Q}_i \boldsymbol{\mu} = \mathbf{0}$  para  $i = 1, \dots, k$ , então as formas quadráticas  $\mathbf{y}^T \mathbf{Q}_i \mathbf{y}$ ,  $i = 1, \dots, k$ , são independentes e  $\frac{\mathbf{y}^T \mathbf{Q}_i \mathbf{y}}{\sigma^2} \sim \chi_{\nu_i}^2$ , onde  $\nu_i = \text{tr}(\mathbf{Q}_i)$ .*

O Teorema de Cochran estabelece que sob condições adequadas, somas de quadrados podem ser decompostas em componentes qui-quadrado independentes, sendo fundamental para a análise de variância e inferência em modelos lineares. A fundamentação teórica deste resultado (Teorema 2.7 e Exemplo 2.13) e sua aplicação prática para testes de hipótese e análise de variância são detalhadas em Seber e Lee [3, Capítulos 2.4, 4 e 8].

## 2 Teste de Hipótese $H_0 : \beta_1 = \mathbf{0}_p$

### 2.1 Formulação do Teste

Particionando  $\beta = (\beta_0, \beta_1^T)^T$  onde  $\beta_1 = (\beta_1, \dots, \beta_p)^T$ , o teste avalia se as variáveis explicativas têm efeito significativo sobre  $Y$ :

$$H_0 : \beta_1 = \mathbf{0}_p \quad \text{versus} \quad H_1 : \beta_1 \neq \mathbf{0}_p \quad (7)$$

onde  $\mathbf{0}_p$  é o vetor nulo de dimensão  $p$ . Sob  $H_0$ , o modelo reduz-se a  $Y_i = \beta_0 + \varepsilon_i$ .

## 2.2 Estatística F e Distribuição

A estatística de teste  $F$  é definida como:

$$F = \frac{MSR}{MSE} = \frac{SSR/p}{SSE/(n-p-1)} \quad (8)$$

onde  $SSR = \sum_{i=1}^n (\hat{y}_i - \bar{y})^2$  é a Soma dos Quadrados da Regressão e  $MSR = SSR/p$ ,  $MSE = SSE/(n-p-1)$  são os quadrados médios.

**Teorema 2.1** (Distribuição da Estatística F). *Sob  $H_0 : \beta_1 = \mathbf{0}_p$  e os pressupostos do modelo:*

$$F \sim F_{p, n-p-1} \quad (9)$$

O teste  $F$  pode ser interpretado como uma transformação monotônica da estatística associada ao Teste da Razão de Verossimilhança ( $\Lambda$ ). Especificamente, para o modelo normal linear, a estatística LRT  $\Lambda = \left( \frac{SSE}{SSE_0} \right)^{n/2}$  está relacionada ao teste  $F$  através de uma transformação monotônica. Esta equivalência reforça que o teste  $F$  não é apenas uma conveniência baseada na decomposição de soma de quadrados, mas sim o **UMP** sob a suposição de normalidade, em virtude da optimalidade do LRT nesse cenário. [1, Teorema 10.1.1].

## 2.3 Derivação via Decomposição de Soma de Quadrados e Teorema de Cochran

A escolha da estatística  $F$  para o teste  $H_0 : \beta_1 = \mathbf{0}_p$  decorre da estrutura distribucional do modelo normal linear. Sob  $H_0$ , o modelo reduz-se a  $Y_i = \beta_0 + \varepsilon_i$  com E.M.Q.  $\hat{\beta}_0 = \bar{y}$ . A soma de quadrados do modelo reduzido é  $SSE_0 = \mathbf{y}^T(\mathbf{I}_n - \mathbf{P}_0)\mathbf{y}$ , onde  $\mathbf{P}_0 = \frac{1}{n}\mathbf{1}_n\mathbf{1}_n^T$  projeta no espaço gerado por  $\mathbf{1}_n$ , contido no espaço coluna de  $\mathbf{X}$ .

A diferença  $SSR = SSE_0 - SSE$  representa a redução na soma de quadrados devido à inclusão das  $p$  variáveis explicativas. Em termos de matrizes de projeção:  $SSR = \mathbf{y}^T(\mathbf{P} - \mathbf{P}_0)\mathbf{y}$  e  $SSE = \mathbf{y}^T(\mathbf{I}_n - \mathbf{P})\mathbf{y}$ , onde  $\mathbf{P} = \mathbf{X}(\mathbf{X}^T\mathbf{X})^{-1}\mathbf{X}^T$ .

Para aplicar o Teorema de Cochran, consideramos  $\mathbf{Q}_1 = \mathbf{P} - \mathbf{P}_0$ ,  $\mathbf{Q}_2 = \mathbf{I}_n - \mathbf{P}$  e  $\mathbf{P}_0$ . Verificamos explicitamente as condições: (i)  $\mathbf{Q}_1$  é idempotente, pois como  $\mathbf{P}_0$  projeta em subespaço de  $\mathbf{P}$ , temos  $\mathbf{P}\mathbf{P}_0 = \mathbf{P}_0 = \mathbf{P}_0\mathbf{P}$ , logo  $(\mathbf{P} - \mathbf{P}_0)^2 = \mathbf{P} - \mathbf{P}_0$ ; (ii)  $\mathbf{Q}_2 = \mathbf{I}_n - \mathbf{P}$  é idempotente; (iii)  $\mathbf{Q}_1\mathbf{Q}_2 = (\mathbf{P} - \mathbf{P}_0)(\mathbf{I}_n - \mathbf{P}) = \mathbf{0}$ , confirmando ortogonalidade; (iv)  $\mathbf{Q}_1 + \mathbf{Q}_2 + \mathbf{P}_0 = \mathbf{I}_n$  e  $\text{tr}(\mathbf{Q}_1) + \text{tr}(\mathbf{Q}_2) + \text{tr}(\mathbf{P}_0) = p + (n-p-1) + 1 = n$ ; (v) Sob  $H_0$ , quando  $\beta_1 = \mathbf{0}_p$ , temos  $\mathbf{X}\beta = \beta_0\mathbf{1}_n$  e  $\mathbf{Q}_1\mathbf{X}\beta = (\mathbf{P} - \mathbf{P}_0)\mathbf{1}_n = \mathbf{0}$ .

Portanto, pelo Teorema de Cochran, sob  $H_0$ :

$$\frac{SSR}{\sigma^2} = \frac{\mathbf{y}^T\mathbf{Q}_1\mathbf{y}}{\sigma^2} \sim \chi_p^2, \quad \frac{SSE}{\sigma^2} = \frac{\mathbf{y}^T\mathbf{Q}_2\mathbf{y}}{\sigma^2} \sim \chi_{n-p-1}^2 \quad (10)$$

e essas quantidades são independentes, pois  $\mathbf{Q}_1\mathbf{Q}_2 = \mathbf{0}$  garante independência via ortogonalidade das projeções.

Como a estatística  $F$  é a razão entre duas variáveis  $\chi^2$  independentes divididas por seus graus de liberdade, ela elimina o parâmetro de escala desconhecido  $\sigma^2$ , tornando-se uma **estatística pivotal**:

$$F = \frac{SSR/p}{SSE/(n-p-1)} = \frac{(SSR/\sigma^2)/p}{(SSE/\sigma^2)/(n-p-1)} \sim F_{p, n-p-1} \quad (11)$$

Portanto,  $F$  possui distribuição completamente especificada sob  $H_0$  e não depende de parâmetros desconhecidos. Valores grandes de  $F_{\text{obs}}$  indicam rejeição de  $H_0$ , pois a variância explicada (MSR) é significativamente maior que a variância residual (MSE).

## 2.4 Região de Rejeição e Testes Complementares

Para nível de significância  $\alpha$ , rejeitamos  $H_0$  se  $F > F_{p,n-p-1;\alpha}$  ou se  $p\text{-valor} = P(F_{p,n-p-1} > F_{\text{obs}}) < \alpha$ .

Para testes individuais  $H_0 : \beta_j = 0$ , utiliza-se  $t_j = \frac{\hat{\beta}_j}{SE(\hat{\beta}_j)} \sim t_{n-p-1}$ , que complementa o teste  $F$  global para identificar quais variáveis específicas são significativas. Note que o teste  $F$  global avalia  $H_0 : \beta_1 = \mathbf{0}_p$  (todas as variáveis simultaneamente), enquanto o teste  $t$  para  $H_0 : \beta_j = 0$  avalia a contribuição de  $X_j$  **dado que as outras variáveis já estão no modelo**. Os coeficientes  $\hat{\beta}_j$  são, portanto, **coeficientes parciais** que medem o efeito de  $X_j$  controlando pelas demais variáveis explicativas. A multicolinearidade pode resultar em rejeição de  $H_0$  pelo teste  $F$  global enquanto os testes  $t$  individuais falham em identificar variáveis significativas.

## 3 Análise de Variância e Conclusão

### 3.1 Decomposição ANOVA

A decomposição fundamental da variabilidade total é  $SST = SSR + SSE$ , onde  $SST = \sum_{i=1}^n (y_i - \bar{y})^2$  é a Soma Total dos Quadrados. A tabela ANOVA resume essa decomposição:

Tabela 1: Tabela ANOVA para Regressão Linear Múltipla

Fonte	Soma de Quadrados	Graus de Liberdade	Quadrado Médio	$F$
Regressão	$SSR$	$p$	$MSR = SSR/p$	$F = MSR/MSE$
Erro	$SSE$	$n - p - 1$	$MSE = SSE/(n - p - 1)$	
Total	$SST$	$n - 1$		

### 3.2 Interpretação e Considerações Finais

O teste  $H_0 : \beta_1 = \mathbf{0}_p$  permite avaliar a significância global das variáveis explicativas no modelo. Rejeitar  $H_0$  significa que pelo menos uma das variáveis explicativas contribui de forma estatisticamente significativa para explicar a variabilidade de  $Y$ . O teste  $F$  global deve ser complementado por testes  $t$  individuais para identificar quais variáveis específicas são responsáveis pela significância.

É relevante salientar que a rejeição da hipótese nula  $H_0$ , indicando significância estatística, não implica que o modelo seja adequado para previsão ou descrição. A avaliação definitiva da adequação do modelo exige a verificação dos pressupostos estatísticos — notadamente a normalidade dos resíduos e a homocedasticidade — por meio de análise residual. Tal procedimento é fundamental para determinar se o modelo apresenta bom ajuste aos dados observados e se as condições subjacentes à aplicação do teste  $F$  foram devidamente satisfeitas [2, Capítulos 4 e 5].

## Referências

- [1] George Casella and Roger L. Berger. *Statistical Inference*. Duxbury Press, Pacific Grove, CA, 2nd edition, 2002.
- [2] Douglas C. Montgomery, Elizabeth A. Peck, and G. Geoffrey Vining. *Introduction to Linear Regression Analysis*. Wiley, Hoboken, NJ, 5th edition, 2012.
- [3] George A. F. Seber and Alan J. Lee. *Linear Regression Analysis*. Wiley, Hoboken, NJ, 2nd edition, 2012.