

Teste de Hipótese em Regressão Normal Linear Múltipla
Análise do Teste $H_0 : \beta_1 = \mathbf{0}_p$

Caio César Barros de Araújo
Universidade Federal de Pernambuco

17 de novembro de 2025

1 Modelo e Fundamentos Teóricos

A regressão linear múltipla modela a relação entre uma variável resposta Y e múltiplas variáveis explicativas X_1, X_2, \dots, X_p . Os testes de hipótese permitem avaliar a significância estatística dos parâmetros e a relevância das variáveis explicativas. Este relatório apresenta o teste de hipótese $H_0 : \beta_1 = \mathbf{0}_p$ no modelo de regressão normal linear múltipla, analisando sua fundamentação teórica.

1.1 Especificação do Modelo

O modelo de regressão linear múltipla é especificado como:

$$\mathbf{y} = \mathbf{X}\beta + \varepsilon \quad (1)$$

onde $\mu_i(\beta) = x_i^T \beta = \beta_0 + \beta_1 x_{i1} + \dots + \beta_p x_{ip}$, $\mathbf{y}^T = (y_1, \dots, y_n)$ é o vetor de variáveis resposta, $\beta = (\beta_0, \beta_1, \dots, \beta_p)^T$ são parâmetros desconhecidos, \mathbf{X} é a matriz modelo $n \times (p+1)$ de planejamento com primeira coluna de uns, e $\varepsilon^T = (\varepsilon_1, \dots, \varepsilon_n)$ é o vetor de erros aleatórios.

1.2 Pressupostos Clássicos

Definição 1.1 (Pressupostos do Modelo Normal Linear). 1. **Linearidade**: $\mu_i(\beta) = x_i^T \beta$.

2. **Normalidade**: $\varepsilon_i \sim N(0, \sigma^2)$, $i = 1, \dots, n$, independentes.
3. **Homocedasticidade**: $\text{Var}(Y_i | x_i) = \sigma^2$ constante.
4. **Independência**: $\text{Cov}(\varepsilon_i, \varepsilon_j) = 0$, $\forall i \neq j$.
5. **Não-colinearidade**: $\mathbf{X}^T \mathbf{X}$ é inversível.

Sob esses pressupostos, $\mathbf{y} \sim N(\mathbf{X}\beta, \sigma^2 \mathbf{I}_n)$.

1.3 Estimadores de Mínimos Quadrados

O estimador de mínimos quadrados (E.M.Q.) para β é definido como o minimizador da soma de quadrados dos resíduos:

$$\hat{\beta} = \arg \min_{\beta \in \mathbb{R}^{p+1}} S(\beta) \quad (2)$$

onde

$$S(\beta) = (\mathbf{y} - \mathbf{X}\beta)^T (\mathbf{y} - \mathbf{X}\beta) = \mathbf{y}^T \mathbf{y} - 2\beta^T \mathbf{X}^T \mathbf{y} + \beta^T \mathbf{X}^T \mathbf{X} \beta \quad (3)$$

Calculando a derivada de primeira ordem e igualando a zero, obtemos as **equações normais**:

$$\frac{\partial S(\beta)}{\partial \beta} = -2\mathbf{X}^T \mathbf{y} + 2\mathbf{X}^T \mathbf{X} \beta = \mathbf{0} \quad (4)$$

Assumindo que $\mathbf{X}^T \mathbf{X}$ é inversível (condição de não-colinearidade), o estimador de mínimos quadrados é:

$$\hat{\beta} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y} \quad (5)$$

Como a segunda derivada $\frac{\partial^2 S(\beta)}{\partial \beta^2} = 2\mathbf{X}^T \mathbf{X}$ é positiva definida, $\hat{\beta}$ é o minimizador global de $S(\beta)$.

Teorema 1.1 (Propriedades do Estimador). *Sob os pressupostos clássicos:*

- (i) $E[\hat{\beta}] = \beta$ (*não-viesado*);
- (ii) $\hat{\beta}$ é o melhor estimador linear não-viesado (*Teorema de Gauss-Markov*);

(iii) $\hat{\beta} \sim N(\beta, \sigma^2(\mathbf{X}^T \mathbf{X})^{-1})$.

Demonstração. A propriedade (i) segue diretamente da linearidade da esperança. Para (ii), pelo Teorema de Gauss-Markov, qualquer estimador linear não-viesado $\tilde{\beta}$ possui $\text{Var}(\tilde{\beta}) = \text{Var}(\hat{\beta}) + \sigma^2 \mathbf{C} \mathbf{C}^T$, onde $\mathbf{C} \mathbf{C}^T$ é semidefinida positiva, garantindo $\text{Var}(\tilde{\beta}) \geq \text{Var}(\hat{\beta})$ no sentido matricial (Casella & Berger, 2002, Teorema 11.2.1). A propriedade (iii) segue da normalidade de \mathbf{y} e da linearidade de $\hat{\beta}$. \square

O estimador não-viesado de σ^2 é dado por:

$$\hat{\sigma}^2 = \frac{SSE}{n - p - 1}, \quad \text{onde } SSE = (\mathbf{y} - \mathbf{X}\hat{\beta})^T(\mathbf{y} - \mathbf{X}\hat{\beta}) \quad (6)$$

Proposição 1.1 (Distribuição de $\hat{\sigma}^2$ e Independência). *Sob os pressupostos do modelo, $\frac{(n-p-1)\hat{\sigma}^2}{\sigma^2} \sim \chi_{n-p-1}^2$ e é independente de $\hat{\beta}$.*

Demonstração. Seja $\mathbf{P} = \mathbf{X}(\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T$ a matriz de projeção ortogonal no espaço coluna de \mathbf{X} . Note que \mathbf{P} é simétrica e idempotente, com $\text{tr}(\mathbf{P}) = p + 1$. Para aplicar o Teorema de Cochran, consideramos $\mathbf{Q}_1 = \mathbf{P}$ e $\mathbf{Q}_2 = \mathbf{I}_n - \mathbf{P}$. Como \mathbf{P} é idempotente, $\mathbf{I}_n - \mathbf{P}$ também é idempotente e $\mathbf{P}(\mathbf{I}_n - \mathbf{P}) = \mathbf{0}$, garantindo ortogonalidade. Além disso, $\mathbf{Q}_1 + \mathbf{Q}_2 = \mathbf{I}_n$ e $\text{tr}(\mathbf{Q}_1) + \text{tr}(\mathbf{Q}_2) = n$.

Como $SSE = \mathbf{y}^T(\mathbf{I}_n - \mathbf{P})\mathbf{y}$ e $\mathbf{I}_n - \mathbf{P}$ é uma matriz de projeção ortogonal com $\text{tr}(\mathbf{I}_n - \mathbf{P}) = n - p - 1$, segue do Teorema de Cochran que $\frac{SSE}{\sigma^2} \sim \chi_{n-p-1}^2$.

A independência entre $\hat{\beta}$ e $\hat{\sigma}^2$ decorre da ortogonalidade: como $\hat{\beta}$ depende linearmente de $\mathbf{P}\mathbf{y}$ e SSE depende de $(\mathbf{I}_n - \mathbf{P})\mathbf{y}$, e $\mathbf{P}(\mathbf{I}_n - \mathbf{P}) = \mathbf{0}$ implica que $\mathbf{P}\mathbf{y}$ e $(\mathbf{I}_n - \mathbf{P})\mathbf{y}$ são vetores normais independentes, segue que $\hat{\beta}$ e $\hat{\sigma}^2$ são independentes (Seber & Lee, 2012, Teorema 3.5(iii)). \square

1.4 Teorema de Cochran e Distribuições Qui-Quadrado

O resultado fundamental sobre distribuições qui-quadrado de formas quadráticas é dado pelo Teorema de Cochran, que fundamenta teoricamente a decomposição de somas de quadrados.

Teorema 1.2 (Teorema de Cochran). *Seja $\mathbf{y} \sim N(\boldsymbol{\mu}, \sigma^2 \mathbf{I}_n)$ e sejam $\mathbf{Q}_1, \dots, \mathbf{Q}_k$ matrizes simétricas idempotentes tais que $\sum_{i=1}^k \mathbf{Q}_i = \mathbf{I}_n$ e $\sum_{i=1}^k \text{tr}(\mathbf{Q}_i) = n$. Se $\mathbf{Q}_i \boldsymbol{\mu} = \mathbf{0}$ para $i = 1, \dots, k$, então as formas quadráticas $\mathbf{y}^T \mathbf{Q}_i \mathbf{y}$, $i = 1, \dots, k$, são independentes e $\frac{\mathbf{y}^T \mathbf{Q}_i \mathbf{y}}{\sigma^2} \sim \chi_{\nu_i}^2$, onde $\nu_i = \text{tr}(\mathbf{Q}_i)$.*

O Teorema de Cochran estabelece que sob condições adequadas, somas de quadrados podem ser decompostas em componentes qui-quadrado independentes, sendo fundamental para a análise de variância e inferência em modelos lineares.

2 Teste de Hipótese $H_0 : \beta_1 = \mathbf{0}_p$

2.1 Formulação do Teste

Particionando $\beta = (\beta_0, \beta_1^T)^T$ onde $\beta_1 = (\beta_1, \dots, \beta_p)^T$, o teste avalia se as variáveis explicativas têm efeito significativo sobre Y :

$$H_0 : \beta_1 = \mathbf{0}_p \quad \text{versus} \quad H_1 : \beta_1 \neq \mathbf{0}_p \quad (7)$$

onde $\mathbf{0}_p$ é o vetor nulo de dimensão p . Sob H_0 , o modelo reduz-se a $Y_i = \beta_0 + \varepsilon_i$.

2.2 Estatística F e Distribuição

A estatística de teste F é definida como:

$$F = \frac{MSR}{MSE} = \frac{SSR/p}{SSE/(n-p-1)} \quad (8)$$

onde $SSR = \sum_{i=1}^n (\hat{y}_i - \bar{y})^2$ é a Soma dos Quadrados da Regressão e $MSR = SSR/p$, $MSE = SSE/(n-p-1)$ são os quadrados médios.

Teorema 2.1 (Distribuição da Estatística F). *Sob $H_0 : \beta_1 = \mathbf{0}_p$ e os pressupostos do modelo:*

$$F \sim F_{p,n-p-1} \quad (9)$$

Nota sobre Equivalência ao Teste de Razão de Verossimilhança: O teste F é uma transformação monotônica da estatística do Teste da Razão de Verossimilhança (Λ). Em particular, para o modelo normal linear, a estatística LRT $\Lambda = \left(\frac{SSE}{SSE_0}\right)^{n/2}$ está relacionada ao teste F através de uma transformação monotônica. Esta equivalência reforça que o teste F não é apenas uma conveniência baseada na decomposição de soma de quadrados, mas sim o **teste uniformemente mais poderoso** quando as distribuições são Normais, uma vez que o LRT é ótimo sob normalidade (Casella & Berger, 2002, Teorema 10.1.1).

2.3 Derivação via Decomposição de Soma de Quadrados e Teorema de Cochran

A escolha da estatística F para o teste $H_0 : \beta_1 = \mathbf{0}_p$ decorre da estrutura distribucional do modelo normal linear. Sob H_0 , o modelo reduz-se a $Y_i = \beta_0 + \varepsilon_i$ com E.M.Q. $\hat{\beta}_0 = \bar{y}$. A soma de quadrados do modelo reduzido é $SSE_0 = \mathbf{y}^T(\mathbf{I}_n - \mathbf{P}_0)\mathbf{y}$, onde $\mathbf{P}_0 = \frac{1}{n}\mathbf{1}_n\mathbf{1}_n^T$ projeta no espaço gerado por $\mathbf{1}_n$, contido no espaço coluna de \mathbf{X} .

A diferença $SSR = SSE_0 - SSE$ representa a redução na soma de quadrados devido à inclusão das p variáveis explicativas. Em termos de matrizes de projeção: $SSR = \mathbf{y}^T(\mathbf{P} - \mathbf{P}_0)\mathbf{y}$ e $SSE = \mathbf{y}^T(\mathbf{I}_n - \mathbf{P})\mathbf{y}$, onde $\mathbf{P} = \mathbf{X}(\mathbf{X}^T\mathbf{X})^{-1}\mathbf{X}^T$.

Para aplicar o Teorema de Cochran, consideramos $\mathbf{Q}_1 = \mathbf{P} - \mathbf{P}_0$, $\mathbf{Q}_2 = \mathbf{I}_n - \mathbf{P}$ e \mathbf{P}_0 . Verificamos explicitamente as condições: (i) \mathbf{Q}_1 é idempotente, pois como \mathbf{P}_0 projeta em subespaço de \mathbf{P} , temos $\mathbf{P}\mathbf{P}_0 = \mathbf{P}_0 = \mathbf{P}_0\mathbf{P}$, logo $(\mathbf{P} - \mathbf{P}_0)^2 = \mathbf{P} - \mathbf{P}_0$; (ii) $\mathbf{Q}_2 = \mathbf{I}_n - \mathbf{P}$ é idempotente; (iii) $\mathbf{Q}_1\mathbf{Q}_2 = (\mathbf{P} - \mathbf{P}_0)(\mathbf{I}_n - \mathbf{P}) = \mathbf{0}$, confirmando ortogonalidade; (iv) $\mathbf{Q}_1 + \mathbf{Q}_2 + \mathbf{P}_0 = \mathbf{I}_n$ e $\text{tr}(\mathbf{Q}_1) + \text{tr}(\mathbf{Q}_2) + \text{tr}(\mathbf{P}_0) = p + (n-p-1) + 1 = n$; (v) Sob H_0 , quando $\beta_1 = \mathbf{0}_p$, temos $\mathbf{X}\beta = \beta_0\mathbf{1}_n$ e $\mathbf{Q}_1\mathbf{X}\beta = (\mathbf{P} - \mathbf{P}_0)\mathbf{1}_n = \mathbf{0}$.

Portanto, pelo Teorema de Cochran, sob H_0 :

$$\frac{SSR}{\sigma^2} = \frac{\mathbf{y}^T\mathbf{Q}_1\mathbf{y}}{\sigma^2} \sim \chi_p^2, \quad \frac{SSE}{\sigma^2} = \frac{\mathbf{y}^T\mathbf{Q}_2\mathbf{y}}{\sigma^2} \sim \chi_{n-p-1}^2 \quad (10)$$

e essas quantidades são independentes, pois $\mathbf{Q}_1\mathbf{Q}_2 = \mathbf{0}$ garante independência via ortogonalidade das projeções.

Como a estatística F é a razão entre duas variáveis χ^2 independentes divididas por seus graus de liberdade, ela elimina o parâmetro de escala desconhecido σ^2 , tornando-se uma **estatística pivotal**:

$$F = \frac{SSR/p}{SSE/(n-p-1)} = \frac{(SSR/\sigma^2)/p}{(SSE/\sigma^2)/(n-p-1)} \sim F_{p,n-p-1} \quad (11)$$

Portanto, F possui distribuição completamente especificada sob H_0 e não depende de parâmetros desconhecidos. Valores grandes de F_{obs} indicam rejeição de H_0 , pois a variância explicada (MSR) é significativamente maior que a variância residual (MSE).

2.4 Região de Rejeição e Testes Complementares

Para nível de significância α , rejeitamos H_0 se $F > F_{p,n-p-1;\alpha}$ ou se p -valor = $P(F_{p,n-p-1} > F_{\text{obs}}) < \alpha$.

Para testes individuais $H_0 : \beta_j = 0$, utiliza-se $t_j = \frac{\hat{\beta}_j}{SE(\hat{\beta}_j)} \sim t_{n-p-1}$, que complementa o teste F global para identificar quais variáveis específicas são significativas.

3 Análise de Variância e Conclusão

3.1 Decomposição ANOVA

A decomposição fundamental da variabilidade total é $SST = SSR + SSE$, onde $SST = \sum_{i=1}^n (y_i - \bar{y})^2$ é a Soma Total dos Quadrados. A tabela ANOVA resume essa decomposição:

Fonte	Soma de Quadrados	Graus de Liberdade	Quadrado Médio	F
Regressão	SSR	p	$MSR = SSR/p$	$F = MSR/MSE$
Erro	SSE	$n - p - 1$	$MSE = SSE/(n - p - 1)$	
Total	SST	$n - 1$		

Tabela 1: Tabela ANOVA para Regressão Linear Múltipla

3.2 Interpretação e Considerações Finais

O teste $H_0 : \beta_1 = \mathbf{0}_p$ permite avaliar a significância global das variáveis explicativas no modelo. Rejetar H_0 significa que pelo menos uma das variáveis explicativas contribui de forma estatisticamente significativa para explicar a variabilidade de Y . O teste F global deve ser complementado por testes t individuais para identificar quais variáveis específicas são responsáveis pela significância.

Referências Bibliográficas

- Casella, G. & Berger, R. L. (2002). *Statistical Inference*. 2nd ed. Duxbury Press.
- Montgomery, D. C., Peck, E. A. & Vining, G. G. (2012). *Introduction to Linear Regression Analysis*. 5th ed. Wiley.
- Seber, G. A. F. & Lee, A. J. (2012). *Linear Regression Analysis*. 2nd ed. Wiley.