

Questões Resolvidas do Capítulo 3

Teoria Assintótica - Soluções Detalhadas

Curso de Inferência Estatística - PPGEST/UFPE

Compilado e detalhado

Novembro 2025

Sumário

Introdução	2
1 Questão Extra 1: Convergência da Variância Amostral	3
2 Questão Extra 2: Consistência do Máximo da Uniforme	8
3 Questão Extra 3: Convergência do Quociente	13
4 Questão Extra 4: Função Contínua de Convergente	16
5 Questão Extra 5: Distribuição Limite do Máximo Uniforme	18
6 Exercício 11: Estatística Qui-Quadrado via TCL	22
7 Questão Extra 6: TCL para Bernoulli via MGF	26
8 Questão Extra 7: Transformação de Q_n via Slutsky	31
9 Questão Extra 9: Distribuição Assintótica de $\sqrt{n}(S_n^2 - \sigma^2)$	35
10 Questão Extra 10: Método Delta para Poisson	39
11 Questão 3.23: Consistência do EMV para Uniforme	43
Conclusão	48

Introdução

Este documento apresenta todas as questões extras resolvidas em sala de aula do Capítulo 3 sobre Teoria Assintótica e Teoremas Limite. As soluções foram expandidas com explicações detalhadas, intuições e comentários didáticos para facilitar o entendimento completo dos conceitos.

Organização do Documento

Cada questão está organizada da seguinte forma:

1. **Enunciado** - apresentação completa do problema
2. **Solução Detalhada** - desenvolvimento passo a passo
3. **Observações e Intuição** - comentários sobre o método e interpretações
4. **Resumo** - síntese dos principais resultados

Questões Incluídas

- Q(Extra 1) - Convergência da variância amostral S_n^2
- Q(Extra 2) - Consistência do máximo: $X_{(n)} \xrightarrow{P} \theta$
- Q(Extra 3) - Convergência do quociente \bar{X}_n/S_n^2
- Q(Extra 4a) - Transformação do máximo: $T_n^2 = X_{n:n}^2$
- Q(Extra 4b) - Convergência de $Q_n = n(\theta - T_n)/T_n$
- Q(Extra 5) - Distribuição limite do máximo uniforme (Exponencial)
- Q(Extra 6) - TCL para Bernoulli via MGF
- Q(Questão 4) - Distribuição assintótica de χ^2 normalizada
- Q(Extra 9) - Distribuição assintótica de $\sqrt{n}(S_n^2 - \sigma^2)$
- Q(Extra 10) - Método Delta para Poisson: \bar{X}_n^3
- Q(Exercício 11) - Estatística qui-quadrado via TCL
- Q(3.23) - Consistência do EMV para Uniforme

1 Questão Extra 1: Convergência da Variância Amostral

Questão Extra 1

Sejam X_1, \dots, X_n v.a.'s i.i.d. com $E[X_i] = \mu < \infty$ e $\text{Var}(X_i) = \sigma^2 < \infty$. Mostre que:

$$S_n^2 \xrightarrow{P}_{n \rightarrow \infty} \sigma^2 \quad (1)$$

onde $S_n^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X}_n)^2$ é a variância amostral.

Solução Detalhada

Estratégia da Demonstração

Usaremos a **transformação de Helmert** para representar S_n^2 como uma média amostral de variáveis com propriedades conhecidas, permitindo aplicar a Lei Fraca dos Grandes Números.

Passo 1: Transformação de Helmert

A transformação de Helmert produz variáveis ortogonais Y_1, \dots, Y_n a partir de X_1, \dots, X_n tais que:

$$Y_i \sim N(0, \sigma^2) \text{ são independentes para } i = 1, \dots, n \quad (2)$$

E, crucialmente:

$$S_n^2 = \frac{1}{n-1} \sum_{i=2}^n Y_i^2 \quad (3)$$

Interpretação: A variância amostral pode ser vista como uma média (com $n-1$ termos) de quadrados de variáveis normais padrão.

Solução Detalhada

Passo 2: Momentos de Y_i^2

Calculemos $E[Y_i^2]$ e $\text{Var}(Y_i^2)$.

Esperança:

$$E[Y_i^2] = \text{Var}(Y_i) + (E[Y_i])^2 = \sigma^2 + 0 = \sigma^2 \quad (4)$$

Variância: Precisamos calcular $E[Y_i^4]$. Como $Y_i \sim N(0, \sigma^2)$, a MGF de Y_i^2 é conhecida. Calculando as derivadas da MGF:

$$M_{Y_i^2}(t) = (1 - 2\sigma^2 t)^{-1/2} \quad (5)$$

Derivando sucessivamente e avaliando em $t = 0$:

$$M'_{Y_i^2}(t) \Big|_{t=0} = 0 = E[Y_i] \quad (6)$$

$$M''_{Y_i^2}(t) \Big|_{t=0} = \sigma^2 = E[Y_i^2] \quad (7)$$

$$M'''_{Y_i^2}(t) \Big|_{t=0} = 0 = E[Y_i^3] \quad (8)$$

$$M''''_{Y_i^2}(t) \Big|_{t=0} = 3\sigma^4 = E[Y_i^4] \quad (9)$$

(Os cálculos completos das derivadas estão nas notas n9, linhas 21-38)

Portanto:

$$\text{Var}(Y_i^2) = E[Y_i^4] - (E[Y_i^2])^2 = 3\sigma^4 - \sigma^4 = 2\sigma^4 < \infty \quad (10)$$

Solução Detalhada

Passo 3: Aplicação do Resultado 1P

Como $S_n^2 = \frac{1}{n-1} \sum_{i=2}^n Y_i^2$ é uma média amostral de $n - 1$ variáveis i.i.d. com:

- $E[Y_i^2] = \sigma^2$
- $\text{Var}(Y_i^2) = 2\sigma^4 < \infty$

Pelo **Resultado 1P** (Lei Fraca dos Grandes Números - versão simples):

$$S_n^2 \xrightarrow{P}_{n \rightarrow \infty} E[Y_i^2] = \sigma^2 \quad \square \quad (11)$$

Pontos Importantes

1. **Transformação de Helmert:** Esta é uma transformação ortogonal crucial que:
 - Preserva a soma dos quadrados: $\sum_{i=1}^n X_i^2 = \sum_{i=1}^n Y_i^2$
 - Separa a informação sobre média (Y_1) da informação sobre variância (Y_2, \dots, Y_n)
 - Produz variáveis independentes quando $X_i \sim N(\mu, \sigma^2)$
2. **Por que funciona para não-normais?** Embora a transformação de Helmert seja exata para normais, o resultado vale para qualquer distribuição com variância finita. A chave é que:

$$S_n^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X}_n)^2 \quad (12)$$

pode ser aproximada por $\frac{1}{n} \sum_{i=1}^n (X_i - \mu)^2$ e aplicar a LFGN diretamente.

Observações e Intuição

Pontos Importantes (continuação)

5. **Taxa de convergência:** Pelo Resultado 2P, a variância de S_n^2 decai como $O(1/n)$:

$$\text{Var}(S_n^2) = \frac{2\sigma^4}{n-1} \rightarrow 0 \quad (13)$$

6. **Distribuição assintótica:** Além de convergência em probabilidade, veremos na Questão Extra 9 que:

$$\sqrt{n}(S_n^2 - \sigma^2) \xrightarrow{D} N(0, \mu_4 - \sigma^4) \quad (14)$$

forneendo informação sobre a velocidade de convergência.

Resumo da Questão

Resultado Principal:

$$S_n^2 \xrightarrow{P} \sigma^2$$

Método Utilizado:

- Representação via Helmert: $S_n^2 = \frac{1}{n-1} \sum_{i=2}^n Y_i^2$
- Lei Fraca dos Grandes Números (Resultado 1P)
- Momentos: $E[Y_i^2] = \sigma^2$, $\text{Var}(Y_i^2) = 2\sigma^4 < \infty$

Conclusão: S_n^2 é consistente para σ^2 .

2 Questão Extra 2: Consistência do Máximo da Uniforme

Questão Extra 2

Sejam X_1, \dots, X_n v.a.'s i.i.d. com $X_i \sim \text{Uniforme}(0, \theta)$ para $\theta > 0$. Mostre que:

$$T_n = X_{(n)} = \max\{X_1, \dots, X_n\} \xrightarrow{P} \theta \quad (15)$$

Solução Detalhada

Estratégia da Demonstração

Calcularemos $E[(T_n - \theta)^2]$ e mostraremos que converge para zero. Pelo **Resultado 2P**, isso implica convergência em probabilidade.

Passo 1: Distribuição de $T_n = X_{(n)}$

Para a maior estatística de ordem:

$$F_{T_n}(t) = P(T_n \leq t) = P(\max\{X_1, \dots, X_n\} \leq t) \quad (16)$$

$$= P(X_1 \leq t, \dots, X_n \leq t) \quad (17)$$

$$\stackrel{\text{i.i.d.}}{=} [P(X_1 \leq t)]^n \quad (18)$$

$$= [F_{X_1}(t)]^n \quad (19)$$

Para $X_i \sim U(0, \theta)$:

$$F_{X_1}(t) = \begin{cases} 0, & t < 0 \\ \frac{t}{\theta}, & 0 \leq t \leq \theta \\ 1, & t > \theta \end{cases} \quad \text{e} \quad f_{X_1}(t) = \frac{1}{\theta} \mathbf{1}_{(0, \theta)}(t) \quad (20)$$

Portanto:

$$F_{T_n}(t) = \begin{cases} 0, & t < 0 \\ \left(\frac{t}{\theta}\right)^n, & 0 \leq t \leq \theta \\ 1, & t > \theta \end{cases} \quad (21)$$

A densidade é:

$$f_{T_n}(t) = n[F_{X_1}(t)]^{n-1} f_{X_1}(t) = \frac{n}{\theta^n} t^{n-1} \mathbf{1}_{(0, \theta)}(t) \quad (22)$$

Solução Detalhada

Passo 2: Cálculo dos Momentos

Primeiro momento:

$$E[T_n] = \int_0^\theta t \cdot \frac{n}{\theta^n} t^{n-1} dt \quad (23)$$

$$= \frac{n}{\theta^n} \int_0^\theta t^n dt \quad (24)$$

$$= \frac{n}{\theta^n} \cdot \frac{t^{n+1}}{n+1} \Big|_0^\theta \quad (25)$$

$$= \frac{n}{\theta^n} \cdot \frac{\theta^{n+1}}{n+1} \quad (26)$$

$$= \frac{n\theta}{n+1} \quad (27)$$

Segundo momento:

$$E[T_n^2] = \int_0^\theta t^2 \cdot \frac{n}{\theta^n} t^{n-1} dt \quad (28)$$

$$= \frac{n}{\theta^n} \int_0^\theta t^{n+1} dt \quad (29)$$

$$= \frac{n}{\theta^n} \cdot \frac{t^{n+2}}{n+2} \Big|_0^\theta \quad (30)$$

$$= \frac{n}{\theta^n} \cdot \frac{\theta^{n+2}}{n+2} \quad (31)$$

$$= \frac{n\theta^2}{n+2} \quad (32)$$

Solução Detalhada

Passo 3: Erro Quadrático Médio

$$E[(T_n - \theta)^2] = E[T_n^2] - 2\theta E[T_n] + \theta^2 \quad (33)$$

$$= \frac{n\theta^2}{n+2} - 2\theta \cdot \frac{n\theta}{n+1} + \theta^2 \quad (34)$$

$$= \theta^2 \left[\frac{n}{n+2} - \frac{2n}{n+1} + 1 \right] \quad (35)$$

Colocando em denominador comum $(n+2)(n+1)$:

$$= \theta^2 \left[\frac{n(n+1) - 2n(n+2) + (n+2)(n+1)}{(n+2)(n+1)} \right] \quad (36)$$

$$= \theta^2 \left[\frac{n^2 + n - 2n^2 - 4n + n^2 + 3n + 2}{(n+2)(n+1)} \right] \quad (37)$$

$$= \theta^2 \left[\frac{2}{(n+2)(n+1)} \right] \quad (38)$$

$$= \frac{2\theta^2}{(n+2)(n+1)} \xrightarrow{n \rightarrow \infty} 0 \quad (39)$$

Passo 4: Conclusão

Como $E[(T_n - \theta)^2] \rightarrow 0$, pelo **Resultado 2P** (com $r = 2$ e $a = \theta$):

$$T_n = X_{(n)} \xrightarrow{P}_{n \rightarrow \infty} \theta \quad \square \quad (40)$$

Pontos Importantes

1. **Estatística de Ordem:** $X_{(n)} = \max\{X_1, \dots, X_n\}$ é um estimador natural para o extremo superior θ da uniforme.

2. **Viés do Estimador:** Note que:

$$E[T_n] = \frac{n\theta}{n+1} = \theta \left(1 - \frac{1}{n+1}\right) < \theta \quad (41)$$

O estimador é viesado negativamente, mas o viés $\rightarrow 0$ quando $n \rightarrow \infty$.

3. **Estimador Não-Viesado:** Se quisermos um estimador não-viesado, podemos usar:

$$\tilde{T}_n = \frac{n+1}{n} X_{(n)} \quad (42)$$

pois $E[\tilde{T}_n] = \frac{n+1}{n} \cdot \frac{n\theta}{n+1} = \theta$.

4. **Taxa de Convergência:** O EQM decai como $O(1/n^2)$:

$$E[(T_n - \theta)^2] = O\left(\frac{1}{n^2}\right) \quad (43)$$

Isso é mais rápido que a taxa típica $O(1/n)$ de muitos estimadores!

5. **EMV:** Na Questão 3.23, veremos que $X_{(n)}$ é de fato o Estimador de Máxima Verossimilhança para θ neste modelo.
6. **Comparação com \bar{X}_n :** A média amostral também é consistente ($\bar{X}_n \xrightarrow{P} \theta/2$), mas $X_{(n)}$ converge para o parâmetro de interesse θ , não $\theta/2$.

Interpretação Gráfica

Resumo da Questão

Resultado Principal:

$$X_{(n)} \xrightarrow{P} \theta$$

Método Utilizado:

- Cálculo da densidade: $f_{T_n}(t) = \frac{n}{\theta^n} t^{n-1} \mathbf{1}_{(0,\theta)}(t)$
- Momentos: $E[T_n] = \frac{n\theta}{n+1}$, $E[T_n^2] = \frac{n\theta^2}{n+2}$
- EQM: $E[(T_n - \theta)^2] = \frac{2\theta^2}{(n+2)(n+1)} \rightarrow 0$
- Resultado 2P: $E[|T_n - \theta|^2] \rightarrow 0 \Rightarrow T_n \xrightarrow{P} \theta$

Importância: Prova a consistência de $X_{(n)}$ como estimador de θ para $U(0, \theta)$.

3 Questão Extra 3: Convergência do Quociente

Questão Extra 3

Sejam X_1, \dots, X_n v.a.'s i.i.d. tais que $X_i \sim N(\mu, \sigma^2)$ para $\mu, \sigma^2 < \infty$. Mostre que:

$$\frac{\bar{X}_n}{S_n^2} \xrightarrow{P}_{n \rightarrow \infty} \frac{\mu}{\sigma^2} \quad (44)$$

Solução Detalhada

Estratégia da Demonstração

Usaremos o **Resultado 4P** sobre operações algébricas com convergências em probabilidade.

Passo 1: Convergências Individuais

Pelo **Resultado 1P** (Lei Fraca dos Grandes Números):

$$\bar{X}_n \xrightarrow{P}_{n \rightarrow \infty} \mu \quad (45)$$

Pela **Questão Extra 1** (já demonstrada):

$$S_n^2 \xrightarrow{P}_{n \rightarrow \infty} \sigma^2 \quad (46)$$

Passo 2: Aplicação do Resultado 4P

O **Resultado 4P** afirma que se $U_n \xrightarrow{P} u$ e $V_n \xrightarrow{P} v$ com $v \neq 0$ e $P(V_n = 0) = 0$ para todo n , então:

$$\frac{U_n}{V_n} \xrightarrow{P} \frac{u}{v} \quad (47)$$

Verificação das condições:

- $U_n = \bar{X}_n \xrightarrow{P} \mu$ ✓
- $V_n = S_n^2 \xrightarrow{P} \sigma^2$ ✓
- $\sigma^2 > 0$ (por hipótese) ✓
- $P(S_n^2 = 0) = 0$ para todo $n \geq 2$ ✓ (precisa de pelo menos 2 observações diferentes)

Passo 3: Conclusão

Pelo Resultado 4P (item iii):

$$\frac{\bar{X}_n}{S_n^2} \xrightarrow{P}_{n \rightarrow \infty} \frac{\mu}{\sigma^2} \quad \square \quad (48)$$

Pontos Importantes

1. **Operações Algébricas Preservam Convergência:** O Resultado 4P é fundamental porque permite operar com limites em probabilidade como se fossem limites determinísticos:
 - Soma: $U_n + V_n \xrightarrow{P} u + v$
 - Produto: $U_n \cdot V_n \xrightarrow{P} u \cdot v$
 - Quociente: $U_n/V_n \xrightarrow{P} u/v$ (se $v \neq 0$)
2. **Condição de Não-Degeneração:** A condição $P(V_n = 0) = 0$ é crucial para o quociente. Se S_n^2 pudesse ser zero com probabilidade positiva, o quociente não estaria bem definido.
3. **Interpretação Estatística:** O quociente $\frac{\bar{X}_n}{S_n^2}$ não é uma estatística comum, mas o resultado ilustra que podemos trabalhar com funções racionais de estimadores consistentes.
4. **Generalização:** Se $g : \mathbb{R}^2 \rightarrow \mathbb{R}$ é contínua em (u, v) , então:

$$g(\bar{X}_n, S_n^2) \xrightarrow{P} g(\mu, \sigma^2) \quad (49)$$

O quociente é o caso especial $g(x, y) = x/y$.

5. **Exemplo Relacionado:** O coeficiente de variação amostral:

$$CV_n = \frac{S_n}{\bar{X}_n} \xrightarrow{P} \frac{\sigma}{\mu} \quad (\text{se } \mu \neq 0) \quad (50)$$

Cuidado com Quocientes

Contraexemplo: Se $V_n \xrightarrow{P} 0$, o quociente U_n/V_n pode divergir mesmo que $U_n \xrightarrow{P} u$. Por exemplo:

- Se $U_n = 1/n$ e $V_n = 1/n^2$
- Então $U_n \xrightarrow{P} 0$ e $V_n \xrightarrow{P} 0$
- Mas $U_n/V_n = n \rightarrow \infty$ (não converge!)

Por isso a condição $v \neq 0$ é essencial.

Resumo da Questão

Resultado Principal:

$$\frac{\bar{X}_n}{S_n^2} \xrightarrow{P} \frac{\mu}{\sigma^2}$$

Método Utilizado:

- Resultado 1P: $\bar{X}_n \xrightarrow{P} \mu$
- Questão Extra 1: $S_n^2 \xrightarrow{P} \sigma^2$
- Resultado 4P (item iii): quociente de convergentes converge

Lição: Operações algébricas preservam convergência em probabilidade (com cuidados para divisão).

4 Questão Extra 4: Função Contínua de Convergente

Questão Extra 4

Sejam X_1, \dots, X_n v.a.'s i.i.d. tais que $X_i \sim U(0, \theta)$ para $\theta > 0$. Mostre que:

$$T_n^2 = X_{n:n}^2 \xrightarrow[n \rightarrow \infty]{P} \theta^2 \quad (51)$$

Solução Detalhada

Estratégia da Demonstração

Usaremos o **Resultado 5P** (teorema da função contínua para convergência em probabilidade).

Passo 1: Convergência do Máximo

Pela **Questão Extra 2** (já demonstrada):

$$X_{n:n} \xrightarrow[n \rightarrow \infty]{P} \theta \quad (52)$$

Passo 2: Aplicação do Resultado 5P

O **Resultado 5P** afirma que se $U_n \xrightarrow{P} u$ e $g(\cdot)$ é uma função contínua, então:

$$g(U_n) \xrightarrow[n \rightarrow \infty]{P} g(u) \quad (53)$$

Aplicação ao nosso caso:

- $U_n = X_{n:n}$
- $u = \theta$
- $g(x) = x^2$ (função contínua em \mathbb{R})

Portanto:

$$g(X_{n:n}) = X_{n:n}^2 \xrightarrow[n \rightarrow \infty]{P} g(\theta) = \theta^2 \quad \square \quad (54)$$

Observações e Intuição

Pontos Importantes

1. **Preservação de Convergência por Funções Contínuas:** Este é um dos teoremas mais úteis em teoria assintótica. Se uma sequência converge em probabilidade, podemos aplicar qualquer função contínua e a convergência é preservada.

2. **Exemplos de Funções Contínuas Úteis:**

- $g(x) = x^2$: $U_n \xrightarrow{P} u \Rightarrow U_n^2 \xrightarrow{P} u^2$
- $g(x) = \sqrt{x}$ (para $x > 0$): $U_n \xrightarrow{P} u \Rightarrow \sqrt{U_n} \xrightarrow{P} \sqrt{u}$
- $g(x) = e^x$: $U_n \xrightarrow{P} u \Rightarrow e^{U_n} \xrightarrow{P} e^u$
- $g(x) = \log x$ (para $x > 0$): $U_n \xrightarrow{P} u \Rightarrow \log U_n \xrightarrow{P} \log u$

3. **Aplicação ao nosso exemplo:** Como $S_n^2 \xrightarrow{P} \sigma^2$, temos:

$$S_n = \sqrt{S_n^2} \xrightarrow{P} \sqrt{\sigma^2} = \sigma \quad (55)$$

4. **Cuidado com Descontinuidades:** Se g tem descontinuidade em u , o resultado pode falhar. Por exemplo:

$$g(x) = \mathbf{1}_{x>0} = \begin{cases} 1, & x > 0 \\ 0, & x \leq 0 \end{cases} \quad (56)$$

é descontínua em $x = 0$.

5. **Demonstração do Resultado 5P:** A prova usa ε - δ da continuidade:

$$|x - u| < \delta \Rightarrow |g(x) - g(u)| < \varepsilon \quad (57)$$

Logo,

$$P(|g(U_n) - g(u)| \geq \varepsilon) \leq P(|U_n - u| \geq \delta) \rightarrow 0 \quad (58)$$

Resumo da Questão

Resultado Principal:

$$X_{n:n}^2 \xrightarrow{P} \theta^2$$

Método Utilizado:

- Questão Extra 2: $X_{n:n} \xrightarrow{P} \theta$
- Resultado 5P: função contínua preserva convergência em P
- Função $g(x) = x^2$ é contínua

Lição: Transformações contínuas de estimadores consistentes são consistentes.

5 Questão Extra 5: Distribuição Limite do Máximo Uniforme

Questão Extra 5

Sejam X_1, \dots, X_n v.a.'s i.i.d tais que $X_i \sim U(0, \theta)$ para $\theta > 0$.
Encontre a distribuição limite da sequência:

$$U_n = \frac{n}{\theta}(\theta - T_n) \quad \text{para} \quad T_n \triangleq X_{n:n} \quad (59)$$

Solução Detalhada

Estratégia da Demonstração

Calcularemos a função de distribuição acumulada (fda) de U_n e tomaremos o limite quando $n \rightarrow \infty$.

Passo 1: Função de Distribuição de T_n

Da Questão Extra 2, sabemos que:

$$F_{T_n}(t) = \left(\frac{t}{\theta}\right)^n \mathbf{1}_{(0,\theta)}(t) + \mathbf{1}_{[\theta,\infty)}(t) \quad (60)$$

Passo 2: Função de Distribuição de U_n

Para $u > 0$, calculemos $F_{U_n}(u) = P(U_n \leq u)$:

$$F_{U_n}(u) = P\left(\frac{n}{\theta}(\theta - T_n) \leq u\right) \quad (61)$$

$$= P\left(\theta - T_n \leq \frac{\theta u}{n}\right) \quad (62)$$

$$= P\left(-T_n \leq \frac{\theta u}{n} - \theta\right) \quad (63)$$

$$= P\left(T_n \geq \theta\left(1 - \frac{u}{n}\right)\right) \quad (64)$$

Solução Detalhada

Passo 3: Cálculo da Probabilidade

$$F_{U_n}(u) = P\left(T_n \geq \theta \left(1 - \frac{u}{n}\right)\right) \quad (65)$$

$$= 1 - P\left(T_n < \theta \left(1 - \frac{u}{n}\right)\right) \quad (66)$$

$$= 1 - F_{T_n}\left(\theta \left(1 - \frac{u}{n}\right)\right) \quad (67)$$

Como $0 < \theta(1 - u/n) < \theta$ para n suficientemente grande:

$$F_{U_n}(u) = 1 - \left(\frac{\theta(1 - u/n)}{\theta}\right)^n \quad (68)$$

$$= 1 - \left(1 - \frac{u}{n}\right)^n \quad (69)$$

Passo 4: Limite quando $n \rightarrow \infty$

Usando o resultado limite (R.3): $\lim_{n \rightarrow \infty} (1 + x/n)^n = e^x$, temos:

$$\lim_{n \rightarrow \infty} F_{U_n}(u) = \lim_{n \rightarrow \infty} \left[1 - \left(1 - \frac{u}{n}\right)^n\right] \quad (70)$$

$$= 1 - \lim_{n \rightarrow \infty} \left(1 + \frac{(-u)}{n}\right)^n \quad (71)$$

$$= 1 - e^{-u}, \quad u > 0 \quad (72)$$

Passo 5: Identificação da Distribuição

Reconhecemos que $F_U(u) = 1 - e^{-u}$ para $u > 0$ é a fda de uma distribuição **Exponencial**(1).

Verificação: Para $E \sim \text{Exp}(1)$ com densidade $f_E(u) = e^{-u} \mathbf{1}_{u>0}$:

$$F_E(u) = \int_0^u e^{-t} dt = -e^{-t} \Big|_0^u = 1 - e^{-u} \quad \checkmark \quad (73)$$

Conclusão

$$U_n = \frac{n}{\theta}(\theta - X_{n:n}) \xrightarrow{D} E \sim \text{Exp}(1) \quad \square \quad (74)$$

Pontos Importantes

1. **Normalização Não-Padrão:** Diferente do TCL onde normalizamos com \sqrt{n} , aqui a normalização correta é n (linear). Isso indica uma taxa de convergência mais rápida.
2. **Distribuição Limite Não-Normal:** Este é um exemplo importante onde a distribuição limite NÃO é normal. O TCL não se aplica aqui porque $X_{n:n}$ não é uma média.
3. **Interpretação do Resultado:** A distância normalizada $n(\theta - X_{n:n})/\theta$ entre o máximo e o limite superior converge para uma Exponencial(1).
4. **Relação com Resultados Anteriores:**
 - Questão Extra 2 mostra: $X_{n:n} \xrightarrow{P} \theta$
 - Esta questão refina: $n(\theta - X_{n:n})/\theta$ tem distribuição limite não-degenerada
 - Isso dá informação sobre a *taxa* de convergência
5. **Aplicação ao Limite (R.3):** A chave da demonstração é o limite:

$$\lim_{n \rightarrow \infty} \left(1 - \frac{u}{n}\right)^n = e^{-u} \quad (75)$$

Este é um dos resultados limites fundamentais apresentados no início do capítulo.

6. **Estatística de Valores Extremos:** Este resultado é um exemplo clássico da teoria de valores extremos, onde distribuições limite de máximos/mínimos são estudadas.

Consequências Práticas

- **Intervalos de Confiança:** Podemos construir IC para θ usando a distribuição de U_n :

$$P\left(a < \frac{n}{\theta}(\theta - X_{n:n}) < b\right) \approx P(a < E < b) = e^{-a} - e^{-b} \quad (76)$$

- **Quantis:** Para $\alpha = 0.05$, os quantis de $\text{Exp}(1)$ são:

$$- P(E > 2.996) = 0.05$$

$$- P(E > 0.051) = 0.95$$

- **IC Aproximado para θ :**

$$\left[X_{n:n}, X_{n:n} + \frac{\theta \cdot 2.996}{n}\right] \approx \text{IC de 95\%} \quad (77)$$

(mas θ é desconhecido, então precisamos estimar)

Resumo da Questão

Resultado Principal:

$$U_n = \frac{n}{\theta}(\theta - X_{n:n}) \xrightarrow{D} \text{Exp}(1)$$

Método Utilizado:

- Cálculo da fda: $F_{U_n}(u) = 1 - (1 - u/n)^n$
- Limite (R.3): $(1 - u/n)^n \rightarrow e^{-u}$
- Identificação: $F_U(u) = 1 - e^{-u}$ é fda de $\text{Exp}(1)$

Importância: Mostra que a taxa de convergência de $X_{n:n}$ é $O(1/n)$, mais rápida que a típica $O(1/\sqrt{n})$.

6 Exercício 11: Estatística Qui-Quadrado via TCL

Exercício 11

Sejam X_1, \dots, X_n v.a.'s i.i.d. reais tais que $\mu = E\{X_i\} < \infty$ e $\sigma^2 = \text{Var}\{X_i\} < \infty$. Mostre que:

$$n \left(\frac{\bar{X}_n - \mu}{\sigma} \right)^2 \xrightarrow[n \rightarrow \infty]{d} Q, \quad (78)$$

tal que $Q \sim \chi_1^2$.

Solução Detalhada

Estratégia da Demonstração

Usaremos o **Teorema Central do Limite** seguido do **Teorema 3.7.6.4(a)** (função contínua preserva convergência em distribuição).

Passo 1: Aplicação do TCL

Pelo **Teorema 3.7.6.1(a)** (Teorema Central do Limite):

$$Z_n \triangleq \sqrt{n} \left(\frac{\bar{X}_n - \mu}{\sigma} \right) \xrightarrow[n \rightarrow \infty]{d} Z \sim N(0, 1) \quad (79)$$

Passo 2: Transformação Contínua

Considere a função $g(x) = x^2$. Claramente, g é contínua em \mathbb{R} .

Pelo **Teorema 3.7.6.4(a)** (teorema da função contínua em distribuição), se $U_n \xrightarrow{d} U$ e g é contínua, então:

$$g(U_n) \xrightarrow[n \rightarrow \infty]{d} g(U) \quad (80)$$

Passo 3: Aplicação ao Nosso Caso

Aplicando com $U_n = Z_n$ e $g(x) = x^2$:

$$g(Z_n) = Z_n^2 \quad (81)$$

$$= \left[\sqrt{n} \left(\frac{\bar{X}_n - \mu}{\sigma} \right) \right]^2 \quad (82)$$

$$= n \left(\frac{\bar{X}_n - \mu}{\sigma} \right)^2 \quad (83)$$

$$\xrightarrow[n \rightarrow \infty]{d} Z^2 \quad (84)$$

onde $Z \sim N(0, 1)$.

Solução Detalhada

Passo 4: Distribuição de Z^2

Se $Z \sim N(0, 1)$, então $Z^2 \sim \chi_1^2$ (qui-quadrado com 1 grau de liberdade).

Verificação: Para $Z \sim N(0, 1)$ e $Q = Z^2$:

$$F_Q(q) = P(Z^2 \leq q) = P(-\sqrt{q} \leq Z \leq \sqrt{q}) \quad (85)$$

$$= \Phi(\sqrt{q}) - \Phi(-\sqrt{q}) \quad (86)$$

$$= 2\Phi(\sqrt{q}) - 1 \quad (87)$$

Derivando:

$$f_Q(q) = \frac{d}{dq}[2\Phi(\sqrt{q}) - 1] = 2\phi(\sqrt{q}) \cdot \frac{1}{2\sqrt{q}} = \frac{1}{\sqrt{2\pi q}} e^{-q/2} \quad (88)$$

que é a densidade de $\chi_1^2 = \Gamma(1/2, 1/2)$. ✓

Conclusão

$$n \left(\frac{\bar{X}_n - \mu}{\sigma} \right)^2 \xrightarrow[n \rightarrow \infty]{d} \chi_1^2 \quad \square \quad (89)$$

Pontos Importantes

1. **Combinação de Dois Teoremas:** Esta questão ilustra a composição de resultados:

$$\text{TCL} + \text{Função Contínua} = \text{Distribuição de } \chi^2 \quad (90)$$

2. **Relação $N(0, 1)$ e χ_1^2 :** Este resultado estabelece a conexão fundamental:

$$Z \sim N(0, 1) \Rightarrow Z^2 \sim \chi_1^2 \quad (91)$$

3. **Aplicação Prática (Testes):** Esta estatística é a base para:

- Teste Z bilateral: rejeitamos $H_0 : \mu = \mu_0$ se $n(\bar{x} - \mu_0)^2 / \sigma^2 > \chi_{1, 1-\alpha}^2$
- Equivalente a rejeitar se $|Z| > z_{\alpha/2}$

4. **Generalização para p Dimensões:** Se $\bar{X}_n \in \mathbb{R}^p$ e:

$$\sqrt{n}(\bar{X}_n - \mu) \xrightarrow{D} N_p(0, \Sigma) \quad (92)$$

então:

$$n(\bar{X}_n - \mu)^\top \Sigma^{-1}(\bar{X}_n - \mu) \xrightarrow{D} \chi_p^2 \quad (93)$$

5. **Exemplos Numéricos:**


- Para $\alpha = 0.05$: $\chi_{1, 0.95}^2 = 3.841$
- Logo, rejeitamos se $n(\bar{x} - \mu_0)^2 / \sigma^2 > 3.841$
- Equivalentemente, $|\bar{x} - \mu_0| > \sigma \cdot 1.96 / \sqrt{n}$ ($z_{0.025} = 1.96$)

6. **Conexão com Variância Amostral:** Para normalidade, temos a decomposição:

$$\sum_{i=1}^n \left(\frac{X_i - \mu}{\sigma} \right)^2 = n \left(\frac{\bar{X}_n - \mu}{\sigma} \right)^2 + \frac{(n-1)S_n^2}{\sigma^2} \quad (94)$$

onde o primeiro termo $\xrightarrow{D} \chi_1^2$ e o segundo $\sim \chi_{n-1}^2$ exatamente.

Visualização



Densidade de χ_1^2

Resumo da Questão

Resultado Principal:

$$n \left(\frac{\bar{X}_n - \mu}{\sigma} \right)^2 \xrightarrow{D} \chi_1^2$$

Método Utilizado:

- TCL: $Z_n = \sqrt{n}(\bar{X}_n - \mu)/\sigma \xrightarrow{D} N(0, 1)$
- Teorema 3.7.6.4(a): $g(Z_n) = Z_n^2 \xrightarrow{D} Z^2$
- Propriedade: $Z^2 \sim \chi_1^2$ quando $Z \sim N(0, 1)$

Importância: Base para testes bilaterais e intervalos de confiança.

7 Questão Extra 6: TCL para Bernoulli via MGF

Questão Extra 6

Sejam X_1, \dots, X_n v.a.'s i.i.d. tais que $X_i \sim \text{Bernoulli}(p)$ com $p = \frac{1}{2}$ e

$$U_n = 2\sqrt{n} \left(\bar{X}_n - \frac{1}{2} \right).$$

Estude a distribuição limite de U_n .

Solução Detalhada

Estratégia da Demonstração

Usaremos o **Resultado 1D** (convergência via função geradora de momentos) para encontrar a distribuição limite.

Passo 1: Reescrever U_n

Primeiro, reescrevemos U_n em termos da soma:

$$U_n = 2\sqrt{n} \left(\bar{X}_n - \frac{1}{2} \right) \quad (95)$$

$$= 2\sqrt{n} \left(\frac{1}{n} \sum_{i=1}^n X_i - \frac{1}{2} \right) \quad (96)$$

$$= \frac{2}{\sqrt{n}} \sum_{i=1}^n X_i - \sqrt{n} \quad (97)$$

$$= \frac{2 \sum_{i=1}^n X_i - n}{\sqrt{n}} \quad (98)$$

Passo 2: Função Geradora de Momentos de U_n

$$M_{U_n}(t) = E \left[e^{tU_n} \right] \quad (99)$$

$$= E \left[\exp \left\{ t \cdot \frac{2 \sum_{i=1}^n X_i - n}{\sqrt{n}} \right\} \right] \quad (100)$$

$$= E \left[\exp \left\{ \frac{2t}{\sqrt{n}} \sum_{i=1}^n X_i - t\sqrt{n} \right\} \right] \quad (101)$$

$$= e^{-t\sqrt{n}} \cdot E \left[\exp \left\{ \frac{2t}{\sqrt{n}} \sum_{i=1}^n X_i \right\} \right] \quad (102)$$

Solução Detalhada

Passo 3: Usando Independência

Como as X_i são independentes:

$$M_{U_n}(t) = e^{-t\sqrt{n}} \cdot \prod_{i=1}^n E \left[e^{\frac{2t}{\sqrt{n}} X_i} \right] \quad (103)$$

$$= e^{-t\sqrt{n}} \cdot \left(E \left[e^{\frac{2t}{\sqrt{n}} X_1} \right] \right)^n \quad (104)$$

Para $X_1 \sim \text{Bernoulli}(p)$, sabemos que $X_1 \in \{0, 1\}$:

$$E \left[e^{\frac{2t}{\sqrt{n}} X_1} \right] = (1-p) \cdot e^{\frac{2t}{\sqrt{n}} \cdot 0} + p \cdot e^{\frac{2t}{\sqrt{n}} \cdot 1} \quad (105)$$

$$= (1-p) + p \cdot e^{\frac{2t}{\sqrt{n}}} \quad (106)$$

Logo:

$$M_{U_n}(t) = e^{-t\sqrt{n}} \left[(1-p) + p \cdot e^{\frac{2t}{\sqrt{n}}} \right]^n \quad (107)$$

Passo 4: Caso Especial $p = \frac{1}{2}$

Substituindo $p = 1/2$:

$$M_{U_n}(t) = e^{-t\sqrt{n}} \left[\frac{1}{2} + \frac{1}{2} \cdot e^{\frac{2t}{\sqrt{n}}} \right]^n \quad (108)$$

$$= e^{-t\sqrt{n}} \left[\frac{1}{2} \left(1 + e^{\frac{2t}{\sqrt{n}}} \right) \right]^n \quad (109)$$

$$= \frac{1}{2^n} e^{-t\sqrt{n}} \left[1 + e^{\frac{2t}{\sqrt{n}}} \right]^n \quad (110)$$

Podemos reescrever como:

$$M_{U_n}(t) = \frac{1}{2^n} \left[e^{-\frac{t}{\sqrt{n}}} + e^{\frac{t}{\sqrt{n}}} \right]^n \quad (111)$$

Ou ainda:

$$M_{U_n}(t) = \left[\frac{1}{2} \left(e^{-\frac{t}{\sqrt{n}}} + e^{\frac{t}{\sqrt{n}}} \right) \right]^n \quad (112)$$

Solução Detalhada

Passo 5: Expansão de Taylor

Expandimos as exponenciais usando Taylor em torno de 0:

$$e^{\frac{t}{\sqrt{n}}} = 1 + \frac{t}{\sqrt{n}} + \frac{t^2}{2n} + o\left(\frac{t^2}{n}\right) \quad (113)$$

$$e^{-\frac{t}{\sqrt{n}}} = 1 - \frac{t}{\sqrt{n}} + \frac{t^2}{2n} + o\left(\frac{t^2}{n}\right) \quad (114)$$

Somando:

$$e^{-\frac{t}{\sqrt{n}}} + e^{\frac{t}{\sqrt{n}}} = 2 + \frac{t^2}{n} + o\left(\frac{t^2}{n}\right) \quad (115)$$

Logo:

$$M_{U_n}(t) = \left[\frac{1}{2} \left(2 + \frac{t^2}{n} + o\left(\frac{t^2}{n}\right) \right) \right]^n \quad (116)$$

$$= \left[1 + \frac{t^2}{2n} + o\left(\frac{t^2}{n}\right) \right]^n \quad (117)$$

Passo 6: Aplicação do Limite (R.3)

Pelo resultado limite (R.3): $\lim_{n \rightarrow \infty} (1 + x/n)^n = e^x$, temos:

$$\lim_{n \rightarrow \infty} M_{U_n}(t) = \lim_{n \rightarrow \infty} \left[1 + \frac{t^2/2}{n} \right]^n = e^{t^2/2} \quad (118)$$

Passo 7: Identificação da Distribuição

Reconhecemos que $M_U(t) = e^{t^2/2}$ é a MGF de $Z \sim N(0, 1)$.

Verificação: Para $Z \sim N(0, 1)$:

$$M_Z(t) = E[e^{tZ}] = e^{t^2/2} \quad \checkmark \quad (119)$$

Conclusão

Pelo **Resultado 1D**, como $M_{U_n}(t) \rightarrow M_Z(t)$:

$$U_n = 2\sqrt{n} \left(\bar{X}_n - \frac{1}{2} \right) \xrightarrow[n \rightarrow \infty]{d} N(0, 1) \quad \square \quad (120)$$

Pontos Importantes

1. **Verificação do TCL:** Podemos verificar que este resultado está de acordo com o TCL:

- Para Bernoulli(1/2): $E[X_i] = 1/2$ e $\text{Var}(X_i) = 1/2 \cdot 1/2 = 1/4$
- Pelo TCL: $\sqrt{n}(\bar{X}_n - 1/2) \xrightarrow{D} N(0, 1/4)$
- Multiplicando por 2: $2\sqrt{n}(\bar{X}_n - 1/2) \xrightarrow{D} N(0, 4 \cdot 1/4) = N(0, 1) \checkmark$

2. **Demonstração via MGF:** Esta questão demonstra o TCL usando a função geradora de momentos, que é uma técnica alternativa à prova via função característica.

3. **Expansões de Taylor Cruciais:** Os passos chave são:

- Expandir $e^{\pm t/\sqrt{n}}$ até ordem 2
- Cancelar os termos lineares (aparecem com sinais opostos)
- Reconhecer a forma $(1 + x/n)^n \rightarrow e^x$

4. **Normalização:** O fator 2 na frente vem de:

$$\frac{\sqrt{n}(\bar{X}_n - 1/2)}{\sqrt{\text{Var}(X_i)}} = \frac{\sqrt{n}(\bar{X}_n - 1/2)}{1/2} = 2\sqrt{n}(\bar{X}_n - 1/2) \quad (121)$$

5. **Aproximação Normal para Binomial:** Como $S_n = \sum X_i \sim \text{Binomial}(n, 1/2)$:

$$\frac{S_n - n/2}{\sqrt{n/4}} = \frac{2(S_n - n/2)}{\sqrt{n}} \xrightarrow{D} N(0, 1) \quad (122)$$

6. **Caso Geral $p \neq 1/2$:** Para p arbitrário:

$$\frac{\sqrt{n}(\bar{X}_n - p)}{\sqrt{p(1-p)}} \xrightarrow{D} N(0, 1) \quad (123)$$

Aplicação Prática

Para testar $H_0 : p = 1/2$ em uma moeda:

- Jogar a moeda n vezes e observar S_n caras
- Calcular $Z = 2(S_n - n/2)/\sqrt{n}$
- Rejeitar H_0 ao nível α se $|Z| > z_{\alpha/2}$

Exemplo: $n = 100$ jogadas, observamos 60 caras.

$$Z = \frac{2(60 - 50)}{\sqrt{100}} = \frac{20}{10} = 2 \quad (124)$$

$$|Z| = 2 > 1.96 = z_{0.025} \quad (125)$$

Concluimos que há evidência contra $p = 1/2$ ao nível 5%.

Resumo da Questão

Resultado Principal:

$$2\sqrt{n} \left(\bar{X}_n - \frac{1}{2} \right) \xrightarrow{D} N(0, 1)$$

Método Utilizado:

- Cálculo da MGF de U_n
- Expansão de Taylor de $e^{\pm t/\sqrt{n}}$
- Limite (R.3): $(1 + x/n)^n \rightarrow e^x$
- Resultado 1D: convergência via MGF

Importância: Demonstração alternativa do TCL via MGF para Bernoulli.

8 Questão Extra 7: Transformação de Q_n via Slutsky

Questão Extra 7 (continuação da Extra 4)

Sejam $\{X_n, n \geq 1\}$ i.i.d. com $X_n \sim U(0, \theta)$, $T_n = X_{n:n}$,

$$U_n = n \cdot (\theta - T_n)/\theta \quad \text{e} \quad Q_n = n \cdot (\theta - T_n)/T_n.$$

Encontre a distribuição limite de Q_n .

Solução Detalhada

Estratégia da Demonstração

Usaremos o **Teorema de Slutsky** (Resultado 3D) combinando convergências em distribuição e em probabilidade.

Passo 1: Resultados Conhecidos

Da **Questão Extra 5**, sabemos que:

$$U_n = \frac{n(\theta - T_n)}{\theta} \xrightarrow{d} E \sim \text{Exp}(1) \quad (126)$$

Da **Questão Extra 2**, sabemos que:

$$T_n \xrightarrow{p} \theta \quad (127)$$

Passo 2: Convergência de θ/T_n

Pelo **Resultado 4P** (operações com convergência em probabilidade), se $T_n \xrightarrow{p} \theta$ e $\theta \neq 0$:

$$\frac{\theta}{T_n} \xrightarrow{p} \frac{\theta}{\theta} = 1 \quad (128)$$

Passo 3: Reescrever Q_n

Observe que podemos reescrever Q_n como:

$$Q_n = \frac{n(\theta - T_n)}{T_n} \quad (129)$$

$$= \frac{n(\theta - T_n)}{\theta} \cdot \frac{\theta}{T_n} \quad (130)$$

$$= U_n \cdot \frac{\theta}{T_n} \quad (131)$$

Passo 4: Aplicação do Teorema de Slutsky

Temos:

- $U_n \xrightarrow{d} E \sim \text{Exp}(1)$ (convergência em distribuição)
- $\theta/T_n \xrightarrow{p} 1$ (convergência em probabilidade)

Pelo **Resultado 3D (Teorema de Slutsky)**, item (b):

$$Q_n = U_n \cdot \frac{\theta}{T_n} \xrightarrow{d} E \cdot 1 = E \quad (132)$$

Conclusão

$$Q_n = \frac{n(\theta - T_n)}{T_n} \xrightarrow{d} \text{Exp}(1) \quad \square \quad (133)$$

Pontos Importantes

1. **Poder do Teorema de Slutsky:** Esta questão ilustra perfeitamente o uso do Slutsky:

- Combinamos uma convergência em distribuição ($U_n \xrightarrow{d} E$)
- Com uma convergência em probabilidade ($\theta/T_n \xrightarrow{p} 1$)
- E obtemos convergência em distribuição do produto

2. **Comparação U_n vs Q_n :**

- $U_n = n(\theta - T_n)/\theta$ normaliza usando o valor verdadeiro θ
- $Q_n = n(\theta - T_n)/T_n$ normaliza usando o estimador T_n
- Ambos têm a MESMA distribuição limite (Exponencial)!
- Isso mostra que podemos substituir θ por T_n sem alterar a distribuição limite

3. **Aplicação Prática:** Na prática, não conhecemos θ , então usamos:

$$Q_n = \frac{n(\theta - X_{n:n})}{X_{n:n}} \quad (134)$$

que tem distribuição assintótica $\text{Exp}(1)$, permitindo construir testes e IC.

4. **Estrutura da Demonstração:**

- Identificar a fatoração: $Q_n = U_n \cdot (\theta/T_n)$
- Verificar: $U_n \xrightarrow{d} E$ e $\theta/T_n \xrightarrow{p} 1$
- Aplicar Slutsky: produto converge para $E \cdot 1 = E$

5. **Generalização:** Se $U_n \xrightarrow{d} U$ e $V_n \xrightarrow{p} c$ (constante), então:

$$\frac{U_n}{V_n} \xrightarrow{d} \frac{U}{c} \quad (135)$$

Este é o item (c) do Teorema de Slutsky.

Exemplo Numérico

Suponha $\theta = 10$ (desconhecido), $n = 50$, e observamos $x_{n:n} = 9.8$.
Estimamos:

$$Q_{\text{obs}} = \frac{50(10 - 9.8)}{9.8} = \frac{50 \cdot 0.2}{9.8} \approx 1.02 \quad (136)$$

Para IC de 95%: queremos a e b tais que $P(a < E < b) = 0.95$.

Para $\text{Exp}(1)$: $P(E < 2.996) = 0.95$, então um IC aproximado para θ é:

$$\theta \approx X_{n:n} + \frac{X_{n:n} \cdot 2.996}{n} = 9.8 + \frac{9.8 \cdot 2.996}{50} \approx 10.39 \quad (137)$$

Resumo da Questão

Resultado Principal:

$$Q_n = \frac{n(\theta - X_{n:n})}{X_{n:n}} \xrightarrow{D} \text{Exp}(1)$$

Método Utilizado:

- Fatoração: $Q_n = U_n \cdot (\theta/T_n)$
- Extra 5: $U_n \xrightarrow{d} \text{Exp}(1)$
- Extra 2: $T_n \xrightarrow{p} \theta \Rightarrow \theta/T_n \xrightarrow{p} 1$
- Slutsky: produto converge

Importância: Permite construir IC para θ usando apenas dados observados.

9 Questão Extra 9: Distribuição Assintótica de $\sqrt{n}(S_n^2 - \sigma^2)$

Questão Extra 9

Sejam X_1, \dots, X_n uma a.a. de $X \sim N(\mu, \sigma^2)$ tal que $\mu, \sigma^2 < \infty$. Encontre a distribuição assintótica de:

$$H_n = \sqrt{n}(S_n^2 - \sigma^2) \quad (138)$$

Solução Detalhada

Estratégia da Demonstração

Usaremos a transformação de Helmert, o TCL e o Teorema de Slutsky.

Passo 1: Representação via Helmert

Usando a transformação de Helmert:

$$S_n^2 = \frac{1}{n-1} \sum_{i=2}^n Y_i^2, \quad \text{para } Y_i \sim N(0, \sigma^2) \quad (139)$$

Isso caracteriza S_n^2 como uma média amostral de Y_i^2 .

Passo 2: Aplicação do TCL

As variáveis $\{Y_i^2, i = 2, \dots, n\}$ são i.i.d. com:

- $E[Y_i^2] = \sigma^2$
- $\text{Var}(Y_i^2) = E[Y_i^4] - (E[Y_i^2])^2 = 3\sigma^4 - \sigma^4 = 2\sigma^4$

(Cálculo de $E[Y_i^4] = 3\sigma^4$ visto na Questão Extra 1)

Pelo **Teorema 3.7.6.1(a)** (TCL) aplicado à média $\frac{1}{n-1} \sum_{i=2}^n Y_i^2$:

$$U_n = \sqrt{n-1} \left[\frac{1}{n-1} \sum_{i=2}^n Y_i^2 - E[Y_i^2] \right] \xrightarrow{d} N(0, \text{Var}(Y_i^2)) \quad (140)$$

Logo:

$$U_n = \sqrt{n-1}(S_n^2 - \sigma^2) \xrightarrow{d} N(0, 2\sigma^4) \quad (141)$$

Solução Detalhada

Passo 3: Ajuste para \sqrt{n}

Queremos a distribuição de $H_n = \sqrt{n}(S_n^2 - \sigma^2)$.

Defina:

$$V_n = \frac{n}{n-1} = 1 + \frac{1}{n-1} \quad (142)$$

Então:

$$H_n = \sqrt{n}(S_n^2 - \sigma^2) = \sqrt{\frac{n}{n-1}} \cdot \sqrt{n-1}(S_n^2 - \sigma^2) = \sqrt{V_n} \cdot U_n \quad (143)$$

Passo 4: Convergência de V_n

Precisamos mostrar que $V_n \xrightarrow{p} 1$.

Pela desigualdade de Chebyshev:

$$P(|V_n - 1| \geq \varepsilon) = P\left(\left|\frac{1}{n-1}\right| \geq \varepsilon\right) \quad (144)$$

$$\leq P\left(\left|\frac{1}{n-1}\right|^2 \geq \varepsilon^2\right) \quad (145)$$

$$\leq \frac{E[(V_n - 1)^2]}{\varepsilon^2} \quad (146)$$

$$= \frac{(n/(n-1) - 1)^2}{\varepsilon^2} \quad (147)$$

$$= \frac{1}{(n-1)^2 \varepsilon^2} \xrightarrow{n \rightarrow \infty} 0 \quad (148)$$

Logo, $V_n \xrightarrow{p} 1$, e portanto $\sqrt{V_n} \xrightarrow{p} 1$ (Resultado 5P).

Passo 5: Aplicação do Teorema de Slutsky

Temos:

- $U_n \xrightarrow{d} N(0, 2\sigma^4)$ (convergência em distribuição)
- $\sqrt{V_n} \xrightarrow{p} 1$ (convergência em probabilidade)

Pelo **Resultado 3D (Teorema de Slutsky)**, item (b):

$$H_n = U_n \cdot \sqrt{V_n} \xrightarrow{d} N(0, 2\sigma^4) \cdot 1 = N(0, 2\sigma^4) \quad (149)$$

Conclusão

$$\sqrt{n}(S_n^2 - \sigma^2) \xrightarrow{d} N(0, 2\sigma^4) \quad \square \quad (150)$$

Pontos Importantes

1. **Caso Especial do Teorema 3.7.6.3(a):** Para $X_i \sim N(\mu, \sigma^2)$:

- $\mu_4 = E[(X_i - \mu)^4] = 3\sigma^4$ (momento de quarta ordem da normal)
- Logo, $\mu_4 - \sigma^4 = 3\sigma^4 - \sigma^4 = 2\sigma^4$
- O resultado geral dá: $\sqrt{n}(S_n^2 - \sigma^2) \xrightarrow{D} N(0, \mu_4 - \sigma^4) = N(0, 2\sigma^4)$

2. **Diferença $\sqrt{n-1}$ vs \sqrt{n} :**

- A transformação de Helmert produz $n-1$ variáveis para S_n^2
- O TCL aplicado diretamente dá $\sqrt{n-1}(S_n^2 - \sigma^2) \xrightarrow{D} N(0, 2\sigma^4)$
- Precisamos ajustar para \sqrt{n} usando Slutsky

3. **Aplicação a Testes:** Este resultado permite testar $H_0 : \sigma^2 = \sigma_0^2$:

$$Z = \frac{\sqrt{n}(S_n^2 - \sigma_0^2)}{\sqrt{2}\sigma_0^2} \xrightarrow{D} N(0, 1) \quad (151)$$

4. **Intervalo de Confiança Assintótico:** IC de $(1 - \alpha)$ para σ^2 :

$$S_n^2 \pm z_{\alpha/2} \cdot \frac{\sqrt{2}\sigma^2}{\sqrt{n}} \quad (152)$$

(na prática, substituímos σ^2 por S_n^2)

5. **Taxa de Convergência:** A variância assintótica é $2\sigma^4$, então:

$$\text{Var}(S_n^2) \approx \frac{2\sigma^4}{n} \quad (153)$$

6. **Generalização para Não-Normais:** Para distribuições não-normais, a variância assintótica é $\mu_4 - \sigma^4$, que pode ser diferente de $2\sigma^4$.

Conexão com Helmert

A transformação de Helmert separa:

- $Y_1 = \sqrt{n} \bar{X}_n$ (relacionado à média)
- Y_2, \dots, Y_n (relacionados à variância)

E preserva:

$$\sum_{i=1}^n (X_i - \mu)^2 = \sum_{i=1}^n Y_i^2 = n\bar{X}_n^2 + (n-1)S_n^2 \quad (154)$$

Resumo da Questão

Resultado Principal:

$$\sqrt{n}(S_n^2 - \sigma^2) \xrightarrow{D} N(0, 2\sigma^4)$$

Método Utilizado:

- Helmert: $S_n^2 = \frac{1}{n-1} \sum_{i=2}^n Y_i^2$
- TCL: $\sqrt{n-1}(S_n^2 - \sigma^2) \xrightarrow{D} N(0, 2\sigma^4)$
- Slutsky: ajuste de $\sqrt{n-1}$ para \sqrt{n}

Importância: Base para testes e IC para σ^2 .

10 Questão Extra 10: Método Delta para Poisson

Questão Extra 10

Sejam X_1, \dots, X_n v.a.'s i.i.d. tais que $X_i \sim \text{Poisson}(\lambda)$. Encontre a distribuição assintótica de:

$$\sqrt{n}(\bar{X}_n^3 - \lambda^3) \quad (155)$$

Solução Detalhada

Estratégia da Demonstração

Usaremos o **Teorema de Mann–Wald (Método Delta)** - Teorema 3.7.6.2(a).

Passo 1: Verificar Condições

Para aplicar o Método Delta, precisamos:

1. Uma estatística T_n com normalidade assintótica: $\sqrt{n}(T_n - \theta) \xrightarrow{D} N(0, \sigma^2(\theta))$
2. Uma função g continuamente diferenciável com $g'(\theta) \neq 0$

Passo 2: Normalidade Assintótica de \bar{X}_n

Para $X_i \sim \text{Poisson}(\lambda)$:

- $E[X_i] = \lambda$
- $\text{Var}(X_i) = \lambda$ (propriedade da Poisson)

Pode-se mostrar que $E[X_i^3] < \infty$ e $\text{Var}(X_i^3) < \infty$.

Pelo **Teorema Central do Limite**:

$$\sqrt{n}(\bar{X}_n - \lambda) \xrightarrow{d} N(0, \lambda) \quad (156)$$

Ou equivalentemente (forma padronizada):

$$\frac{\sqrt{n}(\bar{X}_n - \lambda)}{\sqrt{\lambda}} \xrightarrow{d} N(0, 1) \quad (157)$$

Passo 3: Escolha da Função

Definimos:

$$g(\lambda) = \lambda^3 \quad (158)$$

Esta função é continuamente diferenciável com:

$$g'(\lambda) = 3\lambda^2 \neq 0 \quad (\text{para } \lambda > 0) \quad (159)$$

Solução Detalhada

Passo 4: Aplicação do Método Delta

Pelo **Teorema 3.7.6.2(a)** (Método Delta):

Se $\sqrt{n}(T_n - \theta) \xrightarrow{D} N(0, \sigma^2(\theta))$ e $g'(\theta) \neq 0$, então:

$$\sqrt{n}[g(T_n) - g(\theta)] \xrightarrow{D} N(0, \sigma^2(\theta) \cdot [g'(\theta)]^2) \quad (160)$$

Aplicação ao nosso caso:

- $T_n = \bar{X}_n$
- $\theta = \lambda$
- $\sigma^2(\lambda) = \lambda$
- $g(\lambda) = \lambda^3$
- $g'(\lambda) = 3\lambda^2$

Portanto:

$$\sqrt{n}[g(\bar{X}_n) - g(\lambda)] \xrightarrow{D} N(0, \lambda \cdot [3\lambda^2]^2) \quad (161)$$

$$\sqrt{n}(\bar{X}_n^3 - \lambda^3) \xrightarrow{D} N(0, \lambda \cdot 9\lambda^4) \quad (162)$$

$$\xrightarrow{D} N(0, 9\lambda^5) \quad (163)$$

Conclusão

$$\sqrt{n}(\bar{X}_n^3 - \lambda^3) \xrightarrow{d} N(0, 9\lambda^5) \quad \square \quad (164)$$

Pontos Importantes

1. **Método Delta em Ação:** Esta questão demonstra perfeitamente como o Método Delta funciona:

- Começamos com normalidade de \bar{X}_n
- Aplicamos transformação não-linear $g(\lambda) = \lambda^3$
- A derivada amplifica a variância: $\text{Var} \leftarrow \lambda \cdot (3\lambda^2)^2 = 9\lambda^5$

2. **Fórmula do Método Delta:** A variância assintótica sempre tem a forma:

$$\text{Var}_{\text{assintótica}}[g(\bar{X}_n)] = [g'(\theta)]^2 \cdot \text{Var}_{\text{assintótica}}[\bar{X}_n] \quad (165)$$

3. **Interpretação da Derivada:** $g'(\lambda) = 3\lambda^2$ mede a "sensibilidade" de λ^3 a mudanças em λ . Valores grandes de λ amplificam mais o erro.

4. **IC Assintótico para λ^3 :** Podemos construir:

$$\bar{X}_n^3 \pm z_{\alpha/2} \cdot \frac{3\bar{X}_n^{5/2}}{\sqrt{n}} \quad (166)$$

(substituindo λ por \bar{X}_n)

5. **Comparação com Estimação Direta:** Se quiséssemos estimar λ^3 diretamente:

- Poderíamos usar \bar{X}_n^3 (pelo Método Delta)
- Ou usar a média de X_i^3 (que também funciona, mas requer calcular $E[X_i^3]$ e $\text{Var}(X_i^3)$)

6. **Generalização:** Para qualquer g diferenciável:

$$\sqrt{n}[g(\bar{X}_n) - g(\lambda)] \xrightarrow{D} N(0, [g'(\lambda)]^2 \lambda) \quad (167)$$

Exemplos:

- $g(\lambda) = \sqrt{\lambda}$: variância assintótica = $\frac{1}{4\lambda} \cdot \lambda = \frac{1}{4}$
- $g(\lambda) = \log \lambda$: variância assintótica = $\frac{1}{\lambda^2} \cdot \lambda = \frac{1}{\lambda}$
- $g(\lambda) = e^\lambda$: variância assintótica = $e^{2\lambda} \cdot \lambda$

Exemplo Numérico

Suponha $n = 100$, observamos $\bar{x}_n = 5$.

Estimativa pontual: $\hat{\lambda}^3 = 5^3 = 125$

Erro padrão assintótico:

$$\text{SE} = \frac{3 \cdot 5^{5/2}}{\sqrt{100}} = \frac{3 \cdot 55.90}{10} \approx 16.77 \quad (168)$$

IC de 95%:

41

$$125 \pm 1.96 \cdot 16.77 = 125 \pm 32.87 = [92.13, 157.87] \quad (169)$$

Resumo da Questão

Resultado Principal:

$$\sqrt{n}(\bar{X}_n^3 - \lambda^3) \xrightarrow{D} N(0, 9\lambda^5)$$

Método Utilizado:

- TCL: $\sqrt{n}(\bar{X}_n - \lambda) \xrightarrow{D} N(0, \lambda)$
- Função: $g(\lambda) = \lambda^3$ com $g'(\lambda) = 3\lambda^2$
- Método Delta: variância = $\lambda \cdot (3\lambda^2)^2 = 9\lambda^5$

Importância: Demonstra como obter distribuição assintótica de transformações não-lineares.

11 Questão 3.23: Consistência do EMV para Uniforme

Questão 3.23

Sejam X_1, \dots, X_n uma amostra de $X \sim U(0, \theta)$. Mostre que o estimador de máxima verossimilhança para θ , $T_n = X_{n:n}$, é consistente para θ .

Solução Detalhada

Estratégia da Demonstração

Mostraremos diretamente que $P_\theta(|X_{n:n} - \theta| < \varepsilon) \rightarrow 1$ para todo $\varepsilon > 0$.

Passo 1: Função de Distribuição de $X_{n:n}$

Da Questão Extra 2, temos:

$$F_{X_{n:n}}(t) = \begin{cases} 0, & t < 0, \\ \left(\frac{t}{\theta}\right)^n, & 0 \leq t \leq \theta, \\ 1, & t > \theta \end{cases} \quad (170)$$

Passo 2: Probabilidade de Estar Próximo de θ

Para $\varepsilon > 0$:

$$P_\theta(|X_{n:n} - \theta| < \varepsilon) = P_\theta(\theta - \varepsilon < X_{n:n} < \theta + \varepsilon) \quad (171)$$

$$= P_\theta(\theta - \varepsilon < X_{n:n} < \theta) \quad (172)$$

(pois $X_{n:n} \leq \theta$ sempre, já que todas as observações $\leq \theta$)

$$= F_{X_{n:n}}(\theta) - F_{X_{n:n}}(\theta - \varepsilon) \quad (173)$$

$$= 1 - F_{X_{n:n}}(\theta - \varepsilon) \quad (174)$$

Passo 3: Análise por Casos

Caso 1: $\varepsilon \geq \theta$ Se $\varepsilon \geq \theta$, então $\theta - \varepsilon \leq 0$, logo:

$$F_{X_{n:n}}(\theta - \varepsilon) = 0 \quad (175)$$

Portanto:

$$P_\theta(|X_{n:n} - \theta| < \varepsilon) = 1 - 0 = 1 \quad (176)$$

Caso 2: $\varepsilon < \theta$ Se $0 < \varepsilon < \theta$, então $0 < \theta - \varepsilon < \theta$, logo:

$$F_{X_{n:n}}(\theta - \varepsilon) = \left(\frac{\theta - \varepsilon}{\theta}\right)^n \quad (177)$$

$$= \left(1 - \frac{\varepsilon}{\theta}\right)^n \quad (178)$$

Portanto:

$$P_\theta(|X_{n:n} - \theta| < \varepsilon) = 1 - \left(1 - \frac{\varepsilon}{\theta}\right)^n \quad (179)$$

Solução Detalhada

Passo 4: Limite quando $n \rightarrow \infty$

Para $\varepsilon < \theta$ fixado:

$$\lim_{n \rightarrow \infty} P_{\theta}(|X_{n:n} - \theta| < \varepsilon) = \lim_{n \rightarrow \infty} \left[1 - \left(1 - \frac{\varepsilon}{\theta} \right)^n \right] \quad (180)$$

$$= 1 - 0 \quad (181)$$

$$= 1 \quad (182)$$

pois $0 < 1 - \varepsilon/\theta < 1$ e portanto $(1 - \varepsilon/\theta)^n \rightarrow 0$ quando $n \rightarrow \infty$.

Conclusão

Para todo $\varepsilon > 0$:

$$\lim_{n \rightarrow \infty} P_{\theta}(|X_{n:n} - \theta| < \varepsilon) = 1 \quad (183)$$

Equivalentemente:

$$\lim_{n \rightarrow \infty} P_{\theta}(|X_{n:n} - \theta| \geq \varepsilon) = 0 \quad (184)$$

Portanto, pela definição de convergência em probabilidade:

$$X_{n:n} \xrightarrow[n \rightarrow \infty]{P} \theta \quad \square \quad (185)$$

Logo, o EMV $\hat{\theta}_n = X_{n:n}$ é consistente para θ .

Pontos Importantes

1. **Método Direto vs. EQM:** Esta solução usa a *definição* de convergência em probabilidade diretamente, enquanto a Questão Extra 2 usou o EQM. Ambas são válidas!

2. **Tamanho Amostral Mínimo:** Das notas (n32), podemos encontrar o menor n_0 tal que:

$$P(|X_{n:n} - \theta| < \varepsilon) \geq 1 - \delta \quad (186)$$

Resolvendo $1 - (1 - \varepsilon/\theta)^n \geq 1 - \delta$:

$$(1 - \varepsilon/\theta)^n \leq \delta \quad (187)$$

$$n \geq \frac{\log \delta}{\log(1 - \varepsilon/\theta)} \quad (188)$$

Logo:

$$n_0 = \left\lceil \frac{\log \delta}{\log(1 - \varepsilon/\theta)} \right\rceil + 1 \quad (189)$$

3. **Exemplo Numérico:** Para $\theta = 10$, $\varepsilon = 1$, $\delta = 0.05$:

$$n_0 \geq \frac{\log(0.05)}{\log(1 - 0.1)} \quad (190)$$

$$= \frac{-2.996}{-0.1054} \quad (191)$$

$$\approx 28.43 \quad (192)$$

Portanto, $n_0 = 29$. Com 29 ou mais observações, temos pelo menos 95% de chance de $X_{n:n}$ estar a menos de 1 unidade de $\theta = 10$.

4. **EMV para Uniforme:** A verossimilhança é:

$$L(\theta; x) = \prod_{i=1}^n \frac{1}{\theta} \mathbf{1}_{0 < x_i < \theta} = \frac{1}{\theta^n} \mathbf{1}_{\theta > \max\{x_i\}} \quad (193)$$

Maximizar L é equivalente a minimizar θ^n sujeito a $\theta \geq \max\{x_i\}$, logo $\hat{\theta} = \max\{x_i\} = X_{n:n}$.

5. **Comparação com Método dos Momentos:** O estimador de momentos seria:

$$\tilde{\theta}_n = 2\bar{X}_n \quad (194)$$

(pois $E[X] = \theta/2$). Ambos são consistentes, mas o EMV é preferível por ter menor variância assintótica.

Resumo da Questão

Resultado Principal:

$$\hat{\theta}_n = X_{n:n} \xrightarrow{P} \theta$$

Método Utilizado:

- Definição direta de convergência em probabilidade
- Cálculo de $P(|X_{n:n} - \theta| < \varepsilon)$ via fda
- Limite: $(1 - \varepsilon/\theta)^n \rightarrow 0$

Importância: Prova rigorosa da consistência do EMV para a Uniforme(0, θ).

Conclusão

Este documento apresentou soluções detalhadas e didáticas para as principais questões extras do Capítulo 3 sobre Teoria Assintótica resolvidas em sala de aula.

Síntese dos Tópicos Abordados

1. Convergência em Probabilidade (Q Extra 1–4):

- Variância amostral S_n^2 via transformação de Helmert
- Máximo da uniforme via cálculo de momentos
- Operações algébricas com convergentes (quociente)
- Funções contínuas preservam convergência

2. Convergência em Distribuição (Q Extra 5, Exercício 11):

- Distribuição limite Exponencial do máximo normalizado
- Estatística qui-quadrado via TCL e função contínua

3. Consistência de Estimadores (Q 3.23):

- Consistência do EMV para Uniforme
- Demonstração via definição direta

Conexões Entre as Questões

- Q Extra 1 \rightarrow Q Extra 3: S_n^2 consistente \Rightarrow quociente converge
- Q Extra 2 \rightarrow Q Extra 4: $X_{n:n}$ consistente $\Rightarrow X_{n:n}^2$ consistente
- Q Extra 2 \rightarrow Q Extra 5: Convergência em P \rightarrow distribuição limite
- TCL \rightarrow Exercício 11: Normal \rightarrow qui-quadrado via função contínua

Principais Técnicas Demonstradas

1. **Transformação de Helmert** - representar estatísticas como médias
2. **Cálculo de momentos** - mostrar $EQM \rightarrow 0$
3. **Operações algébricas** - Resultado 4P
4. **Funções contínuas** - Resultados 5P e Teorema 3.7.6.4(a)
5. **Cálculo de fda** - identificar distribuições limite
6. **Limites fundamentais** - (R.1), (R.2), (R.3)

Mensagens Principais

- Convergência em probabilidade permite trabalhar com estimadores como se fossem constantes
- Funções contínuas preservam ambos os tipos de convergência
- Distribuições limite nem sempre são normais (Ex: Exponencial)
- EMVs são geralmente consistentes (sob condições de regularidade)
- Transformações de normalização revelam taxas de convergência

Recomendações de Estudo

Para dominar o material:

1. Refaça todas as questões sem consultar as soluções
2. Identifique qual resultado/teorema aplicar em cada passo
3. Conecte as questões com a teoria do arquivo `teoria_cap3_completo.tex`
4. Pratique variações (e.g., $U(a, b)$ em vez de $U(0, \theta)$)
5. Simule dados no R/Python para visualizar as convergências

Bom estudo! Dominar estas técnicas é essencial para inferência estatística.