

# Questões Resolvidas do Capítulo 3

## Teoria Assintótica - Soluções Detalhadas

Curso de Inferência Estatística - PPGEST/UFPE  
Compilado e detalhado

Novembro 2025

## Sumário

<b>Introdução</b>	<b>2</b>
<b>1 Questão Extra 1: Convergência da Variância Amostral</b>	<b>3</b>
<b>2 Questão Extra 2: Consistência do Máximo da Uniforme</b>	<b>8</b>
<b>3 Questão Extra 3: Convergência do Quociente</b>	<b>13</b>
<b>4 Questão Extra 4: Função Contínua de Convergente</b>	<b>16</b>
<b>5 Questão Extra 5: Distribuição Limite do Máximo Uniforme</b>	<b>18</b>
<b>6 Exercício 11: Estatística Qui-Quadrado via TCL</b>	<b>22</b>
<b>7 Questão Extra 6: TCL para Bernoulli via MGF</b>	<b>26</b>
<b>8 Questão Extra 7: Transformação de <math>Q_n</math> via Slutsky</b>	<b>31</b>
<b>9 Questão Extra 9: Distribuição Assintótica de <math>\sqrt{n}(S_n^2 - \sigma^2)</math></b>	<b>35</b>
<b>10 Questão Extra 10: Método Delta para Poisson</b>	<b>39</b>
<b>11 Questão 3.23: Consistência do EMV para Uniforme</b>	<b>43</b>
<b>Conclusão</b>	<b>48</b>

# Introdução

Este documento apresenta todas as questões extras resolvidas em sala de aula do Capítulo 3 sobre Teoria Assintótica e Teoremas Limite. As soluções foram expandidas com explicações detalhadas, intuições e comentários didáticos para facilitar o entendimento completo dos conceitos.

## Organização do Documento

Cada questão está organizada da seguinte forma:

1. **Enunciado** - apresentação completa do problema
2. **Solução Detalhada** - desenvolvimento passo a passo
3. **Observações e Intuição** - comentários sobre o método e interpretações
4. **Resumo** - síntese dos principais resultados

## Questões Incluídas

- Q(Extra 1) - Convergência da variância amostral  $S_n^2$
- Q(Extra 2) - Consistência do máximo:  $X_{(n)} \xrightarrow{P} \theta$
- Q(Extra 3) - Convergência do quociente  $\bar{X}_n/S_n^2$
- Q(Extra 4a) - Transformação do máximo:  $T_n^2 = X_{n:n}^2$
- Q(Extra 4b) - Convergência de  $Q_n = n(\theta - T_n)/T_n$
- Q(Extra 5) - Distribuição limite do máximo uniforme (Exponencial)
- Q(Extra 6) - TCL para Bernoulli via MGF
- Q(Questão 4) - Distribuição assintótica de  $\chi^2$  normalizada
- Q(Extra 9) - Distribuição assintótica de  $\sqrt{n}(S_n^2 - \sigma^2)$
- Q(Extra 10) - Método Delta para Poisson:  $\bar{X}_n^3$
- Q(Exercício 11) - Estatística qui-quadrado via TCL
- Q(3.23) - Consistência do EMV para Uniforme

# 1 Questão Extra 1: Convergência da Variância Amostral

## Questão Extra 1

Sejam  $X_1, \dots, X_n$  v.a.'s i.i.d. com  $E[X_i] = \mu < \infty$  e  $\text{Var}(X_i) = \sigma^2 < \infty$ . Mostre que:

$$S_n^2 \xrightarrow{P} \sigma^2 \quad (1)$$

onde  $S_n^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X}_n)^2$  é a variância amostral.

## Solução Detalhada

### Estratégia da Demonstração

Usaremos a **transformação de Helmert** para representar  $S_n^2$  como uma média amostral de variáveis com propriedades conhecidas, permitindo aplicar a Lei Fraca dos Grandes Números.

### Passo 1: Transformação de Helmert

A transformação de Helmert produz variáveis ortogonais  $Y_1, \dots, Y_n$  a partir de  $X_1, \dots, X_n$  tais que:

$$Y_i \sim N(0, \sigma^2) \text{ são independentes para } i = 1, \dots, n \quad (2)$$

E, crucialmente:

$$S_n^2 = \frac{1}{n-1} \sum_{i=2}^n Y_i^2 \quad (3)$$

**Interpretação:** A variância amostral pode ser vista como uma média (com  $n-1$  termos) de quadrados de variáveis normais padrão.

## Solução Detalhada

### Passo 2: Momentos de $Y_i^2$

Calculemos  $E[Y_i^2]$  e  $\text{Var}(Y_i^2)$ .

**Esperança:**

$$E[Y_i^2] = \text{Var}(Y_i) + (E[Y_i])^2 = \sigma^2 + 0 = \sigma^2 \quad (4)$$

**Variância:** Precisamos calcular  $E[Y_i^4]$ . Como  $Y_i \sim N(0, \sigma^2)$ , a MGF de  $Y_i^2$  é conhecida. Calculando as derivadas da MGF:

$$M_{Y_i^2}(t) = (1 - 2\sigma^2 t)^{-1/2} \quad (5)$$

Derivando sucessivamente e avaliando em  $t = 0$ :

$$M'_{Y_i^2}(t) \Big|_{t=0} = 0 = E[Y_i] \quad (6)$$

$$M''_{Y_i^2}(t) \Big|_{t=0} = \sigma^2 = E[Y_i^2] \quad (7)$$

$$M'''_{Y_i^2}(t) \Big|_{t=0} = 0 = E[Y_i^3] \quad (8)$$

$$M''''_{Y_i^2}(t) \Big|_{t=0} = 3\sigma^4 = E[Y_i^4] \quad (9)$$

(Os cálculos completos das derivadas estão nas notas n9, linhas 21-38)

Portanto:

$$\text{Var}(Y_i^2) = E[Y_i^4] - (E[Y_i^2])^2 = 3\sigma^4 - \sigma^4 = 2\sigma^4 < \infty \quad (10)$$

## Solução Detalhada

### Passo 3: Aplicação do Resultado 1P

Como  $S_n^2 = \frac{1}{n-1} \sum_{i=2}^n Y_i^2$  é uma média amostral de  $n - 1$  variáveis i.i.d. com:

- $E[Y_i^2] = \sigma^2$
- $\text{Var}(Y_i^2) = 2\sigma^4 < \infty$

Pelo **Resultado 1P (Lei Fraca dos Grandes Números - versão simples)**:

$$S_n^2 \xrightarrow{P} E[Y_i^2] = \sigma^2 \quad \square \quad (11)$$

## Observações e Intuição

### Pontos Importantes

1. **Transformação de Helmert:** Esta é uma transformação ortogonal crucial que:

- Preserva a soma dos quadrados:  $\sum_{i=1}^n X_i^2 = \sum_{i=1}^n Y_i^2$
- Separa a informação sobre média ( $Y_1$ ) da informação sobre variância ( $Y_2, \dots, Y_n$ )
- Produz variáveis independentes quando  $X_i \sim N(\mu, \sigma^2)$

2. **Por que funciona para não-normais?** Embora a transformação de Helmert seja exata para normais, o resultado vale para qualquer distribuição com variância finita. A chave é que:

$$S_n^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X}_n)^2 \quad (12)$$

pode ser aproximada por  $\frac{1}{n} \sum_{i=1}^n (X_i - \mu)^2$  e aplicar a LFGN diretamente.

## Observações e Intuição

### Pontos Importantes (continuação)

5. **Taxa de convergência:** Pelo Resultado 2P, a variância de  $S_n^2$  decai como  $O(1/n)$ :

$$\text{Var}(S_n^2) = \frac{2\sigma^4}{n-1} \rightarrow 0 \quad (13)$$

6. **Distribuição assintótica:** Além de convergência em probabilidade, veremos na Questão Extra 9 que:

$$\sqrt{n}(S_n^2 - \sigma^2) \xrightarrow{D} N(0, \mu_4 - \sigma^4) \quad (14)$$

fornecendo informação sobre a velocidade de convergência.

## Resumo da Questão

### Resultado Principal:

$$S_n^2 \xrightarrow{P} \sigma^2$$

### Método Utilizado:

- Representação via Helmert:  $S_n^2 = \frac{1}{n-1} \sum_{i=2}^n Y_i^2$
- Lei Fraca dos Grandes Números (Resultado 1P)
- Momentos:  $E[Y_i^2] = \sigma^2$ ,  $\text{Var}(Y_i^2) = 2\sigma^4 < \infty$

**Conclusão:**  $S_n^2$  é consistente para  $\sigma^2$ .

## 2 Questão Extra 2: Consistência do Máximo da Uniforme

### Questão Extra 2

Sejam  $X_1, \dots, X_n$  v.a.'s i.i.d. com  $X_i \sim \text{Uniforme}(0, \theta)$  para  $\theta > 0$ . Mostre que:

$$T_n = X_{(n)} = \max\{X_1, \dots, X_n\} \xrightarrow{P} \theta \quad (15)$$

### Solução Detalhada

#### Estratégia da Demonstração

Calcularemos  $E[(T_n - \theta)^2]$  e mostraremos que converge para zero. Pelo **Resultado 2P**, isso implica convergência em probabilidade.

#### Passo 1: Distribuição de $T_n = X_{(n)}$

Para a maior estatística de ordem:

$$F_{T_n}(t) = P(T_n \leq t) = P(\max\{X_1, \dots, X_n\} \leq t) \quad (16)$$

$$= P(X_1 \leq t, \dots, X_n \leq t) \quad (17)$$

$$\stackrel{\text{i.i.d.}}{=} [P(X_1 \leq t)]^n \quad (18)$$

$$= [F_{X_1}(t)]^n \quad (19)$$

Para  $X_i \sim U(0, \theta)$ :

$$F_{X_1}(t) = \begin{cases} 0, & t < 0 \\ \frac{t}{\theta}, & 0 \leq t \leq \theta \\ 1, & t > \theta \end{cases} \quad \text{e} \quad f_{X_1}(t) = \frac{1}{\theta} \mathbf{1}_{(0,\theta)}(t) \quad (20)$$

Portanto:

$$F_{T_n}(t) = \begin{cases} 0, & t < 0 \\ \left(\frac{t}{\theta}\right)^n, & 0 \leq t \leq \theta \\ 1, & t > \theta \end{cases} \quad (21)$$

A densidade é:

$$f_{T_n}(t) = n[F_{X_1}(t)]^{n-1} f_{X_1}(t) = \frac{n}{\theta^n} t^{n-1} \mathbf{1}_{(0,\theta)}(t) \quad (22)$$

## Solução Detalhada

### Passo 2: Cálculo dos Momentos

Primeiro momento:

$$E[T_n] = \int_0^\theta t \cdot \frac{n}{\theta^n} t^{n-1} dt \quad (23)$$

$$= \frac{n}{\theta^n} \int_0^\theta t^n dt \quad (24)$$

$$= \frac{n}{\theta^n} \cdot \frac{t^{n+1}}{n+1} \Big|_0^\theta \quad (25)$$

$$= \frac{n}{\theta^n} \cdot \frac{\theta^{n+1}}{n+1} \quad (26)$$

$$= \frac{n\theta}{n+1} \quad (27)$$

Segundo momento:

$$E[T_n^2] = \int_0^\theta t^2 \cdot \frac{n}{\theta^n} t^{n-1} dt \quad (28)$$

$$= \frac{n}{\theta^n} \int_0^\theta t^{n+1} dt \quad (29)$$

$$= \frac{n}{\theta^n} \cdot \frac{t^{n+2}}{n+2} \Big|_0^\theta \quad (30)$$

$$= \frac{n}{\theta^n} \cdot \frac{\theta^{n+2}}{n+2} \quad (31)$$

$$= \frac{n\theta^2}{n+2} \quad (32)$$

## Solução Detalhada

### Passo 3: Erro Quadrático Médio

$$E[(T_n - \theta)^2] = E[T_n^2] - 2\theta E[T_n] + \theta^2 \quad (33)$$

$$= \frac{n\theta^2}{n+2} - 2\theta \cdot \frac{n\theta}{n+1} + \theta^2 \quad (34)$$

$$= \theta^2 \left[ \frac{n}{n+2} - \frac{2n}{n+1} + 1 \right] \quad (35)$$

Colocando em denominador comum  $(n+2)(n+1)$ :

$$= \theta^2 \left[ \frac{n(n+1) - 2n(n+2) + (n+2)(n+1)}{(n+2)(n+1)} \right] \quad (36)$$

$$= \theta^2 \left[ \frac{n^2 + n - 2n^2 - 4n + n^2 + 3n + 2}{(n+2)(n+1)} \right] \quad (37)$$

$$= \theta^2 \left[ \frac{2}{(n+2)(n+1)} \right] \quad (38)$$

$$= \frac{2\theta^2}{(n+2)(n+1)} \xrightarrow{n \rightarrow \infty} 0 \quad (39)$$

### Passo 4: Conclusão

Como  $E[(T_n - \theta)^2] \rightarrow 0$ , pelo **Resultado 2P** (com  $r = 2$  e  $a = \theta$ ):

$$T_n = X_{(n)} \xrightarrow{P} \theta \quad \square \quad (40)$$

## Observações e Intuição

### Pontos Importantes

1. **Estatística de Ordem:**  $X_{(n)} = \max\{X_1, \dots, X_n\}$  é um estimador natural para o extremo superior  $\theta$  da uniforme.
2. **Viés do Estimador:** Note que:

$$E[T_n] = \frac{n\theta}{n+1} = \theta \left(1 - \frac{1}{n+1}\right) < \theta \quad (41)$$

O estimador é viesado negativamente, mas o viés  $\rightarrow 0$  quando  $n \rightarrow \infty$ .

3. **Estimador Não-Viesado:** Se quisermos um estimador não-viesado, podemos usar:

$$\tilde{T}_n = \frac{n+1}{n} X_{(n)} \quad (42)$$

pois  $E[\tilde{T}_n] = \frac{n+1}{n} \cdot \frac{n\theta}{n+1} = \theta$ .

4. **Taxa de Convergência:** O EQM decai como  $O(1/n^2)$ :

$$E[(T_n - \theta)^2] = O\left(\frac{1}{n^2}\right) \quad (43)$$

Isso é mais rápido que a taxa típica  $O(1/n)$  de muitos estimadores!

5. **EMV:** Na Questão 3.23, veremos que  $X_{(n)}$  é de fato o Estimador de Máxima Verossimilhança para  $\theta$  neste modelo.
6. **Comparação com  $\bar{X}_n$ :** A média amostral também é consistente ( $\bar{X}_n \xrightarrow{P} \theta/2$ ), mas  $X_{(n)}$  converge para o parâmetro de interesse  $\theta$ , não  $\theta/2$ .

### Interpretação Gráfica

## Resumo da Questão

**Resultado Principal:**

$$X_{(n)} \xrightarrow{P} \theta$$

**Método Utilizado:**

- Cálculo da densidade:  $f_{T_n}(t) = \frac{n}{\theta^n} t^{n-1} \mathbf{1}_{(0,\theta)}(t)$
- Momentos:  $E[T_n] = \frac{n\theta}{n+1}$ ,  $E[T_n^2] = \frac{n\theta^2}{n+2}$
- EQM:  $E[(T_n - \theta)^2] = \frac{2\theta^2}{(n+2)(n+1)} \rightarrow 0$
- Resultado 2P:  $E[|T_n - \theta|^2] \rightarrow 0 \Rightarrow T_n \xrightarrow{P} \theta$

**Importância:** Prova a consistência de  $X_{(n)}$  como estimador de  $\theta$  para  $U(0, \theta)$ .

### 3 Questão Extra 3: Convergência do Quociente

#### Questão Extra 3

Sejam  $X_1, \dots, X_n$  v.a.'s i.i.d. tais que  $X_i \sim N(\mu, \sigma^2)$  para  $\mu, \sigma^2 < \infty$ . Mostre que:

$$\frac{\bar{X}_n}{S_n^2} \xrightarrow{P} \frac{\mu}{\sigma^2} \quad (44)$$

#### Solução Detalhada

##### Estratégia da Demonstração

Usaremos o **Resultado 4P** sobre operações algébricas com convergências em probabilidade.

##### Passo 1: Convergências Individuais

Pelo **Resultado 1P** (Lei Fraca dos Grandes Números):

$$\bar{X}_n \xrightarrow{P} \mu \quad (45)$$

Pela **Questão Extra 1** (já demonstrada):

$$S_n^2 \xrightarrow{P} \sigma^2 \quad (46)$$

##### Passo 2: Aplicação do Resultado 4P

O **Resultado 4P** afirma que se  $U_n \xrightarrow{P} u$  e  $V_n \xrightarrow{P} v$  com  $v \neq 0$  e  $P(V_n = 0) = 0$  para todo  $n$ , então:

$$\frac{U_n}{V_n} \xrightarrow{P} \frac{u}{v} \quad (47)$$

Verificação das condições:

- $U_n = \bar{X}_n \xrightarrow{P} \mu \checkmark$
- $V_n = S_n^2 \xrightarrow{P} \sigma^2 \checkmark$
- $\sigma^2 > 0$  (por hipótese)  $\checkmark$
- $P(S_n^2 = 0) = 0$  para todo  $n \geq 2$   $\checkmark$  (precisa de pelo menos 2 observações diferentes)

##### Passo 3: Conclusão

Pelo Resultado 4P (item iii):

$$\frac{\bar{X}_n}{S_n^2} \xrightarrow{P} \frac{\mu}{\sigma^2} \quad \square \quad (48)$$

## Observações e Intuição

### Pontos Importantes

1. **Operações Algébricas Preservam Convergência:** O Resultado 4P é fundamental porque permite operar com limites em probabilidade como se fossem limites determinísticos:
  - Soma:  $U_n + V_n \xrightarrow{P} u + v$
  - Produto:  $U_n \cdot V_n \xrightarrow{P} u \cdot v$
  - Quociente:  $U_n/V_n \xrightarrow{P} u/v$  (se  $v \neq 0$ )
2. **Condição de Não-Degeneração:** A condição  $P(V_n = 0) = 0$  é crucial para o quociente. Se  $S_n^2$  pudesse ser zero com probabilidade positiva, o quociente não estaria bem definido.
3. **Interpretação Estatística:** O quociente  $\frac{\bar{X}_n}{S_n^2}$  não é uma estatística comum, mas o resultado ilustra que podemos trabalhar com funções racionais de estimadores consistentes.
4. **Generalização:** Se  $g : \mathbb{R}^2 \rightarrow \mathbb{R}$  é contínua em  $(u, v)$ , então:

$$g(\bar{X}_n, S_n^2) \xrightarrow{P} g(\mu, \sigma^2) \quad (49)$$

O quociente é o caso especial  $g(x, y) = x/y$ .

5. **Exemplo Relacionado:** O coeficiente de variação amostral:

$$CV_n = \frac{S_n}{\bar{X}_n} \xrightarrow{P} \frac{\sigma}{\mu} \quad (\text{se } \mu \neq 0) \quad (50)$$

### Cuidado com Quocientes

**Contraexemplo:** Se  $V_n \xrightarrow{P} 0$ , o quociente  $U_n/V_n$  pode divergir mesmo que  $U_n \xrightarrow{P} u$ . Por exemplo:

- Se  $U_n = 1/n$  e  $V_n = 1/n^2$
- Então  $U_n \xrightarrow{P} 0$  e  $V_n \xrightarrow{P} 0$
- Mas  $U_n/V_n = n \rightarrow \infty$  (não converge!)

Por isso a condição  $v \neq 0$  é essencial.

## Resumo da Questão

### Resultado Principal:

$$\frac{\bar{X}_n}{S_n^2} \xrightarrow{P} \frac{\mu}{\sigma^2}$$

### Método Utilizado:

- Resultado 1P:  $\bar{X}_n \xrightarrow{P} \mu$
- Questão Extra 1:  $S_n^2 \xrightarrow{P} \sigma^2$
- Resultado 4P (item iii): quociente de convergentes converge

**Lição:** Operações algébricas preservam convergência em probabilidade (com cuidados para divisão).

## 4 Questão Extra 4: Função Contínua de Convergente

### Questão Extra 4

Sejam  $X_1, \dots, X_n$  v.a.'s i.i.d. tais que  $X_i \sim U(0, \theta)$  para  $\theta > 0$ . Mostre que:

$$T_n^2 = X_{n:n}^2 \xrightarrow[n \rightarrow \infty]{P} \theta^2 \quad (51)$$

### Solução Detalhada

#### Estratégia da Demonstração

Usaremos o **Resultado 5P** (teorema da função contínua para convergência em probabilidade).

#### Passo 1: Convergência do Máximo

Pela **Questão Extra 2** (já demonstrada):

$$X_{n:n} \xrightarrow[n \rightarrow \infty]{P} \theta \quad (52)$$

#### Passo 2: Aplicação do Resultado 5P

O **Resultado 5P** afirma que se  $U_n \xrightarrow{P} u$  e  $g(\cdot)$  é uma função contínua, então:

$$g(U_n) \xrightarrow[n \rightarrow \infty]{P} g(u) \quad (53)$$

Aplicação ao nosso caso:

- $U_n = X_{n:n}$
- $u = \theta$
- $g(x) = x^2$  (função contínua em  $\mathbb{R}$ )

Portanto:

$$g(X_{n:n}) = X_{n:n}^2 \xrightarrow[n \rightarrow \infty]{P} g(\theta) = \theta^2 \quad \square \quad (54)$$

## Observações e Intuição

### Pontos Importantes

1. **Preservação de Convergência por Funções Contínuas:** Este é um dos teoremas mais úteis em teoria assintótica. Se uma sequência converge em probabilidade, podemos aplicar qualquer função contínua e a convergência é preservada.

2. **Exemplos de Funções Contínuas Úteis:**

- $g(x) = x^2$ :  $U_n \xrightarrow{P} u \Rightarrow U_n^2 \xrightarrow{P} u^2$
- $g(x) = \sqrt{x}$  (para  $x > 0$ ):  $U_n \xrightarrow{P} u \Rightarrow \sqrt{U_n} \xrightarrow{P} \sqrt{u}$
- $g(x) = e^x$ :  $U_n \xrightarrow{P} u \Rightarrow e^{U_n} \xrightarrow{P} e^u$
- $g(x) = \log x$  (para  $x > 0$ ):  $U_n \xrightarrow{P} u \Rightarrow \log U_n \xrightarrow{P} \log u$

3. **Aplicação ao nosso exemplo:** Como  $S_n^2 \xrightarrow{P} \sigma^2$ , temos:

$$S_n = \sqrt{S_n^2} \xrightarrow{P} \sqrt{\sigma^2} = \sigma \quad (55)$$

4. **Cuidado com Descontinuidades:** Se  $g$  tem descontinuidade em  $u$ , o resultado pode falhar. Por exemplo:

$$g(x) = \mathbf{1}_{x>0} = \begin{cases} 1, & x > 0 \\ 0, & x \leq 0 \end{cases} \quad (56)$$

é descontínua em  $x = 0$ .

5. **Demonstração do Resultado 5P:** A prova usa  $\varepsilon$ - $\delta$  da continuidade:

$$|x - u| < \delta \Rightarrow |g(x) - g(u)| < \varepsilon \quad (57)$$

Logo,

$$P(|g(U_n) - g(u)| \geq \varepsilon) \leq P(|U_n - u| \geq \delta) \rightarrow 0 \quad (58)$$

## Resumo da Questão

### Resultado Principal:

$$X_{n:n}^2 \xrightarrow{P} \theta^2$$

### Método Utilizado:

- Questão Extra 2:  $X_{n:n} \xrightarrow{P} \theta$
- Resultado 5P: função contínua preserva convergência em P
- Função  $g(x) = x^2$  é contínua

**Lição:** Transformações contínuas de estimadores consistentes são consistentes.

## 5 Questão Extra 5: Distribuição Limite do Máximo Uniforme

### Questão Extra 5

Sejam  $X_1, \dots, X_n$  v.a.'s i.i.d tais que  $X_i \sim U(0, \theta)$  para  $\theta > 0$ .

Encontre a distribuição limite da sequência:

$$U_n = \frac{n}{\theta}(\theta - T_n) \quad \text{para} \quad T_n \triangleq X_{n:n} \quad (59)$$

### Solução Detalhada

#### Estratégia da Demonstração

Calcularemos a função de distribuição acumulada (fda) de  $U_n$  e tomaremos o limite quando  $n \rightarrow \infty$ .

#### Passo 1: Função de Distribuição de $T_n$

Da Questão Extra 2, sabemos que:

$$F_{T_n}(t) = \left(\frac{t}{\theta}\right)^n \mathbf{1}_{(0,\theta)}(t) + \mathbf{1}_{[\theta,\infty)}(t) \quad (60)$$

#### Passo 2: Função de Distribuição de $U_n$

Para  $u > 0$ , calculemos  $F_{U_n}(u) = P(U_n \leq u)$ :

$$F_{U_n}(u) = P\left(\frac{n}{\theta}(\theta - T_n) \leq u\right) \quad (61)$$

$$= P\left(\theta - T_n \leq \frac{\theta u}{n}\right) \quad (62)$$

$$= P\left(-T_n \leq \frac{\theta u}{n} - \theta\right) \quad (63)$$

$$= P\left(T_n \geq \theta\left(1 - \frac{u}{n}\right)\right) \quad (64)$$

## Solução Detalhada

### Passo 3: Cálculo da Probabilidade

$$F_{U_n}(u) = P\left(T_n \geq \theta\left(1 - \frac{u}{n}\right)\right) \quad (65)$$

$$= 1 - P\left(T_n < \theta\left(1 - \frac{u}{n}\right)\right) \quad (66)$$

$$= 1 - F_{T_n}\left(\theta\left(1 - \frac{u}{n}\right)\right) \quad (67)$$

Como  $0 < \theta(1 - u/n) < \theta$  para  $n$  suficientemente grande:

$$F_{U_n}(u) = 1 - \left(\frac{\theta(1 - u/n)}{\theta}\right)^n \quad (68)$$

$$= 1 - \left(1 - \frac{u}{n}\right)^n \quad (69)$$

### Passo 4: Limite quando $n \rightarrow \infty$

Usando o resultado limite (R.3):  $\lim_{n \rightarrow \infty} (1 + x/n)^n = e^x$ , temos:

$$\lim_{n \rightarrow \infty} F_{U_n}(u) = \lim_{n \rightarrow \infty} \left[1 - \left(1 - \frac{u}{n}\right)^n\right] \quad (70)$$

$$= 1 - \lim_{n \rightarrow \infty} \left(1 + \frac{(-u)}{n}\right)^n \quad (71)$$

$$= 1 - e^{-u}, \quad u > 0 \quad (72)$$

### Passo 5: Identificação da Distribuição

Reconhecemos que  $F_U(u) = 1 - e^{-u}$  para  $u > 0$  é a fda de uma distribuição **Exponencial(1)**.

**Verificação:** Para  $E \sim \text{Exp}(1)$  com densidade  $f_E(u) = e^{-u} \mathbf{1}_{u>0}$ :

$$F_E(u) = \int_0^u e^{-t} dt = -e^{-t} \Big|_0^u = 1 - e^{-u} \quad \checkmark \quad (73)$$

### Conclusão

$$U_n = \frac{n}{\theta}(\theta - X_{n:n}) \xrightarrow{D} E \sim \text{Exp}(1) \quad \square \quad (74)$$

## Observações e Intuição

### Pontos Importantes

1. **Normalização Não-Padrão:** Diferente do TCL onde normalizamos com  $\sqrt{n}$ , aqui a normalização correta é  $n$  (linear). Isso indica uma taxa de convergência mais rápida.
2. **Distribuição Limite Não-Normal:** Este é um exemplo importante onde a distribuição limite NÃO é normal. O TCL não se aplica aqui porque  $X_{n:n}$  não é uma média.
3. **Interpretação do Resultado:** A distância normalizada  $n(\theta - X_{n:n})/\theta$  entre o máximo e o limite superior converge para uma Exponencial(1).
4. **Relação com Resultados Anteriores:**
  - Questão Extra 2 mostra:  $X_{n:n} \xrightarrow{P} \theta$
  - Esta questão refina:  $n(\theta - X_{n:n})/\theta$  tem distribuição limite não-degenerada
  - Isso dá informação sobre a *taxa* de convergência
5. **Aplicação ao Limite (R.3):** A chave da demonstração é o limite:

$$\lim_{n \rightarrow \infty} \left(1 - \frac{u}{n}\right)^n = e^{-u} \quad (75)$$

Este é um dos resultados limites fundamentais apresentados no início do capítulo.

6. **Estatística de Valores Extremos:** Este resultado é um exemplo clássico da teoria de valores extremos, onde distribuições limite de máximos/mínimos são estudadas.

### Consequências Práticas

- **Intervalos de Confiança:** Podemos construir IC para  $\theta$  usando a distribuição de  $U_n$ :

$$P\left(a < \frac{n}{\theta}(\theta - X_{n:n}) < b\right) \approx P(a < E < b) = e^{-a} - e^{-b} \quad (76)$$

- **Quantis:** Para  $\alpha = 0.05$ , os quantis de  $\text{Exp}(1)$  são:

$$\begin{aligned} - P(E > 2.996) &= 0.05 \\ - P(E > 0.051) &= 0.95 \end{aligned}$$

- **IC Aproximado para  $\theta$ :**

$$\left[ X_{n:n}, X_{n:n} + \frac{\theta \cdot 2.996}{n} \right] \approx \text{IC de 95\%} \quad (77)$$

(mas  $\theta$  é desconhecido, então precisamos estimar)

## Resumo da Questão

### Resultado Principal:

$$U_n = \frac{n}{\theta}(\theta - X_{n:n}) \xrightarrow{D} \text{Exp}(1)$$

### Método Utilizado:

- Cálculo da fda:  $F_{U_n}(u) = 1 - (1 - u/n)^n$
- Limite (R.3):  $(1 - u/n)^n \rightarrow e^{-u}$
- Identificação:  $F_U(u) = 1 - e^{-u}$  é fda de  $\text{Exp}(1)$

**Importância:** Mostra que a taxa de convergência de  $X_{n:n}$  é  $O(1/n)$ , mais rápida que a típica  $O(1/\sqrt{n})$ .

## 6 Exercício 11: Estatística Qui-Quadrado via TCL

### Exercício 11

Sejam  $X_1, \dots, X_n$  v.a.'s i.i.d. reais tais que  $\mu = E\{X_i\} < \infty$  e  $\sigma^2 = \text{Var}\{X_i\} < \infty$ . Mostre que:

$$n \left( \frac{\bar{X}_n - \mu}{\sigma} \right)^2 \xrightarrow[n \rightarrow \infty]{d} Q, \quad (78)$$

tal que  $Q \sim \chi_1^2$ .

## Solução Detalhada

### Estratégia da Demonstração

Usaremos o **Teorema Central do Limite** seguido do **Teorema 3.7.6.4(a)** (função contínua preserva convergência em distribuição).

### Passo 1: Aplicação do TCL

Pelo **Teorema 3.7.6.1(a)** (Teorema Central do Limite):

$$Z_n \triangleq \sqrt{n} \left( \frac{\bar{X}_n - \mu}{\sigma} \right) \xrightarrow[n \rightarrow \infty]{d} Z \sim N(0, 1) \quad (79)$$

### Passo 2: Transformação Contínua

Considere a função  $g(x) = x^2$ . Claramente,  $g$  é contínua em  $\mathbb{R}$ .

Pelo **Teorema 3.7.6.4(a)** (teorema da função contínua em distribuição), se  $U_n \xrightarrow{d} U$  e  $g$  é contínua, então:

$$g(U_n) \xrightarrow[n \rightarrow \infty]{d} g(U) \quad (80)$$

### Passo 3: Aplicação ao Nosso Caso

Aplicando com  $U_n = Z_n$  e  $g(x) = x^2$ :

$$g(Z_n) = Z_n^2 \quad (81)$$

$$= \left[ \sqrt{n} \left( \frac{\bar{X}_n - \mu}{\sigma} \right) \right]^2 \quad (82)$$

$$= n \left( \frac{\bar{X}_n - \mu}{\sigma} \right)^2 \quad (83)$$

$$\xrightarrow[n \rightarrow \infty]{d} Z^2 \quad (84)$$

onde  $Z \sim N(0, 1)$ .

### Passo 4: Distribuição de $Z^2$

Se  $Z \sim N(0, 1)$ , então  $Z^2 \sim \chi_1^2$  (qui-quadrado com 1 grau de liberdade).

**Verificação:** Para  $Z \sim N(0, 1)$  e  $Q = Z^2$ :

$$F_Q(q) = P(Z^2 \leq q) = P(-\sqrt{q} \leq Z \leq \sqrt{q}) \quad (85)$$

$$= \Phi(\sqrt{q}) - \Phi(-\sqrt{q}) \quad (86)$$

$$= 2\Phi(\sqrt{q}) - 1 \quad (87)$$

Derivando:

$$f_Q(q) = \frac{d}{dq} [2\Phi(\sqrt{q}) - 1] = 2\phi(\sqrt{q}) \cdot \frac{1}{2\sqrt{q}} = \frac{1}{\sqrt{2\pi q}} e^{-q/2} \quad (88)$$

que é a densidade de  $\chi_1^2 = \Gamma(1/2, 1/2)$ .

## Conclusão

## Observações e Intuição

### Pontos Importantes

1. **Combinação de Dois Teoremas:** Esta questão ilustra a composição de resultados:

$$\text{TCL} + \text{Função Contínua} = \text{Distribuição de } \chi^2 \quad (90)$$

2. **Relação  $N(0, 1)$  e  $\chi^2_1$ :** Este resultado estabelece a conexão fundamental:

$$Z \sim N(0, 1) \Rightarrow Z^2 \sim \chi^2_1 \quad (91)$$

3. **Aplicação Prática (Testes):** Esta estatística é a base para:

- Teste Z bilateral: rejeitamos  $H_0 : \mu = \mu_0$  se  $n(\bar{x} - \mu_0)^2/\sigma^2 > \chi^2_{1,1-\alpha}$
- Equivalente a rejeitar se  $|Z| > z_{\alpha/2}$

4. **Generalização para  $p$  Dimensões:** Se  $\bar{X}_n \in \mathbb{R}^p$  e:

$$\sqrt{n}(\bar{X}_n - \mu) \xrightarrow{D} N_p(0, \Sigma) \quad (92)$$

então:

$$n(\bar{X}_n - \mu)^\top \Sigma^{-1}(\bar{X}_n - \mu) \xrightarrow{D} \chi^2_p \quad (93)$$

5. **Exemplos Numéricos:**

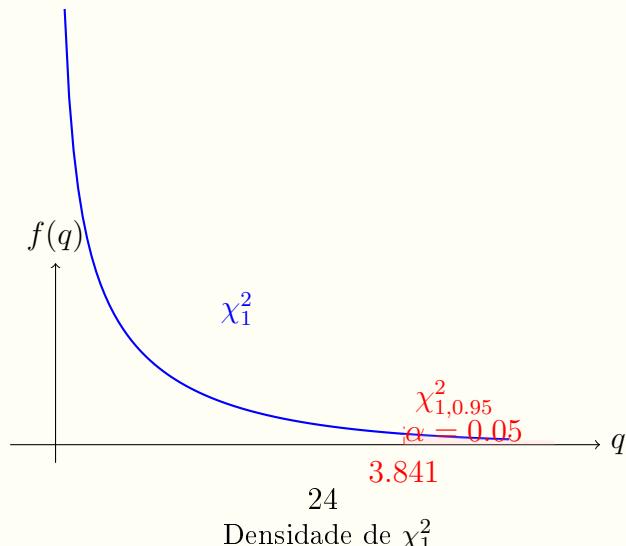
- Para  $\alpha = 0.05$ :  $\chi^2_{1,0.95} = 3.841$
- Logo, rejeitamos se  $n(\bar{x} - \mu_0)^2/\sigma^2 > 3.841$
- Equivalentemente,  $|\bar{x} - \mu_0| > \sigma \cdot 1.96/\sqrt{n}$  ( $z_{0.025} = 1.96$ )

6. **Conexão com Variância Amostral:** Para normalidade, temos a decomposição:

$$\sum_{i=1}^n \left( \frac{X_i - \mu}{\sigma} \right)^2 = n \left( \frac{\bar{X}_n - \mu}{\sigma} \right)^2 + \frac{(n-1)S_n^2}{\sigma^2} \quad (94)$$

onde o primeiro termo  $\xrightarrow{D} \chi^2_1$  e o segundo  $\sim \chi^2_{n-1}$  exatamente.

## Visualização



## Resumo da Questão

### Resultado Principal:

$$n \left( \frac{\bar{X}_n - \mu}{\sigma} \right)^2 \xrightarrow{D} \chi_1^2$$

### Método Utilizado:

- TCL:  $Z_n = \sqrt{n}(\bar{X}_n - \mu)/\sigma \xrightarrow{D} N(0, 1)$
- Teorema 3.7.6.4(a):  $g(Z_n) = Z_n^2 \xrightarrow{D} Z^2$
- Propriedade:  $Z^2 \sim \chi_1^2$  quando  $Z \sim N(0, 1)$

**Importância:** Base para testes bilaterais e intervalos de confiança.

## 7 Questão Extra 6: TCL para Bernoulli via MGF

### Questão Extra 6

Sejam  $X_1, \dots, X_n$  v.a.'s i.i.d. tais que  $X_i \sim \text{Bernoulli}(p)$  com  $p = \frac{1}{2}$  e

$$U_n = 2\sqrt{n} \left( \bar{X}_n - \frac{1}{2} \right).$$

Estude a distribuição limite de  $U_n$ .

### Solução Detalhada

#### Estratégia da Demonstração

Usaremos o **Resultado 1D** (convergência via função geradora de momentos) para encontrar a distribuição limite.

#### Passo 1: Reescrever $U_n$

Primeiro, reescrevemos  $U_n$  em termos da soma:

$$U_n = 2\sqrt{n} \left( \bar{X}_n - \frac{1}{2} \right) \quad (95)$$

$$= 2\sqrt{n} \left( \frac{1}{n} \sum_{i=1}^n X_i - \frac{1}{2} \right) \quad (96)$$

$$= \frac{2}{\sqrt{n}} \sum_{i=1}^n X_i - \sqrt{n} \quad (97)$$

$$= \frac{2 \sum_{i=1}^n X_i - n}{\sqrt{n}} \quad (98)$$

#### Passo 2: Função Geradora de Momentos de $U_n$

$$M_{U_n}(t) = E[e^{tU_n}] \quad (99)$$

$$= E \left[ \exp \left\{ t \cdot \frac{2 \sum_{i=1}^n X_i - n}{\sqrt{n}} \right\} \right] \quad (100)$$

$$= E \left[ \exp \left\{ \frac{2t}{\sqrt{n}} \sum_{i=1}^n X_i - t\sqrt{n} \right\} \right] \quad (101)$$

$$= e^{-t\sqrt{n}} \cdot E \left[ \exp \left\{ \frac{2t}{\sqrt{n}} \sum_{i=1}^n X_i \right\} \right] \quad (102)$$

## Solução Detalhada

### Passo 3: Usando Independência

Como as  $X_i$  são independentes:

$$M_{U_n}(t) = e^{-t\sqrt{n}} \cdot \prod_{i=1}^n E \left[ e^{\frac{2t}{\sqrt{n}} X_i} \right] \quad (103)$$

$$= e^{-t\sqrt{n}} \cdot \left( E \left[ e^{\frac{2t}{\sqrt{n}} X_1} \right] \right)^n \quad (104)$$

Para  $X_1 \sim \text{Bernoulli}(p)$ , sabemos que  $X_1 \in \{0, 1\}$ :

$$E \left[ e^{\frac{2t}{\sqrt{n}} X_1} \right] = (1-p) \cdot e^{\frac{2t}{\sqrt{n}} \cdot 0} + p \cdot e^{\frac{2t}{\sqrt{n}} \cdot 1} \quad (105)$$

$$= (1-p) + p \cdot e^{\frac{2t}{\sqrt{n}}} \quad (106)$$

Logo:

$$M_{U_n}(t) = e^{-t\sqrt{n}} \left[ (1-p) + p \cdot e^{\frac{2t}{\sqrt{n}}} \right]^n \quad (107)$$

### Passo 4: Caso Especial $p = \frac{1}{2}$

Substituindo  $p = 1/2$ :

$$M_{U_n}(t) = e^{-t\sqrt{n}} \left[ \frac{1}{2} + \frac{1}{2} \cdot e^{\frac{2t}{\sqrt{n}}} \right]^n \quad (108)$$

$$= e^{-t\sqrt{n}} \left[ \frac{1}{2} \left( 1 + e^{\frac{2t}{\sqrt{n}}} \right) \right]^n \quad (109)$$

$$= \frac{1}{2^n} e^{-t\sqrt{n}} \left[ 1 + e^{\frac{2t}{\sqrt{n}}} \right]^n \quad (110)$$

Podemos reescrever como:

$$M_{U_n}(t) = \frac{1}{2^n} \left[ e^{-\frac{t}{\sqrt{n}}} + e^{\frac{t}{\sqrt{n}}} \right]^n \quad (111)$$

Ou ainda:

$$M_{U_n}(t) = \left[ \frac{1}{2} \left( e^{-\frac{t}{\sqrt{n}}} + e^{\frac{t}{\sqrt{n}}} \right) \right]^n \quad (112)$$

## Solução Detalhada

### Passo 5: Expansão de Taylor

Expandimos as exponenciais usando Taylor em torno de 0:

$$e^{\frac{t}{\sqrt{n}}} = 1 + \frac{t}{\sqrt{n}} + \frac{t^2}{2n} + o\left(\frac{t^2}{n}\right) \quad (113)$$

$$e^{-\frac{t}{\sqrt{n}}} = 1 - \frac{t}{\sqrt{n}} + \frac{t^2}{2n} + o\left(\frac{t^2}{n}\right) \quad (114)$$

Somando:

$$e^{-\frac{t}{\sqrt{n}}} + e^{\frac{t}{\sqrt{n}}} = 2 + \frac{t^2}{n} + o\left(\frac{t^2}{n}\right) \quad (115)$$

Logo:

$$M_{U_n}(t) = \left[ \frac{1}{2} \left( 2 + \frac{t^2}{n} + o\left(\frac{t^2}{n}\right) \right) \right]^n \quad (116)$$

$$= \left[ 1 + \frac{t^2}{2n} + o\left(\frac{t^2}{n}\right) \right]^n \quad (117)$$

### Passo 6: Aplicação do Limite (R.3)

Pelo resultado limite (R.3):  $\lim_{n \rightarrow \infty} (1 + x/n)^n = e^x$ , temos:

$$\lim_{n \rightarrow \infty} M_{U_n}(t) = \lim_{n \rightarrow \infty} \left[ 1 + \frac{t^2/2}{n} \right]^n = e^{t^2/2} \quad (118)$$

### Passo 7: Identificação da Distribuição

Reconhecemos que  $M_U(t) = e^{t^2/2}$  é a MGF de  $Z \sim N(0, 1)$ .

**Verificação:** Para  $Z \sim N(0, 1)$ :

$$M_Z(t) = E[e^{tZ}] = e^{t^2/2} \quad \checkmark \quad (119)$$

## Conclusão

Pelo **Resultado 1D**, como  $M_{U_n}(t) \rightarrow M_Z(t)$ :

$$U_n = 2\sqrt{n} \left( \bar{X}_n - \frac{1}{2} \right) \xrightarrow[n \rightarrow \infty]{d} N(0, 1) \quad \square \quad (120)$$

## Observações e Intuição

### Pontos Importantes

1. **Verificação do TCL:** Podemos verificar que este resultado está de acordo com o TCL:

- Para Bernoulli( $1/2$ ):  $E[X_i] = 1/2$  e  $\text{Var}(X_i) = 1/2 \cdot 1/2 = 1/4$
- Pelo TCL:  $\sqrt{n}(\bar{X}_n - 1/2) \xrightarrow{D} N(0, 1/4)$
- Multiplicando por 2:  $2\sqrt{n}(\bar{X}_n - 1/2) \xrightarrow{D} N(0, 4 \cdot 1/4) = N(0, 1) \checkmark$

2. **Demonstração via MGF:** Esta questão demonstra o TCL usando a função geradora de momentos, que é uma técnica alternativa à prova via função característica.

3. **Expansões de Taylor Cruciais:** Os passos chave são:

- Expandir  $e^{\pm t/\sqrt{n}}$  até ordem 2
- Cancelar os termos lineares (aparecem com sinais opostos)
- Reconhecer a forma  $(1 + x/n)^n \rightarrow e^x$

4. **Normalização:** O fator 2 na frente vem de:

$$\frac{\sqrt{n}(\bar{X}_n - 1/2)}{\sqrt{\text{Var}(X_i)}} = \frac{\sqrt{n}(\bar{X}_n - 1/2)}{1/2} = 2\sqrt{n}(\bar{X}_n - 1/2) \quad (121)$$

5. **Aproximação Normal para Binomial:** Como  $S_n = \sum X_i \sim \text{Binomial}(n, 1/2)$ :

$$\frac{S_n - n/2}{\sqrt{n/4}} = \frac{2(S_n - n/2)}{\sqrt{n}} \xrightarrow{D} N(0, 1) \quad (122)$$

6. **Caso Geral  $p \neq 1/2$ :** Para  $p$  arbitrário:

$$\frac{\sqrt{n}(\bar{X}_n - p)}{\sqrt{p(1-p)}} \xrightarrow{D} N(0, 1) \quad (123)$$

### Aplicação Prática

Para testar  $H_0 : p = 1/2$  em uma moeda:

- Jogar a moeda  $n$  vezes e observar  $S_n$  caras
- Calcular  $Z = 2(S_n - n/2)/\sqrt{n}$
- Rejeitar  $H_0$  ao nível  $\alpha$  se  $|Z| > z_{\alpha/2}$

**Exemplo:**  $n = 100$  jogadas, observamos 60 caras.

$$Z = \frac{2(60 - 50)}{\sqrt{100}} = \frac{20}{10} = 2 \quad (124)$$

$$|Z| = 2 > 1.96 = z_{0.025} \quad (125)$$

Concluímos que há evidência contra  $p = 1/2$  ao nível 5%.

## Resumo da Questão

**Resultado Principal:**

$$2\sqrt{n} \left( \bar{X}_n - \frac{1}{2} \right) \xrightarrow{D} N(0, 1)$$

**Método Utilizado:**

- Cálculo da MGF de  $U_n$
- Expansão de Taylor de  $e^{\pm t/\sqrt{n}}$
- Limite (R.3):  $(1 + x/n)^n \rightarrow e^x$
- Resultado 1D: convergência via MGF

**Importância:** Demonstração alternativa do TCL via MGF para Bernoulli.

## 8 Questão Extra 7: Transformação de $Q_n$ via Slutsky

### Questão Extra 7 (continuação da Extra 4)

Sejam  $\{X_n, n \geq 1\}$  i.i.d. com  $X_n \sim U(0, \theta)$ ,  $T_n = X_{n:n}$ ,

$$U_n = n \cdot (\theta - T_n)/\theta \quad \text{e} \quad Q_n = n \cdot (\theta - T_n)/T_n.$$

Encontre a distribuição limite de  $Q_n$ .

## Solução Detalhada

### Estratégia da Demonstração

Usaremos o **Teorema de Slutsky** (Resultado 3D) combinando convergências em distribuição e em probabilidade.

### Passo 1: Resultados Conhecidos

Da **Questão Extra 5**, sabemos que:

$$U_n = \frac{n(\theta - T_n)}{\theta} \xrightarrow{d} E \sim \text{Exp}(1) \quad (126)$$

Da **Questão Extra 2**, sabemos que:

$$T_n \xrightarrow{p} \theta \quad (127)$$

### Passo 2: Convergência de $\theta/T_n$

Pelo **Resultado 4P** (operações com convergência em probabilidade), se  $T_n \xrightarrow{p} \theta$  e  $\theta \neq 0$ :

$$\frac{\theta}{T_n} \xrightarrow{p} \frac{\theta}{\theta} = 1 \quad (128)$$

### Passo 3: Reescrever $Q_n$

Observe que podemos reescrever  $Q_n$  como:

$$Q_n = \frac{n(\theta - T_n)}{T_n} \quad (129)$$

$$= \frac{n(\theta - T_n)}{\theta} \cdot \frac{\theta}{T_n} \quad (130)$$

$$= U_n \cdot \frac{\theta}{T_n} \quad (131)$$

### Passo 4: Aplicação do Teorema de Slutsky

Temos:

- $U_n \xrightarrow{d} E \sim \text{Exp}(1)$  (convergência em distribuição)
- $\theta/T_n \xrightarrow{p} 1$  (convergência em probabilidade)

Pelo **Resultado 3D (Teorema de Slutsky)**, item (b):

$$Q_n = U_n \cdot \frac{\theta}{T_n} \xrightarrow{d} E \cdot 1 = E \quad (132)$$

### Conclusão

$$Q_n = \frac{n(\theta - T_n)}{T_n} \xrightarrow{d} \text{Exp}(1) \quad \square \quad (133)$$

## Observações e Intuição

### Pontos Importantes

**1. Poder do Teorema de Slutsky:** Esta questão ilustra perfeitamente o uso do Slutsky:

- Combinamos uma convergência em distribuição ( $U_n \xrightarrow{d} E$ )
- Com uma convergência em probabilidade ( $\theta/T_n \xrightarrow{p} 1$ )
- E obtemos convergência em distribuição do produto

**2. Comparação  $U_n$  vs  $Q_n$ :**

- $U_n = n(\theta - T_n)/\theta$  normaliza usando o valor verdadeiro  $\theta$
- $Q_n = n(\theta - T_n)/T_n$  normaliza usando o estimador  $T_n$
- Ambos têm a MESMA distribuição limite (Exponencial)!
- Isso mostra que podemos substituir  $\theta$  por  $T_n$  sem alterar a distribuição limite

**3. Aplicação Prática:** Na prática, não conhecemos  $\theta$ , então usamos:

$$Q_n = \frac{n(\theta - X_{n:n})}{X_{n:n}} \quad (134)$$

que tem distribuição assintótica  $\text{Exp}(1)$ , permitindo construir testes e IC.

**4. Estrutura da Demonstração:**

- Identificar a fatoração:  $Q_n = U_n \cdot (\theta/T_n)$
- Verificar:  $U_n \xrightarrow{d} E$  e  $\theta/T_n \xrightarrow{p} 1$
- Aplicar Slutsky: produto converge para  $E \cdot 1 = E$

**5. Generalização:** Se  $U_n \xrightarrow{d} U$  e  $V_n \xrightarrow{p} c$  (constante), então:

$$\frac{U_n}{V_n} \xrightarrow{d} \frac{U}{c} \quad (135)$$

Este é o item (c) do Teorema de Slutsky.

### Exemplo Numérico

Suponha  $\theta = 10$  (desconhecido),  $n = 50$ , e observamos  $x_{n:n} = 9.8$ .

Estimamos:

$$Q_{\text{obs}} = \frac{50(10 - 9.8)}{9.8} = \frac{50 \cdot 0.2}{9.8} \approx 1.02 \quad (136)$$

Para IC de 95%: queremos  $a$  e  $b$  tais que  $P(a < E < b) = 0.95$ .

Para  $\text{Exp}(1)$ :  $P(E < 2.996) = 0.95$ , então um IC aproximado para  $\theta$  é:

$$\theta \approx X_{n:n} + \frac{X_{n:n} \cdot 2.996}{n} = 9.8 + \frac{9.8 \cdot 2.996}{50} \approx 10.39 \quad (137)$$

## Resumo da Questão

### Resultado Principal:

$$Q_n = \frac{n(\theta - X_{n:n})}{X_{n:n}} \xrightarrow{D} \text{Exp}(1)$$

### Método Utilizado:

- Fatoração:  $Q_n = U_n \cdot (\theta/T_n)$
- Extra 5:  $U_n \xrightarrow{d} \text{Exp}(1)$
- Extra 2:  $T_n \xrightarrow{p} \theta \Rightarrow \theta/T_n \xrightarrow{p} 1$
- Slutsky: produto converge

**Importância:** Permite construir IC para  $\theta$  usando apenas dados observados.

## 9 Questão Extra 9: Distribuição Assintótica de $\sqrt{n}(S_n^2 - \sigma^2)$

### Questão Extra 9

Sejam  $X_1, \dots, X_n$  uma a.a. de  $X \sim N(\mu, \sigma^2)$  tal que  $\mu, \sigma^2 < \infty$ . Encontre a distribuição assintótica de:

$$H_n = \sqrt{n}(S_n^2 - \sigma^2) \quad (138)$$

### Solução Detalhada

#### Estratégia da Demonstração

Usaremos a transformação de Helmert, o TCL e o Teorema de Slutsky.

#### Passo 1: Representação via Helmert

Usando a transformação de Helmert:

$$S_n^2 = \frac{1}{n-1} \sum_{i=2}^n Y_i^2, \quad \text{para } Y_i \sim N(0, \sigma^2) \quad (139)$$

Isso caracteriza  $S_n^2$  como uma média amostral de  $Y_i^2$ .

#### Passo 2: Aplicação do TCL

As variáveis  $\{Y_i^2, i = 2, \dots, n\}$  são i.i.d. com:

- $E[Y_i^2] = \sigma^2$
- $\text{Var}(Y_i^2) = E[Y_i^4] - (E[Y_i^2])^2 = 3\sigma^4 - \sigma^4 = 2\sigma^4$

(Cálculo de  $E[Y_i^4] = 3\sigma^4$  visto na Questão Extra 1)

Pelo **Teorema 3.7.6.1(a)** (TCL) aplicado à média  $\frac{1}{n-1} \sum_{i=2}^n Y_i^2$ :

$$U_n = \sqrt{n-1} \left[ \frac{1}{n-1} \sum_{i=2}^n Y_i^2 - E[Y_i^2] \right] \xrightarrow{d} N(0, \text{Var}(Y_i^2)) \quad (140)$$

Logo:

$$U_n = \sqrt{n-1}(S_n^2 - \sigma^2) \xrightarrow{d} N(0, 2\sigma^4) \quad (141)$$

## Solução Detalhada

### Passo 3: Ajuste para $\sqrt{n}$

Queremos a distribuição de  $H_n = \sqrt{n}(S_n^2 - \sigma^2)$ .

Defina:

$$V_n = \frac{n}{n-1} = 1 + \frac{1}{n-1} \quad (142)$$

Então:

$$H_n = \sqrt{n}(S_n^2 - \sigma^2) = \sqrt{\frac{n}{n-1}} \cdot \sqrt{n-1}(S_n^2 - \sigma^2) = \sqrt{V_n} \cdot U_n \quad (143)$$

### Passo 4: Convergência de $V_n$

Precisamos mostrar que  $V_n \xrightarrow{p} 1$ .

Pela desigualdade de Chebyshev:

$$P(|V_n - 1| \geq \varepsilon) = P\left(\left|\frac{1}{n-1}\right| \geq \varepsilon\right) \quad (144)$$

$$\leq P\left(\left|\frac{1}{n-1}\right|^2 \geq \varepsilon^2\right) \quad (145)$$

$$\leq \frac{E[(V_n - 1)^2]}{\varepsilon^2} \quad (146)$$

$$= \frac{(n/(n-1) - 1)^2}{\varepsilon^2} \quad (147)$$

$$= \frac{1}{(n-1)^2 \varepsilon^2} \xrightarrow{n \rightarrow \infty} 0 \quad (148)$$

Logo,  $V_n \xrightarrow{p} 1$ , e portanto  $\sqrt{V_n} \xrightarrow{p} 1$  (Resultado 5P).

### Passo 5: Aplicação do Teorema de Slutsky

Temos:

- $U_n \xrightarrow{d} N(0, 2\sigma^4)$  (convergência em distribuição)
- $\sqrt{V_n} \xrightarrow{p} 1$  (convergência em probabilidade)

Pelo **Resultado 3D (Teorema de Slutsky)**, item (b):

$$H_n = U_n \cdot \sqrt{V_n} \xrightarrow{d} N(0, 2\sigma^4) \cdot 1 = N(0, 2\sigma^4) \quad (149)$$

## Conclusão

$$\sqrt{n}(S_n^2 - \sigma^2) \xrightarrow{d} N(0, 2\sigma^4) \quad \square \quad (150)$$

## Observações e Intuição

### Pontos Importantes

1. **Caso Especial do Teorema 3.7.6.3(a):** Para  $X_i \sim N(\mu, \sigma^2)$ :

- $\mu_4 = E[(X_i - \mu)^4] = 3\sigma^4$  (momento de quarta ordem da normal)
- Logo,  $\mu_4 - \sigma^4 = 3\sigma^4 - \sigma^4 = 2\sigma^4$
- O resultado geral dá:  $\sqrt{n}(S_n^2 - \sigma^2) \xrightarrow{D} N(0, \mu_4 - \sigma^4) = N(0, 2\sigma^4)$

2. **Diferença  $\sqrt{n-1}$  vs  $\sqrt{n}$ :**

- A transformação de Helmert produz  $n - 1$  variáveis para  $S_n^2$
- O TCL aplicado diretamente dá  $\sqrt{n-1}(S_n^2 - \sigma^2) \xrightarrow{D} N(0, 2\sigma^4)$
- Precisamos ajustar para  $\sqrt{n}$  usando Slutsky

3. **Aplicação a Testes:** Este resultado permite testar  $H_0 : \sigma^2 = \sigma_0^2$ :

$$Z = \frac{\sqrt{n}(S_n^2 - \sigma_0^2)}{\sqrt{2}\sigma_0} \xrightarrow{D} N(0, 1) \quad (151)$$

4. **Intervalo de Confiança Assintótico:** IC de  $(1 - \alpha)$  para  $\sigma^2$ :

$$S_n^2 \pm z_{\alpha/2} \cdot \frac{\sqrt{2}\sigma^2}{\sqrt{n}} \quad (152)$$

(na prática, substituímos  $\sigma^2$  por  $S_n^2$ )

5. **Taxa de Convergência:** A variância assintótica é  $2\sigma^4$ , então:

$$\text{Var}(S_n^2) \approx \frac{2\sigma^4}{n} \quad (153)$$

6. **Generalização para Não-Normais:** Para distribuições não-normais, a variância assintótica é  $\mu_4 - \sigma^4$ , que pode ser diferente de  $2\sigma^4$ .

### Conexão com Helmert

A transformação de Helmert separa:

- $Y_1 = \sqrt{n} \bar{X}_n$  (relacionado à média)
- $Y_2, \dots, Y_n$  (relacionados à variância)

E preserva:

$$\sum_{i=1}^n (X_i - \mu)^2 = \sum_{i=1}^n Y_i^2 = n\bar{X}_n^2 + (n-1)S_n^2 \quad (154)$$

## Resumo da Questão

**Resultado Principal:**

$$\sqrt{n}(S_n^2 - \sigma^2) \xrightarrow{D} N(0, 2\sigma^4)$$

**Método Utilizado:**

- Helmert:  $S_n^2 = \frac{1}{n-1} \sum_{i=2}^n Y_i^2$
- TCL:  $\sqrt{n-1}(S_n^2 - \sigma^2) \xrightarrow{D} N(0, 2\sigma^4)$
- Slutsky: ajuste de  $\sqrt{n-1}$  para  $\sqrt{n}$

**Importância:** Base para testes e IC para  $\sigma^2$ .

## 10 Questão Extra 10: Método Delta para Poisson

### Questão Extra 10

Sejam  $X_1, \dots, X_n$  v.a.'s i.i.d. tais que  $X_i \sim \text{Poisson}(\lambda)$ . Encontre a distribuição assintótica de:

$$\sqrt{n} (\bar{X}_n^3 - \lambda^3) \quad (155)$$

### Solução Detalhada

#### Estratégia da Demonstração

Usaremos o **Teorema de Mann–Wald (Método Delta)** - Teorema 3.7.6.2(a).

#### Passo 1: Verificar Condições

Para aplicar o Método Delta, precisamos:

1. Uma estatística  $T_n$  com normalidade assintótica:  $\sqrt{n}(T_n - \theta) \xrightarrow{D} N(0, \sigma^2(\theta))$
2. Uma função  $g$  continuamente diferenciável com  $g'(\theta) \neq 0$

#### Passo 2: Normalidade Assintótica de $\bar{X}_n$

Para  $X_i \sim \text{Poisson}(\lambda)$ :

- $E[X_i] = \lambda$
- $\text{Var}(X_i) = \lambda$  (propriedade da Poisson)

Pode-se mostrar que  $E[X_i^3] < \infty$  e  $\text{Var}(X_i^3) < \infty$ .

Pelo **Teorema Central do Limite**:

$$\sqrt{n}(\bar{X}_n - \lambda) \xrightarrow{d} N(0, \lambda) \quad (156)$$

Ou equivalentemente (forma padronizada):

$$\frac{\sqrt{n}(\bar{X}_n - \lambda)}{\sqrt{\lambda}} \xrightarrow{d} N(0, 1) \quad (157)$$

#### Passo 3: Escolha da Função

Definimos:

$$g(\lambda) = \lambda^3 \quad (158)$$

Esta função é continuamente diferenciável com:

$$g'(\lambda) = 3\lambda^2 \neq 0 \quad (\text{para } \lambda > 0) \quad (159)$$

## Solução Detalhada

### Passo 4: Aplicação do Método Delta

Pelo **Teorema 3.7.6.2(a)** (Método Delta):

Se  $\sqrt{n}(T_n - \theta) \xrightarrow{D} N(0, \sigma^2(\theta))$  e  $g'(\theta) \neq 0$ , então:

$$\sqrt{n}[g(T_n) - g(\theta)] \xrightarrow{D} N(0, \sigma^2(\theta) \cdot [g'(\theta)]^2) \quad (160)$$

**Aplicação ao nosso caso:**

- $T_n = \bar{X}_n$
- $\theta = \lambda$
- $\sigma^2(\lambda) = \lambda$
- $g(\lambda) = \lambda^3$
- $g'(\lambda) = 3\lambda^2$

Portanto:

$$\sqrt{n}[g(\bar{X}_n) - g(\lambda)] \xrightarrow{D} N(0, \lambda \cdot [3\lambda^2]^2) \quad (161)$$

$$\sqrt{n}(\bar{X}_n^3 - \lambda^3) \xrightarrow{D} N(0, \lambda \cdot 9\lambda^4) \quad (162)$$

$$\xrightarrow{D} N(0, 9\lambda^5) \quad (163)$$

### Conclusão

$$\sqrt{n}(\bar{X}_n^3 - \lambda^3) \xrightarrow{d} N(0, 9\lambda^5) \quad \square \quad (164)$$

## Observações e Intuição

### Pontos Importantes

1. **Método Delta em Ação:** Esta questão demonstra perfeitamente como o Método Delta funciona:

- Começamos com normalidade de  $\bar{X}_n$
- Aplicamos transformação não-linear  $g(\lambda) = \lambda^3$
- A derivada amplifica a variância:  $\text{Var} \leftarrow \lambda \cdot (3\lambda^2)^2 = 9\lambda^5$

2. **Fórmula do Método Delta:** A variância assintótica sempre tem a forma:

$$\text{Var}_{\text{assintótica}}[g(\bar{X}_n)] = [g'(\theta)]^2 \cdot \text{Var}_{\text{assintótica}}[\bar{X}_n] \quad (165)$$

3. **Interpretação da Derivada:**  $g'(\lambda) = 3\lambda^2$  mede a "sensibilidade" de  $\lambda^3$  a mudanças em  $\lambda$ . Valores grandes de  $\lambda$  amplificam mais o erro.

4. **IC Assintótico para  $\lambda^3$ :** Podemos construir:

$$\bar{X}_n^3 \pm z_{\alpha/2} \cdot \frac{3\bar{X}_n^{5/2}}{\sqrt{n}} \quad (166)$$

(substituindo  $\lambda$  por  $\bar{X}_n$ )

5. **Comparação com Estimação Direta:** Se quiséssemos estimar  $\lambda^3$  diretamente:

- Poderíamos usar  $\bar{X}_n^3$  (pelo Método Delta)
- Ou usar a média de  $X_i^3$  (que também funciona, mas requer calcular  $E[X_i^3]$  e  $\text{Var}(X_i^3)$ )

6. **Generalização:** Para qualquer  $g$  diferenciável:

$$\sqrt{n}[g(\bar{X}_n) - g(\lambda)] \xrightarrow{D} N(0, [g'(\lambda)]^2 \lambda) \quad (167)$$

Exemplos:

- $g(\lambda) = \sqrt{\lambda}$ : variância assintótica =  $\frac{1}{4\lambda} \cdot \lambda = \frac{1}{4}$
- $g(\lambda) = \log \lambda$ : variância assintótica =  $\frac{1}{\lambda^2} \cdot \lambda = \frac{1}{\lambda}$
- $g(\lambda) = e^\lambda$ : variância assintótica =  $e^{2\lambda} \cdot \lambda$

### Exemplo Numérico

Suponha  $n = 100$ , observamos  $\bar{x}_n = 5$ .

**Estimativa pontual:**  $\hat{\lambda}^3 = 5^3 = 125$

**Erro padrão assintótico:**

$$\text{SE} = \frac{3 \cdot 5^{5/2}}{\sqrt{100}} = \frac{3 \cdot 55.90}{10} \approx 16.77 \quad (168)$$

**IC de 95%:**

$$125 \pm 1.96 \cdot 16.77 = 125 \pm 32.87 = [92.13, 157.87] \quad (169)$$

## Resumo da Questão

### Resultado Principal:

$$\sqrt{n}(\bar{X}_n^3 - \lambda^3) \xrightarrow{D} N(0, 9\lambda^5)$$

### Método Utilizado:

- TCL:  $\sqrt{n}(\bar{X}_n - \lambda) \xrightarrow{D} N(0, \lambda)$
- Função:  $g(\lambda) = \lambda^3$  com  $g'(\lambda) = 3\lambda^2$
- Método Delta: variância  $= \lambda \cdot (3\lambda^2)^2 = 9\lambda^5$

**Importância:** Demonstra como obter distribuição assintótica de transformações não-lineares.

## 11 Questão 3.23: Consistência do EMV para Uniforme

### Questão 3.23

Sejam  $X_1, \dots, X_n$  uma amostra de  $X \sim U(0, \theta)$ . Mostre que o estimador de máxima verossimilhança para  $\theta$ ,  $T_n = X_{n:n}$ , é consistente para  $\theta$ .

## Solução Detalhada

### Estratégia da Demonstração

Mostraremos diretamente que  $P_\theta(|X_{n:n} - \theta| < \varepsilon) \rightarrow 1$  para todo  $\varepsilon > 0$ .

### Passo 1: Função de Distribuição de $X_{n:n}$

Da Questão Extra 2, temos:

$$F_{X_{n:n}}(t) = \begin{cases} 0, & t < 0, \\ \left(\frac{t}{\theta}\right)^n, & 0 \leq t \leq \theta, \\ 1, & t > \theta \end{cases} \quad (170)$$

### Passo 2: Probabilidade de Estar Próximo de $\theta$

Para  $\varepsilon > 0$ :

$$P_\theta(|X_{n:n} - \theta| < \varepsilon) = P_\theta(\theta - \varepsilon < X_{n:n} < \theta + \varepsilon) \quad (171)$$

$$= P_\theta(\theta - \varepsilon < X_{n:n} < \theta) \quad (172)$$

(pois  $X_{n:n} \leq \theta$  sempre, já que todas as observações  $\leq \theta$ )

$$= F_{X_{n:n}}(\theta) - F_{X_{n:n}}(\theta - \varepsilon) \quad (173)$$

$$= 1 - F_{X_{n:n}}(\theta - \varepsilon) \quad (174)$$

### Passo 3: Análise por Casos

**Caso 1:**  $\varepsilon \geq \theta$  Se  $\varepsilon \geq \theta$ , então  $\theta - \varepsilon \leq 0$ , logo:

$$F_{X_{n:n}}(\theta - \varepsilon) = 0 \quad (175)$$

Portanto:

$$P_\theta(|X_{n:n} - \theta| < \varepsilon) = 1 - 0 = 1 \quad (176)$$

**Caso 2:**  $\varepsilon < \theta$  Se  $0 < \varepsilon < \theta$ , então  $0 < \theta - \varepsilon < \theta$ , logo:

$$F_{X_{n:n}}(\theta - \varepsilon) = \left(\frac{\theta - \varepsilon}{\theta}\right)^n \quad (177)$$

$$= \left(1 - \frac{\varepsilon}{\theta}\right)^n \quad (178)$$

Portanto:

$$P_\theta(|X_{n:n} - \theta| < \varepsilon) = 1 - \left(1 - \frac{\varepsilon}{\theta}\right)^n \quad (179)$$

## Solução Detalhada

### Passo 4: Limite quando $n \rightarrow \infty$

Para  $\varepsilon < \theta$  fixado:

$$\lim_{n \rightarrow \infty} P_\theta(|X_{n:n} - \theta| < \varepsilon) = \lim_{n \rightarrow \infty} \left[ 1 - \left(1 - \frac{\varepsilon}{\theta}\right)^n \right] \quad (180)$$

$$= 1 - 0 \quad (181)$$

$$= 1 \quad (182)$$

pois  $0 < 1 - \varepsilon/\theta < 1$  e portanto  $(1 - \varepsilon/\theta)^n \rightarrow 0$  quando  $n \rightarrow \infty$ .

## Conclusão

Para todo  $\varepsilon > 0$ :

$$\lim_{n \rightarrow \infty} P_\theta(|X_{n:n} - \theta| < \varepsilon) = 1 \quad (183)$$

Equivalentemente:

$$\lim_{n \rightarrow \infty} P_\theta(|X_{n:n} - \theta| \geq \varepsilon) = 0 \quad (184)$$

Portanto, pela definição de convergência em probabilidade:

$$X_{n:n} \xrightarrow[n \rightarrow \infty]{P} \theta \quad \square \quad (185)$$

Logo, o EMV  $\hat{\theta}_n = X_{n:n}$  é consistente para  $\theta$ .

## Observações e Intuição

### Pontos Importantes

- Método Direto vs. EQM:** Esta solução usa a *definição* de convergência em probabilidade diretamente, enquanto a Questão Extra 2 usou o EQM. Ambas são válidas!
- Tamanho Amostral Mínimo:** Das notas (n32), podemos encontrar o menor  $n_0$  tal que:

$$P(|X_{n:n} - \theta| < \varepsilon) \geq 1 - \delta \quad (186)$$

Resolvendo  $1 - (1 - \varepsilon/\theta)^n \geq 1 - \delta$ :

$$(1 - \varepsilon/\theta)^n \leq \delta \quad (187)$$

$$n \geq \frac{\log \delta}{\log(1 - \varepsilon/\theta)} \quad (188)$$

Logo:

$$n_0 = \left\lceil \frac{\log \delta}{\log(1 - \varepsilon/\theta)} \right\rceil + 1 \quad (189)$$

- Exemplo Numérico:** Para  $\theta = 10$ ,  $\varepsilon = 1$ ,  $\delta = 0.05$ :

$$n_0 \geq \frac{\log(0.05)}{\log(1 - 0.1)} \quad (190)$$

$$= \frac{-2.996}{-0.1054} \quad (191)$$

$$\approx 28.43 \quad (192)$$

Portanto,  $n_0 = 29$ . Com 29 ou mais observações, temos pelo menos 95% de chance de  $X_{n:n}$  estar a menos de 1 unidade de  $\theta = 10$ .

- EMV para Uniforme:** A verossimilhança é:

$$L(\theta; x) = \prod_{i=1}^n \frac{1}{\theta} \mathbf{1}_{0 < x_i < \theta} = \frac{1}{\theta^n} \mathbf{1}_{\theta > \max\{x_i\}} \quad (193)$$

Maximizar  $L$  é equivalente a minimizar  $\theta^n$  sujeito a  $\theta \geq \max\{x_i\}$ , logo  $\hat{\theta} = \max\{x_i\} = X_{n:n}$ .

- Comparação com Método dos Momentos:** O estimador de momentos seria:

$$\tilde{\theta}_n = 2\bar{X}_n \quad (194)$$

(pois  $E[X] = \theta/2$ ). Ambos são consistentes, mas o EMV é preferível por ter menor variância assintótica.

## Resumo da Questão

**Resultado Principal:**

$$\hat{\theta}_n = X_{n:n} \xrightarrow{P} \theta$$

**Método Utilizado:**

- Definição direta de convergência em probabilidade
- Cálculo de  $P(|X_{n:n} - \theta| < \varepsilon)$  via fda
- Limite:  $(1 - \varepsilon/\theta)^n \rightarrow 0$

**Importância:** Prova rigorosa da consistência do EMV para a Uniforme(0,θ).

# Conclusão

Este documento apresentou soluções detalhadas e didáticas para as principais questões extras do Capítulo 3 sobre Teoria Assintótica resolvidas em sala de aula.

## Síntese dos Tópicos Abordados

### 1. Convergência em Probabilidade (Q Extra 1–4):

- Variância amostral  $S_n^2$  via transformação de Helmert
- Máximo da uniforme via cálculo de momentos
- Operações algébricas com convergentes (quociente)
- Funções contínuas preservam convergência

### 2. Convergência em Distribuição (Q Extra 5, Exercício 11):

- Distribuição limite Exponencial do máximo normalizado
- Estatística qui-quadrado via TCL e função contínua

### 3. Consistência de Estimadores (Q 3.23):

- Consistência do EMV para Uniforme
- Demonstração via definição direta

## Conexões Entre as Questões

- Q Extra 1 → Q Extra 3:  $S_n^2$  consistente  $\Rightarrow$  quociente converge
- Q Extra 2 → Q Extra 4:  $X_{n:n}$  consistente  $\Rightarrow X_{n:n}^2$  consistente
- Q Extra 2 → Q Extra 5: Convergência em P  $\rightarrow$  distribuição limite
- TCL → Exercício 11: Normal  $\rightarrow$  qui-quadrado via função contínua

## Principais Técnicas Demonstradas

1. **Transformação de Helmert** - representar estatísticas como médias
2. **Cálculo de momentos** - mostrar EQM  $\rightarrow 0$
3. **Operações algébricas** - Resultado 4P
4. **Funções contínuas** - Resultados 5P e Teorema 3.7.6.4(a)
5. **Cálculo de fda** - identificar distribuições limite
6. **Limites fundamentais** - (R.1), (R.2), (R.3)

## Mensagens Principais

- Convergência em probabilidade permite trabalhar com estimadores como se fossem constantes
- Funções contínuas preservam ambos os tipos de convergência
- Distribuições limite nem sempre são normais (Ex: Exponencial)
- EMVs são geralmente consistentes (sob condições de regularidade)
- Transformações de normalização revelam taxas de convergência

## Recomendações de Estudo

Para dominar o material:

1. Refaça todas as questões sem consultar as soluções
2. Identifique qual resultado/teorema aplicar em cada passo
3. Conecte as questões com a teoria do arquivo `teoria_cap3_completo.tex`
4. Pratique variações (e.g.,  $U(a, b)$  em vez de  $U(0, \theta)$ )
5. Simule dados no R/Python para visualizar as convergências

**Bom estudo! Dominar estas técnicas é essencial para inferência estatística.**