

Material Auxiliar de Teoria

Capítulo 3 – Teoria Assintótica e Teoremas Limite

Definições, Resultados e Demonstrações Completas

Curso de Inferência Estatística – PPGEST/UFPE

Material de Apoio para Estudo

Novembro 2025

AVISO IMPORTANTE: Este documento contém toda a teoria fundamental do Capítulo 3, com ênfase especial nas demonstrações COMPLETAS e DETALHADAS do **Teorema Central do Limite**, **Teorema de Slutsky** e **Teorema de Mann–Wald (Método Delta)**, que têm alta probabilidade de serem cobrados na prova. Todas as provas foram extraídas das notas originais e expandidas com detalhes adicionais. Estude com atenção cada passo das demonstrações.

Sumário

1	Visão Geral do Capítulo	3
2	Notação Assintótica e Ferramentas Analíticas	3
2.1	Limites determinísticos recorrentes	3
2.2	Definições fundamentais	4
2.3	Expansões de Taylor e aplicações	6
3	Convergência em Probabilidade	7
3.1	Definições e equivalências	7
3.2	Resultados fundamentais sobre convergência em probabilidade	7
4	Convergência em Distribuição	10
4.1	Definição e primeiras consequências	10
5	Teoremas Fundamentais	11
5.1	Teorema de Slutsky (Resultado 3D)	11
5.2	Teorema Central do Limite (TCL)	12
5.3	Método Delta (Teorema de Mann–Wald)	14
6	Consistência e Eficiência de Estimadores	15
7	Normalidade Assintótica dos EMVs	15
8	Teorema Especial: Normalidade Assintótica da Variância Amostral	16
9	Exemplos Resolvidos e Aplicações	18

1 Visão Geral do Capítulo

Observações e Comentários

Objetivo central: compreender o comportamento assintótico de estatísticas fundamentais da inferência. Quando $n \rightarrow \infty$, aproximações tornam-se rigorosas e justificam métodos práticos.

- Revisar limites determinísticos e notações assintóticas que sustentam expansões de Taylor.
- Formalizar modos de convergência para sequências de variáveis aleatórias e estabelecer suas relações.
- Demonstrar resultados estruturantes: Leis Fracas dos Grandes Números, Teorema de Slutsky, Teorema Central do Limite e Método Delta.
- Aplicar esses resultados a estimadores clássicos, investigando consistência, normalidade assintótica e eficiência.

Como usar este guia: leia cada definição, acompanhe as demonstrações e replique os exemplos em suas próprias palavras. Os exercícios extras das notas foram incorporados como aplicações guiadas.

2 Notação Assintótica e Ferramentas Analíticas

2.1 Limites determinísticos recorrentes

Observações e Comentários

Resultados básicos (notas R.1–R.3) usados em aproximações:

$$(R.1) \quad \lim_{n \rightarrow \infty} n^{1/n} = 1,$$

$$(R.2) \quad \lim_{n \rightarrow \infty} \left(1 + \frac{1}{n}\right)^n = e,$$

$$(R.3) \quad \lim_{n \rightarrow \infty} \left(1 + \frac{x}{n}\right)^n = e^x, \quad x \in \mathbb{R}.$$

Esses limites justificam, por exemplo, a aproximação da $\text{Binomial}(n, \lambda/n)$ pela $\text{Poisson}(\lambda)$ quando $n \rightarrow \infty$:

$$P(X = k) = \binom{n}{k} \left(\frac{\lambda}{n}\right)^k \left(1 - \frac{\lambda}{n}\right)^{n-k} \xrightarrow{n \rightarrow \infty} e^{-\lambda} \frac{\lambda^k}{k!}.$$

2.2 Definições fundamentais

Definição 3.7.2.1: Notação $O(\cdot)$ para seqüências

Sejam $\{a_n\}$ e $\{b_n\}$ seqüências reais. Escrevemos $a_n = O(b_n)$ quando existe $k > 0$ e $n_0 \in \mathbb{N}$ tais que

$$\left| \frac{a_n}{b_n} \right| \leq k, \quad \forall n \geq n_0.$$

Em particular, $a_n = O(1)$ significa que a seqüência é limitada para n grande.

Definição 3.7.2.2: Notação $o(\cdot)$ para seqüências

Dizemos que $a_n = o(b_n)$ se, e somente se,

$$\lim_{n \rightarrow \infty} \frac{a_n}{b_n} = 0.$$

Logo, $a_n = o(1)$ implica $a_n \rightarrow 0$ quando $n \rightarrow \infty$.

Definição 3.7.2.3: Notação $\theta(\cdot)$

Nas notas do capítulo a notação $\theta(\cdot)$ é usada como sinônimo de $o(\cdot)$. Assim,

$$a_n = \theta(b_n) \iff \lim_{n \rightarrow \infty} \frac{a_n}{b_n} = 0.$$

Quando não houver ambigüidade, manteremos a convenção padrão $o(\cdot)$, lembrando que $\theta(\cdot)$ foi empregada nos arquivos originais.

Definição 3.7.3.2: Notação $O(\cdot)$ e $o(\cdot)$ para funções reais

Para funções $f, g : \mathbb{R} \rightarrow \mathbb{R}$ definidas numa vizinhança de x_0 :

O grande quando $x \rightarrow x_0$: Escrevemos $f(x) = O(g(x))$ quando existe $k > 0$ e $\delta > 0$ tais que

$$\left| \frac{f(x)}{g(x)} \right| \leq k, \quad \forall x \text{ com } |x - x_0| < \delta.$$

O grande quando $x \rightarrow \infty$: Escrevemos $f(x) = O(g(x))$ quando existe $k > 0$ e $M > 0$ tais que

$$\left| \frac{f(x)}{g(x)} \right| \leq k, \quad \forall x > M.$$

o pequeno quando $x \rightarrow x_0$: Escrevemos $f(x) = o(g(x))$ se

$$\lim_{x \rightarrow x_0} \frac{f(x)}{g(x)} = 0.$$

o pequeno quando $x \rightarrow \infty$: Analogamente,

$$\lim_{x \rightarrow \infty} \frac{f(x)}{g(x)} = 0.$$

Exemplos importantes:

- $8x^2 = O(x^2)$ quando $x \rightarrow \infty$ pois $8x^2/x^2 = 8$ (limitado).
- $8x^2 \neq o(x^2)$ quando $x \rightarrow \infty$ pois $8x^2/x^2 \rightarrow 8 \neq 0$.
- $8x^2 = o(x^3)$ quando $x \rightarrow \infty$ pois $8x^2/x^3 = 8/x \rightarrow 0$.

Teorema Extra 1: Propriedades de $O(\cdot)$ e $o(\cdot)$

Sejam $\{a_n\}, \{b_n\}, \{c_n\}, \{d_n\}$ seqüências reais e $r > 0$. Valem:

- (i) Se $a_n = o(b_n)$ então $a_n = O(b_n)$.
- (ii) Se $a_n = O(b_n)$ e $c_n = O(d_n)$, então:
 - (a) $a_n c_n = O(b_n d_n)$,
 - (b) $|a_n|^r = O(|b_n|^r)$,
 - (c) $a_n + c_n = O(\max\{|b_n|, |d_n|\})$.
- (iii) Se $a_n = o(b_n)$ e $c_n = o(d_n)$, então:
 - (a) $a_n c_n = o(b_n d_n)$,
 - (b) $|a_n|^r = o(|b_n|^r)$,
 - (c) $a_n + c_n = o(\max\{|b_n|, |d_n|\})$.
- (iv) Se $a_n = O(b_n)$ e $c_n = o(d_n)$, então $a_n c_n = o(b_n d_n)$.
- (v) Se $a_n = O(b_n)$ e $b_n = o(c_n)$, então $a_n = o(c_n)$.

Demonstração Detalhada

Ideia da demonstração. Todas as afirmações decorrem diretamente das definições. Por exemplo:

- (i) Se $\lim |a_n/b_n| = 0$, então existe n_0 e $k = 1$ tais que $|a_n/b_n| \leq 1$ para $n \geq n_0$.
- (ii.a) Dados $a_n = O(b_n)$ e $c_n = O(d_n)$, existem k_1, k_2 e n_1, n_2 com $|a_n| \leq k_1 |b_n|$ e $|c_n| \leq k_2 |d_n|$. Para $n \geq \max\{n_1, n_2\}$,

$$|a_n c_n| \leq k_1 k_2 |b_n d_n|,$$

$$\text{logo } a_n c_n = O(b_n d_n).$$

- (iii.a) Usando o mesmo raciocínio com $o(\cdot)$, obtemos $\lim_{n \rightarrow \infty} |a_n c_n|/(|b_n d_n|) = 0$.

Os demais itens seguem análoga e mecanicamente. □

Observações e Comentários

Exemplos rápidos:

- $10n^2 + n = O(n^2)$ porque $|(10n^2 + n)/n^2| \leq 11$ para todo $n \geq 1$.
- $n = o(n^2)$ pois $n/n^2 = 1/n \rightarrow 0$.
- $n^{-1} = o(1)$ e $n^{-1} = O(1)$, logo a sequência é limitada e converge a zero.
- A expansão $e^x = 1 + x + O(x^2)$ segue de aplicar Taylor e a propriedade (ii.b) do teorema acima.

2.3 Expansões de Taylor e aplicações

Expansão de Taylor até ordem n

Se $F : \mathbb{R} \rightarrow \mathbb{R}$ é uma função derivável até a ordem n em um ponto x_0 , sua expansão em série de Taylor em torno de x_0 pode ser escrita como:

$$F(x) = \sum_{k=0}^n \frac{F^{(k)}(x_0)}{k!} (x - x_0)^k + o((x - x_0)^n), \quad \text{quando } x \rightarrow x_0 \quad (1)$$

onde $F^{(k)}$ é a derivada de ordem k de $F(\cdot)$.

Observações e Comentários

Expansões fundamentais (usadas repetidamente nas demonstrações assintóticas):

$$\begin{aligned} e^x &= 1 + x + \frac{x^2}{2!} + \frac{x^3}{3!} + O(x^4), \\ \log(1+x) &= x - \frac{x^2}{2} + \frac{x^3}{3} + O(x^4), \\ (1+x)^\alpha &= 1 + \alpha x + \frac{\alpha(\alpha-1)}{2} x^2 + \frac{\alpha(\alpha-1)(\alpha-2)}{6} x^3 + O(x^4). \end{aligned}$$

Exemplo worked out (das notas): Mostrar que $\log(1+x) \cdot e^x = x + O(x^2)$ quando $x \rightarrow 0$.

Solução: Usando as expansões de Taylor:

$$\begin{aligned} e^x &= e^0 + x \cdot e^0 + o(x) = 1 + x + O(x^2), \\ \log(1+x) &= \log(1) + \frac{1}{1+x} \Big|_{x=0} \cdot x + o(x) = x + O(x^2). \end{aligned}$$

Logo,

$$\begin{aligned} e^x \log(1+x) &= [1+x+O(x^2)][x+O(x^2)] \\ &= 1 \cdot x + 1 \cdot O(x^2) + x \cdot x + x \cdot O(x^2) + O(x^2) \cdot x + O(x^2) \cdot O(x^2) \\ &= x + O(x^2) + x^2 + O(x^3) + O(x^3) + O(x^4) \\ &= x + x^2 + O(x^2) \quad (\text{propriedade iii.3}) \\ &= x + O(x^2). \quad \square \end{aligned}$$

3 Convergência em Probabilidade

3.1 Definições e equivalências

Definição 3.7.4.1(a)

Seja $\{U_n\}_{n \geq 1}$ uma sequência de variáveis aleatórias reais. Dizemos que U_n converge em probabilidade para $u \in \mathbb{R}$, e escrevemos

$$U_n \xrightarrow{P} u,$$

quando, para todo $\varepsilon > 0$,

$$P(|U_n - u| \geq \varepsilon) \xrightarrow{n \rightarrow \infty} 0.$$

Definição 3.7.42(a)

Para variáveis aleatórias U_n e U ,

$$U_n \xrightarrow{P} U \iff U_n - U \xrightarrow{P} 0.$$

Assim, convergência para uma constante u é um caso particular ao considerar $U \equiv u$ (variável degenerada).

3.2 Resultados fundamentais sobre convergência em probabilidade

Resultado 1P: Lei Fraca dos Grandes Números (versão simples)

Sejam X_1, \dots, X_n variáveis aleatórias i.i.d. com $E[X_i] = \mu < \infty$ e $\text{Var}(X_i) = \sigma^2 < \infty$. Então

$$\bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i \xrightarrow{P} \mu.$$

Demonstração Detalhada

Para $\varepsilon > 0$, pela desigualdade de Tchebysheff:

$$P(|\bar{X}_n - \mu| \geq \varepsilon) \leq \frac{\text{Var}(\bar{X}_n)}{\varepsilon^2} = \frac{\sigma^2}{n\varepsilon^2} \xrightarrow{n \rightarrow \infty} 0.$$

Logo $\bar{X}_n \xrightarrow{P} \mu$. □

Resultado 2P

Se $\{T_n\}$ é uma sequência de variáveis reais tal que, para algum $r > 0$ e $a \in \mathbb{R}$,

$$E[|T_n - a|^r] \xrightarrow{n \rightarrow \infty} 0,$$

então $T_n \xrightarrow{P} a$.

Demonstração Detalhada

Pela desigualdade de Markov, para qualquer $\varepsilon > 0$,

$$P(|T_n - a| \geq \varepsilon) = P(|T_n - a|^r \geq \varepsilon^r) \leq \frac{E[|T_n - a|^r]}{\varepsilon^r} \xrightarrow{n \rightarrow \infty} 0.$$

□

Resultado 3P: Lei Fraca dos Grandes Números de Khinchine

Se X_1, \dots, X_n são i.i.d. com $E[X_i] = \mu < \infty$ (não exigimos variância finita), então $\bar{X}_n \xrightarrow{P} \mu$.

Demonstração Detalhada

Considere a fgm de \bar{X}_n :

$$M_{\bar{X}_n}(t) = \left[M_{X_1} \left(\frac{t}{n} \right) \right]^n.$$

Expansão de Taylor em torno de 0 produz $M_{X_1}(t/n) = 1 + \mu \frac{t}{n} + o(t/n)$. Aplicando (R.3),

$$M_{\bar{X}_n}(t) \xrightarrow{n \rightarrow \infty} e^{t\mu},$$

que é a fgm da variável degenerada em μ . Logo $\bar{X}_n \xrightarrow{d} \mu$ e, como o limite é degenerado, $\bar{X}_n \xrightarrow{P} \mu$. □

Resultado 4P

Se $U_n \xrightarrow{P} u$ e $V_n \xrightarrow{P} v$, então:

(a) $U_n + V_n \xrightarrow{P} u + v$,

(b) $U_n V_n \xrightarrow{P} uv$,

(c) Se $P(V_n = 0) = 0$ e $v \neq 0$, então $\frac{U_n}{V_n} \xrightarrow{P} \frac{u}{v}$.

Demonstração Detalhada

Usamos apenas álgebra e a definição. Por exemplo, para o item (a):

$$P(|(U_n + V_n) - (u + v)| > \varepsilon) \leq P\left(|U_n - u| > \frac{\varepsilon}{2}\right) + P\left(|V_n - v| > \frac{\varepsilon}{2}\right) \rightarrow 0.$$

Os demais itens seguem substituindo produtos e quocientes e usando que V_n permanece afastado de zero em probabilidade. \square

Resultado 5P: Teorema da Função Contínua

Se $U_n \xrightarrow{P} u$ e $g: \mathbb{R} \rightarrow \mathbb{R}$ é contínua em u , então $g(U_n) \xrightarrow{P} g(u)$.

Demonstração Detalhada

Pela continuidade, dado $\varepsilon > 0$ existe $\delta > 0$ tal que $|x - u| < \delta \Rightarrow |g(x) - g(u)| < \varepsilon$. Assim,

$$P(|g(U_n) - g(u)| \geq \varepsilon) \leq P(|U_n - u| \geq \delta) \rightarrow 0.$$

\square

Observações e Comentários

Exemplo 1 (variância amostral). Seja S_n^2 a variância amostral de uma amostra i.i.d. com $E[X_i^2] < \infty$. Usando a transformação de Helmert,

$$S_n^2 = \frac{1}{n-1} \sum_{i=2}^n Y_i^2, \quad Y_i \sim N(0, \sigma^2).$$

Como $\{Y_i^2\}$ é i.i.d. com média σ^2 , o Resultado 1P implica $S_n^2 \xrightarrow{P} \sigma^2$. Logo S_n é um estimador consistente de σ .

Observações e Comentários

Exemplo 2 (Questão Extra 2 das notas): Máximo da Uniforme.

Enunciado: Sejam X_1, \dots, X_n i.i.d. com $X_i \sim U(0, \theta)$ para $\theta > 0$. Mostrar que $T_n = X_{(n)} \xrightarrow{P} \theta$.

Solução completa: Como $T_n = \max\{X_1, \dots, X_n\}$ é a maior estatística de ordem,

$$\begin{aligned} F_{T_n}(t) &= [F_{X_1}(t)]^n, \\ f_{T_n}(t) &= n[F_{X_1}(t)]^{n-1} f_{X_1}(t). \end{aligned}$$

Para a uniforme, $F_{X_1}(t) = \frac{t}{\theta} \mathbf{1}_{(0, \theta)}(t) + \mathbf{1}_{[\theta, \infty)}(t)$ e $f_{X_1}(t) = \frac{1}{\theta} \mathbf{1}_{(0, \theta)}(t)$. Logo,

$$f_{T_n}(t) = \frac{n}{\theta^n} t^{n-1} \mathbf{1}_{(0, \theta)}(t).$$

Calculamos os momentos:

$$E[T_n] = \int_0^\theta t \cdot \frac{n}{\theta^n} t^{n-1} dt = \frac{n}{\theta^n} \left[\frac{t^{n+1}}{n+1} \right]_0^\theta = \frac{n}{n+1} \theta,$$

$$E[T_n^2] = \int_0^\theta t^2 \cdot \frac{n}{\theta^n} t^{n-1} dt = \frac{n}{\theta^n} \left[\frac{t^{n+2}}{n+2} \right]_0^\theta = \frac{n}{n+2} \theta^2.$$

Portanto,

$$\begin{aligned} E[(T_n - \theta)^2] &= E[T_n^2] - 2\theta E[T_n] + \theta^2 \\ &= \frac{n}{n+2} \theta^2 - \frac{2n}{n+1} \theta^2 + \theta^2 \\ &= \theta^2 \left\{ \frac{n}{n+2} - \frac{2n}{n+1} + 1 \right\} \\ &= \theta^2 \left\{ \frac{n(n+1) - 2n(n+2) + (n+2)(n+1)}{(n+2)(n+1)} \right\} \\ &= \theta^2 \left\{ \frac{n^2 + n - 2n^2 - 4n + n^2 + 3n + 2}{(n+2)(n+1)} \right\} \\ &= \frac{2\theta^2}{(n+2)(n+1)} \xrightarrow{n \rightarrow \infty} 0. \end{aligned}$$

Pelo Resultado 2P, $T_n \xrightarrow{P} \theta$.

□

4 Convergência em Distribuição

4.1 Definição e primeiras consequências

Definição 3.15.1(a)

Seja $\{U_n\}$ uma sequência de variáveis aleatórias com funções de distribuição F_n , e U uma variável com distribuição F . Dizemos que U_n converge em distribuição para U , denotado por $U_n \xrightarrow{D} U$, se

$$F_n(u) \xrightarrow{n \rightarrow \infty} F(u) \quad \text{para todo ponto de continuidade de } F.$$

Resultado 1D: Convergência via função geradora de momentos

Se $M_{U_n}(t) \rightarrow M_U(t)$ em uma vizinhança de $t = 0$ e as mgf's existem nessa vizinhança, então $U_n \xrightarrow{D} U$.

Demonstração Detalhada

A mgf determina unicamente a distribuição quando existe em um intervalo aberto contendo zero. A convergência pontual das mgf's implica convergência das funções características, e o Teorema de Unicidade das funções características garante $U_n \xrightarrow{D} U$.

U .

□

Resultado 2D: Relação com convergência em probabilidade

Se $U_n \xrightarrow{P} U$, então $U_n \xrightarrow{D} U$. A recíproca é verdadeira apenas quando U é degenerada.

Demonstração Detalhada

Se U é constante u , então $F(u^-) = 0$ e $F(u) = 1$, de modo que a convergência de distribuições implica $P(|U_n - u| > \varepsilon) \rightarrow 0$. Para U não degenerada, a convergência em distribuição não garante a concentração das probabilidades. □

Teorema 3.7.6.4(a): Teorema da Função Contínua em Distribuição

Se $U_n \xrightarrow{D} U$ e g é contínua, então $g(U_n) \xrightarrow{D} g(U)$.

Demonstração Detalhada

Considere uma função contínua limitada h . Por $U_n \xrightarrow{D} U$, temos $E[h(g(U_n))] \rightarrow E[h(g(U))]$ (Teorema de Portmanteau). Como as funções indicadoras de intervalos podem ser aproximadas por funções contínuas, conclui-se a convergência das distribuições de $g(U_n)$ para a de $g(U)$. □

Observações e Comentários

Aplicação direta: se $Z_n = \sqrt{n}(\bar{X}_n - \mu)/\sigma \xrightarrow{D} N(0, 1)$, então, para $g(x) = x^2$, obtemos

$$n \left(\frac{\bar{X}_n - \mu}{\sigma} \right)^2 = g(Z_n) \xrightarrow{D} \chi_1^2.$$

Este é exatamente o exercício (11) das notas.

5 Teoremas Fundamentais

5.1 Teorema de Slutsky (Resultado 3D)

Resultado 3D: Teorema de Slutsky

Se $U_n \xrightarrow{D} U$ e $V_n \xrightarrow{P} v$, com $v \in \mathbb{R}$ e $P(V_n = 0) = 0$ para todo n , então:

- (a) $U_n + V_n \xrightarrow{D} U + v$,
- (b) $U_n V_n \xrightarrow{D} Uv$,
- (c) $\frac{U_n}{V_n} \xrightarrow{D} \frac{U}{v}$ quando $v \neq 0$.

Demonstração Detalhada

Primeiro, $V_n \xrightarrow{P} v$ implica $V_n \xrightarrow{D} v$. Usamos o Teorema de Portmanteau e funções contínuas limitadas f .

(a) **Soma.** Escreva

$$f(U_n + V_n) - f(U_n + v) \xrightarrow{P} 0$$

porque f é uniformemente contínua em compactos e $V_n \xrightarrow{P} v$. Logo

$$E[f(U_n + V_n)] = E[f(U_n + v)] + o(1).$$

Como $U_n \xrightarrow{D} U$, o lado direito converge para $E[f(U + v)]$, provando a convergência em distribuição.

(b) **Produto** e (c) **quociente** seguem escrevendo $U_n V_n = U_n v + U_n(V_n - v)$ e $\frac{U_n}{V_n} = \frac{U_n}{v} \cdot \frac{v}{V_n}$. Em ambos os casos, $V_n - v \xrightarrow{P} 0$ e $V_n/v \xrightarrow{P} 1$, aplicando o item (a) e o Resultado 5P completamos a prova. \square

Observações e Comentários

Aplicação. Seja $T_n = \sqrt{n}(\bar{X}_n - \mu)/S_n$. Temos $S_n \xrightarrow{P} \sigma$ (Resultado 1P) e $Z_n = \sqrt{n}(\bar{X}_n - \mu)/\sigma \xrightarrow{D} N(0, 1)$ (TCL). Pelo Teorema de Slutsky,

$$T_n = Z_n \cdot \frac{\sigma}{S_n} \xrightarrow{D} N(0, 1).$$

Isto explica a aproximação normal para o teste- t com amostras grandes.

5.2 Teorema Central do Limite (TCL)

Teorema 3.7.6.1(a): Teorema Central do Limite clássico

Sejam X_1, \dots, X_n i.i.d. com $E[X_i] = \mu$ e $\text{Var}(X_i) = \sigma^2 < \infty$. Então

$$Z_n = \sqrt{n} \frac{\bar{X}_n - \mu}{\sigma} \xrightarrow{D} N(0, 1).$$

Demonstração Detalhada

Para $S_n = \sum_{i=1}^n X_i$, considere a função característica de Z_n :

$$\varphi_{Z_n}(t) = E \left[\exp \left(it \frac{S_n - n\mu}{\sigma\sqrt{n}} \right) \right] = \left[\varphi_{X_1} \left(\frac{t}{\sigma\sqrt{n}} \right) e^{-it \frac{\mu}{\sigma\sqrt{n}}} \right]^n.$$

Expansões de Taylor até segunda ordem dão

$$\log \varphi_{Z_n}(t) = -\frac{t^2}{2} + o(1).$$

Tomando o limite obtemos $\varphi_{Z_n}(t) \rightarrow e^{-t^2/2}$, função característica de $N(0, 1)$. Conclui-se $Z_n \xrightarrow{D} N(0, 1)$.

Observações e Comentários

Versões úteis e aplicações:

- **Versão padronizada sem variância conhecida:** $T_n = \sqrt{n}(\bar{X}_n - \mu)/S_n \xrightarrow{D} N(0, 1)$ (Slutsky).
- **Aplicação à variância amostral:** $(n-1)^{1/2}(S_n^2 - \sigma^2) \xrightarrow{D} N(0, 2\sigma^4)$ usando o TCL sobre $\{Y_i^2\}$ com Y_i variáveis de Helmer.
- **Transformações lineares:** Para $a \neq 0$, $aZ_n + b \xrightarrow{D} N(b, a^2)$.

Observações e Comentários

Exemplo (Questão 4 das notas): Distribuição de χ^2 normalizada.

Problema: Se $X_n \sim \chi_n^2$ e $U_n = \frac{1}{\sqrt{2n}}(X_n - n)$, encontrar a distribuição limite de U_n quando $n \rightarrow \infty$.

Solução pela MGF: Lembre que $E[X_n] = n$ e $\text{Var}(X_n) = 2n$. Logo U_n é a padronização de X_n .

Calculemos a mgf de U_n :

$$\begin{aligned} M_{U_n}(t) &= E[e^{tU_n}] = E\left[e^{\frac{t}{\sqrt{2n}}(X_n - n)}\right] \\ &= e^{-\frac{tn}{\sqrt{2n}}} M_{X_n}\left(\frac{t}{\sqrt{2n}}\right). \end{aligned}$$

Como $X_n \sim \chi_n^2 \equiv \Gamma(n/2, 1/2)$, sua mgf é $M_{X_n}(t) = (1 - 2t)^{-n/2}$. Portanto,

$$\begin{aligned} M_{U_n}(t) &= e^{-\sqrt{n/2}t} \left(1 - 2 \cdot \frac{t}{\sqrt{2n}}\right)^{-n/2} \\ &= e^{-\sqrt{n/2}t} \left(1 - \sqrt{\frac{2}{n}}t\right)^{-n/2}. \end{aligned}$$

Tomando logaritmo:

$$\log M_{U_n}(t) = -\sqrt{\frac{n}{2}}t - \frac{n}{2} \log\left(1 - \sqrt{\frac{2}{n}}t\right).$$

Pela expansão de Taylor $\log(1 - x) = -x - \frac{x^2}{2} + O(x^3)$:

$$\begin{aligned} \log\left(1 - \sqrt{\frac{2}{n}}t\right) &= -\sqrt{\frac{2}{n}}t - \frac{1}{2}\left(\sqrt{\frac{2}{n}}t\right)^2 + O(n^{-3/2}) \\ &= -\sqrt{\frac{2}{n}}t - \frac{t^2}{n} + O(n^{-3/2}). \end{aligned}$$

Logo,

$$\begin{aligned}\log M_{U_n}(t) &= -\sqrt{\frac{n}{2}}t - \frac{n}{2} \left(-\sqrt{\frac{2}{n}}t - \frac{t^2}{n} + O(n^{-3/2}) \right) \\ &= -\sqrt{\frac{n}{2}}t + \sqrt{\frac{n}{2}}t + \frac{t^2}{2} + O(n^{-1/2}) \\ &= \frac{t^2}{2} + o(1).\end{aligned}$$

Assim, $\lim_{n \rightarrow \infty} M_{U_n}(t) = e^{t^2/2}$, que é a mgf de $N(0, 1)$. Concluimos $U_n \xrightarrow{D} N(0, 1)$. \square

5.3 Método Delta (Teorema de Mann–Wald)

Teorema 3.7.6.2(a): Teorema de Mann–Wald / Método Delta

Se $\sqrt{n}(T_n - \theta) \xrightarrow{D} N(0, \sigma^2(\theta))$ e g é uma função continuamente diferenciável com $g'(\theta) \neq 0$, então

$$\sqrt{n} [g(T_n) - g(\theta)] \xrightarrow{D} N(0, \sigma^2(\theta)g'(\theta)^2).$$

Demonstração Detalhada

Expandamos g em série de Taylor ao redor de θ :

$$g(T_n) = g(\theta) + g'(\theta)(T_n - \theta) + R_n,$$

onde $R_n = \frac{g''(\tilde{\theta}_n)}{2}(T_n - \theta)^2$ para algum $\tilde{\theta}_n$ entre T_n e θ . Como $T_n \xrightarrow{P} \theta$, temos $R_n = o_P(|T_n - \theta|)$. Multiplicando por \sqrt{n} ,

$$\sqrt{n}[g(T_n) - g(\theta)] = g'(\theta)\sqrt{n}(T_n - \theta) + o_P(1).$$

O termo principal converge em distribuição para $N(0, \sigma^2(\theta)g'(\theta)^2)$ e o resíduo converge em probabilidade para zero. Aplica-se Slutsky. \square

Observações e Comentários

Exemplo (estatística de ordem). Em $X_{n:n} \sim \max\{X_1, \dots, X_n\}$ com $X_i \sim U(0, \theta)$, temos $T_n = X_{n:n} \xrightarrow{P} \theta$ e

$$U_n = \frac{n}{\theta}(\theta - T_n) \xrightarrow{D} \text{Exp}(1).$$

Logo, $g(T_n) = T_n^2$ satisfaz $g'(x) = 2x$, e o Método Delta fornece

$$\sqrt{n}(T_n^2 - \theta^2) \xrightarrow{D} N(0, 4\theta^2 \text{Var}(T_n)).$$

6 Consistência e Eficiência de Estimadores

Definição 3.7.1: Consistência fraca

Uma sequência de estimadores $\{T_n\}$ para $\tau(\theta)$ é dita consistente (no sentido fraco) se

$$T_n \xrightarrow{P} \tau(\theta).$$

Se a convergência não ocorre, o estimador é inconsistente.

Observações e Comentários

Caracterizações úteis:

- Para todo $\varepsilon > 0$, $P_\theta(|T_n - \tau(\theta)| > \varepsilon) \rightarrow 0$.
- Se $E_\theta[(T_n - \tau(\theta))^2] \rightarrow 0$ então T_n é consistente (desigualdade de Chebysheff).
- Quando T_n é centrado, consistência implica que viés e variância convergem a zero.

Definição 3.4.1: Eficiência relativa assintótica

Se $T_n^{(1)}$ e $T_n^{(2)}$ são estimadores assintoticamente normais para $g(\theta)$,

$$\sqrt{n}(T_n^{(i)} - g(\theta)) \xrightarrow{D} N(0, \sigma_i^2(\theta)),$$

definimos a eficiência relativa de $T_n^{(2)}$ em relação a $T_n^{(1)}$ como $\sigma_1^2(\theta)/\sigma_2^2(\theta)$. O estimador com menor variância assintótica é chamado de mais eficiente.

7 Normalidade Assintótica dos EMVs

Teorema 3.8.1: TCL para o EMV (caso univariado)

Seja X_1, \dots, X_n uma amostra de densidade $f(x; \theta)$, $\theta \in \Theta \subset \mathbb{R}$. Sob as seguintes condições de regularidade:

(A1) $f(x; \theta)$ é três vezes diferenciável em θ ;

(A2) Derivadas podem ser permutadas com integrais:

$$\int \frac{\partial f(x; \theta)}{\partial \theta} dx = 0 \quad \text{e} \quad \int \frac{\partial^2 f(x; \theta)}{\partial \theta^2} dx = 0;$$

(A3) A informação de Fisher é finita e positiva:

$$0 < I_X(\theta) \triangleq E_\theta \left[\left(\frac{\partial \log f(X; \theta)}{\partial \theta} \right)^2 \right] < \infty, \quad \forall \theta \in \Theta;$$

(A4) Para cada $\theta_0 \in \Theta$, existe $\varepsilon = \varepsilon(\theta_0) > 0$ tal que

$$\left| \frac{\partial^3 \log f(x; \theta)}{\partial \theta^3} \right| \leq g(x), \quad \forall \theta \in [\theta_0 - \varepsilon, \theta_0 + \varepsilon],$$

onde

$$\int_{\mathcal{X}} g(x) f(x; \theta) dx < \infty;$$

(A5) A equação de verossimilhança

$$\frac{\partial l(\theta)}{\partial \theta} = 0 \Leftrightarrow \sum_{i=1}^n \frac{\partial \log f(X_i; \theta)}{\partial \theta} = 0$$

tem uma solução consistente $\hat{\theta}_n$ (i.e., $\hat{\theta}_n \xrightarrow{P} \theta_0$).

Então:

$$\sqrt{n}(\hat{\theta}_n - \theta_0) \xrightarrow{D} N(0, I_X^{-1}(\theta_0)), \quad \text{quando } n \rightarrow \infty.$$

Teorema 3.9.2: Versão multivariada

Suponha X_1, \dots, X_n com vetor de parâmetros $\theta \in \Theta \subset \mathbb{R}^p$ e condições (B1)–(B5) das notas:

- (B1) o suporte $\mathcal{C} = \{x : f(x; \theta) > 0\}$ não depende de θ ;
- (B2) $f(x; \theta)$ é três vezes diferenciável em cada componente;
- (B3) derivadas podem permutar com integrais até segunda ordem;
- (B4) a matriz de informação $I(\theta)$ é finita e não singular;
- (B5) derivadas de terceira ordem são dominadas por função integrável em vizinhança de θ_0 .

Então existe uma sequência de EMVs $\hat{\theta}_n$ tal que

$$\hat{\theta}_n \xrightarrow{P} \theta_0 \quad \text{e} \quad \sqrt{n}(\hat{\theta}_n - \theta_0) \xrightarrow{D} N_p(0, I^{-1}(\theta_0)).$$

Observações e Comentários

Consequências práticas:

- EMVs são assintoticamente eficientes: atingem o limite de Cramér-Rao assintótico $I^{-1}(\theta_0)$.
- Pelo Método Delta, $g(\hat{\theta}_n)$ é assintoticamente normal com variância $g'(\theta_0)^\top I^{-1}(\theta_0) g'(\theta_0)$.
- Estatísticas de teste baseadas na razão de verossimilhanças usam diretamente a normalidade assintótica do EMV.

8 Teorema Especial: Normalidade Assintótica da Variância Amostral

Teorema 3.7.6.3(a): TCL para a variância amostral

Sejam X_1, \dots, X_n v.a.'s i.i.d. com média μ , variância σ^2 e $\mu_4 = E[(X_1 - \mu)^4]$. Assuma que $0 < \mu_4 < \infty$ e $\mu_4 > \sigma^4$ (curtose > 1). Então,

$$\sqrt{n}(S_n^2 - \sigma^2) \xrightarrow{D} N(0, \mu_4 - \sigma^4).$$

Demonstração Detalhada

Demonstração completa (das notas n27–n28):

Considere $W_n \triangleq (n-1)n^{-1}S_n^2$, $Y_i \triangleq (X_i - \mu)^2$ para $i = 1, \dots, n$ e $\bar{Y}_n = n^{-1} \sum_{i=1}^n Y_i$. Assim,

$$\begin{aligned} W_n &= \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X}_n)^2 \\ &= \frac{1}{n} \sum_{i=1}^n (X_i - \mu + \mu - \bar{X}_n)^2 \\ &= \frac{1}{n} \sum_{i=1}^n [(X_i - \mu)^2 + 2(X_i - \mu)(\mu - \bar{X}_n) + (\mu - \bar{X}_n)^2] \\ &= \bar{Y}_n - 2(\bar{X}_n - \mu)^2 + (\bar{X}_n - \mu)^2 \\ &= \bar{Y}_n - (\bar{X}_n - \mu)^2. \end{aligned}$$

Vale então

$$\sqrt{n}(W_n - \sigma^2) = \underbrace{\sqrt{n}(\bar{Y}_n - \sigma^2)}_{U_n} - \underbrace{\sqrt{n}(\bar{X}_n - \mu)^2}_{V_n}.$$

Note que $\{Y_i\}$ é i.i.d. com $E[Y_i] = \sigma^2$ e $\text{Var}(Y_i) = E[Y_i^2] - (E[Y_i])^2 = E[(X_i - \mu)^4] - \sigma^4 = \mu_4 - \sigma^4$. Pelo TCL,

$$U_n \xrightarrow{D} N(0, \mu_4 - \sigma^4).$$

Para V_n , como $\bar{X}_n \xrightarrow{P} \mu$, temos $(\bar{X}_n - \mu)^2 \xrightarrow{P} 0$ (Resultado 5P). Logo,

$$V_n = \sqrt{n}(\bar{X}_n - \mu)^2 \xrightarrow{P} 0.$$

Pelo Teorema de Slutsky,

$$\sqrt{n}(W_n - \sigma^2) \xrightarrow{D} N(0, \mu_4 - \sigma^4).$$

Agora,

$$\begin{aligned} \sqrt{n}(S_n^2 - \sigma^2) &= \sqrt{n} \left(\frac{n}{n-1} W_n - \sigma^2 \right) \\ &= \sqrt{n} \left(\frac{n}{n-1} - 1 + 1 \right) (W_n - \sigma^2) + \sqrt{n} \left(\frac{n}{n-1} - 1 \right) \sigma^2 \\ &= \sqrt{n}(W_n - \sigma^2) + \frac{\sqrt{n}}{n-1} W_n. \end{aligned}$$

Como $W_n \xrightarrow{P} \sigma^2$ e $\frac{\sqrt{n}}{n-1} \rightarrow 0$, temos $\frac{\sqrt{n}}{n-1} W_n \xrightarrow{P} 0$. Pelo Teorema de Slutsky,

$$\sqrt{n}(S_n^2 - \sigma^2) \xrightarrow{D} N(0, \mu_4 - \sigma^4). \quad \square$$

9 Exemplos Resolvidos e Aplicações

Observações e Comentários

Exemplo 1: Distribuição limite do máximo uniforme. Se $X_i \sim U(0, \theta)$ e $T_n = X_{n:n}$, então

$$F_{T_n}(t) = \left(\frac{t}{\theta}\right)^n \mathbf{1}_{(0, \theta)}(t) + \mathbf{1}_{[\theta, \infty)}(t).$$

Para $U_n = \frac{n}{\theta}(\theta - T_n)$,

$$P(U_n \leq u) = P\left(T_n \geq \theta \left(1 - \frac{u}{n}\right)\right) = 1 - \left(1 - \frac{u}{n}\right)^n \xrightarrow{n \rightarrow \infty} 1 - e^{-u}.$$

Logo $U_n \xrightarrow{D} \text{Exp}(1)$ e, por $o_P(1)$, $T_n \xrightarrow{P} \theta$.

Observações e Comentários

Exemplo 2: Assintótica da variância amostral. Com Y_i de Helmert,

$$S_n^2 = \frac{1}{n-1} \sum_{i=2}^n Y_i^2.$$

Cada Y_i^2 tem média σ^2 e variância $2\sigma^4$. Pelo TCL,

$$(n-1)^{1/2}(S_n^2 - \sigma^2) \xrightarrow{D} N(0, 2\sigma^4).$$

Multiplicando por $\sqrt{n/(n-1)} \xrightarrow{P} 1$ e aplicando Slutsky, obtemos

$$\sqrt{n}(S_n^2 - \sigma^2) \xrightarrow{D} N(0, 2\sigma^4).$$

Observações e Comentários

Exemplo 3: Estatística χ^2 a partir do TCL. Com $Z_n = \sqrt{n}(\bar{X}_n - \mu)/\sigma \xrightarrow{D} N(0, 1)$,

$$n \left(\frac{\bar{X}_n - \mu}{\sigma} \right)^2 = Z_n^2 \xrightarrow{D} \chi_1^2.$$

Este é o exercício (11) das notas, demonstrando a importância do Teorema 3.7.6.4.

10 Checklist e Estratégia de Revisão

MUITO IMPORTANTE PARA A PROVA

Antes da prova, garanta que você consegue:

- Enunciar e demonstrar os Resultados 1P–5P e os Resultados 1D–2D.
- Explicar passo a passo as demonstrações do Teorema de Slutsky, do TCL e do Teorema de Mann–Wald.
- Aplicar o Método Delta em pelo menos dois exemplos distintos.
- Mostrar que S_n^2 é consistente e obter sua distribuição assintótica.
- Expor as hipóteses dos Teoremas 3.8.1 e 3.9.2 e interpretar a variância assintótica do EMV.
- Usar Slutsky para justificar estatísticas padronizadas (por exemplo, teste- t e estimadores normalizados).

Sugestão de prática: resolva novamente os exercícios extras (Q1–Q11) conferindo cada passagem com este material auxiliar.

Bom estudo! Dominar o comportamento assintótico é essencial para entender os capítulos seguintes sobre estimação e testes.