

Unidade 5 - Compilação Completa

Intervalos de Confiança e Tópicos Relacionados

Curso de Inferência Estatística

Outubro 2025

Sumário

Aula 26 (27/06/2025)

Unidade 5 - Intervalo de Confiança

Vamos começar com o importante conceito de *probabilidade de cobertura*.

Def. 1

Sejam $T_L(\hat{X})$ e $T_U(\hat{X})$ duas estatísticas baseadas numa a.a. $\hat{X} = (X_1, \dots, X_n)$, a probabilidade de cobertura do intervalo aleatório

$$J = [T_L(\hat{X}), T_U(\hat{X})] \quad (1)$$

para o parâmetro desconhecido $\theta \in \Theta \subset \mathbb{R}$ é dada por:

$$P_\theta \left(\theta \in [T_L(\hat{X}), T_U(\hat{X})] \right) \quad (2)$$

Na verdade, o *coeficiente de confiança* de J é dado por:

$$\inf_{\theta \in \Theta} \left\{ P_\theta \left(\theta \in [T_L(\hat{X}), T_U(\hat{X})] \right) \right\} \quad (3)$$

Na maioria das aplicações, a probabilidade de cobertura não depende do parâmetro e será equivalente ao coeficiente de confiança. **Exemplo 1:** Sejam

$$J_1 = (x_1 - 1,96; x_1 + 1,96) \quad \text{e} \quad J_2 = \left(\bar{x} - \frac{1,96}{\sqrt{2}}, \bar{x} + \frac{1,96}{\sqrt{2}} \right)$$


dois intervalos aleatórios tais que $x_1, x_2 \sim N(\mu, 1)$ e

$$\bar{x} = \frac{x_1 + x_2}{2}.$$

Encontre as probabilidades de cobertura de J_1 e J_2 .

Solução: Temos que

$$\begin{aligned} P_\mu(\mu \in J_1) &= P_\mu(\mu \in (x_1 - 1,96; x_1 + 1,96)) \\ &= P_\mu(x_1 - 1,96 < \mu < x_1 + 1,96) \\ &= P_\mu([(x_1 - \mu) < 1,96] \cap [(x_1 - \mu) > -1,96]) \\ &= P_\mu(|x_1 - \mu| < 1,96) \\ &= P_\mu(|Z| < 1,96), \quad Z = x_1 - \mu \sim N(0, 1) \\ &= 95\%. \end{aligned}$$



Da mesma forma,

$$P_\mu(\mu \in J_2) = P_\mu \left(\mu \in \left(\bar{x} - \frac{1,96}{\sqrt{2}}, \bar{x} + \frac{1,96}{\sqrt{2}} \right) \right) \Rightarrow$$

$$P_\alpha(\mu \in I_\alpha) = P_\mu \left(\bar{X} - \frac{1.96}{\sqrt{\nu}} < \mu < \bar{X} + \frac{1.96}{\sqrt{\nu}} \right) \quad (4)$$

$$= P_\mu \left[\frac{\bar{X} - \mu}{\sqrt{\nu}} < 1.96 \right] \cap \left[\frac{\bar{X} - \mu}{\sqrt{\nu}} > -1.96 \right] \quad (5)$$

$$= P_\mu \left(\left| \frac{\bar{X} - \mu}{\sqrt{\nu}} \right| < 1.96 \right) \quad (6)$$

$$= P_\mu (|Z| < 1.96) = 95\% \quad (7)$$

Aula 21 (25/06/2025)

Para construção de intervalos de confiança, podem-se utilizar duas abordagens: (i) inversão do procedimento de teste de hipótese e (ii) usando quantidade pivotal.

Inversão de um procedimento de teste

Em teste de hipótese, a região de não rejeição de H_0 foi denotada como

$$R_C^C = \begin{cases} \{x \in \mathcal{X}^n; T(x|\theta) \leq k\}^C & \text{para } H_1 : \theta > \theta_0, \\ \{x \in \mathcal{X}^n; T(x|\theta) \geq k\}^C & \text{para } H_1 : \theta < \theta_0, \\ \text{(como uma solução plausível)} & \\ \{x \in \mathcal{X}^n; |T(x|\theta)| \leq k\}^C & \text{para } H_1 : \theta \neq \theta_0. \end{cases} \quad (8)$$

O intervalo de confiança é bastante relacionado com R_C .


Exemplo 2: Seja X_1, \dots, X_n uma a.a. de $X_i \sim N(\mu, \sigma^2)$ para média desconhecida e $\sigma > 0$ conhecida. Considere que X obedece tanto $H_0 : \mu = \mu_0$ quanto $H_1 : \mu > \mu_0$. Encontre o estimador intervalar para μ de confiança $1 - \alpha$ para $\alpha \in (0, 1)$ pré-fixado.

Solução: Já foi discutido que o teste UMP para $H_0 < H_1$ de nível α tem função crítica:

$$\Psi(x) = \begin{cases} 1, & \sqrt{n} \frac{\bar{X}_n - \mu_0}{\sigma} > z_\alpha, \\ 0, & \text{c.c.} \end{cases} \quad (9)$$

em que $\bar{X}_n = n^{-1} \sum_{i=1}^n x_i$ e $x = (x_1, \dots, x_n)$ é uma a.a. A região de não rejeição é dada por:

$$R_c = \left\{ x \in \mathbb{R}^n : \sqrt{n} \frac{\bar{X}_n - \mu_0}{\sigma} \leq z_\alpha \right\} \quad (10)$$



Note que:

$$P_{\mu_0} \left(\sqrt{n} \frac{\bar{X}_n - \mu_0}{\sigma} \leq z_\alpha \right) = 1 - \alpha \implies \quad (11)$$

$$P_{\mu_0} \left(\bar{X}_n - \delta_\alpha \frac{\sigma}{\sqrt{n}} \leq \mu_0 \right) = 1 - \alpha \quad (12)$$

Daí,

$$P_\mu \left(\mu \geq \bar{X}_n - \delta_\alpha \frac{\sigma}{\sqrt{n}} \right) = 1 - \alpha, \quad \forall \mu \in \mathbb{R}. \quad (13)$$

Isto é,

$$\text{i.c.}_{1-\alpha}(\mu) = \left(\bar{X}_n - \delta_\alpha \frac{\sigma}{\sqrt{n}}, \infty \right). \quad (14)$$


Exemplo 3: Sejam X_1, \dots, X_n uma a.c. de $X \sim \text{Exp}(\theta)$, para $\theta > 0$ desconhecido. Considere que se deseja testar $H_0 : \theta = \theta_0$ vs $H_1 : \theta > \theta_0$. Encontrar o estimador relacionado para o intervalo de confiança de $1 - \alpha$.

Jd1: já foi discutido que o teste UMP para H_0 e H_1 de nível α tem função crítica

$$\psi(x) = \begin{cases} 1, & \frac{2}{\theta_0} \sum_{i=1}^n x_i > \chi_{2n, \alpha}^2 \\ 0, & \frac{2}{\theta_0} \sum_{i=1}^n x_i < \chi_{2n, \alpha}^2 \end{cases} \quad (15)$$

A região de não rejeição é dada por: para $\alpha \in \mathbb{R}$,

$$R_c = \left\{ x \in \mathbb{R}^n : \frac{2}{\theta_0} \sum_{i=1}^n x_i < \chi_{2n, \alpha}^2 \right\} \quad (16)$$



Note que:

$$P_{\theta} \left(\frac{\alpha}{\theta} \sum_{i=1}^n X_i < \chi_{n,\alpha}^2 \right) = 1 - \alpha \Rightarrow \quad (17)$$

$$P_{\theta} \left(\frac{\alpha}{\theta} \sum_{i=1}^n X_i < \chi_{n,\alpha}^2 \right) = 1 - \alpha \Rightarrow \quad (18)$$

$$P_{\theta} \left(\theta > \frac{\alpha \sum_{i=1}^n X_i}{\chi_{n,\alpha}^2} \right) = 1 - \alpha, \quad \forall \theta \in \mathbb{R}^+. \quad (19)$$

Isto é:


$$IC_{1-\alpha}(\theta) = \left(\frac{\alpha \sum_{i=1}^n X_i}{\chi_{n,\alpha}^2}, \infty \right). \quad (20)$$

Obs.: Se o contraste fosse $H_0 : \theta = \theta_0$ e $H_1 : \theta < \theta_0$, teríamos como região de não rejeição:

$$\mathcal{R} = \left\{ x \in \mathbb{R}^n : \frac{\alpha}{\theta_0} \sum_{i=1}^n x_i > \chi_{n,1-\alpha}^2 \right\} \quad (21)$$

$$P_{\theta} \left(\theta < \frac{\alpha \sum_{i=1}^n X_i}{\chi_{n,1-\alpha}^2} \right) = 1 - \alpha \quad (22)$$

$$IC_{1-\alpha}(\theta) = \left(0, \frac{\alpha \sum_{i=1}^n X_i}{\chi_{n,1-\alpha}^2} \right). \quad (23)$$



Abordagem pela quantidade pivotal

Definição 1: (Pivô) Seja $T(X)$ uma estatística suficiente (minimal) para θ . Um pivô é uma v.a. U que dependa de T e θ cuja distribuição não dependa de θ .

Aula: 30/06/2023

Obs: No caso da família de locação em $a(\theta)$, a distribuição $\{T - a(\theta)\}$ não depende de θ . No caso de família de escala em $b(\theta)$, a distribuição $\left\{\frac{T}{b(\theta)}\right\}$ não depende de θ . No caso de família de locação e escala em $[a(\theta), b(\theta)]$, a distribuição de $\left\{\frac{T - a(\theta)}{b(\theta)}\right\}$ não depende de θ .

Consideremos um exemplo simples dessa abordagem.

Exemplo 4: Seja $X \sim \text{Exp}(\theta)$ com densidade

$$f(x | \theta) = \frac{1}{\theta} e^{-x/\theta} I_{(0,\infty)}(x). \quad (24)$$

Encontrar um intervalo de confiança $1 - \alpha$ bilateral para θ .

Solução: Note que $U := \frac{X}{\theta}$ tem densidade

$$f_U(u) = \frac{dF_U(u)}{du} = \frac{d\mathbb{P}(X \leq u\theta)}{du} = \theta \cdot \frac{1}{\theta} e^{-u} I_{(0,\infty)}(u). \quad (25)$$

Logo:

$$f_U(u) = e^{-u} I_{(0,\infty)}(u). \quad (26)$$

Portanto U pode ser entendido como um pivô. Note que é possível definir $a, b \in \mathbb{R}$ com $a < b$ tais que

$$\mathbb{P}(U < a) = \mathbb{P}(U > b) = \frac{\alpha}{2}. \quad (27)$$

E, portanto:

$$\mathbb{P}(a < U < b) = 1 - \alpha. \quad (28)$$

Com $\alpha \in (0, 1)$ fixado:

$$\int_0^a e^{-u} du = 1 - e^{-a} = \frac{\alpha}{2} \Rightarrow e^{-a} = 1 - \frac{\alpha}{2} \Rightarrow a = -\log\left(1 - \frac{\alpha}{2}\right). \quad (29)$$

$$\int_b^\infty e^{-u} du = e^{-b} = \frac{\alpha}{2} \Rightarrow b = -\log\left(\frac{\alpha}{2}\right). \quad (30)$$

Dado:

$$P_\theta(a < U < b) = P_\theta\left(a < \frac{X}{\theta} < b\right) = P_\theta\left(\frac{1}{b} < \theta < \frac{1}{a}\right) = P_\theta\left(\frac{X}{b} < \theta < \frac{X}{a}\right) = 1 - \alpha \quad (31)$$

Isto é:

$$ic_{1-\alpha}(\theta) = \left(\frac{X}{b}, \frac{X}{a}\right) \quad (32)$$

IC é o intervalo bilateral para θ com confiança $1 - \alpha$.

Exemplo 5: Sejam X_1, \dots, X_n uma a.g. de $X \sim U(0, \theta)$ para θ desconhecido. Encontre o estimador intervalo bilateral para θ com confiança de $1 - \alpha$.

Solução: A estatística $T(X) = X_{\min}$ é suficiente mínima para θ com densidade

$$f_T(t) = \frac{dF_T(t)}{dt} = \frac{d(F_X(t))^n}{dt} = n \left(\frac{t}{\theta}\right)^{n-1} \frac{1}{\theta} \quad (33)$$

Logo:

$$f_T(t) = \frac{n}{\theta^n} t^{n-1}, \quad t \in (0, \theta) \quad (34)$$

Note que $U = \frac{T}{\theta}$ tem densidade

$$f_U(u) = \frac{dF_U(u)}{du} = \frac{dP\left(\frac{T}{\theta} \leq u\right)}{du} = \theta \cdot f_T(u\theta) = nu^{n-1} \quad (35)$$

$$f_U(u) = nu^{n-1}\mathbb{I}_{(0,1)}(u)$$

que independe de θ , portanto U é um pivô. Pode-se determinar a e b com $0 < a < b < 1$ tais que

$$P(U < a) = P(U > b) = \frac{\alpha}{2}$$

e, portanto,

$$P(a < U < b) = 1 - \alpha$$

Temos que:

$$P(U < a) = \int_0^a nu^{n-1} du = u^n \Big|_0^a = a^n = \frac{\alpha}{2} \quad \Rightarrow \quad a = \left(\frac{\alpha}{2}\right)^{1/n}$$

e

$$P(U > b) = \int_b^1 nu^{n-1} du = u^n \Big|_b^1 = 1 - b^n = \frac{\alpha}{2} \quad \Rightarrow \quad b = \left(1 - \frac{\alpha}{2}\right)^{1/n}$$

Note que

$$P(a < U < b) = 1 - \alpha \quad \Rightarrow \quad P\left(a < \frac{T}{\theta} < b\right) = 1 - \alpha$$

$$\Rightarrow \quad P\left(\frac{1}{b} < \frac{\theta}{T} < \frac{1}{a}\right) = 1 - \alpha$$

$$\Rightarrow \quad P\left(\frac{T}{b} < \theta < \frac{T}{a}\right) = 1 - \alpha$$

e, portanto,

$$IC_{1-\alpha}(\theta) = (b^{-1}x_{\min}, a^{-1}x_{\min})$$

Exemplo 6: Sejam X_1, \dots, X_n uma amostra de $X \sim N(\mu, \sigma^2)$ com média desconhecida e σ^2 conhecido. Encontrar o intervalo de confiança $1 - \alpha$ bilateral para μ .

Solução: De discussão anterior $T = \bar{X}$ é uma estatística suficiente mínima para μ e

$$T \sim N\left(\mu, \frac{\sigma^2}{n}\right). \quad (36)$$

Aqui, X 's pertencem à família de locação. Note que

$$U = \sqrt{n} \frac{T - \mu}{\sigma} \sim N(0, 1) \quad (37)$$

é um pivô. Para $z_{\alpha/2} > 0$ tal que $P(U > z_{\alpha/2}) = \frac{\alpha}{2}$, temos que:

$$P(-z_{\alpha/2} < U < z_{\alpha/2}) = 1 - \alpha \quad \Rightarrow \quad P\left(-z_{\alpha/2} < \sqrt{n} \frac{\bar{X} - \mu}{\sigma} < z_{\alpha/2}\right) = 1 - \alpha \quad (38)$$

ou seja,

$$P\left(\bar{X} - z_{\alpha/2} \frac{\sigma}{\sqrt{n}} < \mu < \bar{X} + z_{\alpha/2} \frac{\sigma}{\sqrt{n}}\right) = 1 - \alpha. \quad (39)$$

Portanto,

$$IC_{1-\alpha}(\mu) = \left(\bar{X} - z_{\alpha/2} \frac{\sigma}{\sqrt{n}}, \bar{X} + z_{\alpha/2} \frac{\sigma}{\sqrt{n}}\right). \quad (40)$$

Exemplo 7: Sejam x_1, \dots, x_n uma a.a. de $X \sim N(\mu, \sigma^2)$ com μ desconhecido e $\sigma \in \mathbb{R}^+$ desconhecido. Encontre o intervalo bilateral de confiança $1 - \alpha$ para μ .

Sol: De discussão anterior, (\bar{X}_n, S_n) é uma estatística conjuntamente suficiente mínima para (μ, σ) . Aqui, X 's pertencem à família de locação e escala.

Considere

$$U = \sqrt{n} \left(\frac{\bar{X}_n - \mu}{S_n} \right) = \frac{\frac{\bar{X}_n - \mu}{\sigma/\sqrt{n}}}{\sqrt{\frac{n-1}{n-1} \cdot \frac{S_n^2}{\sigma^2}}} \sim t_{n-1}, \quad (41)$$

que é um pivô. Para $t_{n-1, \alpha/2} > 0$ tal que

$$P(U > t_{n-1, \alpha/2}) = \frac{\alpha}{2}, \quad (42)$$

temos que

$$P(-t_{n-1, \alpha/2} < U < t_{n-1, \alpha/2}) = 1 - \alpha \Rightarrow \quad (43)$$

$$P\left(-t_{n-1, \alpha/2} < \sqrt{n} \frac{\bar{X}_n - \mu}{S_n} < t_{n-1, \alpha/2}\right) = 1 - \alpha \Rightarrow \quad (44)$$

$$P\left(\bar{X}_n - t_{n-1, \alpha/2} \frac{S_n}{\sqrt{n}} < \mu < \bar{X}_n + t_{n-1, \alpha/2} \frac{S_n}{\sqrt{n}}\right) = 1 - \alpha \quad (45)$$

$$\therefore IC_{1-\alpha}(\mu) = \left\{ \bar{X}_n \pm t_{n-1, \alpha/2} \frac{S_n}{\sqrt{n}} \right\}$$


Exemplo 8: Sejam X_1, \dots, X_n uma amostra de $X \sim N(\mu, \sigma^2)$ com $\mu \in \mathbb{R}$ e $\sigma \in \mathbb{R}_+$ desconhecidos. Encontre o intervalo de confiança $1 - \alpha$ para σ .

Solução: Note que

$$U = \frac{(n-1)S_n^2}{\sigma^2} \sim \chi_{n-1}^2. \quad (46)$$

Sejam $\chi_{n-1, \alpha/2}^2$ e $\chi_{n-1, 1-\alpha/2}^2$ tais que

$$P(U < \chi_{n-1, \alpha/2}^2) = \frac{\alpha}{2} \quad \text{e} \quad P(U > \chi_{n-1, 1-\alpha/2}^2) = \frac{\alpha}{2}. \quad (47)$$



Então,

$$P(\chi_{n-1, \alpha/2}^2 < U < \chi_{n-1, 1-\alpha/2}^2) = 1 - \alpha \quad (48)$$

$$P\left(\chi_{n-1, \alpha/2}^2 < \frac{(n-1)S_n^2}{\sigma^2} < \chi_{n-1, 1-\alpha/2}^2\right) = 1 - \alpha \quad (49)$$

$$P\left(\frac{(n-1)S_n^2}{\chi_{n-1, 1-\alpha/2}^2} < \sigma^2 < \frac{(n-1)S_n^2}{\chi_{n-1, \alpha/2}^2}\right) = 1 - \alpha \quad (50)$$

Portanto,

$$IC_{1-\alpha}(\sigma) = \left[\sqrt{\frac{(n-1)S_n^2}{\chi_{n-1, 1-\alpha/2}^2}}, \sqrt{\frac{(n-1)S_n^2}{\chi_{n-1, \alpha/2}^2}} \right]. \quad (51)$$

Problema para duas amostras

Focaremos na abordagem da quantidade pivotal. Para uma função paramétrica diferenciável $K(\theta)$ para $\theta \in \Theta \subset \mathbb{R}^p$, assumamos que temos um estimador $\hat{K}(\hat{\theta})$ que é função de uma estatística suficiente (mínima) para θ .

Frequentemente, a distribuição de

$$U = \frac{\hat{K}(\theta) - K(\theta)}{\hat{\gamma}} \tag{52}$$

não dependerá de θ , $\forall \theta \in \Theta$, para algum $\gamma > 0$.

Aula 29 (02/07/2023)

Se σ é conhecido, podemos obter a, b tais que

$$P_{\theta} \left(a < \frac{\hat{\kappa}(\theta) - \kappa(\theta)}{\sigma} < b \right) = 1 - \alpha \quad (53)$$

Desta última identidade, obtém-se o intervalo de confiança $1 - \alpha$ para $\kappa(\theta)$.

Para σ desconhecido:

$$P_{\theta} \left(a < \frac{\hat{\kappa}(\theta) - \kappa(\theta)}{\hat{\sigma}} < b \right) = 1 - \alpha \quad (54)$$

Desta identidade, obtém-se o intervalo de confiança.

Os resultados anteriores são locação. Quando a inferência é sobre o parâmetro de escala, costuma-se utilizar o pivô

$$U = \frac{\hat{\kappa}(\theta)}{\kappa(\theta)} \quad (55)$$

cujas distribuição geralmente independe de θ . Para este caso, usa-se

$$P_{\theta} \left(a < \frac{\hat{\kappa}(\theta)}{\kappa(\theta)} < b \right) = 1 - \alpha \quad (56)$$

Desta última identidade, obtemos o intervalo de confiança para $u(\theta)$.

Comparando parâmetros de locação

Vamos analisar diferença de médias entre duas populações normais.

Exemplo 10: Suponha x_{i1}, \dots, x_{in_i} para $i = 1, 2$ duas amostras aleatórias de $X_i \sim N(\mu_i, \sigma^2)$ e independentes entre elas $X_1 \perp X_2$. Vamos assumir que $\theta = (\mu_1, \mu_2, \sigma) \in \mathbb{R}^2 \times \mathbb{R}^+$ é desconhecido, encontrar o intervalo bilateral com confiança $1 - \alpha$ para $u(\theta) = \mu_1 - \mu_2$.

Solução: Note que:

$$\begin{aligned} f_{X_1, X_2}(x_1, x_2) &= f_{X_1}(x_1) \cdot f_{X_2}(x_2) \\ &= (2\pi\sigma^2)^{-1} \exp \left\{ -\frac{1}{2} \left(\frac{x_1 - \mu_1}{\sigma} \right)^2 \right\} \cdot \exp \left\{ -\frac{1}{2} \left(\frac{x_2 - \mu_2}{\sigma} \right)^2 \right\} \\ &= (2\pi\sigma^2)^{-1} \exp \left\{ -\frac{1}{2} \left(\frac{x_1^2 - 2x_1\mu_1 + \mu_1^2}{\sigma^2} + \frac{x_2^2 - 2x_2\mu_2 + \mu_2^2}{\sigma^2} \right) \right\} \\ &= (2\pi\sigma^2)^{-1} \exp \left\{ -\frac{1}{2} \left(\frac{x_1^2}{\sigma^2} - \frac{2x_1\mu_1}{\sigma^2} + \frac{\mu_1^2}{\sigma^2} + \frac{x_2^2}{\sigma^2} - \frac{2x_2\mu_2}{\sigma^2} + \frac{\mu_2^2}{\sigma^2} \right) \right\} \end{aligned} \quad (57)$$

$$\Rightarrow f_{X_1, X_2}(x_1, x_2) = (2\pi\sigma^2)^{-1} \exp \left\{ -\frac{1}{2\sigma^2} [(x_1 - x_2) - (\mu_1 - \mu_2)]^2 \right\} \cdot \exp \left\{ -\frac{\mu_1^2 + \mu_2^2}{2\sigma^2} \right\} \quad (58)$$

Pelo teo. 22,

$$T_1 = \left[\sum_{i=1}^{n_1} R_1(x_{1i}), \sum_{i=1}^{n_2} R_2(x_{2i}), \sum_{i=1}^{n_1} x_{1i}, \sum_{i=1}^{n_2} x_{2i}, \sum_{i=1}^{n_1} x_{1i}^2, \sum_{i=1}^{n_2} x_{2i}^2 \right] \quad (59)$$

é conjuntamente suficiente para $\theta = (\mu_1, \mu_2, \sigma^2)$. Pelo teo. 24,

$$T_2 = \left\{ \frac{1}{n_1} \sum_{i=1}^{n_1} x_{1i}, \frac{1}{n_2} \sum_{i=1}^{n_2} x_{2i}, \frac{\sum_{i=1}^{n_1} (x_{1i} - \bar{x}_1)^2 + \sum_{i=1}^{n_2} (x_{2i} - \bar{x}_2)^2}{n_1 + n_2 - 2} \right\} \quad (60)$$

é também conjuntamente suficiente para $\theta = (\mu_1, \mu_2, \sigma^2)$.

O termo S_p^2 é chamado de variância amostral conjunta e pode ser reescrito como:

$$S_1^2 = (n_1 - 1)^{-1} \sum_{i=1}^{n_1} (x_{1i} - \bar{x}_1)^2, \quad S_2^2 = (n_2 - 1)^{-1} \sum_{i=1}^{n_2} (x_{2i} - \bar{x}_2)^2 \quad (61)$$

$$S_p^2 = (n_1 + n_2 - 2)^{-1} [(n_1 - 1)S_1^2 + (n_2 - 1)S_2^2] \quad (62)$$

Note que como $(n_1 - 1)S_1^2/\sigma^2 \sim \chi_{n_1-1}^2$ e $(n_2 - 1)S_2^2/\sigma^2 \sim \chi_{n_2-1}^2$, então

$$(n_1 + n_2 - 2)S_p^2/\sigma^2 \sim \chi_{n_1+n_2-2}^2 \quad (63)$$

Dai, vale-se:

$$U = \frac{\bar{x}_1 - \bar{x}_2 - (\mu_1 - \mu_2)}{\sigma \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}} \cdot \sqrt{\frac{n_1 + n_2 - 2}{S_p^2/\sigma^2}} = \frac{\bar{x}_1 - \bar{x}_2 - (\mu_1 - \mu_2)}{S_p \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}} \sim t_{n_1+n_2-2} \quad (64)$$

Para $\nu = n_1 + n_2 - 2$ e $t_{\nu, \alpha} > 0$ tal que

$$P(U > t_{\nu, \alpha}) = \frac{\alpha}{2}, \quad (65)$$

então

$$P(-t_{\nu, \alpha} < U < t_{\nu, \alpha}) = 1 - \alpha \Rightarrow \quad (66)$$

$$P\left(-t_{\nu, \alpha} < \frac{\bar{X}_1 - \bar{X}_2 - (\mu_1 - \mu_2)}{S_p \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}} < t_{\nu, \alpha}\right) = 1 - \alpha \Rightarrow \quad (67)$$

$$P\left(\bar{X}_1 - \bar{X}_2 - t_{\nu, \alpha} S_p \sqrt{\frac{1}{n_1} + \frac{1}{n_2}} \leq \mu_1 - \mu_2 \leq \bar{X}_1 - \bar{X}_2 + t_{\nu, \alpha} S_p \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}\right) = 1 - \alpha \quad (68)$$

Dai,

$$IC_{1-\alpha}(\mu_1 - \mu_2) = \left\{ \bar{X}_1 - \bar{X}_2 \pm t_{\nu, \alpha} S_p \sqrt{\frac{1}{n_1} + \frac{1}{n_2}} \right\}. \quad (69)$$

Comparando escala entre duas populações

Vamos considerar problemas sobre escala entre duas populações normais.

Exemplo 11. Sejam X_{i1}, \dots, X_{in_i} para $i = 1, 2$ duas amostras aleatórias de $X_i \sim N(\mu_i, \sigma_i^2)$ e independentes entre elas, $i = 1, 2$. Vamos assumir que $\theta_i = (\mu_i, \sigma_i, \sigma_i^2)$ e $H_0 : R_1 = R_2$ e $H_1 \neq R_2$ é desconhecido. Encontre o intervalo.

Bilateral com confiança $1 - \alpha$ para $\mu(\theta) = \sigma_1^2/\sigma_2^2$

Idéia: Pode-se mostrar (fica como exercício) que

$$\bar{X}_1 = \frac{1}{n_1} \sum_{i=1}^{n_1} X_{1i}, \quad \bar{X}_2 = \frac{1}{n_2} \sum_{i=1}^{n_2} X_{2i}, \quad S_1^2 = \frac{1}{n_1 - 1} \sum_{i=1}^{n_1} (X_{1i} - \bar{X}_1)^2, \quad S_2^2 = \frac{1}{n_2 - 1} \sum_{i=1}^{n_2} (X_{2i} - \bar{X}_2)^2 \quad (70)$$


são estatísticas suficientes para μ_1, μ_2, σ_1^2 e σ_2^2 respectivamente. Note que (por definição da distribuição F)

$$U = \frac{S_1^2/\sigma_1^2}{S_2^2/\sigma_2^2} \sim F_{n_1-1, n_2-1} \quad (71)$$

uma vez que $(n_1 - 1)S_1^2/\sigma_1^2 \sim \chi_{n_1-1}^2$ e $(n_2 - 1)S_2^2/\sigma_2^2 \sim \chi_{n_2-1}^2$ são independentes. Logo, U é uma quantidade pivotal.

Sejam $h_1 = F_{n_1-1, n_2-1; \alpha/2}$ e $h_2 = F_{n_1-1, n_2-1; 1-\alpha/2}$ quantidades tais que

$$P(U < h_1) = \frac{\alpha}{2} \quad \text{e} \quad P(U > h_2) = \frac{\alpha}{2}.$$



Daí,

$$P_\theta(h_1 < U < h_2) = 1 - \alpha \quad \Rightarrow \quad P_\theta\left(h_1 < \frac{\sigma_2^2}{\sigma_1^2} \cdot \frac{S_1^2}{S_2^2} < h_2\right) = 1 - \alpha \quad (72)$$

$$P_\theta\left(t_{1-\frac{\alpha}{2}}^{-1} \frac{S_1^2}{S_2^2} < \frac{\sigma_1^2}{\sigma_2^2} < F_{1-\frac{\alpha}{2}}^{-1} \frac{S_1^2}{S_2^2}\right) = 1 - \alpha \quad (73)$$

isto é,

$$IC_{1-\alpha}\left(\frac{\sigma_1^2}{\sigma_2^2}\right) = \left(t_{1-\frac{\alpha}{2}}^{-1} \frac{S_1^2}{S_2^2}, F_{1-\frac{\alpha}{2}}^{-1} \frac{S_1^2}{S_2^2}\right) \quad (74)$$

Teste de Hipóteses: Baseado na Razão entre Verossimilhanças

Discutimos que pode não existir teste UMP para o caso simples bilateral. O teste da razão entre verossimilhanças proposto por Neyman e Pearson (1928, 1933) é um método útil para lidar com este caso.

Construção

Sejam x_1, \dots, x_n uma amostra de X com fdp (ou fmpt) dada por $f(x_i; \theta)$, em que $\theta = (\theta_1, \dots, \theta_p)^T \in \Theta \subset \mathbb{R}^p$ é o vetor de parâmetros desconhecidos.

Desejamos testar

$$H_0 : \theta \in \Theta_0 \quad \text{e} \quad H_1 : \theta \in \Theta_1$$

tal que $\Theta = \Theta_0 \cup \Theta_1$ e $\Theta_0 \cap \Theta_1 = \emptyset$ com nível de significância α .

A função de verossimilhança associada é dada por:

$$L(\theta) = \prod_{i=1}^n f(x_i, \theta), \quad \theta \in \Theta \quad (75)$$

Fixamos nossa atenção em

$$\sup_{\theta \in \Theta_0} \{L(\theta)\}$$

interpretada como a melhor evidência em favor de H_0 . Adicionalmente,

$$\sup_{\theta \in \Theta} \{L(\theta)\}$$

representa a melhor evidência em favor de Θ , sem considerar restrição.

A estatística da razão entre verossimilhanças (RV) é dada por:

$$\Lambda = \frac{\sup_{\theta \in \Theta_0} \{L(\theta)\}}{\sup_{\theta \in \Theta} \{L(\theta)\}} \quad (76)$$

A regra de decisão do teste RV (TRV) é dada por:

"Rejeitamos H_0 se, e só se, Λ é pequena ($< k$).

Valores pequenos de Λ implicam valores pequenos de $\sup 2L(\hat{\theta})$ em comparação com valores de $2L(\theta)$.

Note que o $c_{1\alpha}$ e c deve ser definido em $(0, 1)$ tal que o TSU tenha nível α .

Seguem duas notas importantes:

(1) No entanto, com frequência se objetiva testar parte dos parâmetros de θ , digamos $\theta_0 = (\theta_1, \dots, \theta_q)^T$ tal que $q < p$, conhecidos como parâmetros de interesse:

$$H_0 : (\theta_1, \dots, \theta_q) = (\theta_{1,0}, \dots, \theta_{q,0})$$

Os demais parâmetros $(\theta_{q+1}, \dots, \theta_p)$ são chamados de parâmetros de perturbação ou incógnitos.

(2) Sobre a derivação de Λ :

$$\sup_{\theta \in \Theta_0} \{L(\theta)\} = L(\hat{\theta}), \quad (77)$$

em que $\hat{\theta}$ representa o estimador de máxima verossimilhança (EMV) restrito (assumindo o parâmetro de interesse conhecido):

$$\hat{\theta} = (\theta_1, \dots, \theta_q, \hat{\theta}_{q+1}, \dots, \hat{\theta}_p)$$

Se $(\hat{\theta}_{\text{restr}}, \hat{\theta}_{\text{livre}})$ é o EMV sob H_0 ,

$$\sup_{\theta \in \Theta} L(\theta) = L(\hat{\theta}), \quad (78)$$

em que $\hat{\theta}$ é o EMV irrestrito (considerando todo o espaço paramétrico).

Problemas para 1 amostra

Focaremos nossa atenção sobre a população normal em alguns TRV's. Seguem os casos:

Caso 1:

$$\begin{cases} H_0 : \mu = \mu_0 & \text{para } \sigma^2 \text{ conhecido} \\ H_1 : \mu \neq \mu_0 \end{cases} \quad (79)$$

(Teste Z)

Caso 2:

$$\begin{cases} H_0 : \mu = \mu_0 & \text{para } \sigma^2 \text{ desconhecido} \\ H_1 : \mu \neq \mu_0 \end{cases} \quad (80)$$

(Teste t)

Caso 3:

$$\begin{cases} H_0 : \sigma^2 = \sigma_0^2 & \text{para } \mu \text{ conhecido} \\ H_1 : \sigma^2 \neq \sigma_0^2 \end{cases} \quad (81)$$

(Teste χ_n^2) **Caso 4:**

$$\begin{cases} H_0 : \sigma^2 = \sigma_0^2 & \text{para } \mu \text{ desconhecido,} \\ H_1 : \sigma^2 \neq \sigma_0^2 \end{cases}$$

(Teste χ_{n-1}^2)

Caso 1

Sejam X_1, \dots, X_n uma a.a. de $X_i \sim N(\mu, \sigma^2)$ com μ desconhecido e σ_0 conhecido. Aqui, temos

$$\Theta = \mathbb{R} \quad \text{e} \quad \Theta_0 = \mathbb{R} - \{\mu_0\}.$$

A função de verossimilhança é

$$L(\mu) = (2\pi\sigma^2)^{-n/2} \exp \left\{ -\frac{1}{2} \sum_{i=1}^n \left(\frac{x_i - \mu}{\sigma} \right)^2 \right\}. \quad (82)$$

Desta última identidade, tem-se

$$\sup_{\mu \in \Theta_0} \{L(\mu)\} = (2\pi\sigma^2)^{-n/2} \sup_{\mu \in \Theta_0} \exp \left\{ -\frac{1}{2} \sum_{i=1}^n \left(\frac{x_i - \mu}{\sigma} \right)^2 \right\} \quad (83)$$

$$\sup_{\mu \in \Theta} \{L(\mu)\} = (2\pi\sigma^2)^{-n/2} \sup_{\mu \in \Theta} \exp \left\{ -\frac{1}{2} \sum_{i=1}^n \left(\frac{x_i - \bar{x}}{\sigma} \right)^2 \right\} \quad (84)$$

em que $\bar{x} = \hat{\mu}$ é a estimativa de MV para μ . Note que, para algum certo valor, vale-se.

$$\sum_{i=1}^n (x_i - c)^2 = \sum_{i=1}^n (x_i - \bar{x} + \bar{x} - c)^2 \quad (85)$$

$$= \sum_{i=1}^n \left\{ (x_i - \bar{x})^2 + 2(x_i - \bar{x})(\bar{x} - c) + (\bar{x} - c)^2 \right\} \quad (86)$$

$$= \sum_{i=1}^n (x_i - \bar{x})^2 + n(\bar{x} - c)^2 \quad (87)$$

Assim,

$$\Lambda = \exp \left\{ -\frac{1}{2\sigma^2} [n(\bar{x} - \mu_0)^2] \right\} \quad (88)$$

O TRU fica definido por

"Rejeitar H_0 se, e só se, $\Lambda < k'$ "

$$\Leftrightarrow \left\{ n \left(\frac{\bar{x} - \mu_0}{\sigma} \right)^2 > -2 \log k' \right\} \quad (89)$$

$$\Leftrightarrow \left\{ \sqrt{n} \left| \frac{\bar{x} - \mu_0}{\sigma} \right| > \sqrt{-2 \log k'} \right\} \quad (90)$$

$$\Leftrightarrow \{|Z(x_1)| > k''\} \quad (91)$$

em que

$$Z(x_1) = \sqrt{n} \left(\frac{\bar{x} - \mu_0}{\sigma} \right) \quad (92)$$

Note como $k'' = z_{\alpha/2}$ e satisfaz

$$P_{H_0}(|Z| > z_{\alpha/2}) = \alpha \quad (93)$$

Aula 30 (04/07/2018)

Considere testar $H_0 : \mu = \mu_0$ e $H_1 : \mu \neq \mu_0$ baseado em x_1, \dots, x_n como uma a.a. de $X \sim N(\mu, \sigma^2)$. Neste caso

$$\Theta_0 = \{(\mu_0, \sigma^2); \mu_0 \text{ é fixado e } \sigma \in \mathbb{R}_+\}.$$

Aqui a função de verossimilhança é

$$L(\mu, \sigma^2) = (2\pi\sigma^2)^{-n/2} \cdot \exp \left\{ -\frac{1}{2} \sum_{i=1}^n \left(\frac{x_i - \mu}{\sigma} \right)^2 \right\}. \quad (94)$$

Desta expressão,

$$\sup_{(\mu_0, \sigma^2) \in \Theta_0} L(\mu, \sigma^2) = L(\mu_0, \hat{\sigma}^2) = (2\pi\hat{\sigma}^2)^{-n/2} \cdot \exp \left\{ -\frac{1}{2\hat{\sigma}^2} \sum_{i=1}^n (x_i - \mu_0)^2 \right\}, \quad (95)$$

em que

$$\hat{\sigma}^2 = n^{-1} \sum_{i=1}^n (x_i - \mu_0)^2$$

é a estimativa de MV para σ^2 . Simplificando a última expressão temos:

$$\sup_{(\mu_0, \sigma^2) \in \Theta_0} L(\mu, \sigma^2) = (2\pi\hat{\sigma}^2)^{-n/2} e^{-n/2}. \quad (96)$$

Por outro lado, tem-se:

$$\sup_{(\mu, \sigma^2) \in \Theta} L(\mu, \sigma^2) = L(\bar{x}, \hat{\sigma}^2) = (2\pi\hat{\sigma}^2)^{-n/2} \cdot \exp \left\{ -\frac{1}{2\hat{\sigma}^2} \sum_{i=1}^n (x_i - \bar{x})^2 \right\}. \quad (97)$$

em que $\hat{\mu} = \bar{x}$ e $\hat{\sigma}^2 = n^{-1} \sum_{i=1}^n (x_i - \bar{x})^2$ são os estimadores de MV irrestritos para μ e σ . Simplificando,

$$\sup_{(\mu, \sigma) \in \Theta} L(\mu, \sigma) = (2\pi\hat{\sigma}^2)^{-n/2}. \quad (98)$$

Finalmente,

$$\Lambda = \frac{\sup_{(\mu, \sigma) \in \Theta_0} L(\mu, \sigma)}{\sup_{(\mu, \sigma) \in \Theta} L(\mu, \sigma)} \quad (99)$$

$$= \left\{ \frac{\sum_{i=1}^n (x_i - \mu)^2}{\sum_{i=1}^n (x_i - \bar{x})^2} \right\}^{-n/2} \quad (100)$$

$$= \left\{ \frac{\sum_{i=1}^n (x_i - \bar{x})^2 + n(\bar{x} - \mu_0)^2}{\sum_{i=1}^n (x_i - \bar{x})^2} \right\}^{-n/2} \quad (101)$$

$$= \left\{ 1 + \frac{n(\bar{x} - \mu_0)^2}{\sum_{i=1}^n (x_i - \bar{x})^2} \right\}^{-n/2} \quad (102)$$

O TRVU fica definido por: dado um nível α , rejeitamos $H_0 \iff \Lambda < k$ ($0 < k < 1$). Logo, como $f(x) = x^{-n/2}$ é estritamente decrescente,

$$R_c = \left\{ 1 + \frac{n(\bar{x} - \mu_0)^2}{\sum_{i=1}^n (x_i - \bar{x})^2}, n^{-2/n} \right\} = \left\{ \frac{n(\bar{x} - \mu_0)^2}{\sum_{i=1}^n (x_i - \bar{x})^2} > k^{-2/n} - 1 \right\} \quad (103)$$

Daí, como $g(x)$ é estritamente crescente, temos que...

$$R_c = \left\{ \frac{\sqrt{n} |\bar{x} - \mu_0|}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2}} > \sqrt{k'} \right\} \quad (104)$$

como A :

$$A = \frac{\frac{\bar{x} - \mu_0}{\sigma/\sqrt{n}}}{\sqrt{\sum_{i=1}^n \left(\frac{x_i - \bar{x}}{\sigma} \right)^2}} = \frac{\frac{\bar{x} - \mu_0}{\sigma/\sqrt{n}}}{\sqrt{\frac{n}{n-1}}} = \frac{\frac{\bar{x} - \mu_0}{\sigma/\sqrt{n}}}{\sqrt{\frac{s^2}{\sigma^2}}} \quad (105)$$

para $\delta_c = (n-1)^{-1} \sum_{i=1}^n (x_i - \bar{x})^2$,

$$R_c = \left\{ (n-1)^{-1/2} |T(x)| > \sqrt{k'} \right\} \quad (106)$$

para $T(x) = \frac{\bar{x} - \mu_0}{s/\sqrt{n}}$ e $x = (x_1, \dots, x_n)^T$. Logo:

$$R_c = \left\{ |T(x)| > \sqrt{\frac{(n-1)k'}{n''}} \right\} \Rightarrow R_c = \{|T(x)| > k''\} \quad (107)$$

Note que:

$$T(X) \text{ sob } H_0 \sim t_{n-1}. \quad (108)$$

Seja $t_{n-1, \alpha/2}$ tal que:

$$P_{H_0}(T > t_{n-1, \alpha/2}) = \frac{\alpha}{2}. \quad (109)$$

Então o TRV tem fronteira crítica.

$$\psi(X^1) = \begin{cases} 1, & |T(X^1)| > t_{n-1, \alpha/2} \\ 0, & \text{c.c.} \end{cases}$$

TRV para σ^2 com μ conhecido

Sejam X_1, \dots, X_n v.a. de $X \sim N(\mu, \sigma^2)$ com média conhecida e $\sigma^2 \in \mathbb{R}^+$ desconhecido. Dado um nível $\alpha \in (0, 1)$, considere a derivação do TRV para

$$H_0 : \sigma^2 = \sigma_0^2 \quad \text{vs} \quad H_1 : \sigma^2 \neq \sigma_0^2.$$

A função de verossimilhança é dada por:

$$l(\sigma^2) = (2\pi\sigma^2)^{-n/2} \exp \left\{ -\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2 \right\} \quad (110)$$

Daí, temos:

$$\sup_{(\mu, \sigma^2) \in \Theta} l(\sigma^2) = (2\pi\sigma^2)^{-n/2} \exp \left\{ -\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2 \right\} \quad (111)$$

em que

$$\Theta_0 = \{(\mu, \sigma^2) \mid \mu \text{ é fixado e } \sigma^2 = \sigma_0^2 \text{ é fixado}\}$$

$$\sup_{(\mu, \sigma^2) \in \Theta_0} l(\sigma^2) = (2\pi\sigma_0^2)^{-n/2} \exp \left\{ -\frac{1}{2\sigma_0^2} \sum_{i=1}^n (x_i - \mu)^2 \right\} \quad (112)$$

em que

$$\Theta = \{\mu, \sigma\} : \mu \text{ fixado e } \sigma \in \mathbb{R}_+$$

e

$$\hat{\sigma}^2 = n^{-1} \sum_{i=1}^n (x_i - \mu)^2.$$

Finalmente,

$$\begin{aligned}\Lambda &= \left\{ \frac{\hat{\sigma}^2}{\sigma_0^2} \right\}^{n/2} \exp \left\{ -\frac{1}{2} \sum_{i=1}^n \frac{(x_i - \mu)^2}{\sigma_0^2} + \frac{n}{2} \right\} \\ &= \left[\frac{\hat{\sigma}^2}{\sigma_0^2} \right]^{n/2} \exp \left(1 - \frac{\hat{\sigma}^2}{\sigma_0^2} \right)^{n/2}.\end{aligned}\quad (113)$$

Deste modo, o TRV fica definido como

$$\text{rejeita-se } H_0 \iff \Lambda < k \quad (\alpha \in (0, 1)).$$

Como $x^{1/x}$ para $x > 0$ é inicialmente crescente, da relação acima, temos:

$$R_c = \left\{ \left(\frac{\hat{\sigma}^2}{\sigma_0^2} \right) \exp \left\{ 1 - \frac{\hat{\sigma}^2}{\sigma_0^2} \right\} < k^{2/n} \right\} \quad (114)$$

A fim de apresentar o RV em uma forma implementável, vamos proceder como segue. Considere que

$$g(u) = ue^{1-u}, \quad u > 0$$

Note que

$$\lim_{u \rightarrow 0} g(u) = 0 \quad \text{e} \quad \lim_{u \rightarrow \infty} g(u) = 0.$$

Logo, para

$$T(X) = \sum_{i=1}^n \frac{(x_i - \mu)^2}{\sigma_0^2} \sim \chi_n^2, \quad (115)$$

rejeita-se H_0 se, e só se, (para $a, b \in \mathbb{R}$, $a < b$)


$$[T(X) < a] \quad \text{ou} \quad [T(X) > b]$$

tal que

$$P_{H_0}(T < a) = \frac{\alpha}{2} \quad \Rightarrow \quad a = \chi_{n, 1-\alpha/2}^2 \quad (116)$$

e

$$P_{H_0}(T > b) = \frac{\alpha}{2} \quad \Rightarrow \quad b = \chi_{n, \alpha/2}^2 \quad (117)$$



A função crítica é dada por:

$$\psi(x) = \begin{cases} 1, & T < \chi_{n, 1-\alpha/2}^2 \text{ ou } T > \chi_{n, \alpha/2}^2, \\ 0, & \text{caso contrário.} \end{cases} \quad (118)$$

TRV para duas amostras

Nesta seção vamos discutir problemas relacionados ao TRV para duas amostras em dois contextos:

para $X \sim N(\mu_x, \sigma_x^2)$ e $Y \sim N(\mu_y, \sigma_y^2)$

Caso 1:

$$\begin{cases} H_0 : \mu_x = \mu_y \\ H_1 : \mu_x \neq \mu_y \end{cases} \quad \text{para} \quad \sigma_x^2 = \sigma_y^2 = \sigma^2 \quad (119)$$

Caso 2:

$$\begin{cases} H_0 : \sigma_x^2 = \sigma_y^2 \\ H_1 : \sigma_x^2 \neq \sigma_y^2 \end{cases} \quad \text{para} \quad \mu_x \neq \mu_y \quad (120)$$

TRV para comparar médias

Sejam x_1, \dots, x_n e y_1, \dots, y_m a.a.s independentes de $X \sim N(\mu_x, \sigma_x^2)$ e $Y \sim N(\mu_y, \sigma_y^2)$, respectivamente.

Assuma que $\sigma_x^2 = \sigma_y^2 = \sigma^2 \in \mathbb{R}_+$ e $\theta = (\mu_x, \mu_y, \sigma^2) \in \mathbb{R} \times \mathbb{R} \times \mathbb{R}_+$ é desconhecido.

Dado $\alpha \in (0, 1)$ como o nível, vamos derivar o TRV para

$$H_0 : \mu_x = \mu_y \quad \text{vs} \quad H_1 : \mu_x \neq \mu_y \quad (121)$$

Inicialmente, lembramos que:

$$\begin{aligned} \bar{X} &= n^{-1} \sum_{i=1}^n x_i, \quad \bar{Y} = m^{-1} \sum_{i=1}^m y_i, \quad S_X^2 = (n-1)^{-1} \sum_{i=1}^n (x_i - \bar{X})^2, \\ S_Y^2 &= (m-1)^{-1} \sum_{i=1}^m (y_i - \bar{Y})^2, \\ S^2 &= \frac{(n-1)S_X^2 + (m-1)S_Y^2}{n+m-2} \end{aligned}$$

São estimadores para μ_X/μ_Y , σ_X^2 , σ_Y^2 e σ^2 , respectivamente. Neste caso,

$$\begin{aligned} \Theta_0 &= \{(\mu_X, \mu_Y, \sigma^2) : \mu_X = \mu_Y = \mu \in \mathbb{R} \text{ e } \sigma^2 \in \mathbb{R}_+\} \\ \Theta &= \{(\mu_X, \mu_Y, \sigma^2) : \mu_X, \mu_Y \in \mathbb{R} \text{ e } \sigma^2 > 0\} \end{aligned}$$

A verossimilhança é dada por:

$$L(\mu_X, \mu_Y, \sigma^2) \triangleq L(\mu_X, \mu_Y, \sigma^2; x^n, y^m) = (2\pi\sigma^2)^{-\frac{n+m}{2}} \cdot \exp \left\{ -\frac{1}{2\sigma^2} \left[\sum_{i=1}^n (x_i - \mu_X)^2 + \sum_{j=1}^m (y_j - \mu_Y)^2 \right] \right\} \quad (122)$$

para $(\mu_X, \mu_Y, \sigma^2) \in \mathbb{R}^2 \times \mathbb{R}_+$, em que x^n é uma amostra de X e y^m é uma amostra de Y . Assim,

$$\sup_{\{L(\mu_X, \mu_Y, \sigma^2)\}} = \sup \left\{ (2\pi\sigma^2)^{-\frac{n+m}{2}} \cdot \exp \left[-\frac{1}{2\sigma^2} \left(\sum_{i=1}^n (x_i - \mu)^2 + \sum_{j=1}^m (y_j - \mu)^2 \right) \right] \right\} \quad (123)$$

$$\text{para } (\mu_X, \mu_Y, \sigma^2) \in \Theta_0$$

Pode-se obter (fica como exercício!) que os estimadores... De MV restrito para μ e σ^2 são dados por:

$$\hat{\mu} = \frac{n\bar{x} + m\bar{y}}{n + m}, \quad \hat{\sigma}^2 = \frac{(n-1)\Delta_{x;\mu}^2 + (m-1)\Delta_{y;\mu}^2}{n + m} \quad (124)$$

em que

$$\Delta_{x;\mu}^2 = (n-1)^{-1} \sum_{i=1}^n (x_i - \mu)^2, \quad \Delta_{y;\mu}^2 = (m-1)^{-1} \sum_{i=1}^m (y_i - \mu)^2 \quad (125)$$

Aplicando (2) em (1), temos que:

$$\sup\{L(\mu_x, \mu_y, \sigma^2)\} = (2\pi\sigma^2)^{-\frac{mn}{2}} \cdot e^{-\frac{mn}{2}}, \quad (\mu_x, \mu_y, \sigma^2) \in \Theta \quad (126)$$

Por outro lado, temos que:

$$\begin{aligned} \sup\{L(\mu_x, \mu_y, \sigma^2)\} &= (2\pi\hat{\sigma}^2)^{-\frac{n+m}{2}} \cdot \exp \left\{ -\frac{1}{2\hat{\sigma}^2} \sum_{i=1}^n (x_i - \hat{\mu}_x)^2 + \sum_{i=1}^m (y_i - \hat{\mu}_y)^2 \right\} \\ &= (2\pi\hat{\sigma}^2)^{-\frac{n+m}{2}} \cdot e^{-\frac{n+m}{2}}, \end{aligned} \quad (127)$$

uma vez que $\hat{\mu}_x = \bar{x}$, $\hat{\mu}_y = \bar{y}$ e

$$\hat{\sigma}_{x,y}^2 = \frac{(n-1)\Delta_x^2 + (m-1)\Delta_y^2}{n + m}, \quad (128)$$

para s_x^2 como uma observação de S_x^2 e s_y^2 como uma observação de S_y^2 , são estimativas de MV irrestritas para μ_x , μ_y e σ^2 .

Finalmente,

$$\Lambda = \left\{ \frac{\hat{\sigma}_c^2}{\hat{\sigma}^2} \right\}^{\frac{n+m}{2}} = \left\{ \frac{\frac{\sum_{i=1}^n (x_i - \bar{x})^2 + \sum_{i=1}^m (y_i - \bar{y})^2}{n+m}}{\frac{\sum_{i=1}^n (x_i - \hat{\mu})^2 + \sum_{i=1}^m (y_i - \hat{\mu})^2}{n+m}} \right\}^{\frac{n+m}{2}}. \quad (129)$$

Note que

$$\sum_{i=1}^n (x_i - \hat{\mu}_x)^2 + \sum_{i=1}^m (y_i - \hat{\mu}_y)^2 = \sum_{i=1}^n (x_i - \bar{x})^2 + n(\bar{x} - \hat{\mu})^2 + \sum_{i=1}^m (y_i - \bar{y})^2 + m(\bar{y} - \hat{\mu})^2 \quad (130)$$

$$\underbrace{(n-1)s_x^2}_{\text{variância amostral de } x} \quad \underbrace{(m-1)s_y^2}_{\text{variância amostral de } y}$$

E, para

$$R(\bar{x}, \bar{y}) = \frac{n(\bar{x} - \hat{\mu})^2 + m(\bar{y} - \hat{\mu})^2}{(n-1)s_x^2 + (m-1)s_y^2}, \quad (131)$$

temos

$$\Lambda = \left\{ \frac{1}{1 + R(\bar{x}, \bar{y})} \right\}^{\frac{n+m}{2}} = \{1 + R(\bar{x}, \bar{y})\}^{-\frac{n+m}{2}}. \quad (132)$$

Ainda,

$$n(\bar{x} - \hat{\mu})^2 + m(\bar{y} - \hat{\mu})^2 = n \left[\bar{x} - \frac{n\bar{x} + m\bar{y}}{n+m} \right]^2 + m \left[\bar{y} - \frac{n\bar{x} + m\bar{y}}{n+m} \right]^2 \quad (133)$$

$$= n \left[\frac{m\bar{x} - m\bar{y}}{n+m} \right]^2 + m \left[\frac{n\bar{y} - n\bar{x}}{n+m} \right]^2 \quad (134)$$

$$= \frac{nm^2}{(n+m)^2}(\bar{x} - \bar{y})^2 + \frac{mn^2}{(n+m)^2}(\bar{x} - \bar{y})^2 = \frac{nm}{n+m}(\bar{x} - \bar{y})^2. \quad (135)$$

Então

$$R(\bar{x}, \bar{y}) = \frac{nm}{nm} \left[\frac{(\bar{x} - \bar{y})^2}{(n-1)s_x^2 + (m-1)s_y^2} \right]. \quad (136)$$

A região crítica do TRV é dada por: para

$$z = (\bar{x}^T, \bar{y}^T)^T \in \mathbb{R}^n \times \mathbb{R}^m, \text{ o qual}$$

$$R_c = \{z \in \alpha; \Lambda(z) < k\} = \left\{ [1 + R(\bar{x}, \bar{y})]^{-\frac{nm}{2}} < k \right\} \Rightarrow \quad (137)$$

$$R_c = \left\{ [1 + R(\bar{x}, \bar{y})] > k^{-\frac{2}{nm}} \right\} \Rightarrow \quad (138)$$

$$R_c = \left\{ R(\bar{x}, \bar{y}) > k^{-\frac{2}{nm}} - 1 \right\} \Rightarrow \quad (139)$$

$$R_c = \left\{ \sqrt{\frac{nm}{nm} \cdot \frac{(\bar{x} - \bar{y})^2}{(n-1)s_x^2 + (m-1)s_y^2}} > \sqrt{k^{-\frac{2}{nm}} - 1} \right\} \Rightarrow \quad (140)$$

$$T_1(\bar{x}, \bar{y})$$

$$R_c = \{|T(\bar{x}, \bar{y})| > k'\}.$$

Note que, para as a.o.s \bar{x} e \bar{y} ,

$$T_1(\bar{x}, \bar{y}) = \sqrt{\frac{nm}{nm}} \cdot \frac{\bar{x} - \bar{y}}{\sqrt{(n-1)s_x^2 + (m-1)s_y^2}} = \frac{1}{\sqrt{nm-2}} \cdot \frac{\frac{\bar{x}-\bar{y}}{\sqrt{\frac{1}{n} + \frac{1}{m}}}}{\sqrt{\frac{(n-1)s_x^2 + (m-1)s_y^2}{(nm-2)s^2}}} \quad (141)$$

$$T(\bar{x}, \bar{y})$$

Ainda, a R_c do TRV pode ser dada por:

$$R_c = \left\{ z \in \mathcal{X} \left| \sqrt{mn-2} T(\bar{x}, \bar{y}) > k'' \sqrt{\frac{mn-2}{k''}} \right. \right\} \quad (142)$$

$$\therefore R_c = \{ |T(\bar{x}, \bar{y})| > k'' \}$$

Podemos ver que

$$T(\bar{x}, \bar{y}) \stackrel{H_0}{\sim} t_{nm-2} \quad (143)$$

Tomando $k'' = t_{nm-2, \frac{\alpha}{2}}$ tal que

$$\psi_{H_0}(T(\bar{x}, \bar{y}) > t_{nm-2, \frac{\alpha}{2}}) = \frac{\alpha}{2}, \quad (144)$$

temos que a função crítica do TRV é dada por:

$$\psi(\bar{x}, \bar{y}) = \begin{cases} 1, & |T(\bar{x}, \bar{y})| > t_{nm-2, \frac{\alpha}{2}}, \\ 0, & \text{caso contrário.} \end{cases} \quad (145)$$

em que

$$T(\bar{x}, \bar{y}) = \frac{\sqrt{\frac{nm}{nm-2}} (\bar{x} - \bar{y})}{\Lambda} \quad (146)$$

e

$$\Lambda = \sqrt{\frac{(n-1)s_x^2 + (m-1)s_y^2}{nm-2}} \quad (147)$$

é uma observação de S .

Aula 31 (02/07/2020)

TRV para $H_0 : \sigma_x = \sigma_y$

Sejam x_1, \dots, x_n e y_1, \dots, y_m a.a.s. de $X \sim N(\mu_x, \sigma_x)$ e $Y \sim N(\mu_y, \sigma_y)$. Assuma que

$$\theta = (\mu_x, \mu_y, \sigma_x, \sigma_y)^T \in \mathbb{R}^2 \times \mathbb{R}_+^2$$

é desconhecido. Dado que $\alpha \in (0, 1)$ como nível de significância, vamos derivar o TRV para

$$H_0 : \sigma_x^2 = \sigma_y^2 \quad \text{e} \quad H_1 : \sigma_x^2 \neq \sigma_y^2.$$

A verossimilhança é dada por:

$$\begin{aligned} L(\theta) &= L(\theta; \vec{x}, \vec{y}) \\ &= (2\pi)^{-\frac{n+m}{2}} \cdot (\sigma_x^n \sigma_y^m)^{-1} \cdot \exp \left\{ -\frac{1}{2} \left[\sum_{i=1}^n \left(\frac{x_i - \mu_x}{\sigma_x} \right)^2 + \sum_{i=1}^m \left(\frac{y_i - \mu_y}{\sigma_y} \right)^2 \right] \right\}. \end{aligned} \quad (148)$$

Em que \vec{x} é uma a.o. de X e \vec{y} uma a.o. de Y . Note que o estimador de máxima verossimilhança restrito para μ_x, μ_y e σ é dado por:

$$\hat{\mu}_x = \bar{X}, \quad \hat{\mu}_y = \bar{Y}, \quad \hat{\sigma}^2 = \frac{(n-1)S_X^2 + (m-1)S_Y^2}{n+m}$$

tal que

$$S_X^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{X})^2, \quad S_Y^2 = \frac{1}{m-1} \sum_{i=1}^m (y_i - \bar{Y})^2$$

respectivamente.

Usualmente, os estimadores invariantes de MV para $\mu_x, \mu_y, \sigma_x^2, \sigma_y^2$ são dados por:

$$\hat{\mu}_x = \bar{X}, \quad \hat{\mu}_y = \bar{Y}, \quad \hat{\sigma}_x^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^2, \quad \hat{\sigma}_y^2 = \frac{1}{m} \sum_{i=1}^m (Y_i - \bar{Y})^2 \quad (149)$$

respectivamente. Aqui,

$$\Theta_0 = \{(\mu_x, \mu_y, \sigma_x, \sigma_y) : \mu_x, \mu_y \in \mathbb{R} \text{ e } \sigma_x = \sigma_y \in \mathbb{R}_+\} \quad (150)$$

$$\Theta = \{(\mu_x, \mu_y, \sigma_x, \sigma_y) : \mu_x, \mu_y \in \mathbb{R} \text{ e } \sigma_x^2, \sigma_y^2 \in \mathbb{R}_+\} \quad (151)$$

Dado,

$$\sup_{\Theta_0} \{L(\Theta)\} = (2\pi)^{-\frac{n+m}{2}} (\tilde{\sigma}^2)^{-\frac{n+m}{2}} \cdot \exp \left\{ -\frac{1}{2\tilde{\sigma}^2} [(n-1)s_x^2 + (m-1)s_y^2] \right\} \quad (152)$$

em que s_x^2 é uma observação de S_x^2 e s_y^2 é uma observação de S_y^2 . Logo,

$$\sup_{\Theta_0} \{L(\Theta)\} = (2\pi\tilde{\sigma}^2)^{-\frac{n+m}{2}} e^{-\frac{n+m}{2}} \quad (153)$$

$$\sup_{\Theta} \{L(\Theta)\} = (2\pi)^{-\frac{n+m}{2}} (\hat{\sigma}_x^n \hat{\sigma}_y^m)^{-\frac{1}{2}} e^{-\frac{n+m}{2}} \quad (154)$$

Dado, temos que

$$\Lambda = \frac{(\hat{\sigma}_x^2)^{\frac{n}{2}} (\hat{\sigma}_y^2)^{\frac{m}{2}}}{(\tilde{\sigma}^2)^{\frac{n+m}{2}}} = \frac{(\hat{\sigma}_x^2)^{\frac{n}{2}} (\hat{\sigma}_y^2)^{\frac{m}{2}}}{[(mn)^{-1}(n\hat{\sigma}_x^2 + m\hat{\sigma}_y^2)]^{\frac{n+m}{2}}} \quad (155)$$

Definindo $\lambda = \frac{u}{n+m}$, tem-se:

$$\Lambda = \left[\frac{\hat{\sigma}_x^2}{\lambda \hat{\sigma}_x^2 + (1-\lambda) \hat{\sigma}_y^2} \right]^{\frac{n}{2}} \left[\frac{\hat{\sigma}_y^2}{\lambda \hat{\sigma}_x^2 + (1-\lambda) \hat{\sigma}_y^2} \right]^{\frac{m}{2}} \quad (156)$$

$$(\xi) = \hat{\sigma}_y^2 \left[\frac{\hat{\sigma}_x^2 / \hat{\sigma}_y^2}{\lambda (\hat{\sigma}_x^2 / \hat{\sigma}_y^2) + (1-\lambda)} \right]^{\frac{n}{2}} \left[\frac{1}{\lambda (\hat{\sigma}_x^2 / \hat{\sigma}_y^2) + (1-\lambda)} \right]^{\frac{m}{2}} \quad (157)$$

$$\Lambda = \lambda^{-\frac{n+m}{2}} \left(\frac{\hat{\sigma}_x^2 / \hat{\sigma}_y^2}{\hat{\sigma}_x^2 / \hat{\sigma}_y^2 + b} \right)^{\frac{n+m}{2}}, \quad b \triangleq \frac{1-\lambda}{\lambda} \quad (158)$$

A RC de TRV é dada por: para $z = (\hat{\sigma}_x^2, \hat{\sigma}_y^2) \in \mathbb{R}^n \times \mathbb{R}^m$

$$\{z \in \mathbb{R}^n, \Lambda(z) < c'\}, \quad u \text{ escalar} \quad (159)$$

$$\left\{ \frac{(\hat{\sigma}_x^2 / \hat{\sigma}_y^2)^{n/2}}{[(\hat{\sigma}_x^2 / \hat{\sigma}_y^2) + b]^{\frac{n+m}{2}}} < \frac{k \cdot \lambda^{-\frac{n+m}{2}}}{c'} \right\} \quad (160)$$

A fim de representar a RV de modo implementável, vamos proceder como segue: considere a função

$$g(u) = u^{n/2} (u+b)^{-\frac{n+m}{2}}, \quad u > 0 \quad (161)$$

Vamos investigar o comportamento de Λ . Note que:

$$g'(u) = \frac{2g(u)}{2u} = \frac{\frac{n}{2}u^{\frac{n}{2}-1}(u+b)^{-\frac{n+m}{2}} - u^{\frac{n}{2}}\frac{n+m}{2}(u+b)^{-\frac{n+m}{2}-1}}{(u+b)^{-n+m}} \quad (162)$$


$$\begin{aligned} g'(u) &= \frac{n}{2}u^{\frac{n}{2}-1}(nub)^{-\frac{nm}{2}} - u^{\frac{n}{2}}\left(\frac{nm}{2}\right)(nub)^{-\frac{nm}{2}-1} \\ &= (nub)^{-\frac{nm}{2}} \cdot u^{\frac{n}{2}-1} \left[(nb)\frac{n}{2} - u\left(\frac{nm}{2}\right) \right] \\ &= \frac{1}{a^2}(nub)^{-\frac{nm}{2}} \cdot u^{\frac{n}{2}-1} [nb - mnu] \end{aligned} \quad (163)$$

Dai, $g(u) \geq 0$ e

$$g'(u) = 0 \quad \Rightarrow \quad u = \frac{nb}{m}.$$

(ii) $\lim_{u \rightarrow 0} g(u) = 0$ e $\lim_{u \rightarrow \infty} g(u) = 0$

Logo, $g(u)$ é muito pequena quando $u = \frac{\hat{\sigma}_x^2}{\hat{\sigma}_y^2}$ é muito pequena ou muito grande.



Tomar:

$$\begin{aligned} F_n(\hat{\alpha}_1, \hat{\alpha}_2) &= \frac{\frac{\hat{\sigma}_x}{\sigma_x}}{\frac{\hat{\sigma}_y}{\sigma_y}} = \frac{\frac{n-1}{n} \frac{S_x^2}{\sigma_x^2}}{\frac{m-1}{m} \frac{S_y^2}{\sigma_y^2}} = \frac{\frac{n-1}{n} S_x^2 / \sigma_x^2}{\frac{m-1}{m} S_y^2 / \sigma_y^2} \\ &= \frac{S_x^2 / \sigma_x^2}{S_y^2 / \sigma_y^2} \cdot \frac{m(n-1)}{n(m-1)} \end{aligned} \quad (164)$$